

摘要：

DeepSeek将于9月10日调整API定价，重点优惠缓存命中场景：闲时命中价0.02元/千token，未命中价1元，价差50倍。新策略鼓励开发者提高上下文复用率，降低长文本、高频调用成本，同时引导错峰使用以优化算力效率，重点吸引RAG、代码助手等高粘性用户。

DeepSeek再度调整API定价策略，这次并非简单的全面降价，而是将降价重点放在“缓存命中”上，同时引入高峰、空闲时段差异化计费，进一步瞄准高频调用和长上下文场景。

根据DeepSeek开放平台公告，Flash系列将于北京时间2026年9月10日12:00起实施新定价。空闲时段输入缓存命中单价降至0.02元/千token，缓存未命中单价为1元，二者价差达到50倍；输出单价为4元。高峰时段（北京时间周一至周五9:00-12:00、14:00-18:00）各项价格均为闲时的2倍。

这意味着，对于能够反复复用相同上下文的应用，API成本可能出现明显下降。简单来说，所谓“缓存命中”，就是模型此前已经处理过的一部分内容，在后续请求中无需重新完整计算，系统可以直接复用相关结果。对于长提示词、固定系统指令或持续对话等场景，这部分内容往往占据输入token的大头，因此缓存命中率越高，降本效果越明显。

新定价结构：让价格跟着使用方式走

此次调整最明显的变化，是API价格不再只由调用量决定，而是与调用时间和内容是否重复同时挂钩。

对于开发者而言，这意味着同样调用100万token，如果大部分内容能够被缓存，成本可能远低于每次都重新输入。尤其是RAG、代码助手、客服机器人、Agent等应用，往往存在大量重复的系统指令、知识库和历史上下文，更容易从这一机制中受益。

这也会改变开发者的成本优化方式。过去主要是选择更便宜的模型、减少token消耗；现在则可以进一步通过固定上下文、拆分动态内容等方式提高缓存命中率。换言之，API成本管理开始从“少用token”延伸到“让token尽可能复用”。

降价背后：既抢用户，也调算力

从平台角度看，缓存和时段优惠并不只是给用户“打折”，背后还有明显的算力调度逻辑。

缓存命中意味着部分输入无需重复计算，可以降低相同请求反复处理带来的算力消耗；而闲时折扣则是在价格层面鼓励用户错峰，把部分非实时任务从工作日高峰转移出去。两者结合，本质上都是在提高有限算力资源的利用效率。

对于DeepSeek而言，这种模式还有另一层意义：它重点优惠的是能够形成稳定、高频调用的用户，而不是无差别降低所有请求的价格。RAG、代码助手、客服和Agent等应用一旦建立在API之上，迁移成本通常也会随着调用量和业务深度增加，因此这类用户的长期价值更高。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

59 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论