

摘要：

以旗舰模型deepseek-v4-pro为例，高峰时段百万tokens输出价格从6元升至27元，涨幅同为350%；缓存未命中输入价格从3元升至9元。与此同时，DeepSeek V4 Pro正式版已于8月13日上线，并同步在APP、网页端及API端部署。

13日，深度求索宣布对DeepSeek API实施大幅调价，部分模型价格涨幅超过三倍，同步推出V4 Pro正式版。

根据官方公告，新价格将于北京时间2026年8月17日零时生效，同时引入峰谷定价机制。以旗舰模型deepseek-v4-pro为例，高峰时段每百万tokens输出价格将升至27元，较现行6元上涨约350%；即便是空闲时段的13.5元，亦是现价的2.25倍。

调价消息与V4 Pro正式版发布同步释出。DeepSeek官方表示，V4 Pro在Agent工作流能力上取得重大升级，并新增灵活推理强度设置，支持原生OpenAI Responses API，为企业级应用场景提供更强性能支撑。

(1) 我们将对 DeepSeek API 价格进行更新调整，采用峰谷定价，空闲时段价格为高峰时段价格的一半。高峰时段为北京时间 9:00 - 12:00、14:00 - 18:00（其余为空闲时段）。新价格将于北京时间 2026 年 8 月 17 日 00:00 开始生效，具体如下：

模型		百万tokens输入（缓存命中）	百万tokens输入（缓存未命中）	百万tokens输出
deepseek-v4-flash	空闲时段	0.05元	1.5元	4.5元
	高峰时段	0.10元	3.0元	9.0元
deepseek-v4-pro	空闲时段	0.15元	4.5元	13.5元
	高峰时段	0.30元	9.0元	27.0元

峰谷定价机制，涨幅最高逾三倍

根据深度求索公布的新定价方案，两款主力API模型均面临实质性涨价。

以deepseek-v4-flash为例，高峰时段百万tokens输出价格从现行的2元升至9元，涨幅达350%；缓存未命中输入价格从1元升至3元。deepseek-v4-pro涨幅同样显著，高峰时段百万tokens输出价格从6元升至27元，涨幅同为350%；缓存未命中输入价格从3元升至9元。

缓存命中场景下的涨幅相对较小，但绝对价格同样大幅提升。v4-flash缓存命中输入价格从0.02元升至高峰时段0.10元，v4-pro则从0.025元升至0.30元。

若选择在空闲时段调用，用户可享受高峰价格的五折优惠，一定程度上为对时延要求不敏感的批量处理场景提供了成本缓冲空间。

模型细节

模型		deepseek-v4-flash	deepseek-v4-pro
BASE URL (OpenAI 格式)		https://api.deepseek.com	
BASE URL (Anthropic 格式)		https://api.deepseek.com/anthropic	
模型版本		DeepSeek-V4-Flash-0731	DeepSeek-V4-Pro-0813
思考模式		支持非思考与思考模式（默认） 切换方式详见 思考模式	
上下文长度		1M	
输出长度		最大 384K	
功能	Json Output	支持	支持
	Tool Calls	支持	支持
	Responses API	支持	支持
	Anthropic API	支持	支持
	对话前续写 (Beta)	支持	支持
	FIM 补全 (Beta)	仅非思考模式支持	仅非思考模式支持
价格 ⁽¹⁾	百万tokens输入 (缓存命中)	0.02元	0.025元
	百万tokens输入 (缓存未命中)	1元	3元
	百万tokens输出	2元	6元
并发限制 ⁽²⁾		2500	500

V4 Pro正式版发布，双模式支持思考与非思考

在宣布调价的同时，深度求索于8月13日正式推出DeepSeek V4 Pro正式版，模型版本号为DeepSeek-V4-Pro-0813，API模型名保持不变。



DeepSeek @deepseek_ai · 2m

We're launching DeepSeek-V4-Pro today! 🚀

- ◆ Major Agent upgrades with strong production gains!
- ◆ Flexible reasoning effort for V4-Pro & V4-Flash: low for simple tasks, high for daily Agent workflows, max for complex tasks.
- ◆ Native OpenAI Responses API support, optimized for Codex with one-click setup.

V4 Pro is now available on app/web. Try it via “Expert Mode”.
V4 Pro is also available via API. Model names remain unchanged—please refer to the API docs for setup details.

Benchmarks	DeepSeek-V4-Pro-0813	DeepSeek-V4-Flash-0731	DeepSeek-V4-Pro-Preview	DeepSeek-V4-Flash-Preview	GLM-5.2	Kimi-K3	Opus-4.8	Fable 5 (w/ fallback)
HLE (w/o/w tools)	42.7/60.0	37.8/51.5	37.7/48.2	34.8/45.1	40.5/54.7	43.5/56.0	49.8/57.9	53.3/63.0
Terminal Bench 2.1	87.9	82.7	72.1	61.8	81.0	88.3	85.0	88.0
NL2Repo	61.5	54.2	38.5	39.4	48.9	-	69.7	-
Cybergym	83.3	76.7	52.7	38.7	-	80.0	78.3	83.1
DeepSWE	62.7	54.4	12.8	7.3	46.2	67.5	58.0	70.0
Toolathon-Verified	74.1	70.3	55.9	49.7	59.9	76.5	76.2	77.9
Agents' Last Exam	25.7	25.2	16.5	15.8	23.8	27.6	25.7	-
AutomationBench (Public)	31.8	25.1	12.8	10.8	12.9	30.8	27.2	29.1
DSBench-FullStack	71.1	68.7	41.8	37.0	61.8	73.7	71.6	77.2
DSBench-Hard	67.2	59.6	31.1	25.8	54.5	63.0	71.7	68.3

^{*} For public Code Agent tasks, V4-Pro-0813 was tested using our upcoming DeepSeek Harness (minimal mode) framework. Settings: max tie; topp=0.95, temperature=1.0. Results may vary slightly with other frameworks.



该模型已全面接入APP、网页端和API三端，网页端及APP用户可通过选择"专家模式"使用新版模型。V4 Pro支持思考与非思考双模式，默认启用思考模式，用户可按需切换。

技术规格方面，V4 Pro上下文长度达100万tokens，最大输出长度384K tokens，支持Json Output、Tool Calls、Responses API、Anthropic API及对话前缀续写等功能，并发限制为500路。相比之下，定位更轻量的deepseek-v4-flash并发限制达2500路，更适合高吞吐量场景。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

725 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论

华尔街韭菜

4小时前 中国江苏省

涨幅太大了

0 回复