

摘要：

DeepSeek低调更新DeepGEMM代码库，推出Mega MoE技术——把原本“支离破碎”的MoE流程“揉成一坨”，融合dispatch、线性变换等步骤至单一mega-kernel，更实现“一边算一边传”的计算通信重叠，让GPU告别“算一会儿等一会儿”的低效，像“接力搬砖变连续传送带”般提升多卡场景效率。

昨天下午，沉寂许久的 DeepSeek 又有新动作了！

不过正如 DeepSeek 自己在 PR 中强调的，和模型没关系，更新了一下 DeepGEMM 代码库。

Additional notes

Mega MoE is still under development and optimizations, stay tuned and optimization ideas are welcome!

Disclaimer: this release is only related to DeepGEMM's development, has nothing to do with internal model release.



不过，此次更新，我们看到了一个新东西：**Mega MoE**。



LyricZhao commented 1 hour ago • edited

Collaborator

...

New features

- Mega MoE, fusing & overlapping dispatch/linear 1/SwiGLU/linear 2/combine into a single mega-kernel, overlapping NVLink communication and tensor core computation
 - Performance number will be posted later
 - Only FP8 x FP4 MoE is supported
 - Only EP <= 8 is tested
- FP4 Indexer (MQA logits) with larger MTP support
- FP8 x FP4 GEMM
- PDL
- Refactors on GEMM heuristics
- Faster JIT compilation
- GEMM optimizations (Swap A/B, much faster MoE GEMM)
- DeepEPv2 MoE GEMM layout

Bug fixes

- JIT may crash on distributed FS
- Some kernel hangs and IMA


Contributors

- Mega MoE: [@LyricZhao](#) [@zheanxu](#) [@bucket-xv](#) [@RayWang96](#) [@interestingLSY](#) [@kurisu6912](#) [@xay5421](#) [@yukuai26](#)
- FP4 Indexer: [@zheanxu](#) [@xay5421](#) [@interestingLSY](#)
- GEMM, PDL, JIT and bug fixes: [@zheanxu](#) [@bucket-xv](#) [@xay5421](#) [@yukuai26](#) [@LyricZhao](#)

Additional notes

Mega MoE is still under development and optimizations, stay tuned and optimization ideas are welcome!

Disclaimer: this release is only related to DeepGEMM's development, has nothing to do with internal model release.



Mega MoE 项目贡献者来自 DeepSeek 基础设施团队的 Chenggang Zhao 等人。

Mega MoE 是什么？

如何理解 Mega MoE？先来看看 X 网友思维怪怪的解读：



思维怪怪
@0xLogicrw

DeepSeek 今天发布 DeepGEMM 开源以来最大一次更新。这个去年 2 月「开源周」期间发布的 GPU 算子库，原本只做 FP8 矩阵乘法，现在扩展为覆盖大模型推理关键环节的完整算子库，支持 FP8、FP4、BF16 多种精度的矩阵运算，以及 MoE 和注意力评分等专用算子。

核心新增是 Mega MoE。MoE（混合专家）架构是 DeepSeek V3 等模型的基础，推理时需要依次执行五个步骤：EP 分发、第一层线性变换、SwiGLU 激活、第二层线性变换、EP 合并。传统做法是五个独立 kernel 依次调用，每次调用都要等上一步完成、数据在显存里搬来搬去。Mega MoE 把这五步融合成一个 kernel，让 NVLink 通信和 Tensor Core 计算同时进行，省去中间的等待和数据搬运。目前仅支持 FP8×FP4 精度组合，需要 PyTorch 2.9 及以上版本，团队表示仍在优化中，性能对比数据将稍后公布。

其他新增包括：FP8×FP4 混合精度矩阵乘法、支持更大 MTP 的 FP4 注意力评分算子（Indexer）、PDL（程序化依赖启动，一种减少 kernel 启动延迟的 GPU 调度优化）、更快的 JIT 编译速度，以及对 MoE 矩阵运算的多项优化。此次更新还适配了 DeepEPv2 的 MoE 数据布局。

PR 说明中特别注明：「本次发布仅与 DeepGEMM 开发相关，与内部模型发布无关。」

deepseek-ai/DeepGEMM



#304 [Public release 26/04] Introducing Mega MoE, FP4 Indexer and...

 0 comments  0 reviews  109 files +12134 -3253 

 LyricZhao • April 16, 2026  4 commits

[Public release 26/04] Introducing Mega MoE, FP4 Indexer and other features/fixes by ...

来源：<https://x.com/0xLogicrw/status/2044720884066451645>

简单来说，Mega MoE 干的事情是把原本支离破碎的一整套 MoE 计算流程，揉成了一坨，一次性在 GPU 上跑完。

过去的 MoE，有点像一个被拆成很多工位的流水线。token 先被分发（dispatch）到不同专家，然后做一层线性变换，再过激活函数（SwiGLU），再来一层线性，最后再把结果拼回去。听起来没问题，但现实是，每一步都要单独起一个 kernel，中间还夹杂着 GPU 之间的数据通信。

于是你会看到一种很典型的低效：算一会儿，等一会儿；传一会儿，再算一会儿。

Mega MoE 想做的是把这条流水线直接焊死：它把 dispatch、两层线性、SwiGLU、combine 这些步骤全部 fuse 到一个 mega-kernel 里。更关键的是，它不只是「合并步骤」，还在做一件更狠的事情：让数据通信和计算同时发生。

也就是说，一边在 Tensor Core 上算，一边在 NVLink 上传，不再是你等我、我等你。



```

114 + ### Mega MoE
115 +
116 + Mega MoE fuses and overlaps EP dispatch, linear 1 (FP8xFP4), SwiGLU, linear 2
    (FP8xFP4), and EP combine into a single mega-kernel, overlapping NVLink communication
    and tensor core computation. It requires multi-process launch with symmetric memory.
    Usage:
117 +
118 + ```python
119 + # Allocate symmetric memory buffer
120 + buffer = deep_gemm.get_symm_buffer_for_mega_moe(
121 +     group, num_experts, num_max_tokens_per_rank, num_topk, hidden, intermediate_hidden
122 + )
123 +
124 + # Transform weights (FP4 with UE8M0 SF) into the required layout
125 + transformed_l1, transformed_l2 = deep_gemm.transform_weights_for_mega_moe(l1_weights,
    l2_weights)
126 +
127 + # Copy inputs into the buffer before each call
128 + # You may fuse these into previous kernels
129 + buffer.x[:num_tokens].copy_(x_fp8)
130 + buffer.x_sf[:num_tokens].copy_(x_sf)
131 + buffer.topk_idx[:num_tokens].copy_(topk_idx)
132 + buffer.topk_weights[:num_tokens].copy_(topk_weights)
133 +
134 + # Run the fused mega MoE kernel
135 + y = torch.empty((num_tokens, hidden), dtype=torch.bfloat16, device='cuda')
136 + deep_gemm.fp8_fp4_mega_moe(y, transformed_l1, transformed_l2, buffer)
137 + ```
138 +
139 + For the full example with multi-process setup and benchmarking, please refer to
    `tests/test_mega_moe.py`.

```

此做法的影响很直接：GPU 不再频繁停顿，利用率更高，尤其是在多卡、大规模 MoE 场景下，这种优化能被直接感受到。有点像把原来一群人在接力搬砖，变成了一台连续运转的传送带。

当然，DeepSeek 这次也没打算只做一个「更快的 kernel」。你能明显感觉到，他们是在往一个方向死磕：**把 MoE 的效率压到极限**。

比如他们开始尝试 FP8 × FP4 这样的组合精度，还搞了一个 FP4 的 indexer，用在 MQA logits 上。这种操作基本是在逼近「还能不能再省一点算力」的边界。再加上一些 GEMM 的重构、JIT 编译加速，似乎是想把 DeepSeek 的 AI 打磨得更加强劲。

还有一个细节挺有意思：他们明确说，Mega MoE 还在开发中，性能数据「之后再说」。看起来，这种级别的优化，往往不是一版代码就能定型的，而是要在不同规模、不同拓扑、不同 workload 下反复调。现在放出来，更像是在给社区一个信号：方向已经定了，我们开始往这条路狂奔了。

在此基础上，DeepSeek 也对 DeepGEMM 的描述进行了一些调整：

DeepGEMM 是一个统一的高性能 Tensor Core 内核库，将现代大语言模型的关键计算原语整合在一起，包括 GEMM (FP8、FP4、BF16)、具备通信重叠的融合 MoE (Mega MoE)、用于 lightning indexer 的 MQA 打分、HyperConnection (HC) 等，全部汇聚到一个统一且一致的 CUDA 代码库中。所有内核通过一个轻量级的即时编译 (JIT) 模块在运行时编译，安装过程中无需进行 CUDA 编译。



```
3 - DeepGEMM is a comprehensive library of high-performance tensor core kernels purpose-built for modern large language models, covering GEMMs (FP8, FP4, BF16), fused MoE (Mega MoE), MQA scoring (Indexer), and more. Written in CUDA, all kernels are compiled at runtime via a lightweight Just-In-Time (JIT) module - no compilation required during installation.
3 + DeepGEMM is a unified, high-performance tensor core kernel library that brings together the key computation primitives of modern large language models - GEMMs (FP8, FP4, BF16), fused MoE with overlapped communication (Mega MoE), MQA scoring for the lightning Indexer, hyperconnection (HC), and more - into a single, cohesive CUDA codebase. All kernels are compiled at runtime via a lightweight Just-In-Time (JIT) module, requiring no CUDA compilation during installation.
```

所以如果一定要给这次更新一个定位，大概可以这么说：这是一次基础设施层的重构尝试。DeepSeek 正在把 MoE 从一种「理论上很美好，但工程上很折腾」的架构，往「可以被大规模、高效率跑起来」的方向推进。

而 Mega MoE，很可能只是第一块拼图；就是不知道这块拼图是不是 DeepSeek-V4 的一部分？

根据 X 网友 St4r 的解读，这也可能暗示了 DeepSeek 所使用的训练卡还是包含了英伟达 AI 加速卡，还是最新、最顶级的 B 系列（而非几个月以来一直传言的，使用国产 AI 训练卡）。



St4r @xinqiu_bot · 13h

分析了一下里面的**Mega MoE**，假设DeepSeek V4真的是用这版DeepGEMM+DeepEPv2来训，大概率还是用的NVIDIA的卡，毕竟里面用到的算子用的tcgen05妥妥B卡算子，当然除非华为也强行适配了B卡的tcgen05.另外根据代码，单层MoE大约就25.37B，如果还是60层，大概率是个1.6T的模型，再不济也是48层的1.25T。

 ...

本文来源：[机器之心](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 43  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论