

摘要：

8月6日，DeepSeek宣布将大幅上调API服务价格，主要受AI Agent等应用爆发带来的Token调用量激增，以及算力成本上升推动。此前，DeepSeek凭借“价格屠夫”策略引发行业降价潮，如今转向更可持续的商业化定价。这意味着国产大模型正从“烧钱换用户”阶段迈向盈利验证期，未来竞争将聚焦成本控制与模型性能的平衡。

国产大模型行业正在迎来定价逻辑的转折点。

8月6日，DeepSeek发布公告称，计划近期整体上调DeepSeek API服务定价，“预计涨幅较大”，具体方案以正式通知为准。虽然DeepSeek尚未公布调价幅度和时间表，但市场普遍认为，这意味着国产大模型行业正在告别此前靠低价抢占市场的阶段，进入以成本、效率和商业化为核心的新周期。

此次涨价背后，是AI应用需求爆发与算力成本上升带来的双重压力。随着AI Agent等复杂应用兴起，模型调用量大幅增加，过去依靠低价刺激需求的模式正在面临挑战。



DeepSeek-V4-Flash 正式版 API 已上线公测，Agent 能力大幅增强；V4-Pro 暂未变动。

[点击查看详情。](#)



deepseek 开放平台

用量信息

计划近期整体上调 DeepSeek API 服务的定价，预计涨幅较大，请合理安排您的使用。具体方案以正式通知为准。

知道了

所有日期均按 UTC+0 时间显示，数据可能有 5 分钟延迟。

用量暴涨，倒逼DeepSeek重新定价

此次涨价的核心原因，是AI应用需求增长速度超出预期。



开源AI Agent工具OpenCode数据显示，DeepSeek V4 Flash正式版在其平台单日Token调用量达到8万亿，其中5万亿来自免费额度，3万亿来自付费套餐。作为对比，大模型路由平台OpenRouter接入超过400款模型，全平台日均Token调用规模约为6.6万亿。

这意味着，DeepSeek单一模型在单个平台的调用量，已经超过整个模型聚合平台的日均规模。

Vercel平台数据也显示，DeepSeek Token处理量持续攀升，V4 Flash每周处理约5.3万亿Token，已成为平台使用量最高的模型之一。

随着AI Agent快速普及，模型调用模式正在发生变化。过去聊天机器人一次交互可能只消耗数百至数千Token，而Agent执行复杂任务时，需要持续调用模型、访问工具，Token消耗可能达到传统对话模式的数十甚至上百倍。

在需求爆发之下，极低价格正在成为新的成本压力。

DeepSeek方面此前表示，**涨价主要受到三方面因素影响**：一是智能体应用快速增长带来的Token消耗激增；二是高端AI芯片供应受限，算力成本持续上升；三是行业竞争正在从补贴换规模转向可持续商业模式。

从“价格屠夫”到商业化定价

DeepSeek的定价转向并非突然发生。

今年4月底，DeepSeek曾推出V4-Pro API限时折扣，随后在5月将优惠价格转为长期定价，输出Token价格较原价下降75%。**当时，DeepSeek V4-Pro输出价格约为0.87美元/百万Token，远低于海外主流模型，被市场称为“价格屠夫”。**

这一策略也引发国内大模型厂商集体降价，小米、字节、腾讯云等相继调整价格体系，部分模型价格降幅超过90%，国产大模型市场一度陷入激烈价格竞争。

但6月底，DeepSeek开始改变策略。**公司宣布V4正式版上线后引入峰谷定价机制，工作日高峰时段API价格翻倍。**彼时市场认为，这是DeepSeek通过价格调节用户需求、优化算力利用率的方式。

而此次全面涨价，则意味着DeepSeek正在从“调节流量”转向“重新定义价格”。

DeepSeek创始人梁文锋此前在投资者交流会上曾表示，**API定价应建立在合理回收设备成本的基础上，目标是“买一批设备回来，十个月收回成本”。**他同时指出，当前价格区间内用户需求“几乎没有弹性”，即便价格上涨，Token消耗量变化也有限。

DeepSeek V4 正式版

发布计划及计费调整说明



deepseek-v4-pro

计费项	平时价格	高峰时段价格
百万tokens输入 (缓存命中)	0.0 25 元	0.05 元
百万tokens输入 (缓存未命中)	3 元	6 元
百万tokens输出	6 元	12 元

deepseek-v4-flash

计费项	平时价格	高峰时段价格
百万tokens输入 (缓存命中)	0.0 2 元	0.04 元
百万tokens输入 (缓存未命中)	1 元	2 元
百万tokens输出	2 元	4 元

⌚ ** 高峰时段定义: 每日 9:00~12:00 和 14:00~18:00 (北京时间)

算力紧缺，低价模式难以持续

DeepSeek调整价格的背后，是整个AI算力产业链供需矛盾加剧。

随着大模型训练和推理需求快速增长，GPU、服务器、存储等资源持续紧张。尤其是在AI Agent时代，模型推理需求从简单问答转向长链路任务执行，算力消耗大幅提升。

高盛此前指出，DeepSeek实施峰谷定价并不代表需求疲软，反而反映出国内AI模型需求旺盛、算力资源趋紧。随着AI应用进入规模化阶段，长期维持极低API价格将难以覆盖持续增长的算力投入。

事实上，过去半年，国产大模型行业已经出现集体调整迹象。

包括阿里、字节、小米、智谱、腾讯等多家厂商均调整过产品定价或套餐体系，部分低价方案开始收缩。智谱今年一季度API调用价格较此前提升，但调用量仍保持高速增长；Kimi也曾因用户请求量大幅超预期，暂停部分新用户订阅。

行业正在从“烧钱换用户”转向“规模化商业变现”。



国产大模型进入盈利验证期

DeepSeek此次涨价，也释放出一个更重要信号：国产大模型正在从技术竞争进入商业化竞争。

过去一年，低价甚至免费的模型服务帮助国产大模型快速扩大用户规模，但随着调用量爆发，算力成本、服务器投入和运营压力开始显现。

市场此前关注的是，谁能提供更便宜的模型；而未来竞争重点将转向，谁能以更低成本提供更高性能、更稳定的服务。

对于开发者而言，DeepSeek涨价意味着AI应用的成本红利正在减少，但也意味着行业开始走向更加健康的商业循环。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

428

收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

3 条评论



见闻用户

5小时前 中国北京

比闭源有高性价比，形成飞轮效应，剩下的交给时间

0 回复



门外汉
18小时前 中国北京

DEEPSEEK每日的TOKEN收入超过2亿美元，这年超过600亿美元。这么看股指真的不贵

👍 0 ↩ 回复



joanals 3小时前 中国浙江省

回复 门外汉:

你这600Y是裸利润在算吗

👍 0 ↩ 回复