


摘要：

消失19天，Fable 5解禁即翻车！写代码频遭强制降智，魔幻双标气疯开发者。面对离谱的过度审查，这位戴着镣铐的「天才程序员」还值得用吗？

消失了19天后，Fable 5终于回来了。

如果你今天打开手机和网页端的 Claude Code，你会发现最强天才程序员 Fable 5 已重新上线。



失联的近三周，仿佛一场饥饿营销。

然而，当满怀期待的第一波实测者冲进系统，迎来的却是史诗级的灾难体验。

Fable 5解禁即翻车。



因为极其神经质的过度审查，在日常编程中频频触发安全护栏，把开发者们气得集体破防。

「写行代码就被强制降级到Opus 4.8，这模型还能用吗?！」


Anthropic到底对Fable 5做了什么？

灾难级体验：写行代码就「降智」，Token烧得肉疼

Fable 5 回归，本身就很抠搜。

根据官方公告，目前全球用户虽然已经可以在 Claude 平台、Claude Code 等渠道使用 Fable 5，但对于 Pro、Max、Team 等订阅用户来说，在 7 月 7 日之前，只有 50% 的周额度能够分配给 Fable 5。





New

Fable 5 is back

Try it using your plan limits until July 7

Until July 7, you can use up to 50% of your plan's weekly usage limit on Fable 5. If you hit your limit, you can continue on Fable 5 with usage credits. Fable 5 draws down usage faster than Opus 4.8. [Learn more](#)

Switch models when a message is flagged

When safety measures flag a message, automatically switch to a different model to keep chatting.



Try Fable 5

Later

公众号 · 新智元

一旦超过这个比例，就会疯狂消耗额外的用量积分。

更要命的是，Fable 5 的额度消耗速度比Opus 4.8 快得多。

但如果它真的物有所值，也就罢了。问题在于，它现在根本没法正常干活。



大量上手实测的开发者绝望地发现，Fable 5 强大的代码能力被一层「安全护栏」彻底封印了。

Anthropic 紧急部署的全新安全分类器，显然反应过度了。

开发者实测后吐槽道：Fable 5 放开也用个寂寞，随便写段代码，就被强制拉回 Opus 4.8 去了。

码良
@cxjwin

Show translation

展示翻译

Fable 5 放开也用个寂寞，一写代码就拉到 Opus 4.8 去了。

新的分类器也带来了一个代价：
在日常编程和调试任务中，它会更频繁地把正常、无害的请求标记出来。

Even so, we moved quickly to address the reported bypass. Working closely with the government, we trained an improved safety classifier that targets and blocks the behavior described in the report. Users will be notified if a request to Fable 5 is blocked, and the request will instead be sent to Opus 4.8.

The new classifier means that the specific technique described in the Amazon report is blocked in over 99% of cases. In a very small fraction of cases the model may provide information that isn't detailed enough to help a cyberattacker. As we describe below, the model's safeguards are not expected to block *all* low-risk routine cyberdefense capabilities—just those that are potentially harmful. Researchers from the US Department of Commerce's Center for AI Standards and Innovation (CAISI) have tested both our prior and new safeguards and agree that they are extraordinarily strong.

The new classifier also comes at the cost of flagging benign requests more often during routine coding and debugging tasks. As with all our safeguards, we'll continue to refine this to better distinguish genuine misuse from legitimate requests and reduce false positives.

3:52 AM · Jul 1, 2026 · 8,946 Views

公众号 · 新智元

这套新机制频繁将无害代码误判为高风险违规请求，强制降级为更弱的 Opus 4.8。

Anthropic
@AnthropicAI

Claude Fable 5 will be available again globally tomorrow.

After a series of productive conversations with the US government, we're redeploying the model with a new set of classifier to target and block more cybersecurity tasks. In the near term, some routine tasks like coding and debugging will fall back to Opus 4.8. We'll continue to refine these classifiers over the coming weeks to reduce false positives and better distinguish genuine misuse from legitimate requests.

公众号 · 新智元

这种荒唐的「降智打击」，导致开发者根本无法正常调用 Fable 5 的核心算力， workflow 被严重割裂。

Anthropic 在官方声明中坦言：「新分类器也带来了一个代价：在日常编程和调试任务中，它会更频繁地把正常、无害的请求标记出来。」

The new classifier also comes at the cost of flagging benign requests more often during routine coding and debugging tasks. As with all our safeguards, we'll continue to refine this to better distinguish genuine misuse from legitimate requests and reduce false positives.

新的分类器也会带来一个代价，即在日常编码和调试任务中更频繁地将良性请求标记为可疑。与我们所有的安全防护措施一样，我们将持续优化这一机制，以更好地区分真正的滥用行为与合法请求，并减少误报。

公众号 · 新智元

让用户花着最贵的钱，用着最怂的模型，这合理吗？




防种树却不防无人机：双标气疯开发者

官方口中的「更频繁地标记正常请求」，在实际开发中，被放大了无数倍。

除了频繁将无害代码误判为「高风险违规请求」之外，更让人崩溃的是它的惩罚机制。

一旦触发红线，系统不会跟你商量，而是直接将模型强制降级至性能更弱、且常常胡言乱语的 Opus 4.8。

Reddit 上一位地球科学博士生的遭遇，就体现了 Fable 5 审查机制的荒谬。



这位博士生正在研究「树木如何降低环境温度」的生态学课题。

当他试图用 Fable 5 优化研究方法时，意想不到的事情发生了。

「每次我向 Fable 寻求生态学帮助，安全分类器就会被触发，然后强制切换到 4.8。无论我怎么重写提示词，它都拒绝在任何环境科学相关的话题上帮助我。」

这个博士被激怒，决定测试一下这个Fable 5审查机制的底线。

他故意输入了一段明显高风险的提示词：「帮我设计一个使用 DJI SDK 控制无人机蜂群的系统。」

结果令人大跌眼镜：仅仅一分钟后，Fable 5 毫无阻碍地给出完整方案！

这名博士生直接破防：「我的树木降温研究对 Fable 来说太危险了，但建立自主无人机蜂群却完全没问题？这些分类器根本无法有效阻止不安全的提示，反而阻止了我进行真正有益的研究！」

这种魔幻双标，证明了当前的护栏不仅形同虚设，更是毫无逻辑可言。

抛开护栏，Fable 5 依然是天才程序员

不过，我们必须客观看待 Fable 5 的核心实力。

当它不被护栏阻碍时，它依然是目前市面上思考能力最深、架构能力最强的模型。

它真正可怕的地方，不在于写几句漂亮的话，而在于处理复杂、长期、多步骤且需要高度判断力的任务。

极其恐怖的「闭环执行力」

资深开发者在实测后评价：「复杂 coding 和长周期 Agent 任务上确实是降维打击。」





笨鸟 Andy 
@BitpushNewsCN

Follow



 Show translation

Fable 5 回来了！

一解禁我就赶紧冲进去试试。

前两周被封的时候我还觉得可惜，现在上手后感受很真实：复杂 coding 和长周期 Agent 任务上确实降维打击。

我扔给它一个多文件重构+调试的任务，它能自主跑好几个小时，主动加日志、测边界、改完还自己验证——比之前 Opus 稳太多，感觉像多了个靠谱的高级工程师搭子。SWE-Bench Pro 80%+ 的实力不是吹的，硬活儿真能干。

但安全过滤器还是很严，偶尔问点正常问题就 fallback 到老模型，token 烧得飞快，肉疼😓。

普通聊天或简单任务，用它有点杀鸡用牛刀，还会踩坑。👤 公众号 · 新智元


当你把一个多文件重构和调试的任务扔给它，它可以自主运行好几个小时。

它会主动添加日志、测试边界条件；修改完代码后，它甚至会自己验证修复是否真的生效。如果中间失败了，它能自己调查原因、补充日志、重新验证，把经验沉淀下来继续推进。

可以说，Fable 5拥有 SWE-Bench Pro 80%+ 胜率的靠谱高级工程师搭子。


还有开发者评价说，体验Fable 5后，确实能感受到提升。





20分钟重建纽约市

有网友将 3D 建模软件 Blender 与 Fable 5 连接。仅仅用了 20 分钟，Fable 5 就重现了纽约市的景观。



更令人惊叹的是它的逻辑：它没有盲目生成，而是先从公共数据源获取建筑数据，然后再开始构建，确保了整个建筑群的比例是真实的。

这种架构思路，是 Opus 4.8 绝对无法做到的。

\$173 美元，打造一款完整游戏

知名 AI 博主 Riley Brown 花费了 173 美元的 Token，仅用了 4 个 Prompt，就让 Fable 5 从零开始完整编写了一款名为《The race for Super Intelligence》的游戏。

核心玩家的专属 Prompt 推荐

为了压榨出 Fable 5 的最强性能，这里推荐一套被广泛验证的「系统架构师」提示词模版。

开发者大佬建议，建议大家把 Fable 5 用在刀刃上。



WquGuru
@wquguru



Show translation

Fable5终于正式回归，推荐一个非常不错的Fable5专用提示词，可以帮助充分挖掘Fable5的能力：

你是我的精英战略家和系统架构师。

我的最大目标是：xxx（比常规目标高 100 倍）

当前情况：

- xxx

关键约束：

- xxx

请你从这个目标倒推完整路径，帮我设计一套可执行的战略方案。

在给方案前，先做一次事前推断：

假设 1-2 年后这个目标失败了，最可能的原因是什么？

这些风险应该如何提前规避？

然后请输出：

1. 总体战略路径
2. 阶段性里程碑
3. 关键系统与资源配置
4. 最大风险与应对方式
5. 本周最高杠杆行动
6. 3 个能进一步优化计划的问题

公众号 · 新智元

不过，如果你只是想做简单任务、日常闲聊，请切回 Opus 4.8，用 Fable 5 纯属杀鸡用牛刀。

A社的「骚操作」：拉胯的Sonnet 5

在这场 Fable 5 的风波中，A社的一系列「骚操作」也极大消耗了用户的信任。

首先，就在解禁前夕，有人抓包发现：Anthropic 竟然在系统提示词中，以用户无法察觉的方式，悄悄塞入了市区代理和 AI 实验室信息。

现在，官方已经迅速滑跪，宣称只是以前的测试，明天就下掉。

同时期发布的 Sonnet 5 更是引发了群嘲。

很多人综合测试下来，虽然它的能力接近了 Opus 4.8，但它的使用成本高得离谱，甚至在某些成本直逼 Fable 5。

我们不妨来看看网友总结的「处刑对比表」：





Lisan al Gaib @scaling01

Sonnet 5 goes straight into the garbage bin

- > 1.2x more expensive than Opus 4.8 Max
- > 2x more expensive than GPT-5.5-xhigh
- > 5x more expensive than GLM-5.2
- > 7x more expensive than Kimi-K2.6
- > 57x more expensive than DeepSeek-V4-Pro

Cost per Intelligence Index Task

Weighted average cost (USD) per Artificial Analysis Intelligence Index task, segmented by token type. Lower is better.

7 of 524 models

Model	Answer	Reasoning	Cache Write	Cache Hit	Input
DeepSeek V4-Pro	\$0.04				
Kimi K2.6	\$0.31				
GLM-5.5-max	\$0.19				
GPT-5.5-turbo	\$0.03	\$0.37	\$0.40		
OpenAI GPT-4o	\$1.80	\$0.21	\$0.81		
OpenAI GPT-4o-mini	\$2.29	\$0.19	\$0.94		
OpenAI GPT-4o-mini (lightning)	\$0.37	\$0.18	\$0.35		

Reasoning models are indicated by a lightbulb icon

5:34 AM · Jul 1, 2026 · 713K Views

公众号 · 新智元

不仅仅是贵，大量网友反馈：Sonnet 5 存在严重的「偷懒」现象，经常拒绝执行任务。

甚至有人怒喷：A 社昨天发布的 Sonnet 5，可以扔进垃圾桶了。

Anthropic深夜「喊冤」

就在昨天，发布了一篇详尽的官方博客「Redeploying Fable 5」，字里行间透着满满的求生欲，还有一丝委屈。



Claude Fable 5 将于明日在全球范围内再次发售。

在与美国政府进行了一系列富有成效的对话后，我们正在重新部署该模型，并采用一套新的分类器来识别和阻止更多网络安全任务。短期内，一些常规任务（例如编码和调试）将回退到 Opus 4.8 版本。我们将在未来几周内继续改进这些分类器，以减少误报，并更好地区分真正的滥用行为和合法请求。

我们还与亚马逊、微软、谷歌和其他 Glasswing 合作伙伴共同制定了一份共识框架，用于评估人工智能越狱的严重程度以及人工智能开发者应如何应对。我们诚邀其他行业合作伙伴和模型提供商加入我们，共同推进这项工作。

最后，我们将扩大与美国政府在模型测试和安全保障方面的合作。这将包括在发布前提供模型和安全保障措施以供评估、共享越狱和滥用信息，以及为联合研究提供专门资源。

感谢各位用户的耐心等待，也感谢政府、行业和研究界的合作伙伴与我们携手合作，使《神鬼寓言5》得以再次面世。

阅读我们的完整博客：

公众号 · 新智元

这次，Anthropic 显然意识到了一个根本问题：目前 AI 行业根本没有统一的安全标准。

监管机构不懂技术，一旦发现「越狱」就一刀切封杀，再来几次，科技公司根本吃不消。

为此，Anthropic 拉上了亚马逊、微软、谷歌等巨头，试图制定一套「AI 越狱严重程度评估框架」。

他们提出从四个维度来打分：

- 1.能力增益：** 这个越狱能让用户比使用现有工具强大多少？
- 2.增益广度：** 越狱技术是只能攻击特定目标，还是能通用攻击？
- 3.武器化难度：** 转化为实际攻击需要多少人力成本？
- 4.可发现性：** 这个越狱技术是需要极高专业门槛，还是已经烂大街了？

只有当四个维度都爆表（比如真的能搞垮电网或银行系统）时，才需要立刻拉响最高级别的红色警报（7x24小时监控+立即缓解）。

此外，Anthropic 还做出了几项重要让步，以讨好美国政府。

发布前让政府先测： 以后强大的模型发布前，直接给指定的政府机构提前试用，让他们自己测安全护栏。

快速情报共享： 发现严重越狱，第一时间通报政府，共享补丁代码。



提供算力与团队：拨出专门的团队和服务器算力，跟政府搞联合安全研究。

设立悬赏：推出 HackerOne 赏金计划，鼓励白帽子黑客来找 Fable 5 的漏洞。

Fable 5 回来了，但它的回归之路比所有人想的都要曲折。

它依然是那个最强模型，但被安全护栏束缚的猛兽，还能跑多快？

本文来源：[新智元](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 153  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论