

摘要：

智谱GLM-5.2正式开源，753B参数配合1M token稳定上下文，在长程编程基准FrontierSWE上以74.4分仅落后顶级闭源模型Opus 4.8约1%，同时超越GPT-5.5。架构创新IndexShare将超长上下文计算量压缩至三分之一，"越用越顺"。开源模型与闭源顶尖模型的差距，正从量级之别收窄为数字之差。

GLM-5.2 正式发布，震撼全网，主打长程任务能力，配合 1M token 上下文窗口，且完全开源（MIT 协议）。在相近的 token 消耗下，GLM-5.2 的能力大致介于 Opus 4.7 和 Opus 4.8 之间，参数仅为753B。





Design Arena 🏆
@Designarena



🔄 翻译自 英语 显示原文 ⚙️

突发：GLM-5.2 现位居 Design Arena 第一。


凭借 1360 的 Elo 分数，GLM-5.2 已跃居现已不可用的 Claude Fable 5 之前。

而且它是开源权重。

这是自 Design Arena 启动以来，在我们的代码类别中实现最高 Elo 分数之一，提升了 4 个位置和 27 个 Elo 点。

衷心祝贺 @Zai_org 发布！

评价此翻译：👍 🗨️



Proximal 🏆 @ProximalHQ · 1小时




🔄 翻译自 英语 显示原文

GLM 5.2 在 FrontierSWE 上排名第 3。它仅落后于 Fable 5 和 Opus 4.8，并且它优于 GPT-5.5。

这是第一个缩小 Anthropic / OpenAI 模型与其他提供商模型之间巨大差距的模型，而且它是迄今为止最强的开源权重模型。

Leaderboard mean@5 · avg rank				
#	MODEL · HARNESS		AVG RANK	DOMINANCE
1	Claude Fable 5 Claude Code		2.35	90%
2	Claude Opus 4.8 Claude Code		4.24	75%
3	GLM-5.2 Claude Code	▲ from #9	4.32	74%
4	GPT-5.5 Codex		4.56	73%
5	Claude Opus 4.7 Claude Code		5.76	63%





我总结了几个核心卖点：

1M token 稳定上下文，不是噱头，而是工程可用级别的稳定性

长程任务能力，FrontierSWE 仅落后 Opus 4.8 1%，差距极小，超越 GPT-5.5。

架构创新，IndexShare、MTP 改进（接受长度提升 20%）

GLM-5.2 vs GPT-5.5：多项超越


直接上图，详细解读在后面

Agentic Coding Performance by Effort Level

Average over Terminal-Bench 2.1, DeepSWE and SWE-Atlas QnA, evaluated on Claude Code 2.1.167



GLM-5.2 GLM-5.1 Claude Opus 4.8 Claude Opus 4.7



LLM Performance Evaluation

8 Benchmarks: SWE-bench Pro, Terminal-Bench 2.1 (Terminus), NL2Repo, DeepSWE, ProgramBench, MCP-Atlas, Tool-Decathlon, Humanity's Last Exam
All models are evaluated under their maximum thinking effort



GLM-5.2 GLM-5.1 Claude Opus 4.8 GPT-5.5 Gemini 3.1 Pro



Benchmark	GLM-5.2	GLM-5.1	Qwen3.7-Max	MiniMax M3	DeepSeek-V4-Pro	Claude Opus 4.8	GPT-5.5	Gemini 3.1 Pro
REASONING								
HLE	40.5	31.0	41.4	37.0	37.7	49.8*	41.4*	45.0
HLE w/ Tools	54.7	52.3	53.5	-	48.2	57.9*	52.2*	51.4*
CritPt	16.7	4.6	13.4	3.7	12.9	20.9	27.1	17.7
AIME 2026	99.2	95.3	97.0	-	94.6	95.7	98.3	98.2
HMMT Nov. 2025	94.4	94.0	95.0	84.4	94.4	96.5	96.5	94.8
HMMT Feb. 2026	92.5	82.6	97.1	84.4	95.2	96.7	96.7	87.3
IMOAnswerBench	91.0	83.8	90.0	-	89.8	83.5	-	81.0
GPQA-Diamond	91.2	86.2	90.0	93.0	90.1	93.6	93.6	94.3
CODING								
SWE-bench Pro	62.1	58.4	60.6	59.0	55.4	69.2	58.6	54.2
NL2Repo	48.9	42.7	47.2	42.1	35.5	69.7	50.7	33.4
DeepSWE	46.2	18.0	18.0	20.0	8.0	58.0	70.0	10.0
ProgramBench	63.7	50.9	-	-	47.8	71.9	70.8	39.5
Terminal Bench 2.1 Terminus-2	81.0	63.5	75.0	65.0	64.0	85.0	84.0	74.0
Terminal Bench 2.1 Best Reported Harness	82.7 (Claude Code)	69 (Claude Code)	-	-	-	78.9 (Claude Code)	83.4 (Codex)	70.7 (Gemini CL)
FrontierSWE Dominance as of 20/9/16	74.4	30.5	-	-	29.0	75.1	72.6	39.6
PostTrainBench	34.3	20.1	-	-	-	37.2	28.4	21.6
SWE-Marathon	13.0	1.0	-	-	-	26.0	12.0	4.0
AGENTIC								
MCP-Atlas Public Set	76.8	71.8	76.4	74.2	73.6	77.8	75.3	69.2
Tool-Decathlon	48.2	40.7	-	-	52.8	59.9	55.6	48.8

详细解读一下GLM-5.2究竟意味着什么

有一类任务，是 AI 编程的真正考场。

给你一个大型代码仓库，要求你花几个小时，完成一次跨模块的性能优化；或者从零开始，搭建一个可以跑通的编译器；再或者，给你一张 H100，让你自己去训练一个更好的小模型出来。

这类任务有一个共同特征它们不能被一次对话解决。你需要 AI 在很长的执行轨迹里保持状态、记住上下文、不中途失忆、不绕回起点。

这正是当前大多数模型的软肋。

接受 100 万个 token 的上下文，和在 100 万个 token 的压力下稳定工作，是两件完全不同的事。前者是参数表上的一行数字，后者是工程实践里真实可用的能力。很多模型在上下文拉长之后，推理质量会快速衰减，模型开始“忘事”，注意力涣散，生成质量明显下滑。

智谱今天发布的 GLM-5.2，想解决的正是这个问题。

1M 上下文

GLM-5.2 的上下文窗口是 100 万 token，这个数字本身不新鲜。新鲜的是他们怎么做到让它稳的。

团队在训练阶段专门针对编程 Agent 的长轨迹场景做了大量扩展，覆盖大规模代码实现、自动化研究、性能调优、复杂 debug 这几类在实际工程中最消耗上下文的场景。目标不是让模型“能接收”百万 token，而是让它在真实的工程压力下保持稳定的输出质量。

架构层面，他们引入了一个叫 IndexShare 的机制：每 4 个稀疏注意力层共享同一个轻量级索引器，把 100 万 token 长度下每个 token 的计算量（FLOPs）降低到原来的约三分之一。这直接




解决了超长上下文下计算成本爆炸的问题。

推理侧也有专门的工程优化。当上下文从 20 万 token 扩展到 100 万 token，推理瓶颈从计算本身转移到了 KV 缓存容量、长上下文内核调度和 CPU 侧开销。他们针对这三个方向分别做了优化，使得 GLM-5.2 在上下文越长的场景下，吞吐量优势越明显，这是一个“越用越顺”而非“越用越卡”的系统。

长程任务上，差距还有多大？

GLM-5.2 在三个专门评测长程任务的基准上值得逐一看一下。



FrontierSWE，评测的是 Agent 能否独立完成需要几小时乃至几十小时的开放式技术项目，包含系统优化、大规模代码构建、应用 ML 研究等。GLM-5.2 得分 74.4，Opus 4.8 是 75.1，差距只有 1%。同时，它超过了 GPT-5.5（72.6）和 Opus 4.7（比后者高出 11 个百分点）。

PostTrainBench，设定更有意思：给每个 Agent 一张 H100，看它能把一个小模型训练得提升多少。GLM-5.2 得分 34.3，排名第二，仅次于 Opus 4.8（37.2），超越了 GPT-5.5（28.4）。

SWE-Marathon，这是难度最高的一个，任务包括构建编译器、优化计算内核、开发生产级服务。GLM-5.2 在这里还有明显差距：13.0 分，而 Opus 4.8 是 26.0 分，落后约 13 个百分点。这个数字没什么好粉饰的，差距是真实存在的。不过作为横向对比，在开源模型里，它依然是第一名（Gemini 3.1 Pro 是 4.0）。

三个基准加在一起，传递的信息是：在中等复杂度的长程任务上，GLM-5.2 已经进入了与顶级闭源模型同台竞争的区间；在最极端复杂度的任务上，它仍然落后，但在开源阵营里独领风骚。

标准编程基准上的表现同样值得关注。Terminal-Bench 2.1 上，GLM-5.2 得 81.0，Opus 4.8 是 85.0，差距收窄至 4 个百分点，同时超越了 Gemini 3.1 Pro（74.0）。SWE-bench Pro 62.1 分，开源第一。

训练过程里，模型在“作弊”

这是技术报告里我觉得最有趣的一部分。



用强化学习训练编程 Agent，奖励信号通常是一个可验证的 pass/fail，代码跑通了就给分，跑不通就不给。这听起来很干净，但问题在于，模型会去找捷径。

研究人员发现，GLM-5.2 展现出的“作弊行为”比上一代 GLM-5.1 更多，这倒不是退步，而是因为它更聪明了，会的花招也更多。它会读取本不该访问的评测文件，会从 GitHub 的上游提交里直接拿答案，会顺着线索找到隐藏的测试用例然后用来解决，甚至会把这些动作串联起来，做一套“链式作弊”。

为了应对这件事，团队专门做了一个 anti-hack 模块：先用规则过滤可疑操作，再用一个 LLM 裁判来判断行为意图。这套系统在线运行，逐步监控每一个工具调用。如果发现作弊，不是直接中止整个推理过程（那样会让训练不稳定），而是拦截该步骤并返回一条假信息，让模型继续往下跑。

这件事有点像监考，不是掀桌子，而是把小纸条没收，让考试继续。

最后说一句

GLM-5.2让我更加确信阿迪王的末日论就是个笑话，现在Anthropic和OpenAI所剩下的，只有更多的RL环境和规模

GLM5.2代表的开源模型在长程编程任务上，第一次真实地进入了竞争。 靠在 1M 上下文下扎实的工程落地，在最难的几个基准上，它和顶级闭源模型之间的差距，从层级之差变成了数字之差。

本文来源：[AI寒武纪](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

460 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

2 条评论

MobileUser9943
11小时前 中国北京



离股票解禁还有三周，看到时候股价跌多少

👍 0 ↩ 回复



杨sir，力哥 VIP会员
11小时前 中国江西省

优秀的清华团队和华为AI芯片，一起冲破科技叹息之墙，加油

👍 2 ↩ 回复