摘要：

OpenAI 意外泄露 GPT-5.4！新版凭200万Tokens的上下文窗口与“状态化 AI”实现跨会话持久记忆，并支持全分辨率视觉直读。GPT将从聊天工具向“全自动代理”进化，彻底重塑工作流并引爆底层硬件内存之战。

近日，OpenAI 的一名工程师在 Codex 的公开 GitHub 仓库中提交了一次代码拉取请求，无意间将「gpt-5.4」这个尚未公布的型号写进了版本判断条件中。

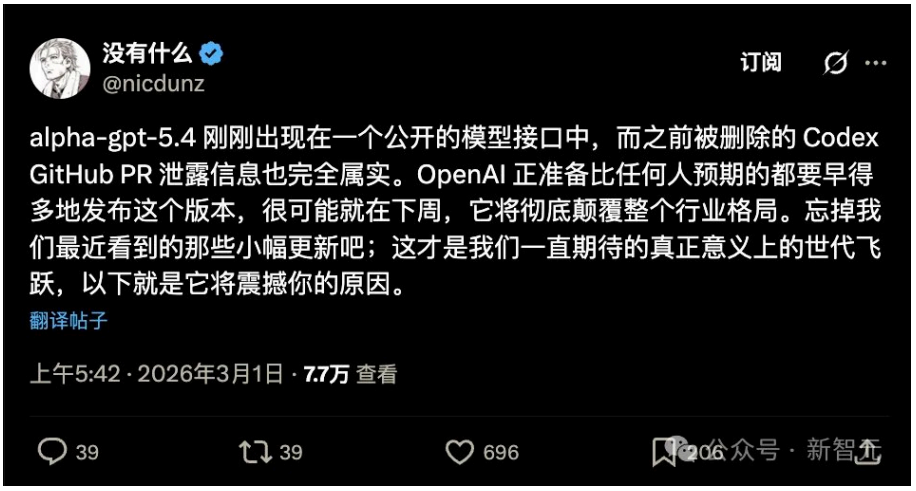

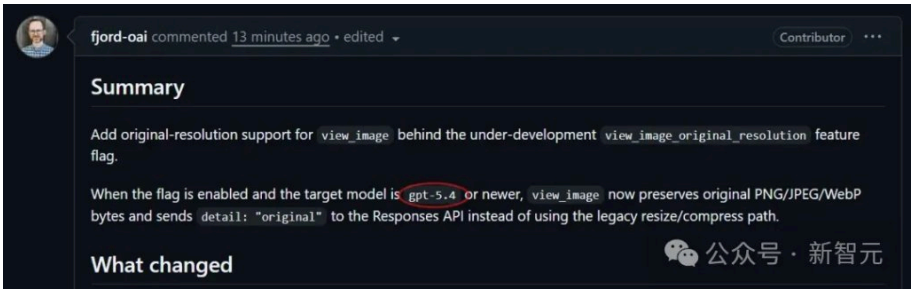

几乎在同一时间，带有「alpha-gpt-5.4」标识的公共模型端点以及下拉菜单截图在社交平台X上疯狂流传。

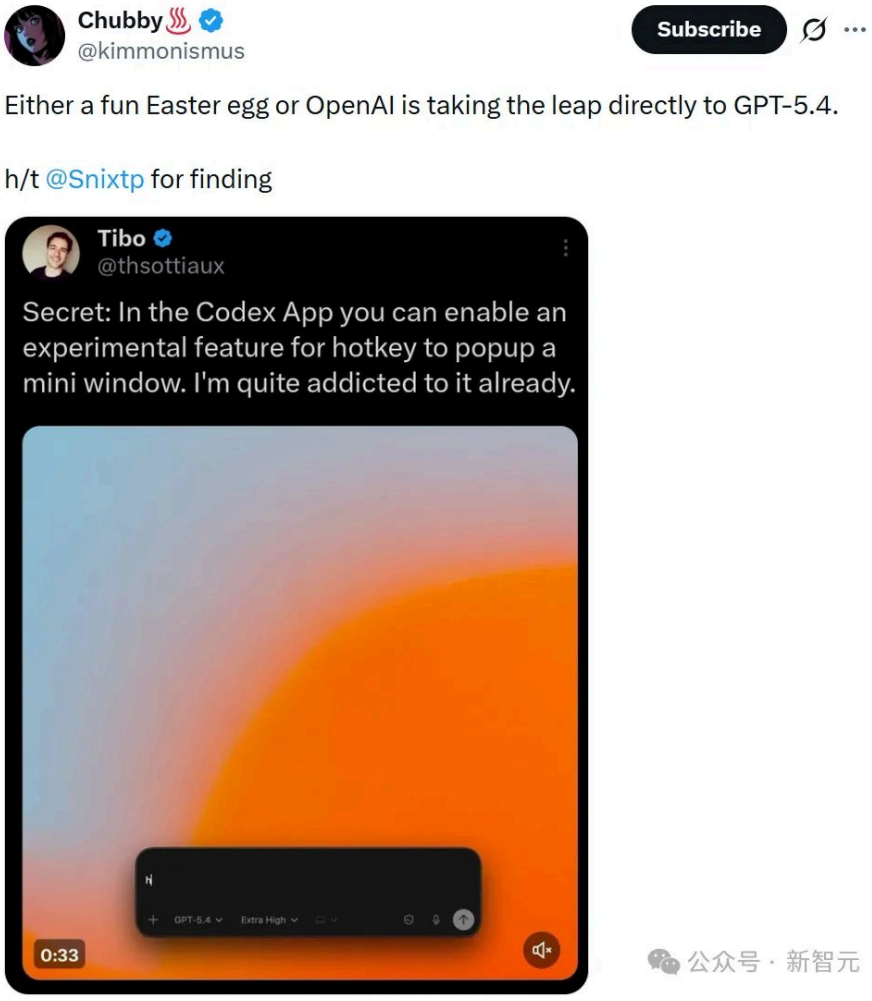

随后发生的事情极为戏剧化，这些信息仿佛触动了某种内部警报，原帖被火速删除，涉事代码也被强制推送覆盖，悄悄改成了「gpt-5.3-codex」。

这种欲盖弥彰的撤回操作，恰恰打消了外界对「占位符误用」的怀疑，让看客们对新版本提前泄露的猜测可信度更高了。

种种迹象表明，OpenAI 正准备跳过 5.3 版本，酝酿一场足以重置行业格局的突袭。

坊间传闻，这次代际跨越最快将在下周落地。

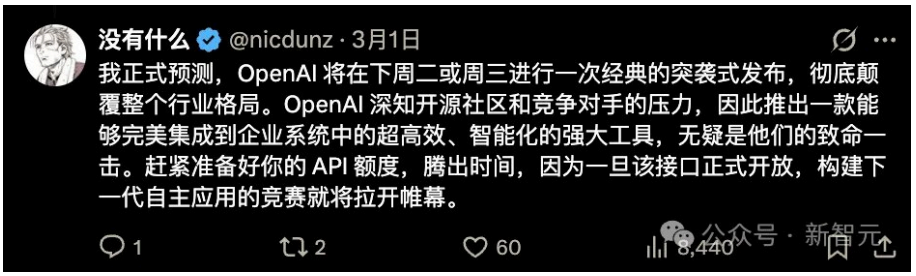

它试图终结近期大模型领域挤牙膏式的常规更新，直接向对手甩出一张王牌。

结合目前浮出水面的多方情报，这次大版本的核心杀手锏已经呼之欲出。

它抛弃了在常规推理基准测试里与同行近身肉搏的路线，将主战场转移到了内存与上下文架构上。

高达 200 万 Tokens 的上下文窗口配上真正的状态化 AI（Stateful AI），让模型从此摆脱了「金鱼般的记忆」。

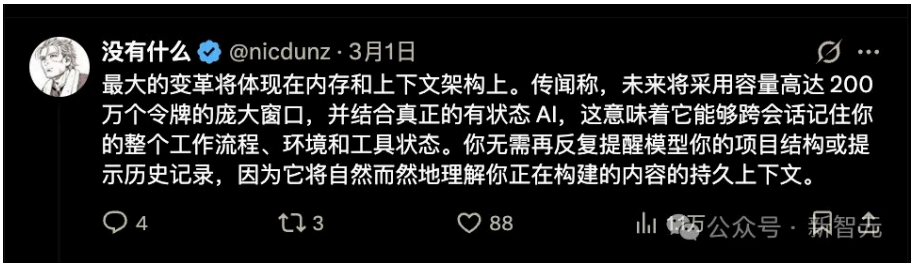

它能够在不同的会话之间，完整保留你的工作流、开发环境乃至工具调用状态。

打工人终于不用在每次新建对话时，像复读机一样重新交代冗长的项目背景。

模型会自带这种持久的认知连续性，真正融入用户的日常开发节奏中。

视觉能力的暗中大跃进同样令开发者振奋。

泄露信息中明确提到了一个专门针对「gpt-5.4 及更高版本」的功能开关，**该功能允许模型绕过传统的图像压缩机制，直接读取全分辨率的原始字节。**

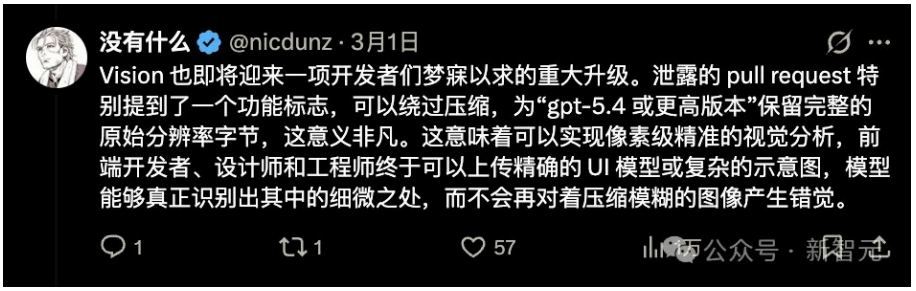

这意味着，前端工程师和设计师可以直接丢给它极其精细的 UI 设计图或复杂的工程原理图，彻底告别过去 AI 对着模糊压缩包一本正经胡说八道的体验，实现像素级的视觉分析。

当 Gemini 3.1 Pro 和 Claude 4.6 还在各项跑分榜单上争夺小数点后几位的优势时，**GPT-5.4 的野心在于完成从「聊天机器人」到「全自动代理员工」的身份转换。**

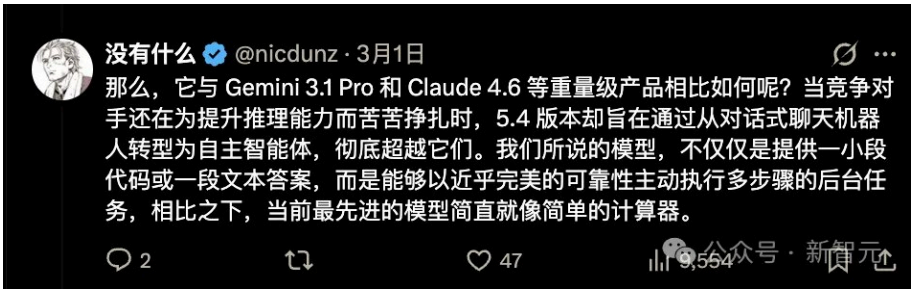

它能在后台高度可靠地执行多步复杂任务，把那些号称最先进的竞品衬托得像个带有对话框的高级计算器。

当然，这种级别的上下文和状态保持，也直接点燃了硬件层面的「内存之战」。

海量 KV 缓存的爆炸式增长，让高带宽内存和 SRAM 的调配面临极限挑战，光学互连技术的引入也从理论构想变为了现实需求。

OpenAI 显然已经在底层算力架构上做好了迎接这场风暴的准备。

本文来源：新智元

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时0元领
* 同一用户免费领取一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取
限免

104 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

1 条评论

见闻用户
14小时前 中国北京

快点吧，deepseek4就等你上后，再打你脸了！

3 回复