

摘要：

GPT-6 Astra重新点燃AI算力增长预期，Computer Use让Agent从程序员进一步扩展至更广泛的知识工作，使一个用户背后可以同时运行多个Agent。模型效率越高、任务成功率越高，人们就越愿意把更多、更长、更复杂的工作交给AI，最终推动AI使用量和总算力消耗持续增长。

9月3日GPT-6 Astra发布后，半导体和内存股率先反弹。9月4日，SOXX单日上涨3.5%，Micron涨6.1%，SanDisk涨11.9%；9月7日，韩国KOSPI上涨4.61%，Samsung Electronics涨5.7%，SK hynix涨约8%。

在此之前，市场对AI资本开支过热、算力需求见顶的担忧，已经让相关板块震荡了相当长一段时间。MarketWatch甚至直接把这一次上涨形容为，Astra“重新点燃了memory-chip trade”。

《The Nvidia Way》作者、前Barron's科技记者Tae Kim给出了一个更激进的解释：**AI可能正在迎来过去四年里的第四轮指数级算力需求增长。**

前三轮分别来自Chatbot、Reasoning和Coding Agent，第四轮有可能是Astra这次重点展示的Computer Use。Kim的逻辑是：Chatbot让数亿人开始消耗推理算力，Reasoning让每一次回答需要更多计算，Coding Agent又让模型从“回答一次”变成连续工作几十分钟甚至数小时。现在，Computer Use把持续运行的Agent从程序员扩展到Excel、Blender、CAD、Power BI和浏览器里的普通知识工作。

Kim长期关注Nvidia和半导体投资，他创办的Newsletter Key Context本身就科技投资判断为核心，近期文章也长期偏多AI基础设施。

因此，“第四轮指数增长”首先是一个**AI算力多头提出的投资假设**，并不是已经被验证的产业规律。但它出现的时间点很微妙。

Astra发布前，Agent范式刚刚经历了一轮“能力撞墙”的怀疑：短任务越来越强，一旦进入长程、多步骤和真实软件环境，可靠性还是明显下降，从而也传导到了开头所提到的算力见顶的质疑。Agent的能力天花板打不开了，算力继续增长的故事就讲不通了。

Astra真的能掀开这个天花板吗？

每1个人类工作日已经对应3.1个Agent工作日

AI算力前三轮“指数增长”，指的是过去几年AI每改变一次使用范式，一个用户能够消耗的计算量都明显上了一个台阶。


ChatGPT让推理第一次进入大众市场；Reasoning（推理）模型开始愿意为了一个问题进行更长时间的内部计算；到了Coding Agent，一个简单指令背后可以触发读代码、修改、测试、检查错误和再次修改的连续循环。

同时，Agent已经开始突破“一个人一天只能工作8小时”的物理限制。

OpenAI 9月6日刚刚披露了一组内部数据。到今年8月中旬，公司研究人员中，使用量位于50分位的，每人每天使用Coding Agent所对应的推理量，按公开API价格折算已经超过**600美元**；使



用量位于90分位的研究员每天超过**7000美元**。而据Business Insider根据OpenAI数据整理，7月中位值还只有约162美元，相当于一个多月增长了近3.7倍。



图：截至8月中旬，OpenAI研究部门每1个人类工作日已经对应3.1个Agent工作日；中位研究员每天使用的Agent推理量按API价格折算超过600美元

这是把内部使用量按照API价格折算，意义更接近“单用户推理强度”。

6月之前，OpenAI研究部门所有Agent的运行时间加起来，还没有超过研究人员自己的工作时间；到了8月中旬，**每1个人类工作日已经对应3.1个Agent工作日**。越来越多研究人员还会同时运行多个Agent。

这意味着，Agent范式之后，一个用户背后开始出现多个可以并行工作的“数字进程”，它不再受“人的输入速度”的物理限制。现在一个人可以让三四个Agent持续工作，甚至让Agent再创建sub-agent。

算力需求的计量单位，也可能因此变成：**一个用户背后同时运行多少个Agent，以及这些Agent每天工作多少小时**。

Computer Use拓展了工作空间

Coding Agent虽然增长很快，但它仍然有一个明显边界，大部分运行多个Agent任务的，都还是程序员群体，而程序员只是全球知识工作者的一小部分。

Computer Use把空间拓展得更大了。Astra发布后，Kim自己做了一个测试。他此前不会用Blender，于是让Astra在一台Mac上研究航天飞机、打开Blender并完成3D建模。大约10分钟后，一个可以旋转查看的模型被做出来。

普通对话大致是“输入—推理—输出”；Coding Agent变成“读代码—推理—修改—测试—再推理”；Computer Use进一步变成“看屏幕—理解界面—决定操作—执行—等待结果—重新观察—验证—纠错”。

一个人类十分钟完成的任务，AI背后可能经历几十轮视觉理解、推理和工具调用。

而一旦这套能力从浏览器和代码编辑器进入Excel、Salesforce、SAP、Power BI、Photoshop、CAD和各种企业内部系统，潜在用户就扩大成为几乎所有坐在电脑前工作的知识劳动者。

这就是Kim所谓“第四轮需求”的核心：

Coding Agent想吃掉程序员的电脑时间，Computer Use想吃掉所有白领的电脑时间。

但到目前为止，这仍然只是可能性。

OpenAI没有公布Astra发布后的Computer Use任务量，也没有公布单用户每天Token、GPU利用率或推理吞吐量的日级曲线。因此还不能板上钉钉地证明“Astra已经带来了第四轮算力增长”。

算力真的已经开始吃紧了吗？

Astra发布之后，腾讯科技注意到，一些开发者社区出现了一个很难量化、但值得注意的反馈：不同地区和不同账号的使用体验似乎开始出现差异。

部分亚太开发者反映，近期ChatGPT和Codex响应变慢，复杂任务的稳定性也不像美区账号。社区习惯于把这种体验直接称为“降智”。

至少其中一部分并非完全是主观感受。

9月4日，OpenAI官方状态页曾单独报告亚太地区服务出现性能下降，影响包括ChatGPT、Work、Codex Cloud等多个产品。四天之后，OpenAI又宣布与Nvidia支持的数据中心运营商Firmus达成多年协议，将从马来西亚两座数据中心获得专用计算能力。

OpenAI

Subscribe to updates

< Users in APAC region may face increased error in ChatGPT, Work, image generation, file upload, Voice, and Codex Cloud

Resolved · Degraded performance

All impacted services have now fully recovered.

Fri, Sep 4, 2026, 06:46 PM (3 days ago) · View all updates

同样，目前也没有证据证明OpenAI因为Astra负载上升，对亚太用户降低了模型推理预算或者切换了更弱模型。

所谓“亚太降智”，至少还可能混杂三种不同因素：区域基础设施和路由问题、账号级风控和速率限制，以及高峰期动态资源调度。它们在用户端都可能表现为更慢、更容易失败、工具调用中断，甚至让复杂任务最终答案变差。

但这些反馈仍然提供了另一种观察AI算力压力的方法。


当模型越来越能持续消耗计算时，供给吃紧可能先表现为不同地区、不同账号之间延迟、失败率和服务质量开始出现波动。

问题是，这个判断目前仍然缺一组最关键的数据：

同一模型、同一套餐、同一任务，在不同区域的首Token延迟、总推理时间、工具成功率和最终任务完成率到底有没有稳定差异。

在拿到这些数据以前，“降智”只能是线索，不能成为算力紧张的证据。





图：9月8日，有用户晒出GPT-6 Astra“容量已满”的提示，并称自己的4个账号均无法正常使用，系统建议切换其他模型。Tibo转发时调侃称“we are so back（我们又回来了）”，把“模型满载”视为AI需求重新升温的信号。

资本市场又开始下注了

虽然Astra发布后的真实算力使用曲线还没有公开，资本市场已经提前交易了“AI需求还没有见顶”这个故事。

MarketWatch统计，Astra发布后，iShares Semiconductor ETF一度上涨约**3.5%**，Samsung、SK hynix、Kioxia等内存相关公司表现更强。外媒报道甚至直接把这轮行情描述为Astra“**重新点燃了memory-chip trade**”。

值得注意的是，这轮上涨最醒目的不是Nvidia，又是内存。

Computer Use如果真的成为持续运行的Agent工作负载，需要增加的也不仅仅是GPU计算。更长上下文、KV Cache、并发Agent、虚拟机、浏览器和软件环境，都可能继续推高HBM、DRAM、CPU、网络和存储需求。

所以资本市场最近交易的并不完全是“GPT-6更强大了”，主要逻辑仍然是：**一个更聪明的模型，会不会让用户愿意购买更多计算。**

这也是这一轮AI基础设施故事与传统软件最大的不同。



传统软件越优化，同一用户需要的服务器资源可能越少。

生成式AI却可能出现相反的“杰文斯悖论”：**模型效率越高、任务成功率越高，人就越愿意把更多、更长、更复杂的工作交给AI，最终总算力消耗反而继续增加。**

但需要警惕的是，资本市场同样有自己的“屁股”。

AI基础设施在此之前已经经历了一轮大涨和调整，半导体股票今年也曾因资本开支过热、云厂商自由现金流下降而出现明显回撤。因此Astra带来的几天反弹，只能说明投资者重新开始下注，还不足以证明第四轮算力需求真的已经出现。

一笔经济账

Kim的判断最终要成立，还是取决于三个更现实的问题。

第一个仍然是可靠性。

真实企业工作不是一次Demo。一个Agent能不能连续几小时操作ERP、财务模型或者工程软件，并在中途出现弹窗、权限变化和数据更新时仍然保持正确，是完全不同的问题。

第二个是成本。

未来Computer Use完成一小时人类电脑前的等效工作，到底需要花多少钱？

如果AI用10美元完成一名员工50美元的工作，需求很容易爆发；如果需要100美元，市场空间就完全不同。

OpenAI内部600美元/天的数据既说明Agent能够制造巨大需求，也侧面说明，今天这种工作方式仍然可能非常昂贵。

第三个问题：Computer Use会不会最终把自己的一部分需求消灭掉？

现在模型需要看屏幕、找按钮，是因为现有软件是给人设计的。一旦Salesforce、Microsoft、Adobe或者企业内部系统开始直接开放API、MCP和Agent接口，大量任务完全没有必要继续模拟鼠标和键盘。

最终更可能出现的形态，是Computer Use和Tool Use融合：有结构化接口的地方直接调用，没有接口、难以改造的旧系统和开放网页，则继续靠视觉操作。

所以Computer Use真正打开的市场，未必是“让AI永远像人一样点击电脑”，而是通过这种“我的主人授权让我点你的软件，所以你管不着”的方式，让Agent强硬突破现有的应用生态格局。Agent终于可以进入此前自动化无法覆盖的最后一大片工作环境。

这也是Kim所谓“第四轮指数增长”真正值得验证的部分，“Computer Use是敲门砖，还是真的又一次范式改变”？

GPT-6之后，那个一度因为Agent撞墙而变得越来越难讲的算力故事，是不是又重新讲得通了？

资本市场又开始下注。



生成式AI爆发之后，市场在持续打脸“算力增长”的空头，这次会不一样吗？

本文来源：[腾讯科技](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 限时权益申领

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 184  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论