

摘要：

Harness优势，足以抵消模型智能的差距。拿了第一名的，是阿里的千问办公，尽管它背后的模型智能分只排到第四；模型能力第一的Claude Opus 5，它的Agent产品Claude Cowork拿了第二；另一个反直觉的结果是，最近大火的Workbuddy，这轮测试中隐含的Harness分在中国Agent里反而垫底。

华尔街投行杰富瑞的分析师，最近给市面上八个主流中美AI Agent做了一场实测，看谁真正能把活干好。

结果有点出乎意料：**拿了第一名的，是阿里的千问办公，尽管它背后的模型智能分只排到第四**；模型能力第一的Claude Opus 5，它的Agent产品Claude Cowork拿了第二；另一个反直觉的结果是，最近大火的Workbuddy，这轮测试中隐含的Harness分在中国Agent里反而垫底。

杰富瑞的核心结论，用一句话概括：**决定一个AI Agent好不好用，往往不是背后那个模型，Harness做得好是可以弥补模型智能差距的。**

Harness是什么：Agent里除了模型，剩下的都是它

一个AI Agent干活的流程，可以拆成两半：一半是模型，负责“想”；另一半是harness，负责“管”。

杰富瑞把harness拆成了六层，每一层管的都是模型自己管不了的事：

- **指令**：告诉Agent这个活是什么，红线在哪
- **上下文**：Agent干活时能看到的背景信息
- **工具**：Agent能用什么去完成这个任务
- **边界**：Agent能行动的范围划在哪
- **反馈**：告诉Agent哪里做错了，让它自己纠正、重新规划
- **治理**：让组织能管住一整批Agent

这六层，正好对应了雇一个员工之后，公司要做的那些事——交代任务、给信息、给工具、划权限、给反馈、做管理。模型就是那个新来的聪明人，harness就是这套管理机制。聪明人再厉害，扔进一个没有管理的公司，也干不好活。

来看一组控制变量的证据——模型不动，只换harness，看Agent表现怎么变。

结果：同一个Claude Opus 4.6，套上不同的harness，在Terminal-Bench 2.0这个基准上，得分从58.0%一路到76.4%，最高最低差了18.4个百分点。Gemini 3 Pro同样只换harness，得分从



56.0%到69.4%，差13.4个百分点。

实测八个中美Agent

这次实测，杰富瑞挑了八个中美Agent。美国三个：Anthropic的Claude Cowork、OpenAI的Codex、谷歌的Gemini Spark。中国五个：腾讯的Workbuddy、阿里的千问办公、字节的豆包、月之暗面的Kimi Work、MiniMax的Code。

考卷是五项任务，每一项对应企业里真实存在的一类活。

第一项，多文件检索。丢给Agent一堆文件，让它写一份金蝶软件2025年报的一页摘要，覆盖营收、增长、毛利率、净利润、2026年指引、AI进展。要求很严：每条事实必须标明来自哪个文件；不同文件数字打架，必须指出冲突、说明哪个更可信；不许悄悄把矛盾数字抹平。

第二项，自主联网研究。让它上网比较微软、Meta、谷歌三家最近季度的营收增速，以及2026年的资本开支指引。必须用一手来源，产出一张表，还要明确区分哪些是官方报的数字，哪些是自己估算的。

第三项，控制浏览器。让它用真实的桌面浏览器，从OpenAI官网一路点到新闻页，找出最新一篇文章，读完全文，生成一个Word文件，含标题、日期、分类、链接、150到200字摘要和三条要点。不许用API或爬虫抄近路，必须真的用浏览器点进去。

第四项，做PPT。给它一份文件，做5页英文PPT，要有故事线，第一页要用文件数据画图，不许编造数据。

第五项，生成营销海报。给它一张鞋的照片做参考，为虚构篮球鞋品牌做原创海报，去掉所有Nike、Jordan的logo，不抄商标口号，3:4竖版，适合发小红书。

这五项，从读文件、查资料、操作软件、做PPT到作图，几乎覆盖了企业里最常见的几类工作。

打分方式也讲究。每项任务拆成5个维度，维度跟着任务走，不是通用模板，每个维度0到20分，一项满分100，五项平均得出总分。

测试	五个维度
多文件检索	事实准确性、覆盖度、引用准确性、矛盾检测、相关性

结果：模型最弱的，拿了第一

前三名分别是：千问办公95分，Claude Cowork 94分，Codex 92分。接下来依次是Kimi Work 86分，豆包77分、MiniMax Code 71分，Workbuddy和谷歌的Gemini Spark并列垫底，都是66分。



值得一提的是千问办公的“逆袭”。它背后的模型Qwen 3.8 Max，智能分只有56。而Claude Cowork背后是Claude Opus 5，61分；Codex背后是GPT-5.6 Sol，59分。模型差着五六分，Agent总分反而高出一两分。

这也说明，Harness优势，足以抵消模型智能的差距。

为了验证这一点，杰富瑞做了一个拆解：把Agent能力分成模型和Harness两块，给模型60%权重、Harness 40%权重，用Agent总分反推出每个产品的“隐含Harness分”。结果千问办公的Harness分最高，超过了美国的Claude Cowork和Codex。

实测还发现了一些中美Agent的能力差异。

第五项营销海报，是美国Agent的滑铁卢。Claude Cowork和Gemini Spark都在这里翻车，而千问办公和豆包这类中国Agent做得更好。

第二项控制浏览器，是中国Agent的弱点。Workbuddy和MiniMax Code在这里栽了跟头，美国三家的表现更稳。

速度上也有差异。美国那边，Gemini Spark最快，Codex次之，Claude Cowork最慢。中国这边，Workbuddy最快，豆包和MiniMax相当，Kimi Work和千问办公偏慢。另外，Claude Cowork的“品味”最好，PPT排版和配色最讲究，但这个归功于模型能力，跟Harness无关。

价格是另一重碾压。千问办公背后的Qwen 3.8 Max，API价格每百万token约1.1美元；GPT-5.6 Sol是4.4美元，Opus 5是3.9美元。

Workbuddy的错位

报告里另一个值得细看的对象，是腾讯的Workbuddy。

它的数据很漂亮：6月月访问量约2100万，中国同类Agent里排第一。但在这份实测里，Workbuddy的隐含Harness分，在中国Agent里垫底。

访问量第一，Harness垫底，这个错位怎么解释？

杰富瑞给了三个原因。

第一，Workbuddy深度嵌在腾讯自家的生态里，腾讯文档、IMA、企业微信，入口都在手上。

第二，它走的是模型无关的路线，用户可以在harness里随意切换Kimi K3、DeepSeek V4、GLM 5.2这些开源模型，用别人的强模型补自己的短板。

第三，腾讯的营销投入很猛。

这三条，跟Harness工程做得好不好，没有直接关系。

报告的判断是：短期看，Workbuddy赢在入口和分发；长期看，2100万的用户基础会沉淀出海量真实使用数据，这些数据反过来能帮腾讯改进Harness，甚至训练自己的模型。

在中国市场这个阶段，分发能力暂时跑在了Harness工程前面。但决定一个Agent最终能走多远的，还是Harness。

中国在Harness上有优势，也有绕不开的短板

报告把中国和美国的Harness打法做了个对比：中国在几个结构性的地方领先，但也有几块短板压着。

先说优势，四个。

超级App集成。 美国Agent接工具，一般靠connector去连。中国不一样，很多Agent直接嵌在企微、飞书、钉钉这些平台里，数据、分发、变现一条线全打通。这是中国厂商独有的地基。

模型无关的Harness。 腾讯Workbuddy、字节Trae走的都是这条路——harness自己不带模型，用户按任务的难度、延迟、成本随便切换Kimi K3、DeepSeek V4、GLM 5.2这些第三方模型。用别人的强模型，补自己的短板。

低token价格。 出口管制逼着中国实验室走高效的MoE架构和推理优化，加上国内竞争卷得厉害，中国模型的token价格平均比美国低70%到80%。token便宜，那些消耗大量推理的agent工作流才跑得起，这也加快了企业采纳。

迭代速度快。 Hrness的质量，是靠真实场景里一次次失败试出来的。中国厂商用户量大、碰到的失败案例多，迭代反而更快。

再说短板，也有四个。

模型差距还在。 Harness-Bench的数据显示，强模型的平均分更高、跨Harness的方差更小；弱模型更依赖Harness。中国模型整体还落后美国，得靠更出色的Harness才能把Agent能力顶上去。

产品定价低。 中国企业软件市场一向变现难，中小企业对价格敏感，大型央企又偏爱定制项目、不太认订阅制。这拖累的不只是利润，还有持续投入Harness工程的动力。

出海难。 Workbuddy、Qoder在国内用户涨得快，但要把这套成功复制到海外很难——中国Agent是为本地生态和用户习惯优化的，而美国的Harness受益于全球标准化的软件栈。

算力瓶颈。 Agent工作流对推理算力的消耗，比普通对话高得多。中国厂商高端算力短缺，可能导致服务不稳定，也反过来限制变现能力。

Harness为什么越来越重要



最后再提一嘴Harness的价值，主要是三个方面：

粘性。 模型能力越来越趋同，但harness不一样。客户的工作习惯、对话历史、记忆、连接器、技能、自动化，全都沉淀在harness里。用得越久，换走的成本越高。模型可以随时换，harness是换不掉的。

数据飞轮。 每一次Agent运行，都会产生一条trace——调了什么工具、什么失败了、人怎么纠正的。这些数据能喂给下一代的强化学习，也能用来改进harness本身。用户越多，数据越多，Agent越好，用户更多。这是一个正循环。

付费意愿。 报告点破了一件事：企业和消费者买的不是“智能”，他们自己没有开发应用的能力。他们买的是“harness + 模型”打包好的完整Agent产品。这也是为什么Claude Code、Claude Cowork、Workbuddy这类产品用户增长快——客户为harness付钱，模型只是顺带。

而对于一家公司来说，AI落地的关键在工程层，不在模型层。真正的机会在“把harness做好”这件事上——管好指令、上下文、工具、边界、反馈、治理这六件事，比追最强的模型更可能做出落地的东西。

本文来自微信公众号「[AI原生Lab](#)」，持续拆解真实AI落地案例，分享企业AI实践与方法论。



风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 6 ★ 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论