

HBM容量限制浮現 記憶體卸載重塑地端AI訓練伺服器供應鏈價值

2026/07/31-伺服器- 鍾易良



DIGITIMES觀察，GPU算力成長速度與HBM容量擴充速度呈現落差，地端模型訓練在特定情況下，將面臨記憶體不足情形。透過軟體資源池化或卸載記憶體等方法，可在不大幅增加GPU數量情形下，增加模型訓練時所需記憶體，進而降低地端AI訓練門檻，提高企業導入模型訓練的意願。

大型模型訓練的記憶體需求通常高於權重本身，部分高記憶體需求的工作負載率先受到HBM容量限制，形成企業建置AI訓練平台時的系統層級挑戰。半導體、高階製造、金融、醫療及政府等均屬於這類有擴充地端AI訓練平台需求的領域。

當既有GPU算力足夠，但HBM容量不足時，若僅透過新增GPU取得更多記憶體，往往必須同步增加伺服器、網路、電力及散熱等整體系統成本，未必符合企業投資效益。在此情況下，市場開始出現不同的記憶體容量擴充路徑，在不大幅增加GPU數量的前提下，提高單機或系統可使用的記憶體容量，以因應模型訓練需求。

軟體資源池化、記憶體卸載及CXL為地端AI訓練的三種擴充記憶體方案，三種方案改善問題及適用情境並不相同，包括軟體資源池化著重提升多節點GPU利用率、記憶體卸載聚焦突破HBM容量限制，以及CXL則代表共享記憶體架構的長期演進方向。記憶體卸載技術的興起，將重塑地端AI伺服器的產業價值分配結構，控制晶片業者、企業級SSD供應商及具備系統整合與驗證能力的OEM廠，正迎來全新的市場切入點與高附加價值機會。

企業AI訓練需求漸起 資料治理與設備利用率決定地端投資效益

企業是否建置地端AI訓練平台，主要取決於資料治理需求、模型自主程度及訓練工作的持續性。敏感資料與自主模型需求提高地端部署必要性，但專案式負載亦可能降低GPU利用率，因此企業須同時衡量部署必要性、設備利用率與長期投資效益。

■ 資料治理與模型自主需求驅動地端AI訓練部署

一般AI應用可透過公有雲快速部署，當涉及核心製程、金融交易、醫療病歷、政府或國防資料時，企業則較傾向保留於地端，以兼顧資料安全、法規遵循及模型控制權。


因此，地端AI訓練需求主要集中於半導體、高階製造、金融、醫療及政府等高度資料治理產業領域。地端部署並非取代公有雲，而是承接因資料治理、法規遵循或模型自主需求而不適合移至公有雲的AI訓練工作。近年企業AI部署逐漸朝依工作負載特性選擇部署模式(Fit-for-Purpose)發展，資料治理需求亦成為地端部署的重要考量。

■ 地端AI訓練呈專案式負載 設備利用率決定長期投資效益

雲端服務供應商(Cloud Service Provider；CSP)可利用多租戶及大規模資源調度維持較高GPU利用率；企業地端訓練則多集中於模型首次建置、資料更新、模型微調及版本迭代等特定階段。由於企業通常僅在新資料累積、模型效能調整或業務需求變動時啟動集中訓練，因此GPU使用呈現階段性高峰；專案完成後，設備多數時間則用於推論、測試或維持待命狀態，難以維持長期高負載。

Ownership；ICU)及投資回收期。只有當訓練需求具持續性且設備維持一定利用率時，地端平台才較可能形成長期成本優勢。

AI訓練工作下CSP與企業GPU資源利用率示意



註：本圖以AI訓練工作負載為例，不包含推論工作負載。

資料來源：DIGITIMES，2026/7

因此，企業開始重新評估地端AI訓練平台的投資效益，並思考如何在既有 GPU 架構下提升記憶體資源配置效率。

GPU算力成長快於HBM容量擴充 高記憶體需求驅動企業重新思考容量擴充方式

近年GPU算力持續提升，但高頻寬記憶體(High Bandwidth Memory；HBM)容量擴充速度不若GPU算力成長速度，使高記憶體需求工作負載率先受到容量限制。相較於CSP可藉由大規模GPU叢集分散負載，企業受限於採購規模及資本支出，難以持續透過增加GPU取得更多HBM容量，因此開始評估既有GPU架構下的記憶體容量擴充路徑。

■ GPU算力成長快於HBM容量擴充 大型模型訓練率先受限

自2017年NVIDIA V100演進至最新Blackwell架構B200，GPU FP16 Dense核心算力由125 TFLOPS提升至2,250 TFLOPS，約成長18倍；HBM容量則由32 GB增至180 GB，約成長5.6倍。由於GPU算力增幅明顯高於HBM容量增幅，單位HBM記憶體需承擔的運算密度(FLOPS-to-Byte Ratio)亦由3.9提升至12.5，反映GPU算力與記憶體容量的成長速度逐漸失衡。


值得注意的是，NVIDIA於2024年推出H200時，在GPU Tensor Core規格與H100大致相同的情況下，主要將HBM容量由80 GB提升至141 GB。此一產品規畫顯示，在既有GPU架構下，HBM容量已逐漸成為大型模型訓練的重要設計考量。對於無法頻繁升級至最新GPU平台的地端企業而言，如何在既有GPU架構下提升可用記憶體容量，將成為大型模型訓練平台的重要評估方向。

大型模型訓練除權重(Weights)外，還需儲存梯度(Gradient)、優化器狀態(Optimizer State)及激活函數(Activation)，模型權重通常僅為訓練期間所需記憶體的一部分，梯度、優化器狀態及激活函數等中間資料亦需同步儲存在HBM，因此整體容量需求遠高於模型權重本身。當總需求超過GPU HBM，模型便無法完整載入或執行；一般推論及小模型則多可在既有架構下完成。

以70B模型採用FP16訓練為例，模型權重約需140 GB(70B×2 Bytes)記憶體。訓練過程需同步保存梯度，其容量通常與權重相當；若採用FP32儲存梯度則約為權重的2倍，因此約需140~280 GB。若採用Adam優化器，還需額外保存一階與二階動量，因此優化器狀態約280~560 GB；激活函數不具固定容量，其需求會隨模型深度、批

架構訓練大型模型，可能率先受到HBM容量限制。

近五代GPU FP16 Dense算力與HBM容量演進比較



註：1. H200主要提升HBM容量與頻寬，GPU Tensor Core規格與H100大致相同，因此FP16 Dense算力維持相近。

2.運算密度FLOPS-to-Byte Ratio等於FP16 Dense TFLOPS÷HBM容量(GB)。

資料來源：NVIDIA，DIGITIMES整理，2026/7

由於完整訓練所需記憶體通常遠高於單張GPU HBM容量，因此市場開始發展不同的外部記憶體容量擴充方案，以降低新增GPU的必要性。

70B模型完整訓練期間的記憶體需求結構(FP16訓練為例)



註：實際需求會隨模型架構、精度、序列長度與批次大小而變動。

資料來源：DIGITIMES，2026/7

增加GPU，可同步提高算力及HBM總容量，但也會增加伺服器、網路、電力及散熱支出。若企業主要缺口是記憶體容量，而非運算能力，持續增加GPU未必具成本效益。因此企業開始重新評估如何沿用既有GPU平台，以較低新增成本擴充可用記憶體容量，也促使市場逐步發展不同的記憶體容量擴充路徑。

三種記憶體擴充路徑改善不同瓶頸 設備條件與效能代價決定適用情境

企業若希望沿用既有GPU平台，目前主要可評估軟體資源池化、記憶體卸載及CXL記憶體擴充。三者改善的系統瓶頸不同，因此適用情境亦有所差異。

三種記憶體擴充路徑改善不同系統瓶頸


技術路徑	主要問題	擴充層級	主要代價
軟體資源池化	叢集GPU及記憶體利用不足	多節點叢集	網路同步與管理複雜度
記憶體卸載	單機GPU HBM不足	單機GPU伺服器	訓練時間增加
CXL記憶體池化	CPU側本地DRAM容量不足	平台與外部記憶體	AI訓練整合尚未成熟

資料來源：DIGITIMES，2026/7

軟體資源池化(如Nutanix AHV或MemVerge GPU Cluster Manager)本質上屬於叢集層級的資源排程與管理軟體，其透過叢集資源排程與工作負載管理，將多台伺服器間閒置的GPU與系統記憶體資源彈性配置給不同AI工作負載，以提高整體叢集設備利用率。

現有方案反映不同層級的資源調度能力，例如Nutanix的「AHV」平台搭配NVIDIA vGPU，可在既有HCI叢集中配置GPU至不同虛擬機，改善GPU與基礎設施資源利用率；MemVerge的「GPU Cluster Manager」則透過工作排程、GPU動態配置及工作負載暫停、恢復與遷移，提高叢集設備利用率。然而，上述方案改善的是叢集資源調度效率與工作負載配置能力，並未增加單張GPU可直接使用的HBM容量。當單一工作負載仍需完整載入單張GPU執行時，仍可能受到HBM容量限制。

AI叢集軟體資源池化之記憶體資源調度機制示意




資料來源：DIGITIMES，2026/7

■ 「記憶體卸載」以訓練時間換取單機容量 商業化方案已逐步形成

記憶體卸載透過資料分層管理機制，將訓練資料依使用時點配置於HBM、DRAM及SSD。立即使用的資料保留於HBM，較晚使用的資料則移至DRAM或SSD，並於GPU運算前預取。GPU完成目前批次運算後，再由控制器依序搬移下一批資料至HBM，以維持模型訓練流程持續進行。

記憶體卸載訓練流程示意




資料來源：DIGITIMES，2026/7

目前記憶體卸載已逐漸形成由儲存控制器、中介軟體、GPU平台及OEM系統整合所構成的商業交付鏈，其中，群聯電子aiDAPTIV+為目前較具代表性的商品化案例。儲存方案業者提供控制器、SSD及中介軟體(Middleware)，GPU平台提供驅動與訓練框架環境，OEM或系統整合業者則負責PCIe配置、韌體、散熱及工作負載驗證。

記憶體卸載可讓模型容量超過HBM，但外部記憶體的頻寬與延遲仍不如HBM。若資料無法及時搬回GPU，GPU必須等待資料搬移完成後才能繼續運算，導致訓練時間增加，而實際效能折損取決於模型架構、卸載資料類型、PCIe頻寬、SSD效能及排程效率。

高頻率訓練、低延遲或大量資料長時間駐留於HBM，則且接增GPU 資源仍可能是較適合的選項。

記憶體卸載資料存取流程及對訓練時間的影響



資料來源：DIGITIMES，2026/7

■ CXL擴充CPU側外部容量 導入成熟度仍待提升

CXL利用PCIe實體層連接處理器與外部記憶體設備，使伺服器可在本地DRAM外，增加可定址容量。Intel Xeon及AMD EPYC等CPU平台已支援CXL記憶體設備，Astera Labs等業者提供控制器，MemVerge等軟體則支援本地DRAM與CXL記憶體分層。相較於HBM容量受GPU封裝限制，CXL可提升CPU側可定址記憶體容量，增加大型資料集管理彈性，並為未來共享記憶體架構奠定基礎。

但目前CXL的案例主要集中於CPU側記憶體擴充、分層及部分AI推論。GPU、作業系統、CXL記憶體解耦(Memory Disaggregation)與自動化動態分層排程的原生支援、PyTorch及DeepSpeed等主流訓練框架與整機平台尚未形成企業可直接部署的完整AI訓練方案。

CXL硬體生態正逐步建立，但仍屬中長期架構選項，目前CXL已具備硬體平台基礎，但GPU AI訓練軟體生態及整機驗證仍持續發展中。

■ CXL擴充CPU側外部容量 導入成熟度仍待提升

三種記憶體擴充方案皆以提升AI訓練平台可使用的記憶體資源為目標，但改善問題及適用情境並不相同。軟體資源池化著重提升多節點GPU利用率，記憶體卸載聚焦突破HBM容量限制，CXL則代表共享記憶體架構的長期演進方向。

已建置多節點叢集者，可優先提高既有資源利用率，單機HBM不足、但可接受訓練時間增加者，可評估記憶體卸載，而CXL則適合納入中長期平台規畫。

三種記憶體擴充方案主要差異

比較項目	軟體資源池化	記憶體池化	CXL記憶體
改善瓶頸	叢集利用率	單機HBM容量	CPU側外部容量
擴充層級	Cluster	Single Server	Platform
代表案例	Nutanix NVIDIA vGPU	群聯電子 aiDAPTIV+	英特爾、超微 CXL平台
主要代價	管理複雜度較高	訓練時間增加	生態與成熟度不足
近期成熟度	高	中高	中低
適用條件	已建GPU叢集	HBM不足且可容忍速度折損	中長期平台導入

資料來源：DIGITIMES，2026/7

記憶體卸載商業化帶動多方協作 導入模式將重新分配供應鏈價值

隨著記憶體卸載方案逐步商品化，企業導入AI訓練平台的方式，也由單純採購GPU，轉向評估完整平台整合、驗證及交付能力，進而帶動地端AI訓練伺服器供應鏈價值重新分配。

記憶體卸載由控制器、企業級SSD、中介軟體及系統驗證共同組成。以群聯電子aiDAPTIV+為例，儲存業者提供容量擴充方案，OEM或系統整合業者則負責硬體配置、相容性及工作負載驗證，使方案能在特定GPU平台部署。因此，儲存業者掌握控制器與資料管理能力，系統業者則透過平台整合及交付取得價值，兩者並非競爭同一環節。

由於記憶體卸載涉及控制器、SSD、GPU驅動、PCIe配置及工作負載驗證，單一業者難以獨立完成交付，因此方案商須透過OEM或系統整合商完成平台驗證，才能降低企業導入風險。

記憶體卸載生態系



資料來源：DIGITIMES，2026/7

■ 企業是否採用記憶體卸載方案 決定SSD生態新增價值

記憶體卸載可利用DRAM或SSD作為外部容量層，但現階段商品化方案多以企業級SSD作為容量媒介，並搭配控制器及資料管理軟體完成資料搬移與管理，因此，目前新增商業價值主要集中於SSD、控制器及相關軟體，而非DRAM元件本身。

企業級SSD可承接部分訓練資料，但並不取代HBM。只有當控制器與軟體能降低資料搬移造成的GPU等待，使整體訓練成本低於新增GPU資源的成本，企業級SSD搭配控制器及資料管理軟體後，才具備AI訓練容量層的商業價值。因此，企業級SSD的新增價值並非來自容量本身，而是在控制器、資料管理軟體及GPU平台協同運作下，於可接受的訓練時間內降低企業容量取得成本。

■ 企業導入模式不同 系統整合角色隨之改變

企業可在既有伺服器加裝記憶體卸載方案，延後新增GPU採購，亦可採購由OEM預先完成配置、驗證及交付的新機。

伺服器購買後，安裝的模式主要增加方案商與SSD業者收入，也可能延後企業升級或採購新伺服器；購買前，安裝模式則可為OEM帶來整合、驗證及售後服務收入。因此，OEM並非必然受益，其利益取決於方案最終採取既有設備後裝或新機預整合交付；然系統整合價值也並非來自單一硬體，而是來自平台驗證、部署效率及降低企業導入風險的能力。

企業導入模式影響方案交付方式



資料來源：DIGITIMES，2026/7

因此，記憶體卸載商業化並非改變GPU的核心地位，而是使AI訓練平台的新增價值由單一硬體規格，延伸至控制器、資料管理軟體、平台整合及系統驗證等能力。

結語

GPU算力成長快於HBM容量擴充，使大型模型微調、長文本及多模態等高記憶體需求工作負載更容易受到容量限制，也使企業重新評估AI訓練平台的投資方式。

軟體資源池化、記憶體卸載及CXL三種路徑改善的系統瓶頸、導入條件與效能代價並不相同，並不存在適用所有企業的單一最佳方案。隨著企業逐步導入外部容量方案，新增價值亦開始由單一GPU硬體規格，延伸至控制器、資料管理軟體、系統驗證及整機交付等系統整合能力。

然而後續仍須持續觀察GPU原生HBM容量演進、CXL軟硬體生態成熟速度，以及AI訓練框架與GPU平台對外部記憶體的支援程度，這些因素都可能改變不同記憶體擴充路徑的市場定位。

此外，企業AI訓練工作負載是否持續朝大型模型、多模態及長文本發展，以及資料治理需求是否持續推動地端部署，也將直接影響容量擴充需求與相關供應鏈價值分配；然而上述因素仍快速演變，亦將持續影響企業AI訓練平台的記憶體容量需求，以及不同記憶體擴充路徑的市場定位與供應鏈價值分配，值得後續持續觀察。



為協助我們做得更好，請幫我們評分 😊

非常不重要	5	非常重要
請問這篇報告主題的重要性：		
1		10
沒有幫助	5	非常有幫助
請問這篇報告內容對工作的幫助：		
1		10
送出評分		

相關報告

[2026年通用伺服器需求看漲 挾記憶體成本續增有望帶動CXL需求](#)

熱門報告 - Research

- 1 [產銷調查：CPU運算力躍升AI要角 全球伺服器2026年出貨將顯增19.2%](#)
- 2 [產業趨勢不變加上算力需求分散 伺服器OEM加入AI基礎設施戰局](#)
- 3 [CoWoS與SolC共構台積電先進封裝護城河 藉深度整合強化系統級封裝優勢](#)
- 4 [2026/4 NB產業觀察：受通路鋪貨力道減弱及高基期影響 五大NB品牌出貨月減33%](#)
- 5 [Google AI生態系加速擴大 Gemini與TPU為軟硬體關鍵支柱](#)



最近瀏覽報告

- 1 [產銷調查：供料限制箝制出貨力道 3Q26全球伺服器將季增2.8%](#) (2026/08/04)
- 2 [比亞迪以半導體自研支撐汽車智慧化下半場 智駕晶片布局邁向4奈米SoC](#) (2026/08/04)
- 3 [產銷調查：2奈米導入與記憶體成本攀升 3Q26全球手機AP出貨量預估年減13%](#) (2026/08/04)
- 4 [HBM容量限制浮現 記憶體卸載重塑地端AI訓練伺服器供應鏈價值](#) (2026/08/04)

產業九宮格
科技樞送門
展會
影音
修訂與更新

- ▼ DIGITIMES 領域
- 行動・通訊・XR
 - AI・智慧應用・電商物流
 - 航太・衛星・軍工
 - IT・系統供應鏈
 - 光電・顯示・光學
 - 物聯科技・智慧製造
 - 科技政策
 - 圖表

- ▼ 地區
- 東亞/中國
 - 國際
 - 圖表

報導簡覽
影音
商情
展會專區

產業垂直
化合物/功率半導體 作者群
Green Tech
EV Focus
新興科技
亞洲供應鏈
智慧製造
智慧家庭
物聯網
寬頻與無線
次世代行動通訊
Cloud
電腦運算
伺服器
行動裝置與應用
智慧穿戴
CarTech
IC設計
IC製造
顯示科技與應用

白話版
雲端 & 資安
產品 & 研發
AI & 創新
其他
AI EXPO Taiwan

科技產業報訂閱
訂閱DIGITIMES行動版
整合行銷服務
人才招募
聯絡我們

下載新聞App

