

摘要：

腾讯推出Hy-Memory，一款专为Openclaw这类长期协作型Agent设计的记忆插件。它采用6层记忆框架、双系统和演化链三层核心设计，让Agent真正“记得住、记得对、记得轻”。测试显示，记忆量降低70%以上，信息密度提升45%，token消耗降低35%，写入速度是Graphiti的8倍。

今天，我们正式推出 Hy-Memory，这是一个专门为 Openclaw 这类长期协作型 Agent 设计的记忆插件——它不只是个查询工具,而是真的能成为 Agent 的"第二大脑"。

Hy-Memory 用 **6 层记忆框架 × System1/System2 双系统 × 演化链**三层底牌，让 Agent 在长期使用中真正“记得住、记得对、记得轻、更懂你”。

在权威公开测试集上，Hy-Memory效果超过现有主流memory框架，可以解决记忆碎片化问题，记忆数量低70%+，每条记忆信息密度高45%+。在处理超长上下文方面，Hy-Memory消耗的token量降低35%，记忆更新速度快20%。

Agent 任务对长期记忆的要求远超 Chat

使用 Agent和 Openclaw 深度用户，常常描述过一种常见的“三周轨迹”。

第一周: 蜜月期，把自己当下正在忙的事情，比如一个项目的来龙去脉、最近的决定和取舍、未来想做的方向一股脑都告诉 Openclaw。能回答问题、能查资料、能帮你规划、能写代码、能起草文档。“这玩意儿真好用”——这是大多数人第一周的真实感受。

第二周: 开始不安。人们注意到每天打开 Openclaw都得先花 3 到 5 分钟提醒它我们在做什么。它好像不太记得几天前讨论过的判断。当你对它说“按之前那个方案”，它会反问“哪个方案”，说“那个我们排除掉的选项”，它却想不起来排除的是什么、为什么排除。不是完全不记得。Openclaw 默认的记忆机制能记住一些最近的对话原文，但跨天、跨 Session、那些更深的判断，它就漂移了。

第三周: 主动降级使用，开始下意识地缩短跟它讨论的深度。不再问“这个方向我该不该走”，因为知道明天它就忘了。变成只问最具体、最即时的小问题: 搜个资料、查个语法、改一段文字。

最常见的结局是，Openclaw 在使用者眼里，慢慢从“能陪你思考的伙伴”，降级成了“一个查询工具”。这不是 Openclaw 的问题——它的内核能力一直很强。问题在于：长期协作类任务对长期记忆的要求，远超过普通 Chat。

Hy-Memory 这个 Openclaw 记忆插件的初衷，就是为了把这三周轨迹的后两周抹掉——让用户第一周怎么用 Openclaw，第三个月还能怎么用，而且越用越懂。

1、长期任务对记忆的挑战比想象中难

长期任务跟普通 Chat 完全是两种工作。不管你拿 Openclaw 调研一个复杂决策、写一本书、规划一次大旅行、跟进一个跨季度的项目，一次对话可能 30 轮 50 轮 100 轮，中间不停地查资料、调工具、读文档、出方案、回退、再改、再走，一个 Session 可能持续几个小时，任务可能跨越数周。

记忆系统至少要扛住 4 件事：

挑战	具体表现
挑战一：信息过载	当用户输入的信息量过大时，系统能否快速识别关键信息并忽略冗余内容？

任何一个环节崩了，体验就崩了。

2、一个合格的 Openclaw 记忆插件要满足的 3 条标准

我们在设计 Hy-Memory 的时候围绕“什么样的记忆插件才配得上 Openclaw 这种长期协作场景”，定了 3 条硬标准。

标准一：不能丢历史。

用户跟 Agent 聊过的所有“为什么选这个、为什么否那个”——这些判断和因果不能丢。否则下次它推荐方案，可能直接推荐回用户已经否过的那个，白费时间。

标准二：要能演化。

人不是一个静态的存在。技术偏好、生活习惯、长期目标都会随时间变，对某件事的看法也会反复调整，这些都得被记住。不是覆盖式的“只记最新”，也不是堆积式的“全都留下”，而是要有一个清晰的演化轨迹。

标准三：要在主链路里不仅足够快，还要有认知迭代，进化。

记忆插件不能拖慢用户当下打字、调用工具、等结果的速度。每次搜索要在毫秒级，召回也不能成为响应瓶颈。同时还要有深层次的语义和事实理解。

接下来，我们把 Hy-Memory 满足这 3 条标准的三层底牌分别讲清楚。

Hy-Memory 的三层核心

第一层：6 层记忆框架——给每种记忆找到正确位置

Hy-Memory 做的第一件事,是没有把所有记忆塞进同一张表。

想一下——用户跟 Openclaw 聊到最近在准备出国留学,这段话里其实混着好几种东西：

- “我在准备出国留学”——这是事实
- “我偏好北欧那种慢节奏的项目”——这是画像



- “我做大决策前会先列利弊清单”——这是心智模型
- “我下周大概率会问推荐信怎么找教授”——这是前瞻意图

这些东西信息形态完全不一样,但传统记忆系统会把它们全揉成一堆向量，搜索时一锅捞。Hy-Memory 把记忆分成 6 层，每层一种职责。下面用一组多领域混合的例子，让你感受 Agent “记的是什么”：

层	内容	类别 (模型工作 / 生活 / 学习 / 决策)
---	----	--------------------------

用户问 Openclaw “我做大决策有什么习惯”,它应该优先看 L5 心智模型,而不是把过去 100 轮对话原文一锅塞过来。用户问“我现在住在哪”,L2 一条事实就够了。问什么、走哪层、用什么样的检索权重——分层让这些变得可能。

整个 prompt 会变干净。模型的注意力不再被无关原文稀释。

第二层：双系统设计，既保障速度又具备认知迭代

Hy-Memory 把来自人脑认知科学的 System1 / System2 机制直接复刻到了 Agent 的记忆加工上——就像给 Openclaw 装了一颗符合认知科学的“大脑”。

Hy-Memory 把记忆加工拆成两套。

System1(白班)：用户回车那一秒，实时地处理写入的记忆。负责写原始痕迹、抽事实、更新画像、压会话摘要——也就是 L1–L4

System2(夜班)：秒到分钟级，在后台跑。负责抽心智模型、构建知识网络、预测意图——也就是 L5–L6

为什么要拆？因为深度认知很慢。抽你的“决策心智模型”、构建你的“知识网络”——做完一遍 LLM 可能要 5 到 20 秒。如果让你每次调用 Openclaw 都等 20 秒才能收到回复，谁都用不下去。

但你要的也不仅是“快”——你要的是 Agent 越用越懂你。Hy-Memory 的拆分把这两件互相打架的事变成两条独立通道：

- 1、发送消息后System1 已经把“立即可用的记忆”写好了——下一句对话能立刻用上
- 2、 System2 在后台慢慢做更深的认知——把你两周的对话沉淀成“你的决策心智”



结果在对话最直接的影响：你每次说完的信息它能立马记住；而它对你的理解还在后台不断变深。

第三层：演化链——记忆能改写但不丢因果

第三层是 Hy-Memory 真正的杀手锏，也是我们觉得用户长期跟 Agent 协作时最容易踩坑、也最值得做对的一件事。

一个典型的长期场景：假设一位用户跟 Openclaw 聊了大半年自己的健身计划。过去半年里他的训练方式发生过4 次明显的态度转折：

- 去年春 — 开始跑步训练有氧，效果不错，体重和精神状态都改善了，对跑步充满信心
- 去年夏 — 跟练 HIIT，强度太大，膝盖出了问题，被迫停训两周
- 去年秋 — 转向纯力量训练，只练大重量、放弃了心肺，结果跑两公里都喘,挫败
- 上月 — 形成「力量 + 慢跑 + 瑜伽」混合方案，身体状态终于稳定下来

今天他打开 Openclaw问它：“我下个月想再加一种新的训练方式，你建议什么？”

三种记忆系统会给出三种答案。

答案 1：覆盖派(只记最新)

很多默认记忆系统是"用新覆盖旧"。库里只剩"用户当前用混合训练效果好"。

Agent 的回答：“你现在的力量 + 慢跑 + 瑜伽组合挺好,可以再加一个 CrossFit 试试,效率高。”

不算错，但很浅。它不知道用户为什么走到混合训练——错过了"HIIT 伤过膝盖"、“纯力量丢了心肺”这条完整的踩坑路径。直接推荐 CrossFit 很可能让用户再伤一次膝盖。

答案 2：堆积派(全部保留)

另一些系统是"什么都留下，搜索时按向量相似度召回"。库里 4 条事实都在,但搜索 “新训练方式” 时，最近的、最相似的先被召回——大概是"跑步起步效果不错"和"混合训练稳定"。

中间的"HIIT 膝盖受伤"、“纯力量丢心肺”在语义空间里距离稍远，可能根本召回不回来。

Agent 的回答：“你跑步效果不错、混合训练也稳定,可以加一个 HIIT 试试,提升心肺效率高。”

踩雷了。它没意识到用户已经在 HIIT 上受过伤——重新推荐 HIIT 等于让用户再走一次老路、再伤一次膝盖。

答案 3：Hy-Memory 演化链

Hy-Memory 在写入第 2 条记忆时，会用 supersedes 指针指向第 1 条；第 3 条指向第 2 条；第 4 条指向第 3 条。4 条记忆通过指针串成一条链。D (混合训练，链头) ↓ supersedes C (纯力



量,丢心肺) ↓ supersedes B (HIIT,膝盖受伤) ↓ supersedes A (跑步起步) 用户问“新训练方式选什么”时,搜索命中链头 D,整条链自动展开——A、B、C、D 一起返回给 Agent。

Agent 拿到的不再是孤立结论而是完整的态度演变：

- 跑步起步 →
- HIIT 伤膝盖 →
- 纯力量丢心肺 →
- 混合方案稳定下来

它的回答会是这样：

“你之前在训练方式上走过完整的路:跑步起步、HIIT 伤过一次膝盖、纯力量又丢了心肺，上月才走到力量 + 慢跑 + 瑜伽这个稳定组合。

所以新方式我会建议你避开高冲击的爆发类训练（比如 CrossFit、HIIT 这类）——你的膝盖已经踩过一次坑。如果想再加新内容,可以考虑游泳或骑行这种低冲击有氧,或者爬山 / 长距离慢跑——都比再回 HIIT 安全。”


这个回答的质量，不是来自模型本身，是来自记忆结构。

演化链的本质

技术上演化链做的就是两件事：

- 1、新记忆写入时,通过 supersedes 指针指向旧记忆,形成一条链

2、搜索命中链上任意一节点，自动展开整条链



最新的判断在最前面（链头），但被否过的、被替代的、被废弃的旧版本不会丢——只是退到链身后面，需要时随时展开。这是我们能想到的、最适合 Agent 长期陪伴用户的“长期记忆”形态。

Hy-Memory：超过同类框架

Hy-Memory 在LongMemEval 和 PersonaMem这两个权威的长期记忆评测上跑过。

1、LongMemEval：得分达85.2，远超其他框架。LongMemEval 是公认很难的长期记忆评测，500 道题覆盖 6 个能力维度。

Hy-Memory不仅打赢所有同类系统，在 6 个维度中的 4 个维度取得最高分——尤其在最考验“演化能力”的偏好(+21.11pp)、时序推理(+9.63pp)、知识更新(+21.37pp)三项上领先同类产品。

2、PersonaMem：打赢所有同类产品，PersonaMem 是 6000+ 条消息 / 589 道题的真实长期对话评测,更贴近“用户用了好几个月”的真实场景。

3、性能：有更高的记忆密度同时，更有8 倍写入速度

指标	Hy-Memory	mem0	Graphiti
----	-----------	------	----------

Openclaw 用户能感受到的是：

- 写入快：跟 mem0 同档，是 Graphiti 的 8 倍快，不会卡 Openclaw 的对话主链路
- 存得少：记忆条数只有 mem0 的 1/3、Graphiti 的 1/4–1/5，本地嵌入式存储，不需要外部服务，内存占用低
- 密度高：单条记忆是 mem0 的 3–4 倍信息密度，每次召回的记忆更管用，prompt 不被噪声污染

最后这条对长期任务特别重要：当一次 Session 跑到 80 轮对话,召回的每一条记忆都得是高密度的,否则 prompt 一下就被噪声塞爆,模型注意力被稀释。

Hy-Memory 的高密度意味着同样的 Token 预算下Openclaw 能看到比别的记忆系统多 3-4 倍的有效信息。

快速装上 Hy-Memory：从决定到能用，大概 5 分钟

1、一行命令安装



```
npm config set registry https://mirrors.tencent.com/npm/ &&  
openclaw plugins install @tencent/hy-agent-memory --dangerously-  
force-unsafe-install --force && openclaw hy-memory init
```

默认配置下 Hy-Memory 使用 Chroma 作为本地嵌入式向量库,数据自动持久化到本地目录,不需要先安装 Qdrant、不需要启动任何外部服务、不需要部署 Docker,只要配置好 LLM / Embedding 的 API Key,就可以直接用。可以用下面命令验证安装情况,以及 LLM, Embedding 服务是否连通:

```
openclaw hy-memory status  
[plugins] openclaw-hy-memory: registered (user: tom001, server:  
http://127.0.0.1:19527, autoRecall: true, autoCapture: true)  
  
OpenClaw 2026.5.26 (10ad3aa) – Built by lobsters, for humans.  
Don't question the hierarchy.  
  
HY Memory Server: http://127.0.0.1:19527  
  Status:      ✓ healthy  
  User ID:     tom001  
  VDB:         ok [chroma] (collection: agent_memories_1024,  
points: 0)  
  Embed:       ok (dims: 1024)  
  LLM:         ok  
  SDK Version: 1.2.5
```

2、 Lite / Pro / Ultra: 不一定需要"全开"

Hy-Memory 把同一个内核拆成三档,按需启用:

档位	容量	混合模型
----	----	------

建议: 第一次装, 直接上 Pro。开 MemAgent 但不开 System2 后台。开发机基本扛得住。真正高频用可以升级 Ultra, 把 System2 打开, L5 / L6 都沉淀。三档共用同一份 SDK, 升级只改一个开关, 不需要重新接入。



如果你是 Openclaw 现有用户: 把 Hy-Memory 装上, 你会感觉这个 Agent 可能接触过的 AI 里第一个真的认识你的。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 8  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论