

摘要：

Anthropic称，Haiku 5.5是该公司迄今发布的最便宜、最快且能力最强小模型，瞄准高吞吐量、成本敏感型应用，编程、电脑操作等任务能力较前代4.5明显提升；首次纳入可调节的effort推理强度；对提示词不超过10万Token的请求，API价格较前代低90%，超过这一门槛，价格低50%；可配合一个月内发布的前两款Claude 5.5模型Opus 5.5、Sonnet 5.5配合使用，作为后两者的“子智能体”。Sonnet 5.5缓存读取价砍半至0.1美元/百万Token。

最近传出冲刺感恩节前上市的Anthropic继续在IPO前加速扩充产品线。

美东时间10月7日周三，Anthropic宣布推出该公司“迄今为止发布的最便宜、最快且能力最强小模型”Claude Haiku 5.5，完成Claude 5.5系列模型的最后一块拼图，将**重点放在高频、低成本和大规模AI应用**。

Anthropic称，新模型平均运行成本较前代Haiku 4.5下降约75%，同时，在执行编程、计算机操作和知识工作等任务的能力方面，较前代明显提升。

Claude Haiku 5.5

	Haiku 5.5	Haiku 4.5	GPT-6 Luna	Sonnet 5.5 For reference
Knowledge work GDPval-AA v2.1	1620	735	1437	1840
Knowledge work AA-Briefcase v1.1	1578	614	1336	1824
Computer use OSWorld 2.1 (Offline subset)	72.4%	15.7%	48.9%	83.9%
Multidisciplinary reasoning Humanity's Last Exam (no tools)	45.9%	10.2%	—	56.9%
Multidisciplinary reasoning Humanity's Last Exam (with tools)	57.4%	18.7%	—	64.5%
Agentic coding Terminal-Bench 4.0	39.2%	0.0%	16.4%	70.6%
Agentic coding FrontierCode 1.1 (Main)	46.4%	—	42.4%	52.1% Xhigh
Visual reasoning Chartography (no tools)	46.4%	6.4%	29.1%	61.6%

For details on how we run our evaluations, see the Haiku 5.5 System Card.

这是Anthropic在过去一个月内推出的第三款Claude 5.5模型。筹备IPO之际，Anthropic于9月22日发布旗舰模型Opus 5.5，9月28日推出Sonnet 5.5，如今Haiku 5.5也正式上线。三款模型分别覆盖复杂智能体任务、日常知识工作以及高频低成本任务，形成从高端到大规模应用的完整产品梯队。

同在本周三，Anthropic还宣布将Sonnet 5.5的缓存读取价格下调50%，每百万Token定价从0.20美元降至0.10美元，公司称这将使Sonnet 5.5在大多数智能体任务中的运行成本再下降约20%。

瞄准海量短任务，小模型首次加入“推理档位”

与面向最复杂任务的Opus 5.5不同，Anthropic对Haiku 5.5的定位非常明确：**高吞吐量、成本敏感型应用**。

Anthropic称，Haiku 5.5能够稳定处理摘要、上下文压缩、数据库查询和分类等重复性任务，同时可以作为Opus 5.5和Sonnet 5.5的“子智能体”，承担复杂编程任务中的部分工作。

由于速度更快，Haiku 5.5也适用于实时客户支持和浏览器操作。Anthropic称，这是其迄今速度最快的模型之一，在标准速度下，Haiku 5.5的运行速度超过此前所有Haiku模型。

更值得注意的是，Haiku 5.5首次加入了**可调节的effort推理强度**。用户可以根据任务需要，在成本和智能水平之间进行选择：简单任务采用较低推理强度，以速度和价格为优先；复杂任务则可以提高推理强度，以换取更高的准确率和更强的推理能力。

这实际上让Haiku从一个单纯的“便宜小模型”，变成了一个可以根据不同工作负载动态调整成本的模型。

九成请求瞄准的10万Token门槛

Haiku 5.5此次最具冲击力的变化，是价格的大幅下探。

Anthropic表示，Haiku 5.5平均运行成本较Haiku 4.5下降约75%。其中，对于提示词不超过10万Token的请求，Haiku 5.5的API价格较上一代低90%；超过10万Token的请求，价格则下降50%。

而10万Token恰好覆盖了绝大多数Haiku的使用场景。Anthropic称，上一代Haiku 4.5约90%的请求都属于10万Token以内的任务。

目前，Haiku 5.5对于10万Token以内的请求，每百万Token的输入价格为0.10美元、输出价格为0.50美元；超过10万Token的请求，输入和输出价格分别为0.50美元和2.50美元。缓存读取价格则为每百万Token 0.01美元和0.05美元。

Price per 1 million tokens	Haiku 5.5 prompts up to / over 100k	Haiku 4.5	Sonnet 5.5
Cache reads	\$0.01 / \$0.05	\$0.10	\$0.10
Cache writes	\$0.125 / \$0.625	\$1.25	\$2.50
Input tokens	\$0.10 / \$0.50	\$1.00	\$2.00
Output tokens	\$0.50 / \$2.50	\$5.00	\$10.00

这意味着，Anthropic此次并非针对少数极端长上下文任务降价，而是直接压低了**数量最多的一批AI调用的成本**。

媒体指出，这一价格水平已经将Haiku 5.5推向与OpenAI GPT-6 Luna等低成本、高速度模型直接竞争的位置。AI模型的价格战正在从旗舰模型进一步向轻量级模型蔓延。

对于企业客户而言，这一变化尤其重要。大量实际AI工作并不需要最强模型：客服问答、文本分类、摘要、数据库查询、数据整理，以及大型智能体拆解出来的子任务，都可以交给更轻量的



模型。

因此，在企业大规模部署AI的情况下，**每次任务到底花多少钱**，可能比模型在单项基准测试中多拿几分更重要。

“便宜模型”开始成为智能体的基础设施

Anthropic此次尤其强调Haiku 5.5可以与Opus 5.5、Sonnet 5.5配合使用，作为后两者的“子智能体”。

这意味着AI应用正在出现一种更加明显的分工模式：一个复杂任务可以由Opus或Sonnet负责总体规划，再把大量简单、重复的子任务交给Haiku执行。

例如，在一项复杂的软件开发工作中，高端模型可以负责理解需求、设计方案和处理关键代码，而Haiku则可以承担代码摘要、文件分类、数据库查询以及其他重复性工作。

这种架构的关键并不是让每一个模型都做到最强，而是**让不同任务匹配不同成本的模型**。

Anthropic此次将Haiku 5.5的价格压到更低水平，同时加入可调节的推理强度，本质上也是在争夺这类高频调用场景。

随着AI智能体从“回答问题”逐渐转向持续运行数小时甚至更长时间的工作流，模型的调用量可能远远超过传统聊天机器人。如果其中大量子任务能够由低成本模型完成，企业整体AI支出就有可能明显下降。

Sonnet 5.5缓存读取价格再砍半

除了发布Haiku 5.5，Anthropic还同步下调Sonnet 5.5的缓存读取价格。

公司宣布，从10月7日起，Sonnet 5.5的缓存读取价格从每百万Token 0.20美元降至0.10美元，直接下降50%。Anthropic称，由于缓存读取在长时间运行的智能体任务中占据较大比重，这一调整可以让Sonnet 5.5在大多数智能体任务中的运行成本下降约20%。

这也是Anthropic此前“降低模型实际使用成本”策略的延续。

9月底发布Sonnet 5.5时，公司并没有调整其每百万输入Token 2美元、输出Token 10美元的基础价格，而是通过减少完成同一任务所需的Token数量以及提高输出速度，使单任务成本最高下降30%。

此次再下调缓存读取价格，则进一步降低了长时间运行智能体的成本。

换言之，Anthropic此次不仅推出一个更便宜的Haiku，还同时压低了Sonnet在长期工作流中的使用成本，显示公司正在系统性地向**更低的单位任务成本**推进。

Claude 5.5家族正式补齐

Haiku 5.5目前已经全面上线，包括Anthropic的Claude平台和Claude Code，并登陆亚马逊云科技（AWS）、谷歌云（Google Cloud）和微软Azure。

至此，Claude 5.5家族正式形成三级产品结构：



- **Opus 5.5**：面向最复杂的编程、智能体和专业知识工作；
- **Sonnet 5.5**：面向日常编程、办公生产力和知识工作；
- **Haiku 5.5**：面向高频、大规模、成本敏感型任务。

这也是Anthropic一个月内连续发布三款模型的重要意义——公司不再只是推出单个“旗舰模型”，而是在建立一套覆盖不同性能和成本档位的AI模型体系。

对于正筹备IPO的Anthropic而言，这种产品矩阵也有着更直接的商业意义。此前彭博报道称，Anthropic目标是在11月感恩节前上市，最早可能于11月9日当周启动IPO路演。

在AI行业从“谁的模型最强”逐渐转向“谁能以更低成本完成更多工作”的背景下，Anthropic此次将Haiku 5.5的平均运行成本压低约75%，并同步下调Sonnet 5.5的缓存价格，释放出的信号十分明确：

AI模型的下一轮竞争，不仅是能力之争，也是成本之争；而随着智能体进入大规模商业化阶段，每美元能够完成多少有效工作，可能越来越成为衡量模型商业价值的关键指标。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 232  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论