

摘要：

ChatGPT联合创始人Almeida隐身两年后推出Jev，这个AI模型不聊天、不写代码，只做判断——从预定义选项中选择、打分或给出是非概率。Jev在自动化工作流任务上比现有大语言模型快193.6倍、成本低444.6倍，输入每百万Token仅0.042美元，输出免费。上线即刷屏开发者圈，现已向所有用户开放。

9月21日，TypeSafe官方在X上宣布：Jev向所有用户全面开放，无需等待候补名单。所有注册用户将获得5美元初始额度，由于其极低的定价策略，这笔额度相当于直接送出约1.2亿Token。



在刚刚过去的周末，这个叫**Jev**的模型在开发者社区迅速出圈，现在已经对所有人敞开了大门。

它不能像ChatGPT那样陪人聊天，不能写长文，也不会一本正经地生成代码。

它的工作更像一道高频选择题：继续还是停止？通过还是拦截？点哪个按钮？这封邮件该转给谁？


看起来能力被“砍掉”不少，为什么反而火了？

因为Jev瞄准的就是一件事情：判断，在“零幻觉”的基础上做判断。



Jev由ChatGPT联合创始人Diogo Almeida主导开发。他在X上写道：“参与共同发明ChatGPT之后，我一直在问自己：为什么超人级别的聊天模型没有带来AGI？”两年隐身研发后，他给出了自己的答案——一套全新的决策模型，或许比更强的聊天更有效。

根据TypeSafe官网公布的测试数据，Jev在自动化工作流任务上比现有大语言模型快193.6倍，成本低444.6倍。输入每百万Token仅需0.042美元，输出Token免费。上线后需求量一度超出预期，API短暂无法正常响应。



一个人，两件相反的事

Diogo Almeida的履历有一种内在张力。



他曾在OpenAI参与构建RLHF（基于人类反馈的强化学习）和InstructGPT，这套方法直接催生了ChatGPT。


然后他离开了，开始反思这套方法。

他在一场演讲中直接提出问题：“今天的AI已经能挑战高等数学，为什么企业还是不敢把客服决策交给它？”

他的答案是：“今天的AI非常擅长协助，但还不擅长自动化。”

协助，是人坐在屏幕前，AI帮你干活，你来检查。

自动化，是人根本不在场，AI在后台自己判断、自己执行。



Almeida把问题指向了RLHF本身。他在演讲中说：“为什么今天的大模型总需要有人在回路里？因为训练它的时候，我们字面意义上就把人塞进了那个回路里。”

RLHF让模型学会了一件事：什么样的回答，人更喜欢？

这对聊天产品是优点。但对自动化系统，却是问题所在。

Diogo Almeida, TypeSafe创始人

多年来，模型在聊天方面一直表现出超乎常人的能力，那么自动化程度在哪里呢？

过去四年，这始终是我思考的核心问题。在 OpenAI，我参与构建了使语言模型能够有效理解指令并与人交流的方法。这项工作最终成为了 ChatGPT 背后的研究基础。当时，我曾认为聊天模型或许能最终发展成通用人工智能（AGI），但尽管当时炒作不断，我逐渐意识到其中还缺少一些至关重要的东西。

经过两年的秘密研发、无数的技术挑战和研究突破……我无比激动地宣布，今天，TypeSafe AI 发布了我们的第一个**System One 模型**：一类新型前沿模型，旨在做出软件可以直接使用的快速、结构化的决策。

我们构建了一个完全专注于自动化的新堆栈：采用新的模型架构、并行采样器以实现最高效率，以及我们称之为校准决策强化学习 (RLCD) 的训练方法。

我们的首个公开模型是**Jev**，现已推出抢先体验版。与现有的 LLM 模型相比，Jev 在系统一任务上达到了类似的智能水平，同时速度和效率都提高了两个数量级。虽然 Jev 不具备字符串生成功能，但它针对结构化输出进行了优化，并且不会产生幻觉。

把 Jev 看作是一个前沿智能函数调用：输入非结构化状态，输出类型化的概率决策。

非同寻常的主张需要非同寻常的证据，请查看下方收据。🔥

Jev是什么：一个会做判断的函数

TypeSafe官网将Jev定义为：“把非结构化状态输入，输出类型化的概率决策。”

换成人话：你给它一段信息，它告诉你答案是什么，以及它有多大把握。并且不会产生一点幻觉。

它不生成文字。它只做三件事：

- **Noul**：是非判断，返回一个0到1之间的概率，代表某件事为真的可能性
- **Choice**：从预定义列表中选一项，最多支持255个选项，适合分类和路由
- **Score**：按照设定的尺度打分，用于衡量紧迫程度、质量或风险

每次回答都附带完整的概率分布和置信度。强类型输出，不需要写JSON提示词，不需要额外解析器。

旧与新边疆		
	现有LLM	系统一号 + Jev
已优化	基于人类反馈的强化学习（RLHF） / 基于可验证奖励的强化学习（RLVR）	用于校准决策的强化学习（RLCD）
优化	人类偏好：人类评分者更喜欢的评价内容和聊天回复。 可验证奖励：可以通过程序进行验证的输出。	校准决策：在系统一任务中给出认知上诚实的概率答案。
输入	非结构化数据（例如文本），重点是顺序消息。	非结构化数据（例如文本），重点是结构化程序状态。
输出	字符串/生成文本。字符串非常灵活，可以是任何内容：聊天回复、代码、幻觉、拒绝，甚至是类型安全的结构化值。要供软件使用，回复需要经过解析和验证。此外，人工智能始终存在失控的风险。	类型安全的结构化值。所有可能的输出及其结构均预先定义。该模型不会出现类型错误。所有答案均附有校准后的概率和置信度评分。
采样	顺序生成。每次生成一个标记，每个标记都以前一个标记为条件。	并行处理。一次查询即可生成所有输出。效率极高，并能充分利用硬件资源。

成本	输入代币：0.20 美元至 10 美元/MTok。 输出代币：比输入代币贵约 5 倍。	输入代币：0.042 美元/MTok（每十亿代币 42 美元）。 输出代币：免费（价格太低，不计量）。
速度	对于前沿模型而言，端到端响应时间为3 到 329 秒。对于人机交互来说速度足够快，但集成到代码中则成为一大瓶颈。	TypeSafe 的端到端响应时间为 70 毫秒至 500 毫秒。对于相同级别的前沿智能，System One 架构的查询速度可提升 40 倍至 200 倍。
信心	即使被要求给出置信度估计，模型也往往过于自信且结果不一致。如果一个模型95%的情况下都能完成某项任务，但却无法指出剩余的5%的情况，那么它就无法实现该任务的自动化。	每次输出都清晰地传达置信度和不确定性。经过校准：置信度越高，准确度越高。更加一致：对相似的输入返回相似的结果。
用例	人机协作任务（聊天机器人、副驾驶、编码代理）。这类任务通用且功能强大，但需要人工监督，因为它们自由度也意味着它们可能会失控。 可验证问题（例如数学证明、核优化）。当正确性能够以低成本且自动化的方式进行验证时，LLM 可以生成、测试并迭代，直到找到有效的解决方案。	AI驱动的工作流/智能if语句。结构化输出可以作为模糊决策规则嵌入到普通软件中：在手工编写的逻辑过于脆弱的情况下，进行分类、路由、评分、提取或分支等操作。周围的代码限制了它们的自由度，使它们更容易组合成可靠的系统。 大数据上的MapReduce 技术。将 PB 级数据转化为特征和洞察。

为什么快，为什么便宜

普通大语言模型生成答案的方式是：一个Token一个Token地往外输出，每个Token都依赖上一个。

Jev的采样方式是并行的。所有输出在一次查询中同时生成。这是速度差距的根本来源。

根据TypeSafe官网数据：

- **Jev端到端响应时间：70毫秒至500毫秒**
- **现有前沿模型：3秒至329秒**
- 速度差距：40倍至200倍（System One类型任务）


价格方面：

- **Jev输入：每百万Token 0.042美元（每十亿Token 42美元）**
- **现有前沿模型输入：每百万Token 0.20美元至10美元**
- 输出Token：免费





TypeSafe官网注明，193.6倍速度提升和444.6倍成本降低的数据，来自其自动化工作流评测，“预计这些数字处于实际收益的较高端”。评测由公司模型能力团队成员制作，存在一定偏差可能性。



“校准”才是真正的核心

速度和价格之外，TypeSafe强调的另一个关键词是“校准”。

现有大语言模型即使被要求给出置信度，也往往过度自信且不一致。TypeSafe官网指出：“**如果一个模型能完成某项任务95%的时间，但不告诉你它什么时候处于那5%，它就无法自动化那项任务。**”

为此，TypeSafe开发了新的训练方法RLCD（Reinforcement Learning for Calibrated Decisions，校准决策强化学习）。

目标是：如果模型说某件事有80%的概率，那么在它判断为80%的一批事情里，最终应该真的有大约80%发生。

这在自动化系统里直接决定了如何分配任务：

- 置信度 > 90%：直接自动执行
- 置信度在70%至90%之间：交给更强的大模型复核
- 置信度 < 70%：转给人来决策

Earendil公司CTO Armin Ronacher对此解释道：“归根结底，这种方式将幻觉问题的处理责任稍微转移到了用户身上。用户需要决定：如果这种情况出现的概率只有50%，那或许可以忽略它。但如果概率达到95%，那我就可以利用它了。”



并行判断：一次问十个问题

Jev还有一个特点：同一次请求中的多个问题，共享一份输入，但独立并行评估。

公众号“[数字生命卡兹克](#)”做了个实测：他把一条新闻扔进去，可以同时问——是否AI相关？是否广告？是否融资？应归哪个分类？是否值得推送？

Jev一口气把这些判断全部做完，速度不变。

传统大语言模型需要逐个问题生成回答，或者把所有问题塞进一个提示词，再解析输出。

这个并行特性，在多问题场景下优势最为明显。



开发者已经在用它做什么

Jev上线后, 开发者社区迅速涌现出大量实际应用案例。

信息流过滤: 开发者Marcel Pociot接入Jev做了一个浏览器插件, 用于过滤X平台上不想看的内容。每条帖子的判断平均耗时380毫秒。

广告分析: [有人用Jev在40秒内分析724条实时广告, 共做出8724次判断。](#)

浏览器代理: Browser Use的开源项目jev-ultrafast, 将Jev用作浏览器操作的判断层。以查机票为例, 每一轮程序同时问多个问题: 下一步点击还是输入? 点哪个编号? 这些问题共用同一份网页状态, 分别作答。

上下文压缩: 将Jev接入Claude Code, 判断哪些上下文内容是关键信息, 实现近乎即时的上下文压缩。



安全分类器: Vercel公司软件工程师Pranit Sharma表示, 用Jev替代OpenAI的ChatGPT Luna 5.6来运行命令安全性分类器后, 处理速度提高了5到18倍, 准确性也大幅提升。

邮件分类: Bryo AI的CTO Nikhil Mudholkar测试了Jev和Gemini在分类商业邮件方面的表现。他的测试结果显示, Gemini准确率略高, 但成本高出10到20倍。

营销分析: 有团队将Jev接入营销分析流程, 扫描Meta广告库、比较广告格式存活周期, 把原本需要人工完成的判断提速了30倍, 成本压到3美元以内。

游戏演示: TypeSafe官网展示了Jev玩Doom的演示, 每秒可做出约10次决策, Jev依据结构化游戏状态做出实时操作判断, 每小时成本约7美元。在Ably Pong演示中, Jev在12秒内做出47次操作决策, 而Gemini、Claude和GPT在同样时间里只做出两三次。






“零幻觉”不等于“永远答对”

Jev官网上写着“Zero Hallucinations”，即“零幻觉”。

这句话很抓眼球，也容易被误读。

TypeSafe在技术说明中给出的含义是：Jev的输出类型和结构预先定义，因此模型不会产生类型错误，不会突然跳出指定格式、捏造一个不存在的字段，或在限定选项外随意发挥。

例如，程序只允许它在“通过、拒绝、人工复核”三个选项里选，它不会输出一首诗，也不会附带一段Markdown说明。



Zero Hallucinations

Every Jev decision comes with a confidence estimate, so your software can act when confidence is high and escalate when it is not.

这解决的是自动化系统中的结构可靠性问题。

但它不等于模型不会选错。TypeSafe自己的FAQ也明确承认：Jev“仍然可能出错”。

为什么是现在爆火：Agent需要的，可能正是这些小决定

Jev的出现，正好踩中了Agent开发中的一个现实问题。

一个能操作网页、调用工具、处理文件的Agent，在完成任务前，往往要经历大量微小判断。

下一步点击哪个元素？这个工具返回的结果是否有效？上下文里哪部分已经没用？这个任务是真的完成了，还是看起来完成了？

这些判断单独看不难，但一旦进入高频工作流，成本会迅速堆积。

Jev这次爆火，至少有三个清晰原因。

第一，它的定位足够反常。

当行业持续追逐更长的推理、更强的聊天、更大的上下文时，Jev直接放弃生成文本，只解决选择、分类、打分和路由。

第二，它击中了Agent的成本问题。

如果一个系统每天要做数十万次小判断，20—200倍的速度差异、40—400倍的成本差异，即使只在部分任务上成立，也足以吸引开发者测试。

第三，它把“不确定性”做成了接口的一部分。

过去，模型总能给答案；真正让自动化系统头疼的是，模型常常不知道自己什么时候会错。

Jev给出的答案是：不只返回结论，也返回对结论的把握程度。

为什么叫Jev，为什么叫System One

TypeSafe把Jev所在的模型类别命名为“System One Models”。

名称来自丹尼尔·卡尼曼《思考，快与慢》中关于“系统1”和“系统2”的区分：**前者偏快速、直觉式判断，后者偏慢速、审慎推理。**


Jev显然押注前者。

TypeSafe的产品定位并不是让Jev替代所有大模型。

官方列出的适用任务包括分类、路由、打分、信息提取、工作流分支、内容审核、模型输出验证，以及在大数据上进行批量处理。

复杂推理、长文生成、写代码、创作内容，仍属于传统大语言模型更擅长的领域。

在这种分工下，Jev负责先做大量低延迟决策；当它不够确定时，再把问题交给更慢、更贵、但更适合生成与推理的大模型，或者交给人工。



融资与开放

TypeSafe AI由Diogo Almeida与Erik Gafni、Sasha Sheng共同创办，公司隐身运营约两年。

2026年9月15日正式亮相，同步宣布完成4000万美元种子轮融资，由DCVC领投。

TypeSafe表示，目前市面上采用这一路线的公司只有他们一家。Ronacher预计，随着这种模式的实用价值逐渐被验证，跟进者会陆续出现。

被问及公司是否算前沿实验室时，Almeida说：“**前沿实验室的主要产物要么是恐惧，要么是炒作，我希望我们的主要产品是智慧，我们不属于那种一门心思创造无限财富，或者搞宗教式叙事，或者试图在数据中心里造神的实验室。**”

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

402 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论