

摘要：

月之暗面发布Kimi K3的模型权重、技术报告，并开源支撑Kimi K3模型训练的关键Infra技术：MoonEP、FlashKDA和AgentEnv，任何人都可免费下载部署。


今天是 Kimi K3 开放日，我们发布 Kimi K3 的模型权重、技术报告，并开源支撑 Kimi K3 模型训练的关键 Infra 技术：MoonEP、FlashKDA和AgentEnv。希望以此加速前沿智能的部署与普及，促进 AGI 研究。

Kimi K3 权重公布

Kimi K3 是我们能力最强的模型：这是一个拥有 2.8 万亿参数的混合专家（MoE）模型，具备原生视觉理解能力，并支持 100 万 token 的上下文窗口。

Kimi K3 参数规模是 Kimi K2.5 的 3 倍左右，但是规模化并不仅仅是参数的堆叠，在并不宽裕的算力条件下，我们凭借 Kimi Delta Attention、Attention Residuals 以及 MoonEP 等一系列技术创新，规模化效率提升了 2.5 倍（即在算力最优意义下，单位算力产出智能约等于原来 2.5 倍）。

现在，每个人都可以下载并部署 Kimi K3 模型——无论是用于内部研发，还是嵌入到面向终端用户的产品中，均可自由使用（其他使用情形，详见Kimi K3 许可证）。



Kimi K3 技术报告发布

今天，与 Kimi K3 模型权重一起公开的，还有我们的模型训练方法——Kimi K3 技术报告已同步上线。

从技术报告中，你可以了解这些技术细节：

- KDA + AttnRes：以 3:1 比例混合 KDA 与 Gated MLA，实现高效长上下文建模，并通过块级注意力残差增强跨层信息流动。
- Stable LatentMoE：每个 token 从 896 个路由专家中激活 16 个，并通过 SiTU-GLU 与 Quantile Balancing 保持极高稀疏度下的训练稳定。
- MoonViT-V2：视觉编码器从零开始使用 next-token prediction 训练，无需对比预训练，在达到 SigLIP 初始化基线效果的同时获得更稳定的优化过程。

- 后训练与评估：在通用推理、通用 Agent 和编程 Agent 三大领域进行大规模任务合成，百万 token 上下文的强化学习基建，近 20 个内部评测集的完整评估结果。

以上几点只是概览，详细论述与消融实验，都已在技术报告中展开。

Kimi K3 关键 Infra 技术开源

模型能力背后，离不开训练系统，即 Infra 基础设施层的稳定支撑。今天，我们向大家介绍支撑 Kimi K3 训练的三项 Infra 技术：MoonEP、FlashKDA 和 AgentEnv，覆盖从高性能通信、高性能算子到分布式 RL 环境的关键链路。其中 FlashKDA 此前已开源，MoonEP 和 AgentEnv 则随本次发布正式开源。

- MoonEP：MoonEP 是我们为超大的细粒度 MoE 打造的高性能通信库，让专家并行（expert-parallel）的通信在不均衡的情况下仍然实现极致效率。
- FlashKDA：FlashKDA 是我们实现的 Kimi Delta Attention 高性能算子（kernel）。在英伟达 H20 上，相比 flash-linear-attention 基线，它的 prefill 速度提升 1.72-2.22 倍，可以直接作为 flash-linear-attention 的替换后端。
- AgentEnv：AgentENV 是我们与 KVCache.ai 合作开发的沙箱系统，用于大规模运行 Agent 环境。它为 Kimi K3 的后训练提供高保真、强隔离沙箱，灵活支持快速快照、恢复和分叉（fork）等，可以应对大规模并行的 Agent 工作流与训练任务。

这三项技术是支撑 Kimi K3 训练效率与稳定性的关键。现在将它们开放出来，希望也能为你训练下一代模型提供帮助。

为什么我们选择开放

我们坚信开放权重模型的价值。它们能降低获取智能的门槛，推动创新，并赋予用户对数据更大的控制权、隐私保护和所有权。在过去几周里，我们很高兴听到了许多来自 AI 社区，以及与我们有着共同愿景的技术领袖的支持声音。

我们相信，对于 AGI 这样具有深远影响的技术，一个广泛、开放的生态系统是最适合承载它的土壤。为此，我们将继续贡献自己的力量。

本文来源：[月之暗面Kimi](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

写评论

请发表您的评论



表情



图片

发布评论

3 条评论



见闻用户

43分钟前 中国江苏省

试用后，反应速度赶不上其他App，且经常语音识别错误，有些失望



0



回复



海外新生活 34分钟前 加拿大

回复 见闻用户：

不要和豆包比，没有可比性。不是用来聊天的



0



回复



明天会更好

7小时前 中国四川省

干嘛都开放给美国，不能偷偷藏点技术吗



1



回复

