

摘要：

Kimi K3重磅落地！2.8万亿参数携百万上下文切入复杂Agent生产流，推理负载剧增引爆64卡超节点算力需求。智能跃升带动定价上移，国产大模型正式告别低价内卷，迈向“能力+效率”的商业变现新纪元！

核心观点

7月16日，Kimi更新K3模型，实现2.8万亿参数、100万Token上下文和原生视觉能力，进一步切入长时程编程、知识工作与复杂推理场景。与市场主要关注开放权重与榜单成绩不同，我们更关注其生产案例中数千次网页检索、终端数据调用、递归迭代及多子Agent并行所反映的推理负载变化。Kimi K3建议采用64张以上加速卡组成的超节点部署，表明高带宽互联、推理集群、上下文缓存及Agent基础软件的重要性进一步提升。K3智能的提高直接带来了token定价的提高，进一步强化了国产模型的商业化能力。

模型规模与稀疏架构同步升级，开放模型继续向前沿能力靠拢

Kimi K3参数规模达到2.8万亿，采用Kimi Delta Attention、Attention Residuals及Stable LatentMoE架构，每次推理有效激活896个专家中的16个，并通过训练和数据配方优化，实现相较Kimi K2约2.5倍的整体缩放效率提升。模型同时支持100万Token上下文及原生视觉理解，覆盖软件工程、知识工作与深度推理。市场主流观点更重视参数规模与开放权重，我们认为，KDA、AttnRes及高稀疏MoE对跨卡通信、专家路由和推理软件提出的新要求，或构成更具持续性的国产软硬件适配变化。

长时程Agent工作负载显著扩大，单任务计算消耗可能持续上行

据Kimi官方披露，K3生成AI ASIC行业研究网站时经历120轮以上递归改进，完成2800次以上网页搜索与抓取、1100次以上终端数据调用，处理超过1.1万页内容，覆盖87份季度报告和99份原始PDF；引力波分析案例则调用20个以上并发子Agent处理391个事件。上述任务已由一次问答转向检索、执行、校验、绘图和修改组成的长链路流程。我们认为，Agent渗透带来的核心增量并非用户请求数量本身，而是每个任务内部Token、工具调用次数和并行执行宽度的共同增长，带来真实工作流渗透提升。

智能能力升级推动价格中枢上移，逐步接近海外高端模型

Kimi K3 API缓存命中输入、未命中输入和输出价格分别为\$0.30、\$3.00和\$15.00/百万Token，较Kimi K2系列价格明显提升，反映其产品定位已由低价模型服务转向长上下文、复杂推理和Agent任务驱动的旗舰能力定价。横向比较看，K3价格高于GLM、MiniMax等多数国产模型，国产模型价格中枢正在随智能能力提升逐步向海外水平靠拢。我们认为，K3通过自动缓存和推理系统优化降低实际调用成本，使模型厂商能够在提升名义Token价格的同时维持用户使用门槛，行业商业化竞争正由单纯低价转向模型能力、缓存效率与算力利用率的综合比拼。

投资结论


随着国产模型在长上下文、多模态、工具调用及复杂Workflow执行等方面持续进步，其与海外前沿模型的能力差距正在收窄，模型价值也由单轮问答逐步转向检索、分析、执行、验证和交付等实际工作环节。我们认为，复杂工作能力提升有望增强客户付费意愿，推动API价格中枢、调用量及商业化空间同步改善。



Kimi K3：开放模型向复杂生产任务延伸

Kimi K3以全球参数规模领先的开放模型定位，推动智能能力向生产场景延伸。据Kimi官方博客披露，Kimi K3总参数规模达到2.8万亿，是全球首个达到3万亿参数级别的开放模型，按总参数量计处于当前已公开开放模型的较高水平。模型采用Kimi Delta Attention和Attention Residuals架构，并通过Stable LatentMoE将专家数量扩展至896个、单次推理激活16个专家，结合训练及数据配方优化，相较Kimi K2实现约2.5倍的整体缩放效率提升。Kimi K3同时具备原生视觉能力和100万Token上下文窗口，主要面向长时程编程、知识工作及复杂推理，产品定位由对话模型进一步转向能够持续调用工具、执行复杂Workflow并交付完整成果的生产型智能系统。Kimi K3完整模型权重计划于2026年7月27日前发布，并将同步披露更完整的架构、训练及评测技术报告。

图表 1：开放模型进入万亿参数竞争阶段，Kimi K3 推动国产模型规模迈向 3T 级别




资料来源：Kimi 官网、华泰研究

Kimi K3的Coding能力已进入全球前沿模型梯队，多项复杂工程评测领先海外闭源模型。据Kimi官方评测，Kimi K3在Program Bench中得分77.8，超过GPT-5.6 Sol的77.6和Claude Fable 5的76.8；在Terminal Bench 2.1中得分88.3，接近GPT-5.6 Sol的88.8，并高于Claude Fable 5和Claude Opus 4.8的84.6；在FrontierSWE中得分81.2，较GPT-5.6 Sol和Claude Opus 4.8分别高9.9和14.5；在SWE Marathon中得分42.0，同样超过GPT-5.6 Sol的39.0及Claude Fable 5的35.0。我们认为，Kimi K3在代码理解、终端操作、仓库级修改及长期软件工程任务方面已具备较强竞争力，国产模型Coding能力与海外前沿模型的差距正在明显收窄。

Kimi K3将代码生成延伸至较长周期的工程任务。据Kimi官方披露，模型能够在较少人工干预下持续执行长时间工程任务，浏览大型代码仓库并协调终端工具。在GPU内核优化测试中，各模型可使用不超过24小时，对NVIDIA H200及另一类通用GPU上的四项任务进行分析、重写和测试；Kimi K3在部分任务中表现出较强竞争力，早期版本还承担了研发团队较多内核优化工作。我们认为，代码模型的价值正在由局部补全转向仓库级理解、性能分析和验证闭环，任务持续时间与外部工具调用量的上升将显著扩大单次编程请求的推理负载。

图表2: Kimi K3 多项代码基准位居前列，长周期工程任务表现突出



资料来源：Kimi 官网、华泰研究

原生多模式使视觉信息直接参与代码修改。Kimi K3能够在代码与实时截图之间反复迭代，根据视觉结果调整游戏开发、前端页面和CAD内容。官方案例显示，模型使用Three.js WebGPU和GPU计算构建程序化浏览器3D探索游戏，并结合外部生成工具制作人物与马匹资产，形成包含森林、村庄、雪山和动态天气的开放场景。我们认为，视觉进入执行闭环后，模型不再只生成代码，而是需要持续获取截图、识别问题并重新运行程序，推理调用次数和外部计算任务将随迭代轮数增长。

图表3: Kimi K3 使用 Three.js WebGPU 和 GPU 计算构建了一个完全程序化的基于浏览器的 3D 探索游戏



资料来源：Kimi 官网、华泰研究

图表4: Kimi K3 及国内外主流前沿模型多模态能力与定位对比

公司	模型正式名称	多模态能力	原生多模态能力	支持输入模态	模型定位
月之暗面	Kimi K3	支持	已公开确认	文本、图像、视频	长周期 Coding、知识工作、复杂推理、Agent
月之暗面	Kimi K2.6	支持	已公开确认	文本、图像、视频	Coding、长周期执行、Agent、多模态理解
智谱 AI	GLM-5.2	不属于多模态模型	不适用	文本	1M 长上下文、Coding、复杂推理、长周期 Agent
智谱 AI	GLM-5V-Turbo	支持	已公开确认	文本、图像、视频、文件	多模态 Coding、视觉 Agent、界面理解与操作
MiniMax	MiniMax M3	支持	已公开确认	文本、图像、视频	Coding、Agent、1M 上下文、原生多模态
字节跳动	Doubao-Seed-2.1 Pro / Turbo	官方归入文本生成模型	不适用	文本	通用文本生成与推理；Pro 偏能力，Turbo 偏性价比
阿里巴巴	Qwen3-VL 系列	支持	未明确以“原生多模态模型”定性	文本、图像、视频	视觉语言模型、视频理解、视觉推理、视觉 Agent
Anthropic	Claude Fable 5	支持	未公开明确确认	文本、图像	长周期 Agent、Coding、企业知识工作、视觉理解
OpenAI	GPT-5.6 系列（Sol / Terra / Luna）	支持	未公开明确确认	文本、图像	Coding、专业知识工作、复杂推理、科学、设计、计算机操作

资料来源：各公司官网、官方技术报告及开发者文档、华泰研究

图表 5: 国内主流 MoE 模型专家路由架构对比

模型	总参数量	Expert 数量	Top-K 激活	激活比例	激活参数	架构特点
Kimi K3	2.8T	896	16	1.79%	未披露	Stable LatentMoE, 高稀疏 MoE 架构
Kimi K2	1T	384	8	2.08%	32B	MoE + MuonClip 训练优化
DeepSeek V3	671B	256 Routed Experts + 1 Shared Expert	8 Routed + Shared Expert	3.13% (按 Routed 计算)	37B	DeepSeekMoE, MLA 注意力
MiniMax M3	428B	128	4	3.13%	≈23B	Sparse MoE + MiniMax Sparse Attention
GLM-5.2	≈750B	256	8	3.13%	≈40B	MoE + DSA + MLA
Qwen3-235B-A22B	235B	128	8	6.25%	22B	Pure Routed Experts
Qwen3-30B-A3B	30B	128	8	6.25%	3B	小型高稀疏 MoE


资料来源：各公司官网、官方技术报告及开发者文档、华泰研究

架构升级：稀疏化与信息流优化并行推进

Kimi K3通过注意力机制和残差结构调整改善规模扩张效率。模型采用Kimi Delta Attention与Attention Residuals作为架构骨干，其中KDA用于提升注意力在长序列条件下的计算效率，AttnRes则在不同网络深度之间选择性检索历史表征，而非对多层信息进行统一累积。配合训练方法和数据配方优化，官方测算Kimi K3相较Kimi K2实现约2.5倍的整体缩放效率提升。我们认为，在参数规模持续增加的背景下，单纯依靠计算资源扩张的边际效率可能下降，注意力计算、跨层信息流和数据配方将共同决定训练投入向模型能力转化的效率。

高稀疏MoE降低有效计算量，但提高专家并行复杂度。Kimi K3采用Stable LatentMoE，在896个专家中有效激活16个专家，激活比例约为1.8%。为应对高稀疏度条件下的路由和负载均衡问题，模型引入Quantile Balancing，根据路由分数量化分位数直接分配专家，减少启发式更新及敏感超参数；Per-Head Muon则对不同注意力头独立优化，SiTU和Gated MLA分别用于改善激活控制与注意力选择。我们认为，MoE能够控制单次推理有效计算量，但专家数量提升后，负载均衡、跨设备通信和调度效率对集群利用率的影响将进一步扩大。

图表 6: Kimi K3 以 KDA、Stable LatentMoE 及注意力残差构建高效稀疏架构



资料来源：Kimi 官网、华泰研究

多代技术持续复用与迭代，Kimi K3体现较强的技术积累效应。月之暗面自2024年推出Mooncake分离式推理架构后，持续围绕超大模型训练与长上下文推理完善技术体系：2025年Kimi K2通过MoE与MuonClip验证万亿参数模型的稳定训练，随后推出Kimi Linear及KDA，以降低长上下文计算量和KV Cache占用；2026年又通过Attention Residuals改善超深网络的信息传递。Kimi K3进一步将上述技术与Stable LatentMoE、专家负载均衡及量化感知训练相结合，实现2.8万亿参数规模和100万Token上下文，并使整体缩放效率较K2提升约2.5倍。我们认为，K3的能力提升并非单次堆叠参数，而是模型架构、训练方法和推理系统持续积累的结果，技术复用有望缩短后续模型迭代周期，并提升API定价及商业化效率。

图表 7: Kimi K3 核心技术演进路径——从推理基础设施到超大规模模型架构

技术	首次公开时间	技术核心内容	在 Kimi K3 中的作用
Mooncake	2024 年 6 月	以 KV Cache 为中心,将 Prefill 与 Decode 集群分离,并利用 CPU.DRAM 支撑自动上下文缓存和长上下文推理, K3 编码场和 SSD 构建分布式缓存池, 通过调度器兼顾吞吐与时延。论文显示, 景缓存命中率超过 90%, 降低实际输入成本。真实负载下可使 Kimi 多处理 75% 的请求。	
Kimi K2 MoE 与 MuonClip	2025 年 7 月	Kimi K2 采用 1 万亿总参数、320 亿激活参数的 MoE 架构, 并提出 为 K3 进一步扩大专家规模、提升稀疏度和稳定训练 MuonClip 优化器, 通过 QK-Clip 缓解超大模型训练不稳定问题, 实现 训练奠定基础。	
Kimi Linear 与 KDA	2025 年 10 月	KDA 是一种高效线性注意力机制, 通过更细粒度的门控改善有限状态记忆成为 K3 长上下文注意力架构基础, 并与 Prefill 记忆:在 100 万 Token 上下文,实验模型 KV Cache 占用最多降低 75%, Cache 结合控制百万 Token 上下文的推理成本。解码吞吐量最高提升至 6 倍。	
Attention Residuals	2026 年 3 月	改变传统残差连接对各层输出等权重累积的方式, 通过注意力机制按输入改善超大模型在深度方向的信息流动, 与 KDA 分动态选择此前层或模块的表征, 缓解模型加深后的信息稀释问题。 别解决序列长度和网络深度方向的扩展问题。	
Stable LatentMoE 等 K3 架构	2026 年 7 月	K3 将专家数量扩展至 896 个、每个 Token 激活 16 个, 并引入 Quantile 支撑 2.8 万亿参数规模, 结合 KDA 和 AttnRes, Balancing, Per-Head Muon、静态专家并行及关键路径无主机同步等机制使整体缩放效率较 K2 提升约 2.5 倍。	

资料来源: Kimi 官网、华泰研究

Kimi K3明确提出64张以上加速卡的超节点部署建议。据Kimi官方披露，大规模模型推理效率受益于更大的高带宽通信域，因此建议在拥有64张或更多加速卡的超节点环境中部署Kimi K3。该要求意味着模型虽然每次仅激活部分专家，但在百万Token上下文、长时程执行和专家并行场景下，仍需要较强的设备间通信、显存管理及任务调度能力。我们认为，推理基础设施的竞争指标正在从单卡算力扩展至超节点内部互联、共享内存域、集合通信效率和系统级稳定性，高速网络与整机系统价值量有望随模型规模同步提升。

商业化：缓存效率成为低价长上下文服务的关键

智能能力提升推动API价格中枢上移。Kimi K3缓存命中输入、未命中输入和输出价格分别为\$0.30、\$3.00和\$15.00/百万Token，较Kimi K2.6明显提价，并高于GLM-5.2和MiniMax-M3；其中输出价格已与GPT-5.6 Terra相当，但仍低于GPT-5.6 Sol和Claude Fable 5。我们认为，随着长上下文、多模态和复杂Workflow能力提升，国产模型定价正由低价竞争逐步转向能力定价。

系统级优化降低实际调用成本，支撑API提价后的商业化效率。Kimi平台对常规模型请求自动启用上下文缓存，缓存命中输入价格仅为未命中的十分之一；据Kimi官方披露，Mooncake分离式推理架构使编码工作负载缓存命中率超过90%。同时，Kimi K3通过Prefill与Decode分离、KDA前缀缓存、静态专家并行、关键路径无主机同步及专家负载均衡等方式，提高长上下文和高稀疏MoE场景下的集群利用率。我们认为，模型竞争正由单纯比较Token报价，转向缓存复用、显存管理、算力调度及集群吞吐效率的综合竞争。

图表 8: Kimi K3 百万 Token 长上下文定价具备竞争力，输入成本低于主流闭源模型

模型	上下文窗口	缓存命中输入	未缓存输入	输出
Kimi K3	1M	0.3	3	15
Kimi K2.6	256K	0.16	0.95	4
GLM-5.2	1M	0.26	1.4	4.4
MiniMax-M3（输入≤512K）	1M	0.06	0.3	1.2
MiniMax-M3（输入>512K）	1M	0.12	0.6	2.4
GPT-5.6 Sol（输入≤272K）	1.05M	0.5	5	30
GPT-5.6 Sol（输入>272K）	1.05M	1	10	45
GPT-5.6 Terra（输入≤272K）	1.05M	0.25	2.5	15
GPT-5.6 Terra（输入>272K）	1.05M	0.5	5	22.5
GPT-5.6 Luna（输入≤272K）	1.05M	0.1	1	6
GPT-5.6 Luna（输入>272K）	1.05M	0.2	2	9
Claude Fable 5	1M	1	10	50

资料来源: Kimi 官网、华泰研究

风险提示

宏观经济波动。若宏观经济波动，可能对AI产业资本投入产生负面影响，导致AI产业变革、新技术落地节奏、整体行业增长不及预期。

技术进步不及预期。若AI技术、大模型技术、AI应用进展不及预期，或对行业落地情况产生不利影响。

中美竞争加剧。中美竞争加剧，或影响国内算力基础设施布局，导致国内AI大模型技术迭代速度放缓。



风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 0  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论