

摘要：

月之暗面企业业务负责人黄震昕：三项自研底层技术带来K3性能跃升，期待和马斯克“掰手腕”；幻觉于创造力同源，无法完全避免，“K3已是幻觉很少的模型”。针对暂停新会员开放一事，其表示，目前尚未有明确的时间表。

7月21日，月之暗面Kimi在北京办公区举行媒体交流活动。活动上，围绕备受关注的K3与月之暗面后续的商业规划，月之暗面企业业务负责人黄震昕首次进行了全面回应。

就在四天前，Kimi官宣布发布全新开源大模型K3，总参数2.8万亿，具备100万Token上下文窗口。该模型在测试中，其综合智能水平仅次于Claude Fable 5和GPT-5.6 Sol。马斯克留言称“令人印象深刻”，更有多家外媒和研究机构将之称为“DeepSeek2.0时刻”。

## 底层技术创新：期待和马斯克“掰手腕”

作为首款参数量接近3万亿的开源大模型，此次发布后的K3，凭借其优秀的性能，迅速在全球科技圈内引发关注。OpenAI战略负责人DeanW.Ball用“K3性能优异，无法依靠蒸馏实现”的评价来回应西方的质疑。

此次交流上，黄震昕也明确表示，K3性能跃升来自底层原创架构创新。

黄震昕重点介绍了三项自研技术。

第一项MoonClip二阶优化器，由Kimi首次应用于大模型训练。黄震昕表示：“当前全球可用训练数据基本见底，这项技术能让20T训练数据跑出40T的效果，同等性能下训练成本、算力功耗直接减半。”

第二项KimiLinearTension线性注意力机制，解决了传统线性注意力处理超长任务时性能衰减的痛点，使得上下文窗口扩大十倍，训练成本仅同步扩大十倍。

第三项AttentionResiduals（注意力残差）优化多层网络间信息传递，让2.8万亿超大参数模型在稳定训练的同时推理效率提升25%。

“这三个东西加在一起——LongContext决定了模型的干活时长，TokenEfficiency决定了模型的聪明程度，AgentSwarm决定了模型之间如何协作。所有技术创新都围绕这三个点展开。”黄震昕说道。

对于马斯克称Grok4.5有望超越K3的表态，黄震昕笑称：“拭目以待。”

## 幻觉之辩：创造力的“同源产物”

此次新发布的K3最引人瞩目的性能便是其长时间执行复杂任务的能力，在此前官方演示的案例中就包含了游戏制作、深度报告撰写等多种复杂任务。

例如，在一份覆盖推理芯片行业42年历史的研究项目里，K3经过120多轮递归自我改进，最终生成。

从成品效果来看，K3将证据转化为定制图表、动画示意图和交互式视觉叙事。整个过程中，它完成了2800多次网页搜索与抓取、1100多次终端数据拉取，处理了87份季报和99份原始PDF，合计超过11000页资料。

不过，相比于炫酷的最终效果，在现场交流中，不少媒体则更关心此类复杂项目中AI幻觉问题的处理。

对此，黄震昕坦言，模型幻觉目前无法完全避免，但“幻觉本质是模型创造力的同源产物”。同时他表示，模型越强，幻觉比例越低，“K3已是幻觉很少的模型”。

如何解决幻觉问题，现场他对K3的技术做了简单的介绍：基于AgentSwarm架构，系统会安排三个Agent分别撰写内容，再由一个专门的“事实校验员”子Agent逐项校验数据。

但黄震昕也承认，幻觉只能降低、无法杜绝，因为从机制来看，模型的幻觉来源也是其创造力来源。“因为人说的话也有幻觉，我们也会搞错。”他说道。

## 算力缺口：宁弃新增收入，守住体验底线

就在K3发布后的7月19日晚间，月之暗面官方突然发布公告，表示由于算力需求逼近峰值，将暂停新会员的开放。

此次交流活动上，黄震昕坦言K3上线后的火爆程度远超团队预期。

“团队提前做了流量预案，但实际火爆程度远超预期，最终不得不暂停新用户注册。”他还还原了决策时的两难：放开新用户注册会伤害存量付费老用户体验；优先保障付费客户则需限制新注册。公司选择了后者。

“宁可暂时放弃新增收入，也要守住付费客户的使用体验底线。这是公司的价值观。”他说道。

对于后续何时能够重新开放新会员注册，黄震昕表示，公司正通过模型效能优化和算力供给尽快解决问题，但目前尚未有明确的时间表。

## 开源并非低价，回应“减速主义”论调

K3发布后，开源与闭源的路线之争再度发酵。OpenAI高管更是将这种开源大模型定义为“减速主义”，认为开源会降低前沿模型商业回报、削弱行业研发投入意愿。

此次交流上，黄震昕表示开源与闭源并非对立关系，二者与模型质量高低并无绑定关系。他进一步强调，开源模型本身也意味着商业回报上的低价。

“我们摆脱了‘开源模型就是要做便宜的、低价的’这样的印象。我们在全球市场上真正做出了SOTA级别的模型，定价不是朝便宜去定的。K3在全球范围内供不应求。”

记者注意到，在高盛最新的研报中，团队认为Kimi K3标志着中国模型走向定价权的全新节点；摩根士丹利评价称，K3证明中国大模型在规模、性能、定价层面美国头部模型实现“全方位追赶”。

Kimi自K2起持续坚持开源路线，黄震昕表示这一路线未来不会改变，核心底层技术与论文均对外公开。



## 商业化路径：不做私有化，对标海外成熟模式

在商业化策略上，黄震昕透露，Kimi现阶段不提供私有化部署服务，商业模式对标海外成熟头部AI企业，核心发力打磨模型基础能力。收入结构中API业务占比最高，约70%，主要来自数据平台类客户。

此前记者获悉，截至6月中旬，月之暗面ARR（年度经常性收入）突破3亿美元。这是继今年3月ARR突破1亿美元、5月突破2亿美元后，Kimi商业化进程的又一重要节点。

谈及面对海外头部模型公司的竞争，黄震昕表示，全球模型公司在商业化方面已找到一条可行路径，Kimi在产品创新上持续投入，包括AgentSwarm路由在行业做Agent之前就已经做出来。“我们还是希望从产品驱动，然后设计不同的商业模式，打造出非常有竞争力的产品。”

黄震昕同时透露了Kimi长期的产品“审美”取向：不布局娱乐、文生图、文生视频赛道，长期聚焦编程、金融、法律、科学研究等高难度生产力场景。“大模型里1%的数据会影响整个模型的审美。我们所有做的事情都是围绕审美或价值观去奋进的。”

对于参数规模是否持续增长，他给出肯定回答：“大模型参数规模会持续向上拓展，不会止步于当前2.8万亿规模。”

本文来源：[上海证券报](#)

### 风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 限时权益申领

\* 体验资格每人限申领一次

扫码 >  
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 137    ★ 收藏

分享到:  

### 写评论

请发表您的评论

 表情     图片

发表评论

