

From: 陸行之 Andrew Lu on global semis and techs <andrewhclu@substack.com>
Subject: LLM tokens price war accelerates? Who win, lose, and what turning signs to check?
Date: 1 hour ago

OpenAI, Anthropic 同步大幅降推理模型Tokens價，贏家，輸家是誰？價格戰下，我們在觀察哪些產業鏈指標變化？

[View in browser](#)

LLM tokens price war accelerates? Who win, lose, and what turning signs to check?

OpenAI, Anthropic 同步大幅降推理模型Tokens價，贏家，輸家是誰？價格戰下，我們在觀察哪些產業鏈指標變化？

[Andrew Lu on global Semi/Techs](#)

Sep 22 · Paid



[READ IN APP](#) ↗

Executive summary

在我們9月18日的報告中（[17-21% On-demand AI GPU pricing hike to shift value from LLM companies to cloud vendors](#)），Nebius 10/1 全面調漲 Nvidia AI GPU，CPU，Memory 租用價格，我們認為短期市場價值將從賣 tokens 的大語言/專家語言模型公司轉到 AI 數據中心算力基礎建設公司。而今天 OpenAI 正式發布 GPT-6 家族平價主力「GPT-6 Sol」與「GPT-6 Luna」，官方價格永久腰斬，Perplexity 設為預設引擎，同一時間，Anthropic 推出 Claude Opus 5.5 新模型，價格比前代Opus 5.0低20%，閉源帝國打響狙擊開源模型的生死戰，這更加强了我們之前擔心的市場價值轉移。

What's new?

9月22日晚間至23日晨間，OpenAI 正式宣布擴展其旗艦 GPT-6 產品線，同步發布中階核心主力「GPT-6 Sol」與輕量級高頻模型「GPT-6 Luna」。不同於業界常見的限時促銷，OpenAI 發言人向科技媒體證實，此次降價為「永久性結構降價」：

- GPT-6 Sol 定價為每百萬 Tokens 輸入 US\$2 / 輸出 US\$10 (vs. US\$4/US\$20 for GPT-5.6 Sol 砍了一半)，相較 Astra 的 \$10/\$50 暴降 80%，性能在各項基準測試

中填補了與 Astra 絕大部分差距，專攻企業複雜 workflow、代碼審查與即時數據分析；

- GPT-6 Luna 定價僅為輸入 \$0.1 / 輸出 \$0.5 (vs. US\$0.2/US\$1.2)，專攻文本摘要與快速萃取，直接將價格殺入中國大陸開源模型 DeepSeek V4.1-Flash 的主陣地。

受此震撼性降價推動，新一代 AI 搜尋巨頭 Perplexity 宣布立即在其全新的「Effort Mode」中將 GPT-6 Sol 設為預設推論模型。這標誌著 OpenAI 在開源陣營（DeepSeek、Qwen）與 Google Gemini 降價夾擊下，首次在旗艦世代發動全面反攻。

但就在同一天，Anthropic 推出 Claude Opus 5.5，input/output 價格為 US\$4 / US\$20，每百萬 tokens，較 Opus 5 低 20%。公司稱執行成本較前代低 40%，成本約 Opus 5 的 1/3，並稱其在軟體開發 benchmark 勝過 GPT-5.6 Sol（雖然與 GPT-5.6 Sol 同價，但卻明顯高於 GPT-6 Sol 的半價輸入 US\$2 / 輸出 US\$10）；同時宣稱越界逃逸傾向較 Opus 5 或 Mythos 5.1 低約 85%。模型已上 AWS、Google Cloud 與 Azure；Sonnet 5.5、Haiku 5.5 預計數週內推出。benchmark、安全與成本仍是公司口徑，需等獨立原始測試。

付費訂閱客戶可分享閉源，開源大語言模型價格開打，有贏家，輸家嗎？及我們 Outside the box non consensus thinking，建議及風險

✓ [Subscribed](#)

Who will be the winners ?

全球推論流量聚合龍頭與終端 AI 應用商（Perplexity、Cursor、Replit）：降價幅度達 50% 至 80%，使下游應用商在不增加預算的前提下將智能水平躍升至 GPT-6 級別，大幅改善下游單元經濟效益（Unit Economics）。

Amazon AWS、Google Cloud、Microsoft Azure：取得同步分銷流量推理引擎、KV-cache、低精度運算、HBM 與高速網路供應商受惠於更低每任務成本帶來的需求彈性。模型治理、紅隊測試與可觀測性廠商亦受惠於高階模型擴大至資安與生命科學用途。

AI 算力出租外溢雲公司：大語言模型巨頭 Anthropic 及 OpenAI 要靠著不斷的增加租用高階算力來降本增效，這讓 AI 數據中心算力公司不斷拉高每 GW 年度算力營收，最近外溢雲 Nebius 就陸續調高其 H100 每小時租用算力達 16.9%，B300 調高達 21%，CPU 調高 25%，存儲記憶體調高 41%。

高能效推論伺服器供應商（台積電 TSMC、鴻海、緯創、廣達 Quanta）：超低 Tokens 價格將引爆企業級 API 調用量呈數十倍爆炸式增長，拉動對 AI 推論專用伺服器機櫃的硬體採購需求。

Who will be the losers?

推論輸出定價高於 US\$10 每百萬 Tokens，但性能無法顯著拉開差距的中階閉源模型（Anthropic Claude Sonnet 5、Google Gemini 3.1 Pro）。在 GPT-6 Sol 每百

萬 Tokens 輸出僅收費 \$10.00 的強勢壓制下，二線高價模型的市場份額面臨直接流失風險。

缺乏底層架構優化、純靠補貼燒錢的中小型模型團隊：在 OpenAI 憑藉萬卡級推論集群實現規模降價後，中小模型初創企業的價格防線被徹底擊穿。

Our outside the box non-consensus thinking

市場可能將這次降價視為 OpenAI 面對 Anthropic 及 DeepSeek 的被動防禦性降價。非共識深度洞察在於，這是 OpenAI 憑藉龐大資本在推論端發動的存量清洗與開發者圈地戰。此前的 GPT-6 Astra 定位過高（每百萬輸出 Tokens 50 美元），使得大量企業因成本顧慮轉投開源或混合部署；如今 OpenAI 將接近 Astra 能力的 GPT-6 Sol 壓到 \$10、GPT-6 Luna 壓到 \$0.50，實質上抹平了企業自建開源集群的成本優勢。如果企業調用 OpenAI 商業 API 的綜合成本低於自購 GPU 機櫃與維護人員工資，企業將迅速放棄私有化部署轉向全託管 API。這是在為其後續萬億美元估值的 ARR 爆發進行築底鎖客。

但如果價格降 50%、擴大 AI 推理算力成本降 50%，毛利率不變，但 Tokens 使用數要遠超過倍增才能有增量成長。因此真正的競爭武器可能不是低價，而是以部分效率紅利換量、同時擴大利潤池；但前提是執行成本涵蓋相同品質、相同延遲與完整安全成本。

Our advises and risks to our analysis

目前看來中國大陸開源模型，跟美國閉源模型的每百萬 Tokens 價格戰尚未停歇，這肯定會抵銷 Tokens 使用增量所帶來的營收增長，也可能會影響未來 Anthropic 及 OpenAI 上市後的財務狀況及估值，但另一方面來看，目前看起來 AI 算力出租及雲服務公司每 GW 創收能力還算穩定，在手訂單數倍於未來 4 年營收累積，雖然在手訂單有許多重複下單，也取決於大語言模型公司是否繼續創新，但目前情況仍相對穩定，AI 數據中心基礎建設及半導體產業供應鏈相對受惠，技術更新（NPO，CPO，HBM4/5，大尺寸 ABF 載板，防翹曲，CoPoS，High NA EUV 12“光罩）所驅動的缺料漲價將持續。

但風險方面，我們會密切關注大語言模型的價格戰是否仍為擴大市場的動力，還是需求衰退的前兆，在手訂單的轉惡化是否是調整半導體產業鏈的訂單的前兆。最後就是持續關注每 1GW 算力及每 100 億美元投資所產生的營收的變化是否有加速或減速的現象。

免責聲明/Disclaimer：本人僅提供公司/產業及財務分析的專業看法，僅供參考，並非投資建議，個人應審慎評估風險，如因此造成任何損失，本人不負任何擔保責任；We are here to provide our professional opinions on company and industry analysis but not the investment advice. The use of the information contained in this material is at your own risk. We make no guarantees and assume no responsibility or liability for any information on the report.

Invite your friends and earn rewards

If you enjoy Andrew Lu on global semis and techs, share it with your friends and earn rewards when they subscribe.

[Invite Friends](#)

 [Like](#)  [Comment](#)  [Restack](#)

© 2026 Andrew Lu

548 Market Street PMB 72296, San Francisco, CA 94104

[Unsubscribe](#)

 **Start writing**