摘要：

Marvell发布第二代CXL内存扩展器，单控制器最高支持9TB DDR4或6TB DDR5内存，压缩吞吐量提升至250GB/s，旨在缓解大模型推理的内存瓶颈，并提升AI基础设施效率。AMD、Arm、阿里巴巴、三星及SK海力士等参与生态合作，新产品预计于2027年一季度提供样品。

Marvell正通过更大容量、更高带宽的内存扩展方案，瞄准AI推理基础设施升级带来的需求增长。

据彭博报道，10月12日，**Marvell正式发布第二代Structera X 3406和3506 CXL内存扩展器。公司称，这是业界首款六通道CXL 3.2内存扩展器，单控制器最高支持9TB DDR4或6TB DDR5内存，内存通道数量较上一代增加50%。**两款产品预计于2027年第一季度开始向客户提供样品。

此次发布旨在应对AI推理工作负载日益突出的内存瓶颈。随着大型语言模型（LLM）规模扩大、上下文窗口延长以及KV缓存需求快速增长，传统服务器架构的内存容量与带宽正面临更大压力，内存逐渐成为制约AI性能和基础设施效率的关键因素。

AMD、Arm、阿里巴巴、三星和SK海力士等企业均对新产品及相关生态合作表示支持。

核心技术升级：更多通道，更大容量

Structera X 3406和3506在上一代产品基础上实现了内存通道、扩展容量及压缩性能等方面的升级。

在内存配置方面，两款产品均支持六通道内存。其中，3406支持18个DDR4 RDIMM插槽，最高容量达9TB；3506支持12个DDR5 RDIMM插槽，最高容量为6TB。在主机互联方面，两款产品均支持最多四台主机共享内存资源，主机互联带宽最高可达256GB/s，采用PCIe 6.0 x16接口。

在压缩性能方面，新产品内置LZ4压缩引擎，压缩和解压缩吞吐量最高达250GB/s，较上一代提升5倍，可将有效内存容量扩大至原来的2至3倍。

Marvell表示，在大型语言模型推理场景中，新产品可在相同上下文长度下，将首字节响应时间（TTFT）缩短40%至50%；在深度学习推荐模型（DLRM）场景中，单控制器每秒查询量最高可提升至原来的2倍，嵌入表有效容量则可扩大至原来的2至3倍。

瞄准超大规模数据中心，生态合作持续扩展

Marvell表示，第二代Structera X沿用已向超大规模数据中心客户出货的第一代2404/2504产品的软件栈和生态集成方案，旨在加快新产品的客户导入进程。

多家行业伙伴公开表达了支持。AMD企业副总裁Raghu Nambiar表示，双方的合作依托EPYC处理器的性能与可扩展性，帮助企业在AI和数据密集型应用需求增长的背景下扩展内存容量、提高资源利用效率。

Arm云端AI go-to-market副总裁Eddie Ramirez表示，Structera X将CXL 3.2、内存扩展和压缩能力引入Arm生态，为超大规模数据中心高效运行复杂AI工作负载提供更多选择。

三星电子内存产品规划副总裁Jangseok Choi和SK海力士下一代产品规划与使能负责人Uksong Kang则表示，双方已分别与Marvell完成Structera产品与各自DDR内存的验证。

完善CXL产品组合，布局内存池化与分解架构

Marvell客制化云端解决方案执行副总裁兼总经理Will Chu表示，公司是业内唯一提供完整端到端CXL产品组合的供应商，产品覆盖多个层级：用于内存扩展的Structera X、用于近内存加速的Structera A，以及面向机柜级CXL内存共享的PFMA（Photonic Fabric™ Memory Appliance），覆盖从直连内存扩展到内存池化与分解的不同应用场景。

市场研究机构Objective Analysis总经理Jim Handy指出，CXL正逐步应用于AI系统，其高带宽、大容量特性有望带来显著收益。**他还表示，在内存供应紧张、价格高企的背景下，IT管理者正考虑利用CXL在DDR5系统中复用DDR4内存模组，以降低成本；具备内存压缩功能的控制器则有望进一步增强这类方案的吸引力。**

Structera X 3406和3506将于10月12日至15日在加州圣何塞举行的OCP全球峰会上亮相，正式样品预计于2027年第一季度推出。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

63 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论