

摘要：

与闲置率较高的聊天机器人不同，Meta Muse等智能体的“始终在线”特性使其对算力的消耗呈数量级增长。花旗预计，这一趋势将使CPU-GPU配比从训练期的1:8向1:1演进，推动2030年CPU市场规模达3000亿美元。同时，仅1亿Muse日活用户就可能为英伟达带来最高190亿美元的GPU收入。

随着Meta Muse等个人AI智能体的发布，AI正从被动响应的聊天机器人向全天候自主运行的智能体演进，这或将推高对CPU、GPU、内存及网络基础设施的消耗。

据花旗10月6日最新发布的研究报告，以Meta Muse为代表的智能体应用，正将计算硬件的市场预期推向新高度。该行预计，到2030年，全球CPU总潜在市场规模（TAM）将从2025年的290亿美元扩张至3000亿美元，年复合增长率高达60%。

在GPU端，智能体同样带来了结构性的增量需求。该行测算，若Meta Muse达到1亿日活跃用户，将需要约20万至39万块Blackwell级别的GPU，这可能为英伟达带来70亿至190亿美元的一次性收入。

这一趋势直接利好核心算力供应商。该行指出，由于Meta是AMD服务器业务的最大客户之一，AMD将成为CPU复兴的主要受益者，其目标价被上调至800美元；同时，英伟达也将因GPU需求激增而持续获益。

智能体崛起，CPU成为新瓶颈

在智能体AI爆发之前，CPU主要局限于传统工作负载和作为AI应用的头节点（Head Node）。在头节点中，CPU仅负责“管理”，将用户请求发送给GPU并返回结果，繁重的矩阵乘法和推理工作由GPU承担。

然而，智能体改变了这一分工。花旗在报告中指出：“相比传统的聊天机器人，我们认为智能体AI是计算需求潜在的呈数量级增长的驱动力。”智能体需要处理编排、推理循环、数据处理和安全组件，这使得CPU成为了新的瓶颈。

随着AI从模型训练转向推理，再转向智能体自主工作流，CPU与GPU的配比正在发生显著变化。在模型训练阶段，这一比例为1:8；在推理阶段为1:4；而在智能体AI中，这一比例正向1:1甚至更高水平演进。该行预计，到2030年，专用于智能体的CPU将以247%的年复合增长率增长，占据整个CPU市场52%的份额。

Figure 1. Citi Updated CPU TAM Model

TAM Estimates (\$M)	C25	C26E	C27E	C28E	C29E	C30E
General Purpose CPU	\$20,544	\$27,777	\$34,545	\$38,989	\$48,121	\$64,488
% of Total	71%	54%	35%	28%	24%	21%
YoY		35%	24%	13%	23%	34%
AI Headnodes	\$8,185	\$12,549	\$27,856	\$36,188	\$55,938	\$78,086
% of Total	28%	24%	28%	26%	28%	26%
YoY		53%	122%	30%	55%	40%
Agentic CPU Applications	\$311	\$11,591	\$37,637	\$62,842	\$98,447	\$157,426
% of Total	1%	22%	38%	46%	49%	52%
YoY		3627%	225%	67%	57%	60%
Total	\$29,039	\$51,917	\$100,038	\$138,018	\$202,506	\$300,000
YoY		76%	35%	24%	30%	18%

© 2026 Citigroup Inc. No redistribution without Citigroup's written permission.
Source: Citi Research, Mercury Research



Meta Muse的GPU算力账本

Meta Muse是首个在真正社交网络规模上发布的消费者AI智能体，其计算足迹是目前AI基础设施中最重要的变量之一。与标准聊天机器人不同，Muse作为自主智能体持续运行，其底层逻辑决定了它对GPU的消耗更为庞大。

花旗构建了自下而上的GPU需求模型。在基准情形下，假设典型用户每天进行4次简单请求和12次智能体任务（如寻找餐厅、核对日历并起草邀请函），每个智能体任务包含约8次模型调用。由于模型在调用之间没有记忆，它必须每次重新读取不断增长的对话上下文。

基于此，该行测算每位Muse用户大约需要0.0020块GB200级别的GPU。简而言之，一块GPU大约只能服务500名用户。该行强调：“智能体在结构上是比聊天机器人更繁重的推理工作负载。”在相同的框架下，聊天式用户所需的GPU容量仅为智能体用户的12.5%至25%。

Figure 2. MUSE User GPU Estimate

MUSE User GPU Estimate				
Users served by one GPU	users	498	377	254
Users served by one NVL72 rack (72 GPUs)	users	35,867	27,176	18,305
GPUs per 1,000 users	GPUs	2.0	2.6	3.9
GPUs per 1 million users	GPUs	2,007	2,649	3,933
Share of GPUs spent writing (decode)	%	70%	70%	70%

© 2026 Citigroup Inc. No redistribution without Citigroup’s written permission.
Source: Citi Research

内存与网络的连锁反应

智能体工作流不仅对逻辑芯片提出更高要求，其连锁反应也蔓延至内存和网络领域。在内存方面，CPU对LP、DDR和SSD有很高的附加率。美光近期指出，以Meta Muse为代表的智能体工作流正在让消费者获取更多价值，而CPU正对DRAM造成更多限制。

在网络端，智能体AI实质性地增加了网络流量。英伟达管理层在与花旗的沟通中表示：“智能体可以持续运行数小时或不间断运行……从而在消费者和企业工作负载中驱动多得多的Token生成。”

这种持续运行意味着，越来越多访问基础设施的是智能体而非人类。这推动了数据中心内部“南北向”流量（如存储访问、安全、配置等服务）的增长，从而为使用DPU（如BlueField 4）和Spectrum-X以太网创造了新的加速机会。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

148 收藏

分享到:

写评论

请发表您的评论





表情



图片

发布评论

