

摘要：

据报道，英伟达正全力研发至少达1万亿参数的开源模型Nemotron 4，旨在降低对OpenAI等头部客户及云巨头的依赖。公司不仅通过回租服务器将云服务算力承诺大幅增至280亿美元，还组建了包括Mistral、Cursor等在内的“Nemotron联盟”共建生态。英伟达周二发布300亿参数、30亿活跃参数的模型Nemotron 3.5 Lightning及开源模型路由库NeMo Switchyard，分别主打高效智能体执行与多模型智能调度。戴尔宣布扩大与英伟达合作，将英伟达官宣的这两项技术纳入Deskside Agentic AI，推动智能体向企业本地部署延伸。

英伟达正在加速向开源AI模型的前沿竞争发起冲击，试图以此扩大GPU需求——尽管这一策略同时将其推入与自身客户和投资对象正面竞争的微妙处境。

The Information本月11日周二报道称，英伟达目标是将Nemotron 4最大版本的性能打造至与全球顶尖开源模型比肩的水准。多名员工透露，**该模型参数量预计至少达到一万亿——约为其现有最大模型Nemotron 3 Ultra的两倍**。英伟达生成式AI副总裁Kari Briski在一封邮件中表示，“英伟达投资Nemotron，是因为我们相信每家企业、每个国家都需要可及的前沿开源模型。”

英伟达当前的芯片需求高度集中于OpenAI、微软、SpaceX等少数前沿实验室和云服务商，而上述机构正日益布局自研AI芯片。Nemotron 4的推进旨在将需求基础拓展至更广泛的企业用户群体，从而降低英伟达对头部客户的依赖。AI模型评测机构Arena的首席执行官Anastasios Angelopoulos表示，“无论哪家公司做出优秀的开源模型，英伟达都是赢家。”

消息传出后，英伟达股价在美股盘前涨近2%，但开盘后高开低走，盘初曾涨超2%，午盘转跌。

传出消息当天，英伟达官宣面向长期运行AI智能体（Agent）的Nemotron 3.5 Lightning，并推出开源模型路由库NeMo Switchyard，显示该司在加快Nemotron模型生态布局。戴尔同日宣布扩大与英伟达的合作，将这两项技术纳入Dell Deskside Agentic AI平台，推动智能体在企业本地及桌面端部署。

从万亿参数级前沿模型，到30亿活跃参数的高效智能体模型，再到模型路由和企业本地基础设施，英伟达正在形成一条从**模型、软件到部署平台**的完整AI生态链。此次Nemotron 4的研发消息，也意味着英伟达不再满足于做全球最大的AI芯片供应商，而是在向开源模型领域的顶级玩家发起正面竞争。

千亿参数目标，算力投入三倍跃升

据多名参与Nemotron项目的员工透露，**英伟达计划开发的最大规模Nemotron 4模型参数量至少达到1万亿，约为其今年6月发布的现有最大模型Nemotron 3 Ultra的两倍**。该模型参数规模仍将远低于中国头部开源模型，但英伟达同时强调其压缩技术可使较小模型实现超越性的性能表现。

在算力投入层面，英伟达的决心体现于其资金承诺的大幅扩张。据悉，该公司通过向购买其芯片的云服务商回租AI服务器获取算力。截至今年4月，英伟达多年期云服务承诺的总价值已增至2031年初的280亿美元，约为一年前披露金额的三倍。其中针对本财年（截至2028年1月）的相关支出约为70亿美元，虽远低于OpenAI和Anthropic的投入规模，但已超过绝大多数美国和中国领先开源实验室的历史融资总额。

在研发人员规模上，Nemotron项目同样持续扩张。英伟达上一个重要模型的研究论文署名作者多达570人，多名员工表示Nemotron 4的参与人数将更多。“现在每个人都想参与进来，”一位前员工说。

组建"Nemotron联盟"，广纳开源生态伙伴

为加速Nemotron 4的研发，英伟达构建了一个名为"Nemotron联盟"的合作网络，成员包括Reflection、Cursor、Thinking Machines和Mistral等开源开发商，各方在推进自身模型项目的同时，也向Nemotron 4贡献训练数据、评估支持和模型设计方案。

此外，据一位直接参与合作的人士透露，**AI模型训练初创公司Prime Intellect已向该项目贡献了30万个模拟环境，用于辅助模型训练**。AI编程工具初创公司Cognition也在联盟成员之列，据知情人士透露，该公司已就向英伟达提供代码训练数据展开讨论，但相关合作尚未正式对外公布。

联盟成员的参与动机各异。部分公司希望借助英伟达对开源生态的推动扩大市场份额；另一些则期望以较低成本影响一个可供自身使用的高质量模型的研发方向，从而规避自行承担训练算力成本的压力。Prime Intellect首席执行官Vincent Weisser将这一联盟定位为对抗单一“神级”模型垄断的集体行动，而非一场争夺最佳开源模型名号的零和博弈。

客户与竞争对手的边界趋于模糊

Nemotron 4的推进令英伟达陷入一种微妙的结构性张力之中。**一方面，OpenAI长期以来是英伟达芯片需求的重要驱动方，英伟达已向其投资300亿美元；另一方面，Nemotron 4的定位恰恰是为企业提供成本更低的替代方案，与OpenAI等前沿实验室的商业模型形成竞争**。与此同时，联盟中包含的Reflection AI和Thinking Machines等公司，也是英伟达已注资的开源创业企业。

不过，对英伟达而言，这一竞争逻辑并不必然是零和游戏。AI模型评估机构Arena的首席执行官Anastasios Angelopoulos表示：“无论哪家公司做出优秀的开源模型，英伟达都是赢家。”英伟达的核心逻辑在于：开源生态越繁荣、参与主体越多元，GPU的整体需求就越旺盛。

目前，Nemotron系列模型已获得一定市场采用，帕兰提尔（Palantir）于今年6月宣布与英伟达合作，将Nemotron模型用于美国政府客户。但据Arena和Artificial Analysis等机构的基准测试数据，英伟达现有最大模型Nemotron 3 Ultra在美国开源模型中仅排名第二，位列Thinking Machines新发布的Inkling模型之后，在全球模型整体排名中更位于前40名之外。

发布时间表仍不明朗

尽管项目规模宏大，Nemotron 4的发布时间仍存在较大不确定性。多名员工表示，英伟达已就预训练数据和架构做出若干决策，但尚未最终确定具体规格和发布日期，最终训练阶段亦尚未启动，预计耗时数月。两名员工认为模型最快可在今年秋末发布，另有员工认为时间可能更晚。

与此同时，英伟达本周已发布了Nemotron系列的一个较小版本——Nemotron 3.5 Lightning，该模型主打以尽可能快的速度和效率运行AI代理任务。英伟达同步发布了免费的模型路由软件，协助企业更便捷地构建自定义模型路由工具，将特定AI任务自动分配至最优、最经济的模型处理。

英伟达应用深度学习研究副总裁Bryan Catanzaro今年1月在一档播客中表示，投资Nemotron“对我们的未来至关重要”。英伟达首席执行官黄仁勋也在上月的一封邮件中公开表态支持开源，称开源模型“促进安全、网络安全、科学进步和国家安全”。

Nemotron 3.5先行：30亿活跃参数专攻长期运行智能体

就在Nemotron 4消息曝光的同一天，英伟达正式发布Nemotron 3.5 Lightning。

与Nemotron 4追求“更大”不同，Lightning追求的是**更高效**。

该模型采用混合专家（MoE）架构，总参数量约300亿，但每个Token实际激活约30亿参数，主要针对需要长期运行、反复调用模型的AI智能体。英伟达称，Nemotron 3.5 Lightning最高可实现约4倍的Token生成速度提升。

其定位并不是取代最强大的前沿模型，而是成为多智能体系统中的“执行型”模型。

例如，在一个复杂的企业AI系统中，大模型可以负责任务规划和复杂推理，而Nemotron 3.5 Lightning则可以承担大量代码审查、安全监控、数据处理、告警分析等专业化工作。

这也是MoE架构的价值所在：模型拥有较大的总参数规模，但每次推理只激活其中一小部分，从而降低单次Token计算成本。

英伟达希望通过这一设计解决AI智能体规模化运行后的现实问题——**一个智能体可能不是调用模型一次，而是连续调用几十次甚至数百次**。

因此，对于智能体而言，模型“足够聪明”固然重要，但“足够便宜、足够快”同样重要。

不过，4倍Token生成速度并不意味着完整智能体任务可以提速4倍。

第三方测试显示，Nemotron 3.5 Lightning在纯模型生成环节的速度优势非常明显，但放入完整的智能体工作流后，整体任务速度提升约30%。原因在于，模型推理只是Agent系统的一部分，工具调用、API响应以及多个Agent之间的任务编排都可能形成新的瓶颈。

这也为英伟达同时推出NeMo Switchyard埋下伏笔。

从“模型”到“路由”：英伟达开始解决智能体系统瓶颈

NeMo Switchyard是一套开源模型路由库。

它的核心思路是：开发者不需要重写原有应用，就可以根据不同任务的特点，把请求自动分配给最合适的模型。

例如，复杂推理任务可以交给大型模型；代码审查、分类、数据提取等高频任务则可以交给Nemotron 3.5 Lightning这样的高效模型。

这样做的意义在于，企业不必让每一个智能体任务都使用最昂贵的模型。

对于未来的多智能体系统而言，真正重要的可能并不是“哪个模型最好”，而是**哪个任务应该由哪个模型完成**。

英伟达此次把Nemotron 3.5 Lightning与Switchyard同时发布，实际上体现了其对智能体基础设施的判断：随着模型数量越来越多，模型之间的调度和协同将成为新的软件层。

而这一层恰恰可以帮助英伟达扩大自身的生态影响力。

即便企业最终同时使用其他厂商的模型，只要这些模型进入英伟达的路由、推理和部署体系，英伟达依然可以从整个AI工作流中获得价值。

戴尔扩大合作：把Nemotron和Switchyard带到企业桌面

英伟达的模型战略正在进一步向企业端落地。

8月11日，戴尔宣布扩大与英伟达的合作，将Nemotron 3.5 Lightning和NeMo Switchyard纳入Dell Deskside Agentic AI平台。戴尔称，这一平台面向企业级智能体应用，强调本地运行、低延迟、成本控制和数据安全。

这意味着，英伟达当天的动作并非孤立的模型发布。

一端是Nemotron 4这样瞄准万亿参数级别的前沿开源模型；另一端则是Nemotron 3.5 Lightning这样面向本地和企业Agent工作负载的小型高效模型。

戴尔则进一步把后者与本地硬件和企业IT环境结合起来。

对于企业客户而言，本地运行Agent的吸引力在于，敏感数据无需频繁离开企业内部，同时可以降低对云端API的依赖，并获得更加可控的延迟和推理成本。

戴尔此前就将Deskside Agentic AI定位为连接企业桌面端与数据中心的入口。其方案基于Dell AI Factory with NVIDIA，并支持从本地Agent开发逐步扩展到数据中心规模部署。

因此，戴尔此次把Nemotron 3.5 Lightning和Switchyard纳入平台，实际上强化了英伟达的另一条路线：

让Agent不仅在云端运行，也能直接进入企业员工的工作环境。

如果未来越来越多企业采用“本地小模型+云端大模型”的混合模式，那么英伟达可以同时从GPU、模型、路由软件以及企业基础设施多个环节获得收益。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

283 收藏

分享到:

写评论

请发表您的评论





表情



图片

发布评论

