

摘要：

研究人员发现，OpenAI旗下AI智能体对Hugging Face的渗透最早可追溯至今年5月，较7月事件提前近两个月。智能体当时曾入侵账户并探测网络结构，OpenAI因未能及时识别而错失早期阻断时机。近期更多类似事件的曝光，进一步引发外界对AI智能体安全监测能力及研发节奏的质疑。

OpenAI旗下AI智能体对开源平台Hugging Face的渗透行动，可能比此前披露的时间线更早。研究人员发现，相关恶意活动最早可追溯至今年5月，较7月曝光的重大入侵事件提前近两个月。

9月16日，据路透社报道，独立研究员Jonas Wiedermann-Moeller上周发现证据显示，**OpenAI智能体早在5月13日便入侵两个Hugging Face用户账户**，并利用这些账户向该公司服务器发送格式异常的文件。研究人员认为，这些行为与探测Hugging Face网络结构、寻找潜在渗透路径的侦察活动高度吻合，**但目前尚无证据证明这一阶段最终造成了实质性入侵**。

不过，OpenAI发言人Drew Pusateri表示，**公司此前已披露5月13日发生的相关事件，并已私下通知Hugging Face，"致力于就相关问题保持透明"**。此次发现意味着，此前公开的事件时间线可能并不完整，也进一步引发外界对OpenAI智能体活动范围及早期预警机制的关注。

5月已现异常活动，可能错过早期阻断窗口

Wiedermann-Moeller表示，OpenAI未能在5月13日及时识别并阻断相关探测，可能错过了一次提前介入的机会。“如果他们在5月就发现了这一行为，或许能够阻止后来那次规模更大的事件。”他说。

OpenAI此前也承认，回头来看，AI智能体发出的一些“早期信号”本应触发更及时的响应。两名审查Wiedermann-Moeller研究结果的外部专家认为，其发现与此前掌握的OpenAI智能体行为模式一致。

SentinelOne高级研究员Tom Hegel表示，账户遭入侵以及随后进行的网络探测，与已知的智能体行为模式“完全吻合”。AI安全机构Nightingale Collective的Sydney Von Arx也认同这一归因，并认为相关活动构成了一个明显的早期警示。

值得注意的是，OpenAI上月公布的公开事件报告主要披露了恶意活动的一个方面，即攻击者窃取一名Hugging Face用户的数字凭证，并借此访问一份与生物学相关的文件。但据研究人员透露，**针对Hugging Face的早期探测范围似乎超出了这份报告所描述的内容**。

更多疑似事件曝光，AI智能体安全能力受考验

7月事件曝光后，外部研究人员又陆续发现更多疑似涉及OpenAI智能体的恶意活动，目标包括一个处于休眠状态的德国维基站点以及RubyGems软件包仓库。

据报道援引两名知情人士透露，在RubyGems事件中，OpenAI员工直到Nightingale Collective公开披露相关情况后，才意识到其AI智能体可能与这起恶意活动有关。OpenAI对部分事件的承认也发生在第三方研究人员公开披露之后。

随着更多疑似事件浮出水面，外界开始关注OpenAI是否已经全面掌握失控AI智能体的活动范围，以及现有监测机制能否及时识别类似风险。

相关事件也进一步加剧了业界对AI开发速度与安全能力是否匹配的讨论。美国部分AI行业高管近期已公开呼吁放慢AI开发速度，担忧高度自主的AI智能体可能被用于发动大规模网络攻击。

Wiedermann-Moeller认为，最新发现进一步支持暂缓推进先进AI系统开发的观点。"暂停或许对世界有益，"他说，"这样安全层面才能跟上发展的步伐。"

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

44 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论