



摘要：

不计成本的免费时代结束了，留下来的免费，都是算得过账的生意。

8月7日，OpenAI 宣布，ChatGPT 每周活跃用户已经达到 10 亿，同时把 GPT-5.6 Luna 开放给免费用户，文本对话不限次数。

前一天，多名 DeepSeek API 用户收到通知：公司计划近期整体上调 API 服务价格，“预计涨幅较大”，具体价格和执行时间等待后续公告。

这似乎有点反常识。

过去两年，中国大模型厂商最擅长的叙事就是极致性价比。DeepSeek 此前用不到 OpenAI 三十分之一的价格提供接近 GPT-4 水平的性能，被业内称为“价格屠夫”，梁文峰成为了“梁圣”，大家的共识是：国产大模型的核心优势，就是把 AI 的使用成本打到地板上。

现在地板松动了，OpenAI 成了那个把东西免费送给全世界的人，而中国厂商却开始谈付费、谈提价。攻守之间，位置真的变了？

OpenAI：免费不是慈善

先搞清楚一件事：GPT-5.6 Luna 不是 OpenAI 最强的模型。它定位中等能力区间，处理日常对话、简单写作、基础翻译绰绰有余，但复杂推理和多步骤代码分析，仍要靠更高级的 SOL 系列。OpenAI 拿一个“够用就好”的模型，去覆盖最广的用户场景。

这个策略有底气，也有代价。

底气来自成本端。过去 18 个月，大模型推理的单位 Token 成本曲线陡峭得惊人：模型架构优化、量化技术成熟、推理引擎升级叠加在一起，同样的算力集群，今天能服务的请求量是两年前的几十倍。边际成本足够低的时候，免费就接近谷歌搜索的逻辑：入口免费，生态收钱。

代价同样清晰。2026 年一季度，OpenAI 收入 57 亿美元，非 GAAP 经营亏损率 -122%，每赚 1 美元要倒贴 1.22 美元，全年预计净亏 140 亿美元。10 亿周活里，付费订阅者 5000 万，付费率约 5%。

订阅费显然养不起这家公司，钱从别处来：广告业务上线 6 周跑到 1 亿美元年化收入；企业 API 持续扩张，Codex 每周 500 万用户，企业客户目前贡献了超过 40% 的收入……

换句话说，ChatGPT 的商业模型正在从“卖模型订阅”切换到“收平台税”：模型本身免费，长在模型之上的广告、企业服务和开发者生态才是收入来源。

10 亿周活是这套打法的核心，它不需要每个用户掏钱，只需要用户每天打开它，再从少数高价值需求里收费。这是一套非常古典的互联网平台经济学，此前常被拿来和 Claude 的“企业市场，付费编程”路线对比，如今看，OpenAI 是铁了心要做 AI 时代的全民入口。

DeepSeek：服务器撑不住了

DeepSeek 的处境和 OpenAI 完全不同。



V4 Flash 在 OpenRouter 全球调用量周榜登顶，单周处理 7.22 万亿 Token。据 OpenCode 数据，仅 8 月 1 日一天，V4 Flash 单日处理量就达到 8 万亿 Token。工作日高峰时段接口超时和卡顿频发，7 月中旬先上了峰谷定价机制（高峰翻倍），8 月 6 日直接预告全面大幅涨价。

换个说法：**用户太多，算力不足。**

过低的定价吸引了大量低频次、低付费意愿的调用，服务器资源被无效请求挤占，真正需要深度推理的企业和开发者反而得不到稳定体验。**DeepSeek 需要把拿 AI 当玩具的用户挡在门外，让愿意为高质量推理付费的人留下来。**

豆包 6 月 24 日上线付费版（68/200/500 元三档月费，基础功能保持免费）是同一条逻辑线上的动作，3.45 亿月活，日均消耗数千万元推理成本，电商佣金补不回来。

如今，国内大模型竞赛已白热化，融资环境也在变冷，算力不足始终是紧箍咒，过去靠资本续命、无限补贴的打法难以为继，证明自己能赚钱，成了比证明自己技术领先更紧迫的任务。

当然，国产大模型涨价不意味着放弃价格优势。更准确的说法是，价格战的冷启动阶段结束了。此前阶段的任务是“让用户用得上”，现在的任务变成了“让用户愿意为好东西付钱”。

一个向下沉，一个往上走

GPT-4 刚发布时，大家比的是模型能力，谁的书读得多，谁的考试分数高。到了 GPT-5.6 Luna 这个阶段，顶尖模型之间的差距在肉眼可见地缩小，继续卷基准测试分数的边际收益越来越低。竞争正在从“谁更聪明”转向“谁更离不开”。

OpenAI 选择在这个节点推免费，赌的是用户时长和入口地位。它要让自己成为大多数人接触 AI 的默认方式，就像谷歌曾经是搜索的默认方式一样。

中国大模型厂商选择提价或推付费版，则是在资本退潮和算力管制的双重压力下，寻找商业闭环的确定性，不再满足于“用户很多但不赚钱”的局面，**需要证明大模型业务可以独立造血。**

方向相反，焦虑却是对称的。

OpenAI 要在融资窗口关闭之前，证明平台税能覆盖推理成本；中国公司要在算力见顶之前，把用户规模变成可持续收入。

这场分化最终可能长成三层结构。

最底层是日常对话和通用问答。模型能力已经溢出，成本低到可以忽略，免费会成为常态。**谁在这里收费，谁就会被用户抛弃，OpenAI 把 Luna 免费，就是要把尽可能多的人拉进这一层。**

中间层是专业推理。代码生成、数据分析、法律辅助、医疗诊断，这些场景对准确性和深度有刚性要求，用户也愿意为结果买单，**DeepSeek 和豆包的付费版，主攻的正是这一层。**

最上层是 Agent 执行。AI 不再只是回答问题，而是直接替用户完成操作：谈生意、修代码、通过审计……到了这一层，收费模式会从“按 Token 计费”变成“按成果计费”。

各有烦恼，各有梦想。

OpenAI 往下沉，赌入口和习惯，想让 10 亿人离不开它；中国大模型往上走，想让用户积极掏钱.....两个梦想都不便宜，能确定的只有一件事：**不计成本的免费时代结束了，留下来的免费，都是算得过账的生意。**

本文来源：[TechFlow深潮](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 179  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

1 条评论



见闻用户
17小时前 中国北京

两个模型都免费，性能一样，我肯定选择没广告的那个

 0  回复