

摘要：

OpenAI与Anthropic正推动AI定价标准从“每token成本”转向“每任务成本（cost-per-task）”，强调高溢价模型能一次性高效完成任务，从而降低综合成本。第三方机构Ramp数据亦显示，Anthropic最贵模型Fable 5仅占其软件支出的11%，表明企业为高溢价AI付费已触及上限。

在AI模型价格战进入白热化之际，OpenAI与Anthropic正联手改写行业衡量模型价格的底层标尺——从“每token成本”转向“每任务成本（cost-per-task）”，试图在企业客户面前为自身高溢价模型重建价值坐标系。

过去数周，两家美国AI龙头相继发声。OpenAI首席财务官Sarah Friar在7月的博客中写道，低成本模型token虽便宜，但得到好结果“可能需要更多尝试、更多时间或更多人工审查”；Anthropic金融服务主管Jonathan Pelosi在近期采访中表示，token成本只是衡量消耗了多少AI算力的“代理指标”，“对每家企业而言，更好的代理指标是完成任务的实际成本”。

这场定价叙事之争的直接背景，是Meta、SpaceX等厂商正以极低的token价格挤压市场。据企业支出管理平台Ramp的数据，近几个月企业对OpenAI与Anthropic的采用已有所放缓，现有客户正越来越多地转向更便宜的开源替代方案。

而第三方数据给出的信号更为直接：Anthropic最强、也最贵的广泛可用模型Fable 5，仅占其Claude软件支出的11%。Ramp据此断言，已经“找到了企业愿意为AI付费的新上限”。

从“Token”到“任务”：重设定价锚点

Token是AI模型处理的数据单位，也是衡量工作量的一种方式。行业惯常假设：单token收费越低，软件对客户整体就越划算。OpenAI与Anthropic正试图推翻这一共识。

Sarah Friar写道：

“低成本模型可能有更便宜的token，但要得到好结果可能需要更多尝试、更多时间或更多人工审查；能力更强的模型token更贵，却能一次完成同一任务。”

Pelosi的观点与之呼应：token只衡量AI被使用了多少，无法衡量产出。他认为每token成本“仅作为代理指标有用”，企业真正该关注的是完成任务的实际成本。

低价冲击：从“tokenmaxxing”到成本设限

指标转换发生在竞争压力加剧之时。多家厂商都在力推更低的token成本，试图压价Anthropic这类以更高价格提供更强模型的公司。以DeepSeek为例，其4月发布的旗舰开源模型输入输出token成本仅为Anthropic最先进产品的零头。

D.A. Davidson技术与研究主管Gil Luria打了个比方：“美国实验室想传达的是，用开源token就像用廉价卫生纸——确实能擦干净，但你需要更多，还有别的不愉快副作用。”

过去一度鼓励员工通过“tokenmaxxing”最大限度使用AI的企业，在遭遇“账单冲击”后纷纷设限。Luria称：

“对许多这类公司而言，内部成本已经高得令人望而却步。”

最贵模型“性能不值价”：第三方数据亮出上限

尽管Anthropic等厂商公布了自己的每任务成本估算，越来越多客户正转向Artificial Analysis、Vals AI等第三方基准机构寻求独立评估。Vals联合创始人兼CEO Rayan Krishnan指出：

“当实验室自报结果时，往往用的是内部基准，因此无法做真正的同类比较。”

按每任务成本计，Anthropic与OpenAI的模型仍是市场上最贵的，Anthropic的Claude Fable 5位居榜首；但两家也提供更具竞争力的低价产品，如OpenAI的GPT-5.6 Luna。

真正给高溢价叙事泼冷水的是Ramp的数据：Anthropic最强、也最贵的广泛可用模型Fable 5，仅占Claude软件支出的11%。“通过Fable 5，我们找到了企业愿意为AI付费的新上限。”Ramp在报告中写道，“在此之上，更高的性能并不值这个价。”

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 65  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论