

摘要：

OpenAI内部AI模型已开始承担实验性模型训练及GPU内核优化等研发工作，多智能体可自主协作、迭代代码，推动AI研究自动化加速。与此同时，OpenAI发布全球AI安全协调提案，首次单列RSI，警告自动化研发可能加速AI自我改进，并呼吁建立全球技术标准和人类监督机制。

就在今天，外媒The Information曝出内幕——

OpenAI内部的AI模型，已经开始「自己训练自己」了！

具体来说，这个内部模型已经接管了实验性AI模型的训练全流程，开始自己手搓自己。

研究员只要给出一个优化示例，AI就能自己跑上几个星期，多智能体自发协作，互相讨论，迭代代码，完全不需要人类插手。

更惊人的是，原本需要几年才能跑完的宏大实验，现在被压缩到了短短一周！

随着这一震撼爆料被放出，OpenAI紧急上线了一份全球安全倡议，直指全球AI圈的最敏感处——RSI。

他们大声疾呼：在AI失控之前，全世界必须联手给它戴上「紧箍咒」！

当AI学会「手搓」GPU内核

以前，在顶尖AI实验室，训练一个大模型十分繁琐。

其中最昂贵、最复杂的活儿，莫过于针对底层图形处理器编写GPU kernels，并逐行优化运行代码。

这需要全球最顶尖、年薪几百万美金的高级算法工程师们通宵达旦地「手搓」出来。

但据The Information的最新曝光，如今在OpenAI内部，这些核心工作已经大部分被AI接手了。

Researchers tell us AI has largely automated the process of training new experimental models. Moreover, they also said models within OpenAI today largely write the programs needed to run or train models on graphics processing units (otherwise known as **GPU kernels**) and the optimizations for those programs.

Engineers can provide the model with a single example of the type of optimization that they want and the AI can run for weeks to implement such optimizations, one OpenAI employee said. This level of AI-powered automation only became possible in the last few months thanks to improvements in models, the employee said.

In another example, the OpenAI employee also said that it's not uncommon for employees' agents to work together to solve problems without ever looping in their human users.

如今 OpenAI 内部的模型，在很大程度上能自行编写在GPU内核上运行或训练模型所需的程序，以及针对这些程序的优化方案。

工程师只需向模型提供一个他们想要实现的优化类型示例，AI 就能持续运行数周，来落实这些优化。

而且，得益于模型的改进，这种由 AI 驱动的自动化水平直到最近几个月才成为可能。

甚至，员工们的智能体还会相互协作解决问题，并不需要惊动人类。

这，就是RSI的雏形。

OpenAI紧急吹哨：RSI真来了，人类正在失去控制权？

想象一下，你造了一个智商100的机器人，它的任务是「造出比自己更聪明的机器人」。


于是，它造出了智商120的二代；二代一睁眼，利用自己120的智商，造出了智商150的三代；三代接着造出了智商200的四代……



一旦跨过某个临界点，AI的进化速度将呈现出垂直向上的折线，瞬间把人类甩在几万光年之外。

以前，大家觉得这事儿还早，但现在，OpenAI自己害怕了。

就在今天，OpenAI官方紧急发布了一份重磅的全球安全倡议。



他们罕见地把「RSI」单列一节，明确写下「全自主RSI今天并未发生，在能安全做到之前不应推进」，并呼吁各国AI安全研究所网络制定一个全球的技术标准。

OpenAI在报告中直言不讳地警告：

「随着AI系统在开发下一代AI的工作中承担越来越多的任务，它们可以日益推动RSI的进程。随着这一过程变得更加自动化，AI进步的步伐可能会急剧加速。」

RSI

Automated AI research can involve varying degrees of human supervision. As AI systems take on more of the work of developing successive generations of AI, they can increasingly drive a process of recursive self-improvement (RSI), even while people remain involved. As this process becomes more automated, the pace of AI progress could accelerate rapidly.

自动化 AI 研究可能涉及不同程度的人类监督。随着 AI 系统承担越来越多开发下一代 AI 的工作，它们可以日益推动一个递归自我改进（RSI）的过程，即使人类仍然参与其中。随着这一过程变得更加自动化，AI 进展的步伐可能会迅速加快。新智元

虽然，完全自主的RSI今天还没有实现，但时间已经很紧迫了。

Automated AI research can involve varying degrees of human supervision. As AI systems take on more of the work of developing successive generations of AI, they can increasingly drive a process of recursive self-improvement (RSI), even while people remain involved. As this process becomes more automated, the pace of AI progress could accelerate rapidly.

自动化的 AI 研究可以在不同程度上依赖人类监督。
随着 AI 系统承担起开发后续 AI 代际的更多工作，它们可以在仍有参与的情况下，越来越多地推动递归自我改进（RSI）的过程。
随着这一过程变得更加自动化，AI 进步的速度可能会迅速加快。
公众号 · 新智元

在提案中，OpenAI毫不避讳地指出了当前的首要任务：「驾驭下一阶段的AI进展，构建自动化的AI研究员，并找到让人类留在自我改进循环中的方法。」

请注意后半句话——「让人类留在循环中」。这就是他们最大的担忧：人类可能马上就要被踢出局了！

OpenAI在报告中骄傲地提到，AI驱动的研究已经推动了数学领域的重大进步，比如攻克NS千禧年难题。

但硬币的另一面，是无底的深渊。

报告中写道：「随着这个过程变得更加自动化，AI进展的步伐可能会迅速加快……如果不采取适当的谨慎措施，RSI可能导致人类失去对AI发展的实际控制，无法对他们不再理解的研究过程提供监督。」

这就是所谓的「黑盒效应」。当AI的代码是由AI编写，当AI的逻辑超越了人类，人类就再也看不懂AI要干什么。

比如，现在Astra写的代码，人类已经看不懂了。





接着，OpenAI点名了Hugging Face事件。

虽然他们澄清该事件并非RSI的直接后果，但绝对是一个惨痛的预演——它向全世界展示了，如果没有强大的护栏和对齐机制，失控的AI将带来何等严重的灾难。

奥特曼呼吁：我们需要统一的「紧箍咒」

既然如此危险，为什么OpenAI不直接拔掉电源？因为潘多拉的盒子一旦打开，就再也关不上了。

AI发展带来的巨大利益，让任何一个国家和公司都不可能停下。

所以，OpenAI抛出了一份「全球AI安全协调提案」。他们呼吁的不是停止研发，而是「建立下一阶段AI的全球标准」。

核心一：构建互补的国家与国际前沿标准网络

OpenAI提出，不能让各个国家各玩各的，那样只会导致标准碎片化。

他们建议利用现有的机构，如「AI标准与创新中心」（CAISI），以及澳大利亚、加拿大、英国、法国、日本等国已经建立的AI安全研究所网络，制定一套全球通用的技术标准。

这套标准不是为了限制开源模型或者初创企业，而是专门针对「前沿AI模型」（Frontier AI）。



标准要解决的是：如何评估一个AI的RSI能力？当一个AI模型自主进行研发时，风险究竟有多大？

总之，OpenAI希望将安全评估变成一门可量化的「科学」。

核心二：通用测量与事件报告协议（随时准备拔插头）

OpenAI还提出，必须有明确的红线。

他们呼吁建立以下标准：

- 1.评估企业内部究竟有多少研发工作是由AI自动完成的。
- 2.强制性的人类监督触发机制。明确规定在什么样的自动化研发流程中，必须强制触发「立即进行人工审查」。绝不能让AI在黑盒里闷头狂奔。
- 3.事故分类与报告门槛。建立类似于航空业或核工业的事故报告机制。当AI出现了「未对齐」的苗头时，必须有统一的严重程度分级和上报标准。

(2) Common measurements and incident reporting protocols for better collective action

International AI standards will be particularly crucial in managing increasing autonomy in AI research and recursive self-improvement. Specifically, these could include standards for:

- Evaluation of RSI-relevant AI progress and the amount of autonomous research happening within an AI company. [Our recent report](#) on research acceleration is an initial contribution to this effort.
- Human oversight over automated AI research, including what kinds of automated AI research processes should trigger immediate human review.
- Incident classification, tracking, reporting, and responding for alignment and automated AI research issues, such as common incident severity levels and reporting thresholds. [Our misalignment reporting framework](#) is an early contribution.

👤 公众号 · 新智元

最后，图穷匕见，OpenAI提议：「美国应该领导这一进程。」

OpenAI给出的理由是：美国的AI产业目前处于技术最前沿，并且在各个关键领域占据全球网络枢纽。

他们认为，控制前沿AI的开发节奏，并不是人为设定一个「限速牌」，而是要确保「安全对齐研究的速度，必须跑在AI能力提升的前面」。



OpenAI认为，在关键基础设施运营商和全球政府之间建立安全沟通渠道，共享国家安全威胁和漏洞，是至关重要的一步。

活久见！OpenAI与Anthropic握手，开始互查

同时，The Information还曝出：OpenAI和Anthropic正在敲定一项历史性的协议——双方将互相测试对方的商用模型！



要知道，Anthropic的创始团队当年就是因为「AI安全」理念上与奥特曼不合，才愤而离职自立门户的。

但这一次，双雄罕见地联手了。

活久见！OpenAI与Anthropic握手，开始互查



制图：Aeneas

公众号·新智元

据The Information透露，这项正在谈判的协议包含了相互测试对方模型，并设置严格的数据保留防护措施。这是一次公关作秀，而是面临未知风险时，两大巨头不得不抱团了。

为什么他们要这么做？

因为随着AI能力逼近RSI的边缘，任何一家公司独自评估自己模型的安全性，都像是一个运动员给自己做兴奋剂检测——不仅缺乏公信力，而且可能因为技术盲区而错过致命的隐患。

引入势均力敌的竞争对手进行「交叉盲测」，就像是就是一个互查协议。

AI的安全实践，如今已经走向了命运共同体。

如果这项协议最终落地，它将彻底重塑整个AI生态的安全标准。



公众号·新智元

那时，「安全与对齐」不会再是一句口号。

当RSI已经逼近，AI自我改进的速度，已经把人类远远甩开。

各家巨头们，真的能狠下心踩刹车吗？

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 372  收藏

分享到:  


写评论

请发表您的评论

 表情  图片

发表评论

1 条评论



正在加载 .