

摘要：

“这对他们来说是非常重要的核心机密（secret sauce），他们甚至不想告诉 OpenAI 内部的其他员工。因为如果这些东西泄露出去，很可能会很快被其他实验室采用，他们也可以利用这些来降低成本。”

在人工智能大模型从“技术军备竞赛”全面转向“商业化落地”的关键节点，推理成本的控制或已成为决定企业盈利能力和市场定价权的核心变量。

据The Information最新报道，OpenAI工程师已成功将模型推理成本降低了一半。这一技术突破不仅将大幅改善其因算力消耗带来的长期亏损状况，更为其即将推进的 IPO 和新一轮高达 120 亿美元的融资提供了关键的盈利预期支撑。

由于该技术对维持竞争优势至关重要，OpenAI 将其视为“核心机密”（secret sauce），甚至采取了极端的内部保密措施。公司严格限制知情员工范围，以防技术细节外泄被其他 AI 实验室效仿，从而抹平其来之不易的成本优势。




显示翻译

OpenAI engineers just halved its inference costs.

@steph_palazzolo reports: “This is a very important secret sauce for them that they don’t even want to tell other OpenAI employees about...”

“Because if these things leak, it can very quickly be picked up by other labs, which can also then use that to lower their costs.”



上午5:30 · 2026年7月1日 · 5,856 查看

记者 Steph Palazzolo 在报道中指出：“这对他们来说是非常重要的核心机密（secret sauce），他们甚至不想告诉 OpenAI 内部的其他员工。因为如果这些东西泄露出去，很可能会很快被其他实验室采用，他们也可以利用这些来降低成本。”

推理成本腰斩：重塑盈利模型与定价权

在 AI 大模型的商业化进程中，高昂的推理成本一直是制约盈利的核心痛点。此前，OpenAI 因算力稀缺和持续亏损，不得不彻底关闭视频生成工具 Sora，将宝贵的算力资源转向更具商业确



定性的新模型与生产力工具。在此背景下，推理成本减半的战略意义被显著放大。

成本的骤降直接赋予了 OpenAI 更强的市场定价权与利润空间。以其最新发布的 GPT-5.6 系列旗舰模型 Sol 为例，该模型在 Terminal-Bench 2.1 基准上超越了 Anthropic 的 Claude Mythos 5，但定价却仅为竞品 Claude Fable 5 的一半。推理成本的降低，使得 OpenAI 能够在发起激进“价格战”抢占市场份额的同时，依然维持健康的毛利率。

对于资本市场而言，这一突破是其估值逻辑的重要支撑。OpenAI 目前正接近完成新一轮 120 亿美元融资，融资前估值高达 7300 亿美元，且Sam Altman正积极筹备在 Anthropic 之前完成 IPO。推理成本的实质性下降，将直接改善公司的现金流预期，为高昂的估值提供财务基本面背书。

推理成本的降低，也与 OpenAI 近期的战略大调整高度契合。应用部门 CEO Fidji Simo 已在全员会议上明确宣布，公司将收缩多线并进策略，边缘化 Sora 等消费级产品线，将核心资源集中于编程工具和企业市场。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 137  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

4 条评论



MobileUser0530
1小时前 中国广东省

直接感谢梁圣 🤖 搁那儿装啥机密呢

 0  回复



见闻用户
6小时前 中国

估计使用中国开源AI模型做为该企业降低成本，所以奥特曼不愿透露所谓的机密，当然这是个人纯粹推测，只能让时间来验证这个推测，因奥特曼企业与埃隆马斯克对簿公堂后，让奥特曼三观尽毁，他管理之下的企业不会走远。

 0  回复



MobileUser5806
6小时前 中国北京



大概是2C 业务的降智，财务表现因token消耗降低，减少成本开支。财务表现是整体结果，混在一起谁知道到底是什么

 0  回复



MobileUser5806

6小时前 中国北京

大概是2C 业务的模型降智

 0  回复