

摘要：

OpenAI发布前沿AI训练安全准则，要求启动或继续强化学习训练前完成系统性安全论证，并由高级管理层审核，任何成员均可一票否决。框架覆盖对齐训练、沙箱隔离和实时监控，若高优先级安全警报未及时响应，训练将自动暂停；严重失准事件还须开展根因调查并公开披露结果。

OpenAI正式为前沿AI训练划定安全红线。这家全球最具影响力的人工智能公司发布了一套针对前沿AI训练的安全准则框架，要求在启动或继续任何前沿强化学习训练之前，必须完成系统性的安全论证文件，并赋予高级管理层对训练任务的一票否决权。

据OpenAI官方博客，该准则涵盖技术防护、运营管理与失准事件调查三大板块，核心要求包括：训练过程中若出现未被及时响应的优先级安全警报，相关训练任务须自动暂停；负责审核安全论证的高级领导层成员，每人均拥有叫停训练运行的否决权。OpenAI表示，上述建议目前正处于内部落地实施阶段，并预计将持续迭代演进。

September 28, 2026 Safety

Towards safety cases for frontier AI training

▶ Listen to article 9:30

🔗 Share

We believe we are entering a new era in which structured safety documentation should be required before continuing any frontier reinforcement learning training run. Ideally, such documentation would rise to the level of “safety cases”—comprehensive, structured, evidence-based arguments about risk which are used in other safety-critical industries. We treat safety cases as an aspirational north star we are building towards, while acknowledging the challenges of making them as rigorous for AI models as for aviation or nuclear power, due to the emergent complexity at each new level of AI capability. We’re working on a framework to codify these practices.

Below are some initial guidelines that we think should be part of such safety cases for frontier AI training. These best practices reflect our current learnings, and we expect them to evolve as we continue iterating on internal processes for careful development. We’re sharing them now to make our current thinking transparent, and invite feedback from the community. Note that this document is focused on frontier reinforcement learning training; internal and external deployment require considering a much broader set of alignment properties.

此举标志着OpenAI在前沿模型开发流程中引入了更为结构化的安全管控机制。对于市场而言，这一框架的出台既反映出头部AI实验室对模型失控风险的高度警惕，也意味着前沿模型的训练周期与合规成本可能进一步上升。

安全论证须覆盖三大技术层面

OpenAI在博客中指出，安全论证文件应覆盖技术栈的三个核心环节：**对齐训练、沙箱隔离（containment）与实时监控。**

在对齐训练层面，OpenAI要求通过自动化数据集审查、人工数据集复核及评分器调优等手段，降低模型在训练过程中形成失准行为的风险。具体措施包括：使用智能体识别并修复存在缺陷的强化学习环境，防止模型通过“奖励黑客”手段获得高分；同时追踪模型是否存在“元博弈”行为——即模型识别出自身正处于测试状态并据此调整行为。

在沙箱隔离层面，OpenAI强调须对模型运行的沙箱环境及承载该沙箱的研究基础设施进行多层安全加固，并通过持续红队测试发现并修补安全漏洞。此外，所有强化学习训练、评估及内部部署的智能体交互记录须以不可篡改的方式保存，以支持事后溯源调查。

在实时监控层面，OpenAI要求建立高召回率的监控系统，确保能够捕捉已知类型的失准行为，并对优先级警报设定明确的响应时限——若警报在规定时间内未被确认，相关训练任务将被自动暂停。

高管拥有一票否决权，问责机制延伸至绩效考核

在运营管理层面，OpenAI设计了一套多重内部制衡机制。

安全论证文件完成后，须由另一团队成员撰写“异议报告”，主动寻找论证中的潜在漏洞，并对风险给出独立评估，训练团队须就此作出回应。随后，安全论证须提交高级领导层审核，审核成员包括研究部门负责人或副总裁、安全负责人及首席科学家，每位成员均拥有独立的一票否决权。

OpenAI还将安全责任纳入绩效考核体系。负责训练任务的高级领导须对安全论证及任何事件响应承担直接责任，以此激励训练团队将安全与对齐置于优先位置。

此外，安全论证文件须向内部监督机构（如安全与安保委员会）开放，审计人员须获得足够的访问权限以核实论证内容的有效性。一旦发现可能使安全论证失效的新问题（如新的安全漏洞），须立即启动暂停所有相关训练任务的预案。

失准事件调查须公开披露，结果向公众透明

针对严重AI失准事件的调查，OpenAI亦制定了相应规范。

OpenAI要求研究人员通过定向消融实验或重采样实验，对训练动态进行根因分析，以理解失准行为的形成机制。调查期间须定期向内部发布进展更新，员工可通过既定渠道申请获取原始交互记录及失准模型的采样数据。

在外部透明度方面，OpenAI明确要求，调查结论、事后复盘报告及运营改进措施须在调查结束后向公众公开披露，受影响的第三方须尽快获得通知。

OpenAI表示，上述准则反映了公司当前的最佳实践认知，并将在未来数周内持续演进。公司同时表示，将这些内容公开分享，旨在提升透明度，并邀请外部社区提供反馈。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

18 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论