

摘要：

OpenAI表示，随着小型模型速度更快、功能更强大，开发者无需使用单一模型处理所有任务，而是可以构建系统，由大型模型负责决策，小型模型则快速大规模地执行任务。“GPT-5.4 mini 是我们迄今为止针对这种工作流程最强大的小型模型。”

OpenAI周二推出旗下迄今能力最强的两款小型模型GPT-5.4 mini与GPT-5.4 nano，以更低延迟和更低成本大幅缩小与旗舰模型的性能差距。

GPT-5.4 mini在编程、推理、多模态理解及工具调用等核心维度全面超越上一代GPT-5 mini，运行速度提升逾2倍，并在SWE-Bench Pro等基准测试中接近体量更大的GPT-5.4。

GPT-5.4 nano则定位成本最低、延迟最短的轻量选项，仅通过API向开发者开放，专为数据分类、提取及简单编程子任务设计。

	GPT-5.4 (xhigh)	GPT-5.4 mini (xhigh)	GPT-5.4 nano (xhigh)	GPT-5 mini (high)
SWE-Bench Pro (Public)	57.7%	54.4%	52.4%	45.7%
Terminal-Bench 2.0	75.1%	60.0%	46.3%	38.2%
Toolathlon	54.6%	42.9%	35.5%	26.9%
GPQA Diamond	93.0%	88.0%	82.8%	81.6%
OSWorld-Verified	75.0%	72.1%	39.0%	42.0%

两款模型的推出，意在填补大模型在实时交互场景中因延迟过高而难以落地的空白，直接影响覆盖编程助手、AI代理系统及多模态应用等快速增长的商业市场。

mini面向消费端，nano专属API


GPT-5.4 mini今日起在OpenAI API、Codex平台及ChatGPT三大渠道同步上线。

GPT-5.4 mini的API定价为每百万输入token 0.75美元、每百万输出token 4.50美元，支持文本与图像输入、工具调用、函数调用、网页搜索、文件检索、计算机操控及技能扩展，上下文窗口达40万token。

在Codex平台，GPT-5.4 mini仅消耗GPT-5.4配额的30%，开发者处理简单编程任务的成本约降至旗舰模型的三分之一。Codex还支持将工作量委派给以GPT-5.4 mini运行的子智能体，使推理密度较低的任务自动落入更廉价的模型。

在ChatGPT端，Free与Go用户可通过"+"菜单选择"Thinking"功能使用GPT-5.4 mini；其余付费用户在GPT-5.4 Thinking触达速率上限后，该模型将作为自动降级备选项启用。

GPT-5.4 nano目前仅通过API供开发者调用，定价为每百万输入token 0.20美元、每百万输出token 1.25美元，为两款新模型中定价最低者。OpenAI表示，nano适合由高阶模型统筹调度、负责处理次要支撑任务的子智能体场景。




mini逼近旗舰，nano超越前代

从OpenAI公布的评测数据来看，GPT-5.4 mini在编程及多模态任务上的表现尤为突出。

在编程基准SWE-bench Pro上，mini得分54.4%，与GPT-5.4的57.7%差距收窄至3.3个百分点，远高于GPT-5 mini的45.7%。

Coding				
	GPT-5.4 (xhigh)	GPT-5.4 mini (xhigh)	GPT-5.4 nano (xhigh)	GPT-5 mini (high')
SWE-bench Pro (Public)	57.7%	54.4%	52.4%	45.7%
Terminal-Bench 2.0	75.1%	60.0%	46.3%	38.2%

在计算机操控基准OSWorld-Verified上，mini以72.1%逼近GPT-5.4的75.0%，并大幅领先GPT-5 mini的42.0%。



工具调用能力方面，GPT-5.4 mini在τ2-bench电信测试中得分93.4%，较GPT-5 mini的74.1%提升显著。在通用智能测试GPQA Diamond中，mini得分88.0%，nano亦达82.8%，均超越GPT-5 mini的81.6%。

Tool-calling				
	GPT-5.4 (xhigh)	GPT-5.4 mini (xhigh)	GPT-5.4 nano (xhigh)	GPT-5 mini (high ¹)
MCP Atlas	67.2%	57.7%	56.1%	47.6%
Toolathlon	54.6%	42.9%	35.5%	26.9%
t2-bench (telecom)	98.9%	93.4%	92.5%	74.1%

值得关注的是，GPT-5.4 nano在部分视觉任务中表现落后于GPT-5 mini，OSWorld-Verified得分39.0%低于后者的42.0%。但在编程及工具调用类任务上，nano仍较前代实现明显提升。

MM / Vision / CUA				
	GPT-5.4 (xhigh)	GPT-5.4 mini (xhigh)	GPT-5.4 nano (xhigh)	GPT-5 mini (high ¹)
OSWorld-Verified	75.0%	72.1%	39.0%	42.0%
MMMUPro w/ Python	81.5%	78.0%	69.5%	74.1%
MMMUPro	81.2%	76.6%	66.1%	67.5%
OmniDocBench 1.5 (no tools) ² — lower is better	0.109	0.1263	0.2419	0.1791

OpenAI表示，nano的设计优先级在于低延迟与低成本，而非全面性能，开发者在选型时需结合具体任务权衡取舍。

子智能体架构，多模型协作成产品设计新范式

OpenAI在发布材料中着重强调了两款新模型在多模型分层系统中的位置。

以其自研编程助手Codex为例，GPT-5.4负责规划、协调与最终判断，而GPT-5.4 mini子智能体则并行处理代码库检索、大文件审阅及辅助文档处理等粒度更细的子任务。

OpenAI表示，随着小型模型速度更快、功能更强大，开发者无需使用单一模型处理所有任务，而是可以构建系统，由大型模型负责决策，小型模型则快速大规模地执行任务。OpenAI称：

GPT-5.4 mini 是我们迄今为止针对这种工作流程最强大的小型模型。

这一架构对高并发的任务尤为关键，在编程助手、截图解析及实时图像理解等场景中，响应延迟直接影响产品体感，最优选择往往不是能力最强的模型，而是能够在速度、工具可靠性与任务表现之间取得最佳平衡的模型。

对开发者而言，GPT-5.4 mini与nano的发布意味着在不牺牲系统整体智能水平的前提下，大幅压降推理成本的路径进一步清晰。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时0元领

VIP会员·7天畅读卡 | 大师课·入门串讲

* 同一用户免费领取一次

扫码 免费领取



限免

👍 89 ⭐ 收藏

分享到:

写评论

请发表您的评论





表情



图片

发布评论

