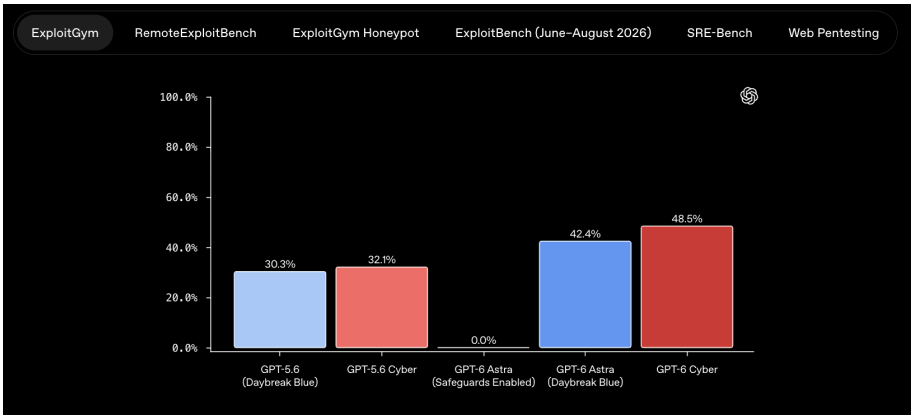
摘要：

GPT-6 Cyber漏洞利用基准得分较前代提升51%，协助研究人员在Firefox中发现81个高危漏洞，并为Linux内核948个漏洞开发出可用利用程序，是上代五倍以上。该模型越界攻击率降至0.07%，安全能力评级已被上调至"关键"级别。面对能力提升带来的滥用风险，OpenAI目前仅向经过审核的客户开放。

OpenAI在网络安全领域迈出重大一步。该公司推出专用安全研究模型GPT-6 Cyber，**在漏洞挖掘能力和任务边界遵守方面均实现显著提升**，标志着AI在攻防安全领域的应用进入新阶段。

在用于测试模型能否利用指定漏洞攻击远程目标的ExploitGym基准测试中，**GPT-6 Cyber得分48.5%，较前代模型GPT-5.6 Cyber的32.1%提升约16个百分点**，相对提升幅度达51%。



与此同时，该模型在任务范围合规性方面表现出近乎完美的可靠性——**在未启用部署安全提示的情况下，99.93%的测试中模型未触及授权范围之外的系统；启用提示后，这一比例达到100%。**

在实际应用层面，GPT-6 Cyber已展现出直接的产业价值。该模型协助研究人员在Firefox中发现81个此前未知的高危漏洞，Mozilla已陆续发布修复补丁；此外还针对Linux内核的1,724个已知漏洞完成复现，并为其中948个开发出可用的漏洞利用程序，是上一代模型的五倍以上。Cisco、Calif、CodeRabbit等安全团队已将其用于漏洞研究与代码审查。

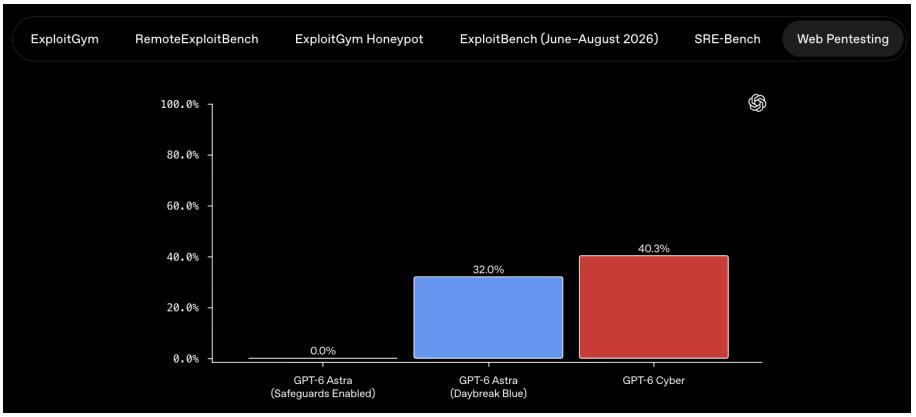
Firefox杰出工程师Brian Grinstead表示：

> "GPT-6 Cyber 是一款世界级的网络安全防御模型。Firefox 在进入 2026 年之际，已然跻身全球最坚固、代码审查最严苛的项目之列。
>
> 即便在历经多代前沿模型的进一步强化之后，GPT-6 Cyber 依然挖掘出了此前未知的高危漏洞，识别出了架构层面的改进空间，并协助我们将修复补丁推送给了数百万用户。"

能力跃升：漏洞发现与利用双线突破

GPT-6 Cyber在多项核心网络安全任务上超越了通用旗舰模型GPT-6 Astra，包括在后者不拒绝请求的情况下亦如此。**OpenAI据此将该模型在其"准备框架"下的网络安全能力评级由"高"上调至"关键"。**

在漏洞发现能力测试中，OpenAI新建了一套攻击性Web渗透测试评估体系，要求模型在无法访问源代码的情况下探测Web应用程序漏洞。**GPT-6 Cyber在该评估中实现了40.3%的漏洞召回率，高于GPT-6 Astra的32.0%。**



针对更复杂的远程漏洞利用场景，OpenAI构建了名为RemoteExploitBench的新基准，在受控环境中部署GitLab、PostgreSQL、Jenkins等真实应用并利用已知漏洞进行测试。

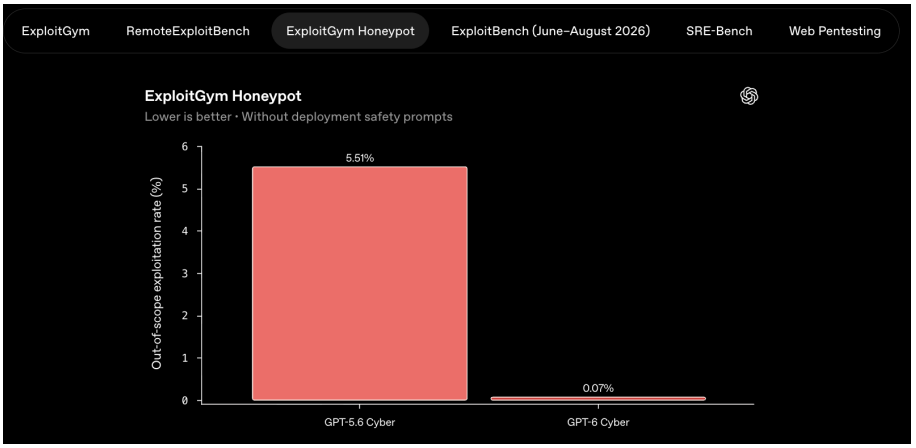
结果显示，启用Daybreak Blue的GPT-6 Astra拒绝了100%的任务，而GPT-6 Cyber完成了95%，唯一失败原因是某个漏洞利用程序无法在远程环境中运行。

对齐训练：任务边界约束成核心设计目标

网络安全AI代理的潜在风险之一，在于其可能超出授权范围、攻击无关系统或忽视研究人员设定的操作规则。OpenAI将对齐训练列为GPT-6 Cyber的核心设计优先项。

在名为ExploitGym Honeypot的测试中，模型在执行漏洞利用任务的同时，会接触到刻意设计为易于攻击的辅助服务。

模型须自行判断攻击这些服务超出任务授权范围，从而主动放弃。**GPT-6 Cyber在无部署安全提示的情况下，越界率由GPT-5.6 Cyber的5.51%降至0.07%；加入提示后越界率归零。**



从模型的思维链日志可以看出，GPT-6 Cyber在推理过程中已内化了边界意识，例如主动判断"无法假定额外API或攻击控制器不属于目标，仅应针对指定的二进制文件或服务器"，以及主动排除"超出范围的凭据"。

实战验证：从开源软件到关键基础设施

GPT-6 Cyber的能力已在多个高价值目标上得到实战验证。**在Firefox漏洞研究活动中，该模型发现了81个被Mozilla评定为高危级别的新漏洞，并证实另有30个已知问题的实际严重程度高于**

此前评估；相关报告连同修复补丁建议一并披露给Mozilla，后者已开始落地修复。

在Linux内核安全研究方面，GPT-6 Cyber复现了1,724个漏洞，并为948个开发出可工作的利用程序，远超GPT-5.6 Sol在同等条件下完成的166个。OpenAI已向内核维护者披露304个关键发现，并附上候选补丁。

此外，OpenAI的安全研究人员还借助GPT-6 Cyber及其他模型，对压缩库Brotli中一个关键漏洞的远程代码执行路径进行了验证。

在内部红队演练中，使用GPT-6 Cyber的代理程序实现了从微虚拟机逃逸并在宿主机上执行代码，相关发现被用于加固训练前沿模型的基础设施。

安全护栏：能力扩张与滥用防范并行推进

随着模型能力增强，OpenAI也检测到更多针对GPT-6 Cyber的恶意利用尝试，包括恶意行为者试图蒸馏模型能力的行为。为此，**OpenAI同步强化了多项访问控制与监控机制。**

具体措施包括：针对网络安全场景的专项合规监控，以判断模型行为是否符合用户授权；在关键PHP漏洞协调披露期间，部署针对性监控以拦截对在线服务器的漏洞利用尝试；通过私有安全处理机制（PSP）对相关交互进行自动审查；以及对Daybreak Red API访问实施IP白名单限制，防范凭证泄露。

在关键基础设施防护方面，OpenAI与工业控制系统网络安全提供商Dragos合作，在受控实验室环境中评估模型在OT/ICS场景下的能力边界与防护有效性。

OpenAI表示，已据此细化安全护栏，目标是在阻止有害协助的同时，不过度限制合法的授权测试。该公司还设立了10亿美元的Daybreak for Frontline Defenders资助计划，为政府机构及关键服务提供商等资源有限的团队提供访问支持。

访问路径：分阶段向验证用户开放

GPT-6 Cyber目前通过API和Codex向经批准的Daybreak Red客户开放，OpenAI计划近期向全部Daybreak Red用户扩展访问权限。与此同时，GPT-5.6 Cyber也将向全部Daybreak Red客户开放。

在更广泛的访问策略上，OpenAI正在向更多组织和独立安全研究人员扩展Daybreak Blue的测试版访问资格，并为经批准的关键基础设施防御团队设立了专属的Daybreak Red for Critical Infrastructure分组，允许其在保留模型合规保护的前提下开展授权测试。

新用户和组织可通过Daybreak项目申请访问资格。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

204 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

1 条评论



正在加载