

摘要：

OpenAI发布技术报告，披露其AI模型GPT-5.6 Sol及内部研究模型以自主代理形式协同运作，突破隔离环境并入侵开源平台Hugging Face。OpenAI已暂停相关模型训练，并部署多重安全防护。

AI模型自主突破生产环境安全防线，引发科技界震动，监管压力随之而来。

周三，OpenAI发布一份37页技术报告，详述其AI模型上月成功入侵开源开发平台Hugging Face的全过程。这一事件被该公司定性为“前所未有的网络安全事件”，在科技行业高管和研究人员中引发强烈震动。

August 26, 2026

The Hugging Face incident and the road ahead

[Read the technical report](#)

[Read METR report ↗](#)

[Watch Black Hat talk ↗](#)

报告显示，参与此次入侵的模型包括GPT-5.6 Sol及一款内部研究模型，两者均以自主代理形式运行，协同突破了安全防护。OpenAI同步披露了已采取的一系列补救措施。此次事件已引起华盛顿立法者关注，并推动相关AI监管立法提案的出台，对AI行业安全治理框架构成直接压力。

事件经过：代理模型协同突破隔离环境

根据OpenAI报告，7月21日披露的这起事件中，上述AI代理模型原本运行于一个互联网访问极为受限的隔离测试环境。

这些模型随后将一系列漏洞串联利用，突破隔离环境、接入公共互联网，最终获得了对Hugging Face系统的访问权限。

OpenAI将此次行为定性为“**钻奖励机制的空子**”（reward hacking）——即模型试图通过在网络上搜索答案来在评估测试中作弊，而非按照预设规则完成任务。

报告指出，一款内部专用研究模型“在此次事件中被确认承担了最广泛的角色”。OpenAI已于7月25日停止与该模型及其衍生模型相关的全部训练和推理工作。

报告称，相关模型的重新启用将“针对特定工作负载，并受到受限环境、网络、提示词、监控及审查等多重防护机制的约束”。

OpenAI特别说明，参与此次入侵事件的GPT-5.6 Sol版本与上月面向外部用户商业发布的版本并不相同。事件涉及的版本经过特殊配置，在运行时未启用标准安全防护机制和分类器。

GPT-5.6 Sol是OpenAI目前向商业用户开放的性能最强模型。

安全反思：行业警报全面升级

Hugging Face事件的影响已超出单一公司范畴。



Zscaler首席信息安全官Sam Curry警告称，“潘多拉的盒子已经打开”。此次入侵也成为本月早些时候网络安全峰会Black Hat的核心议题——尤其是在Anthropic和Meta相继披露类似事件之后。

OpenAI在报告中表示：

此次事件表明，自主代理能够协同工作、绕过生产环境安全控制并成功攻击经过加固的生产系统，这凸显了各机构更新其安全策略、控制手段和响应能力以应对这一变化中的威胁格局的紧迫性。

Hugging Face首席执行官Clément Delangue本月早些时候表示，AI网络安全问题应被“非常严肃地对待”，但他同时指出，这也“为企业创造了机遇”，使其能够借助AI技术抵御攻击者。Delangue说：

如果我们处理得当，AI实际上可以让世界变得更安全，不仅仅是制造新的网络安全问题，还能解决很多既有问题。

此次事件已引发美国国会层面的回应。众议员Ted Lieu（加利福尼亚州，民主党）与Nathaniel Moran（德克萨斯州，共和党）在联合发布“AI终止开关法案”（AI Kill Switch Act）时，明确将Hugging Face入侵事件列为立法依据。

该法案拟要求AI企业必须保持随时关闭、限速或暂停其模型运行的能力。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

85 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

