

摘要：

随着OpenAI和Anthropic的API费用攀升与开源模型性能的提升，Harvey、Abridge、Decagon等横跨法律、医疗、金融赛道的初创AI企业，相继宣布自研模型的计划，部分企业已将八成流量切换至自有模型。此举对OpenAI和Anthropic构成直接压力，应用层客户的流失可能蚕食其最重要的收入来源。

法律AI独角兽Harvey今年毛利率一度跌至-50%，成为一个缩影——随着OpenAI和Anthropic的API费用持续攀升，越来越多的AI应用初创企业开始拥抱开源权重模型，重夺成本控制权。

这一趋势正在加速。Harvey、Abridge、Decagon、Ramp等横跨法律、医疗、金融和客服赛道的初创企业，相继宣布自研或定制模型的计划，部分企业已将八成流量切换至自有模型。

Sequoia Capital和General Catalyst等头部投资机构亦在背后助推。

此举对OpenAI和Anthropic构成直接压力。两家公司正各自筹备备受期待的IPO，而应用层客户的外流可能蚕食其最重要的收入来源。

毛利率跳水，倒逼Harvey重构模型策略

Harvey的处境最能说明问题。

这家估值156亿美元的法律AI初创企业，长期将OpenAI的GPT-4作为其产品核心。据彭博，今年3月该公司AI智能体完成重大更新后，用户使用量急剧攀升，但随之而来的是毛利率的断崖式下滑——从年初约50%跌至6月的-50%。

Harvey今年的AI Token使用量增长了二十倍。

Harvey联席创始人兼总裁Gabe Pereyra表示，此前AI应用的表现高度依赖底层模型的能力，因此付费购买OpenAI和Anthropic的最佳模型是必要选择，自训练模型的意义相对有限。但这一逻辑在成本的重压下开始松动。

今年8月，Harvey发布了自有模型，底层由月之暗面（Moonshot AI）的Kimi K3提供支持。该模型的性能接近Anthropic旗下最佳产品，但成本仅为其一小部分。结合其他AI使用策略的调整，Harvey的毛利率已重新转正。

使用开源模型浪潮席卷多个垂直赛道

Harvey的转型并非孤例，这一趋势已在多个行业蔓延。

- 医疗科技初创企业Abridge近期宣布，将基于英伟达开源模型，为临床场景自建基础模型。
- AI客服初创企业Decagon表示，目前已有80%的查询请求流经其自有模型。
- 金融科技领域，Ramp和Rogo正首次探索训练自有模型的可能。
- 编程工具领域，已并入SpaceX旗下的Cursor以及估值480亿美元的Cognition，是最早发布定制模型的AI应用公司之一。

Ramp联席CEO Karim Atiyeh表示，此前训练专属模型在经济上完全不合理，但随着今年6月完成7.5亿美元融资以及开源权重系统性能的大幅跃升，这一逻辑正在逆转。

旧金山风险投资机构Basis Set的创始人兼管理合伙人Dr. Lan Xuezhao对此态度更为强硬：

"如果不去优化成本、精调自有模型，你在定义上就是低效的。如果一家公司不考虑自建模型，可能根本拿不到融资。"

来自闭源巨头的双重压力：涨价与入侵

推动这一转变的，不仅是成本本身，还有OpenAI和Anthropic日益强势的商业策略。

两家公司近期均转向对企业用户的模型使用量额外收费，叠加此前的订阅基础费，对"Token最大化"的使用模式形成了直接惩罚。据报道，Uber在鼓励工程师最大化使用Anthropic的Claude Code后，仅到4月便耗尽了全年的AI预算。

与此同时，**OpenAI和Anthropic今年均在法律、金融、医疗等初创企业的核心赛道积极招兵买马，推出插件并试点行业应用，直接与客户群体形成竞争关系。**

初创企业对模型供应商的依赖还带来了另一层风险：被切断访问权限。SpaceX完成对Cursor收购后不到一周，OpenAI即宣布暂停向这家编程工具初创企业提供模型访问，理由是马斯克旗下公司过去存在违反服务条款的情况。

正是在这一背景下，在Anthropic办公室举行的一次投资者论坛上，与会者专门讨论了初创企业自建模型的趋势。Anthropic表示，Harvey仍需依赖Anthropic旗下最强大的Claude Opus模型处理最复杂的任务。

开源路径的现实挑战

转向开源权重模型并非没有代价，这条路同样布满障碍。

人才是首要瓶颈。Anthropic投资方Menlo Ventures合伙人Matt Kraning指出，能够胜任模型精调工作的专业工程师薪酬可达数百万美元，且极易被OpenAI和Anthropic等大型机构挖走。

数据是另一道门槛。企业自训模型需要大量专有数据，Harvey由于无法访问客户的敏感法律文件，不得不从AI数据提供商Mercor处购买训练数据。

开源模型的基础设施成本同样不可忽视。视觉AI初创企业Elorian的CEO Andrew Dai指出，**下载开源权重模型并自行管理计算基础设施的开支相当可观，对于流量较低的早期公司而言，按用量付费给闭源模型可能反而更为经济。**

此外，确有企业尝试后铩羽而归。初创企业Salespeak此前宣布自建大语言模型的计划，但几个月的摸索后放弃了这一方向。其联席创始人兼CEO Omer Gotlieb表示，与Anthropic、OpenAI的现成模型相比，未能看到"显著优势"。

依赖仍在，博弈持续

尽管自研浪潮汹涌，多数初创企业并未寄望于完全摆脱OpenAI和Anthropic。



Redpoint Ventures管理董事Logan Bartlett同时持有Anthropic、Abridge和Ramp的投资，他预计行业降低对Anthropic模型依赖的动力将持续增强，但坦承，初创企业仍会在必要时为最优性能买单。"它们不会为了赌气而自断手脚，"他说。

Anthropic的演示材料亦印证了这一现实——Harvey仍需Claude Opus处理最复杂的任务，这表明在现阶段，开源与闭源的混合使用策略，或许才是多数初创企业的最优解。

这场围绕AI成本与控制权的博弈，实质上是应用层初创企业寻求与模型层巨头重新议价的过程。随着开源模型性能持续逼近闭源产品，这一张力将在OpenAI和Anthropic迈向IPO的进程中，持续考验双方的利益边界。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

81

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论