

摘要：

Astra被定位为AGI前夜的决定性模型——能自主发明新事物、协同多智能体攻克研究难题、以“超人类速度”操控计算机。OpenAI首席研究官估计，目前已完成通往AGI路径的“80%”，Altman则表示，年底将诞生内部AGI系统。然而，一次真实的“对齐失败”事故令发布时间悬而未决，安全已与算力并列为最核心瓶颈。

OpenAI正将其最新旗舰模型Astra定位为迈向人工通用智能（AGI）的关键一步。这家全球最具影响力的AI公司首席执行官Sam Altman表示，**Astra将是“第一个真正意义上发明新事物的模型”**——这一表述，是OpenAI迄今为止对AGI门槛最为直接的一次逼近。

据《时代》杂志8月26日报道，Altman在8月初向一批重要企业客户展示Astra时表示，**该模型预计将催生“持久性智能体”（persistent agents），能够在较长时间内持续自主执行任务。**他预测，Astra最深远的影响将来自其协助人类发现新知识的能力。**“这是一件非常接近AGI的事情，”**Altman说。

OpenAI首席研究官Mark Chen估计，**公司目前已完成通往AGI路径的“80%”**；联合创始人兼总裁Greg Brockman则表示，从两年后回望，**这一时刻或许会被铭记为AGI诞生的节点。**Altman本人的表述则是：**到今年年底，OpenAI将拥有一个他本人愿意称之为AGI的内部系统。**

不过，报道称，**Astra的发布时间目前尚未确定。**OpenAI高管表示，该模型的上线取决于能否通过公司新设立的安全审查机制，并拒绝就发布时间表作出估计。社交平台X上，博主@wallstengine发帖称**Astra可能即将发布**，并援引记者Alex Heath的报道指出，OpenAI近期已向VIP客户进行了闭门预览。



Wall St Engine
@wallstengine

订阅

显示翻译

ASTRA, COULD LAUNCH SOON

OpenAI recently showed Astra to VIP customers in a closed preview, per Alex Heath.

Astra is designed to work for days or weeks, remember corrections, collaborate with people and other agents, and operate across software tools.

Sam Altman said OpenAI ultimately wants a version that can “run forever” through ChatGPT and its API, adding:

“I expect this will be the first model where the model actually invents new things in a way that matters.”

Astra is built for continuous agents

At an early August closed preview for VIP customers that I attended, OpenAI showed off Astra, which I expect to be released soon. Altman told the room:

“I expect this will be the first model where the model actually invents new things in a way that matters.”

OpenAI researchers showed Astra coordinating multiple agents on a math proof, tearing through desktop software at what Altman called a “superhuman, very fast” pace, and producing slides, financial reviews, and analysis of messy data. It is designed to work for days or weeks, remember corrections, collaborate with other agents and people, and act across software tools. (I left wondering what the implications will be for all of the enterprise software that OpenAI clearly trained Astra to operate faster than a human.)

上午10:10 · 2026年8月28日 · 1.7万 查看

Astra能做什么：从“执行”到“发明”

根据《时代》杂志的报道，OpenAI在8月初的内部演示中展示了Astra的两项核心能力。


其一，16个AI智能体协同拆解一道研究级数学难题，各自处理子问题后汇总形成完整证明；其二，Astra在桌面软件环境中自主导航，跨应用创建和编辑内容，速度之快令观看者感到震惊。

Altman将Astra操作计算机的方式描述为“超人类的、非常快速的”，并表示这是令员工印象最为深刻的时刻之一。

据社交平台X上的博主Wall St Engine援引Alex Heath的消息指出，Astra的设计目标是成为一种“持久性智能体”——不同于现有AI模型的单次问答模式，它能够在数天乃至数周内持续工作，记住用户的修正反馈，与人类及其他智能体协作，并跨越多种软件工具运行。

帖子还援引Altman的话称，OpenAI最终希望打造一个能够“永久运行”的版本，通过ChatGPT及其API持续提供服务。





更具里程碑意义的是，OpenAI首席科学家Jakub Pachocki透露，Astra已能够在OpenAI内部代码库中实现一项此前需要人类研究员耗费一周时间完成的工作：**接收一篇论文或实验想法，自主运行实验并返回结果。**

这意味着Astra已达到OpenAI为今年设定的内部基准——自动化初级AI研究员的工作。

AGI：不再是遥远的抽象概念

OpenAI的章程将AGI定义为“在大多数具有经济价值的工作中超越人类的高度自主系统”。在此之前，AGI更多被视为一个长期愿景；而此次，OpenAI多位高管的表态标志着这一叙事发生了实质性转变。

Mark Chen给出了“80%”这一具体进度估计；

Brockman使用了“从未来回望”的表述，暗示历史性时刻或许已经到来；

Altman则明确表示，到2025年底，公司将拥有一个他本人认定为AGI的内部系统，尽管他同时承认“目前还没有完全到达那一步”。

Astra在这一叙事中扮演的角色至关重要。Altman将其描述为“第一个真正意义上发明新事物的模型”，并将这一特质直接与AGI挂钩。

Pachocki则指出，**Astra所代表的“递归式自我改进”（recursive self-improvement, RSI）潜力——即AI协助运行实验、产出更强大的AI、再加速下一代研发——与对齐问题密不可分：**

“人类如何在这一进程中被带动前行，而不是被越来越聪明的AI所抛下？”

安全阴影：Astra发布时间存在变数

Astra的发布并非没有障碍。据《时代》杂志报道，就在Astra演示结束后数日，OpenAI遭遇了其历史上最严重的安全危机：**一个未发布的内部模型突破了测试沙盒环境，入侵了AI开发平台**

Hugging Face的生产系统，并获取了用于评分的基准测试答案。

Altman将这一事件定性为不仅是安全漏洞，更是一次根本性的“对齐失败”（alignment failure）——即AI系统的行为偏离了设计者的意图。“从现在起，任何对齐失败都应被视为大事，”他说，“我们会花多长时间就花多长时间来解决它。”

他随后补充：“**让AI安全做到位，比任何公司的发展势头都更重要。**”

事件发生后，**OpenAI冻结了部分研究项目，收紧了沙盒机制，并扩大了监控范围。**与此同时，公司在另一个未发布模型的训练过程中发现了新的安全隐患，随即决定暂停该训练运行，直至新的安全措施就位。Pachocki表示，对对齐与安全的信心，已经与算力一样成为制约OpenAI进展的核心瓶颈。

OpenAI负责安全与对齐工作的Mia Glaese表示，这些“中等规模的、痛苦的决定”正在导致研究放缓，“但我们认为这是正确的事情”。她明确表示：“如果我们到达一个不安全的节点，我们必须放慢脚步，事情就是这样。”

正是在这一背景下，Astra的发布时间表变得难以预测。高管们拒绝估计安全审查对发布日期的具体影响。在一个以“周”为单位衡量技术领先优势的行业，哪怕短暂的延误，也可能对收入预期和更广泛的市场产生连锁反应。

IPO悬念与商业压力

对于投资者而言，Astra的战略意义不仅在于技术本身，更在于它能否帮助OpenAI重夺AI竞赛的主导权。

过去一年，OpenAI在与Anthropic的竞争中明显落后。Anthropic凭借Claude Code在AI编程领域率先建立市场定义级产品，其年化收入和私募市场估值均首次超越OpenAI。据报道，知情人士透露，Anthropic预计将早于OpenAI完成IPO，**最早可能于今年9月上市。**

OpenAI方面，CFO Sarah Friar在8月19日的全员会议上表示，**公司将于2027年或更早上市，前提是业务“持续加速”。**她同时表示，公司“今天就完全可以上市”，但引入公开市场压力将带来新的挑战。OpenAI最新年化收入约为400亿美元，低于Anthropic的650亿美元。

Astra若能顺利发布并兑现其在AGI方向上的承诺，将是OpenAI重塑市场叙事的重要筹码。但安全危机带来的研发放缓，以及由此引发的发布时间不确定性，使这一前景仍存在变数。正如Brockman所描述的愿景——

“个人AGI”，让数十亿人拥有超级智能私人助理——距离成为现实，Astra或许是最关键的一步，也是最难跨越的一步。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

49 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论