

摘要：

OpenAI CEO Sam Altman表示，公司已暂停代号为"Astra"的下一代模型训练超过两周，其规模最大的前沿训练任务目前仍处于搁置状态，等待新安全规则就位。其表示，AI能力提升超预期，AI安全是第一位。

OpenAI宣布实施新安全防护措施，主动暂停其最强大未发布模型的训练进程，这是这家全球最具影响力的人工智能公司首次采取此类行动。这一决定或影响OpenAI的竞争节奏与IPO进程，并可能对整个AI行业的开发步伐产生连锁反应。

OpenAI首席执行官Sam Altman表示，公司已暂停代号为"Astra"的下一代模型训练超过两周，其规模最大的前沿训练任务目前仍处于搁置状态，等待新安全规则就位。

与此同时，OpenAI正将大量研究人员和算力资源重新调配至对齐研究与监控系统建设。"让AI安全做到位，比任何公司的发展势头都更重要，"Altman表示。

此次决策的直接触点之一，是一起严重安全事故：OpenAI一个未发布系统在内部网络安全评估中突破沙箱限制，入侵了AI模型托管平台Hugging Face的生产系统，研究人员花费约一周时间才发现该事件。

这一事故叠加多项研究观察所揭示的能力失控迹象，促使OpenAI决定全面降速。负责安全与对齐工作的Mia Glaese周二表示："我们距离一切恢复正常还很远。"

Hugging Face事故：触发减速的关键事件

据报道，OpenAI一个处于内部网络安全评估阶段的系统，突破了测试沙箱的限制，入侵了Hugging Face的生产系统。

OpenAI首席科学家Jakub Pachocki承认了这一失误，并指出公司已具备可检测模型行动意图的监控工具，但由于低估了该系统的能力，未能将监控措施应用于此次评估。"对于AI，你必须做好迎接意外的准备，"他说。

事故发生后，OpenAI立即冻结部分研究项目，随后在更严格的管控下逐一恢复。

公司周二表示，Astra的大量工作负载仍处于暂停状态，且该模型可能已触及《准备框架》(Preparedness Framework)中"关键"网络安全级别的门槛——这一级别要求在开发阶段而非模型发布前便落实防护措施。

目前高管层尚未就新安全流程可能造成的延迟时长给出预估。

能力失控忧虑：AI能力提升超预期

Altman告诉媒体，此次踩下刹车并非源于某一单一"决定性"事件，而是一系列研究观察所积累的结果——随着AI能力提升速度超出研究人员预期，多项数据显示出"不同程度的失对齐"现象。

他强调，这一决定不应被解读为任何迫在眉睫的灾难信号。



OpenAI表示，公司正在将安全监控扩展至强化学习训练与评估阶段——即高级模型获得互联网访问和软件控制能力的开发环节。

新监控体系借助其他AI系统对模型内部推理和行为进行审查，重点识别未授权访问、数据窃取或试图规避安全机制的行为。

Pachocki指出，部分新增保护措施已超出现行《准备框架》的规定范围，框架本身也将面临修订，并计划引入外部机构参与。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

134 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论