

摘要：

OpenAI正式向外部开发者开放Agents API公测，该API将支撑Codex及企业版ChatGPT的代理框架以编程接口形式提供，仅按token及工具调用量计费。核心能力在于强大的harness机制，包括上下文自动压缩、工具并行调用及多代理协同，支持单次API调用创建生产级代理。

OpenAI正将支撑其旗舰编程助手Codex的底层代理框架向全体开发者开放，标志着该公司将内部积累的Agent工程化经验正式产品化输出。

OpenAI周三宣布，Agents API即日起进入公开测试阶段，面向所有开发者开放。

Introducing the Agents API

Build and run cloud agents with the Codex harness, fully managed by OpenAI.

此前这套代理框架与基础设施只服务于Codex和企业版ChatGPT，如今以编程接口的形式对外提供，开发者无需额外付费，仅按实际消耗的token及工具调用量计费。

过去一年，随着Codex和ChatGPT for Work触达全球数百万用户，OpenAI也在实践中摸清了一件事：要让长时运行的Agent在真实场景中真正好用，光有模型远远不够，它需要一套强大的harness来管理上下文、高效调用工具、协调子Agent，还需要配套的基础设施支撑Agent连续运行数天，并在可以读写文件、执行代码、保存中间结果的环境中持续工作。

从早期客户披露的数据来看，落地效果颇为可观。SafetyKit将案例审核 workflow 迁移至Agents API后，单案处理成本下降了60%；Hypha通过将代理执行框架与沙箱环境解耦，把代理响应失败率压低了86%；科技公司Cirridae的评估分数则从0.71提升至0.85，同时实现了4倍的延迟降低。

单次API调用即可创建生产级代理

Agents API的核心设计理念是降低构建长时运行代理的工程门槛。

每当新模型发布，开发者往往不得不重新搭建自己的 harness 才能用上新能力，这无疑占用了本该用于打磨产品的宝贵精力。Agents API 通过版本化的方式，让每次模型更新都能直接对应相应的能力访问入口。

OpenAI 与模型保持同步，持续维护和优化这套 harness。这意味着开发者只需在一次API调用中指定任务、模型、工具与运行环境，即可创建可投入生产的代理，而无需自行搭建上下文管理、子代理编排等底层基础设施。

JSON

```
1 import OpenAI from "openai";
2
3 const client = new OpenAI();
4
5 const session = await client.beta.agents.sessions.create({
6   agent: {
7     model: "gpt-6-astra",
8     tools: [
9       {
10        type: "mcp",
11        server_label: "observability",
12        transport: {
13          type: "http",
14          server_url: "https://observability.example.com/mcp",
15        },
16      },
17    ],
18    multi_agent: { enabled: true, max_concurrent_subagents: 3 },
19  },
20  vault_ids: ["vault_YOUR_VAULT_ID"],
21  environment: {
22    type: "openai_hosted",
23    capability_directories: ["/workspace/capabilities/skills"],
24  },
25  input:
26    "Investigate service-api's elevated 5xx rate over the last 30 minutes. " +
27    "Delegate deployment, error, and dependency analysis to subagents. " +
28    "Save findings, evidence, and recommended mitigation in /workspace/outputs.",
29 });
```

该API具备三项关键能力：


- 其一，上下文自动压缩。当会话趋近上下文窗口上限时，系统自动对早期内容进行压缩，使代理可持续运行数小时乃至数天；
- 其二，工具搜索与并行调用。按需加载相关工具定义以降低token消耗，并支持并行执行多个工具调用；
- 其三，多代理协同。主代理可将复杂任务分解后下发至多个并行运行的子代理，各子代理独立维护上下文，最终由主代理汇总结果。

物流科技公司Nash表示，其平台通过Agents API部署了数千个长时运行的AI代理，负责管理全球数亿次配送任务，代理运行周期可横跨数小时乃至数天。

环境选择灵活，生态合作伙伴覆盖多元需求


在计算环境层面，Agents API提供多种部署选项。

OpenAI提供自托管沙箱，与Codex及ChatGPT共用同一沙箱基础设施，支持快速启动与弹性扩展；



(Agents API 为AI代理提供与 Codex 相同的框架和基础架构)

同时，OpenAI已与Blaxel、Cloudflare、Daytona、DigitalOcean、E2B、Modal、甲骨文、Runloop及Vercel等生态合作伙伴达成一级集成协议，为开发者提供涵盖私有云部署、特定存储机制以及不同CPU、GPU与内存配置的差异化选项。



这一设计使Agents API得以覆盖从初创团队快速验证到企业级生产部署的全谱系需求。

建筑及居家服务领域的AI平台Long Lake表示，借助该API，其团队现可在数小时内跨行业部署代理，而非此前所需的数天周期。

开源框架与版本化更新降低迭代成本

Agents API基于开源的Codex执行框架构建，开发者可查阅其公开代码库以了解模型调用、工具协调与上下文管理的核心逻辑。

OpenAI负责维护并持续优化该框架，开发者在每次模型升级时可自动获益，无需自行重构代理架构。

OpenAI表示，Agents API当前处于公开测试阶段，将根据开发者反馈快速迭代，后续推进至正式发布。

该公司同时表示，支持MCP协议、自定义函数及网页搜索等内置工具。对于开发者而言，无需为API本身支付额外订阅费用，这一定价策略有助于降低采用门槛，同时将收入来源与实际使用量直接挂钩。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

186 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论