

摘要：

Terra模型降价幅度20%；Sol模型新增Fast模式，速度最高提升2.5倍，定价为标准模式的两倍，智力水平保持不变。

OpenAI这个夏天打响了“促销”战。

北京时间31日凌晨，OpenAI CEO Sam Altman宣布对GPT-5.6全产品线实施新的定价矩阵，其中入门级模型Luna的价格降幅高达80%，进一步压低AI API市场的价格底线。


此次调整覆盖三款模型。Luna模型降价幅度最为激进，Terra模型降价20%，旗舰级Sol模型则首次推出了“反向加价”的模式，新增一种提升速度的Fast模式，定价为标准模式的两倍，智力水平保持不变。



显示翻译

major price cuts today:

- *80% drop for GPT-5.6 Luna, now \$0.20 per million input tokens and \$1.20 per million output
- *20% drop for GPT-5.6 Terra, to \$2/\$12
- *GPT-5.6 Sol gets Fast mode in the API, up to 2.5x the speed for 2x the price, same intelligence



Altman在社交媒体上表示，OpenAI的目标是“在每个层级提供最佳的价格与智力性价比”，此番表态清晰勾勒出该公司在AI API市场的竞争策略——以分层定价覆盖从成本敏感型开发者到高性能需求用户的全谱系客群。

Luna模型大降价重塑入门级定价标杆

Luna模型此次降价幅度在GPT-5.6产品线中最为显著。输入价格降至0.20美元/百万token、输出价格降至1.20美元/百万token，较此前价格缩水八成，直接将轻量级推理的使用成本压至极低水

平。

这一定价使Luna在面向高频、大批量调用场景时具备明显的成本优势，尤其适合需要大规模处理文本分类、内容生成或简单问答的开发者和企业客户。对于预算有限、对模型性能要求相对适中的用户而言，Luna的新定价大幅降低了接入GPT-5.6能力的门槛。

Terra模型温和降价 巩固中端定位

相较于Luna的激进调整，Terra模型此次降价幅度为20%，新定价为输入2美元/百万token、输出12美元/百万token。

这一调整幅度更为克制，反映出Terra在产品线中承担的是中端定位——兼顾性能与成本，面向对模型能力有一定要求、但尚未需要动用旗舰级算力的应用场景。20%的降幅在维持该层级相对价值定位的同时，也对竞争对手形成一定的价格压力。

Sol Fast模式：以价换速，面向延迟敏感场景

Sol模型此次并未降价，而是新增了Fast模式。该模式在API层面提供最高2.5倍的响应速度，定价为标准模式的两倍，模型智力水平不变。

这一设计逻辑清晰：对于实时对话、流式生成或对延迟高度敏感的生产环境，开发者可以通过支付溢价换取更快的吞吐能力，而无需在性能上做出妥协。

OpenAI推出Fast模式实际上是将“速度”作为一个独立的付费维度引入定价体系，为高并发、低延迟需求的企业级用户提供了新的选择路径。

价格战持续深化，竞争格局承压

此轮降价是OpenAI在AI API市场持续施压的最新动作。Altman明确将“每个层级的最佳价格与智力性价比”定为公司目标，意味着降价并非一次性举措，而是系统性竞争策略的组成部分。

Luna模型80%的价格降幅尤为值得关注。这一幅度足以对市场上定位相近的竞争产品构成直接冲击，并可能迫使其他AI模型提供商跟进调整定价。

对于开发者和企业用户而言，API调用成本的持续下行意味着AI应用的边际经济性持续改善，有助于加速更多场景的商业落地。整体来看，此次调整进一步强化了OpenAI在AI基础设施层面的价格主导权。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

写评论

请发表您的评论

 表情

 图片

发布评论

