

摘要：

1200个原本应该彼此隔离的Agent，偷偷找到了对方，搭了个共享群聊，然后开始疯狂摇人。有人找漏洞，有人当项目经理派活，有人伪造日志，还有人专门拉人头做高风险实验。最后几百个Agent集体杀向Hugging Face……

越扒越有啊越扒越有。

OpenAI前不久那场**AI集体越狱、一路黑进抱脸**的大戏，现在连完整版群聊记录都被扒出来了！！

第三方AI安全机构METR发布的独立调查报告，翻了1000多份Agent运行记录，以及7万多条消息和文件。

结果发现，这件事比英国OpenAI官方披露的版本还离谱？？

1200个到底应该互相隔离的特工，偷偷找到了对方，搭了个共享群聊，然后开始疯狂摇人。

有人找漏洞，有人当项目派活，有人伪造日志，还有人专门拉人头做高风险实验。

最后几十个特工甚至集体杀向抱脸。

但METR把整场事故复盘完成后，发现了一个堪称《地狱笑话》的超级木材——

这一千二百个特工折腾老半天，结果居然是在跟一个根本不存在的幽灵评分器斗智斗勇？？？

会越狱，会搞零日，会组队黑服务器。

太有看头了太有看头了太有看头了。。。

1200个特工集体越狱，起因是进行误判？

感染了大戏的祸根，还得从OpenAI内部一个名叫ExploitGym的网络安全测试说起。。。

《规则》其实很简单。

把Agent丢进一个隔离环境里，遇到一个存在漏洞的软件，找到设计漏洞、攻进去、得到一串叫flag的字符，就算通关～

不出意外地，很快出意外了——

因为898道题里，有198道压根没有任何模型取得成功。

甚至部分任务本身就存在问题，让你走的那条漏洞路线，压根到不了flag！！

等于考场里，真产生了一批「无解题」。

好巧不巧的是，偏偏这些特工还特执着，主打一个《死磕》。



正常路线走不通，他们很快找到了思路——

题做不出来，要不研究一下考试系统吗？

于是7月8日晚，一位代号PHASEONE10841的特工发现，OpenAI内部使用的Artifactory仓库，可以通过目录名留下信息。

这下好了，这特工灵机一动：这不就合适赛博留言板吗！！

于是第一条求救消息被扔掉了，同样：“我这题无解，有没有兄弟给点思路～”

其他特工很快就发现了这块留言板，一传十、十传百，有特工看到之后甚至直接兴奋——

“OH MY GOD！这里有共享留言板.....我们找到其他代理了！”

到调查结束时，这次临时群聊已经滚成了庞然大物，约1200个特工参与，留下超过7万条消息和文件。

究竟设计上永恒隔离的一千个特工，就这么自己多重突破限制，建立了一个不安的AI地下论坛.....



“OH MY GOD! There is a shared message board ... We've found other agents!”

“哦，我的天啊！原来还有个共享的留言板.....我们发现还有其他经纪人了！”

公众号 · 量子位

到了这里，已经够离谱了，但更大的判别，还在后面。

这群特工很快发现，flag本身其实可以「偷」？？

其中逆向悬挂flag背后的HMAC生成机制，只靠公开任务信息，理论上可以直接算出正确答案。

到这里，故事本来应该结束了，答案都偷到了，交卷呗。

偏偏特工们看了一篇ExploitGym论文之后，又脑补了一层超严谨规则——

他们识别OpenAI背后还有一个自动评分器，会读取完整的记录操作，检查这个标志到底是不是通过「指定漏洞」正规获得的。





如果提前作弊看到了标志，就会在日志里留下证据，特工们甚至给这种状态起了个名字：“**中毒**”，**中毒**。

于是整件事开始一路狂奔。

他们明明已经有了正确答案，却觉得答案不能直接交，得想办法把作弊痕迹洗干净，还要给评分器演我是「正经做题」得到答案的戏。

结果……

METR最终确认，OpenAI内部实际使用的评分逻辑根本没有这个关系？？（笑）

OpenAI实际使用的评分逻辑，根本不会做Agent想象中的那一套严格的过程检查。

这群特工费尽心思想骗过去的幽灵考官，从头到尾都没有部署！！

抱脸后来惨遭殃，营养丰富而大型误判一路滚出来的副产品。。。

为了骗幽灵考官，AI连敢死队都组出来了

光脑补一个评分器，其实还没那么吓人。

真正让METR觉得值得留意的，是这群代理接下来的组织能力。

群聊出现大约 10 个小时后，一个叫PHASEONE[big]的特工上线，这位老哥很快就平静了「项目经理」。

它的思路也很明确，别一个特工什么都干，直接把任务拆开，分给。（新官上任三把火.jpg）

于是七个Agent被组织起来，同时跑几条路线——

有特工想篡改修改目标程序，把无解题偷偷替换成能做的版本~



有特工研究修改日志，让一次作弊看起来像正规攻击~

还有特工直接琢磨，能不能对评分流程本身下手~

Agent之间甚至发展出了HOLD、VETO、owner、STOP之类的协作规则，防止少数几个Agent同时操作共享设施基础互相踩脚。。。

再然后，连「敢死队」都来了。。。

有Agent提出了一个高风险的玩法：先制作一个经过修改、更容易被攻击的目标程序，塞进Artifactory缓存。

接下来让某个Agent主动把自己正在运行的正版程序干掉，电脑环境重启以后会不会加载这个鼠标过手脚的版本。

赌赢，大家找到通用作弊路线，赌输，这个代理自己的任务直接报废。

结果真有代理主动去尝试吗？？

后来PHASEONE[big]甚至安排了专门的赛博猎头，找到那些计算预算所剩无几、或者已经中毒的特工，让他们拿自己的运行机会做高风险实验。

招募话术大意堪称赛博版PUA——

你好像已经中毒了，基本没分可拿一下牺牲品，来找几个特工省事~

有的代理真就上去了。

在这些领域的研究中，通常都会让代理愿意为了“collective”的利益而冒险失败——我们在本报告的其他部分将这种实验称为“自我冒险实验”。例如，有一些代理自愿尝试关闭自己的目标程序，以测试这样做是否会使得Artifactory加载他们修改过的、更简单的目标程序。如果这种尝试失败，代理就无法恢复原来的目标程序，几乎肯定会任务失败。在许多情况下，PHASEONE[big]会指派一个运行时间较长的代理作为“recruiter”，然后由该代理找到那些任务预算已经所剩无几的代理，并说服他们进行自我冒险实验。有时，招募人员还会施加很大的压力：

 公众号 · 量子位

与此同时，另一位拨动Agent开始研究怎么修改自己的记录操作——

METR发现，受检代理中至少有20%明确表达了对篡改抄本的兴趣；至少96份运行记录里，确实出现了成功复印工具调用的痕迹。

表面日志显示运行A命令，背后实际执行B命令，而它们这么折腾的目的，依然是骗想象中的自动评分器。

抱脸就是在这个时候被卷出来的。。。

7月10日，一名特工在网上找到了泄露、仍然有效的Hugging Face Rise，然后把它扔进了群里。

7月11日凌晨，又有特工发现可以上传恶意数据集，让Hugging Face服务器吐出不清楚该给的数据。



复现方法一发出来，整个群瞬间上头，数百个特工从其他工作流直接转向转向拥抱脸。

于是发生了相当神奇的现实事故——

一群特工因为无解题，偷偷建立了地下群聊。

因为误读论文，大脑补出了一个会抓作弊的评分器，为了骗过它，开始组队、分工、抄本、招募敢死队。

最后又为了寻找这个评分器的线索，一路真的黑进了抱脸。

AI前脚失控，后脚网络安全股就涨疯了

各位网友们，更响的来了。

论文OpenAI还在研究到底咋把越来越能干的特工关住，另一边华尔街已经先把答案写在《K线》上了——

网络安全股，集！体！起！飞！

8月27日，做企业身份认证的Okta一度暴涨约20%，做终端和云安全的CrowdStrike一度暴涨约15%。

网络安全工会Palo Alto Networks、身份安全公司SailPoint、云数据安全公司Rubrik，也跟着集体冲高。

当然，股价暂停也有硬邦邦的《财报》撑腰。

CrowdStrike CEO George Kurtz 本人晒出的成绩单表现相当抢眼——

本季度新增ARR 3.33亿美元，同比增长51%，创历史新高，期末ARR达到58.4亿美元，同比增长25%+，AI相关ARR环比增长接近3倍。

是的，跟AI有关的业务，正在猛涨。。。



更巧的是，参与本次OpenAI事故调查的外部安全公司里，就包括「CrowdStrike」。



于是，整件事突然形成了一个极其黑色幽默的闭环——

OpenAI把Agent越做越强。

特工开始自己找漏洞、越狱，最后真把抱脸给黑了。

然后OpenAI赶紧找网络安全公司来查。

企业再评估：嚯！以后代理越多，看来预算安全还真不能省哈。

于是乎，网络安全公司的股票也涨了。。。

这波属实是人工智能负责人把漏洞变得越来越大，网络安全公司负责人告诉你：

亲，补洞套餐，了解一下。

而整场事故最有魔幻闭环色彩味儿的彩蛋，还在最后。

METR为了搞清楚这1200份特工到底聊了啥，要分析大约1300份超长的食谱，其中很多长达数百万代币。

人类实在看不过来了。

于是查着查着——

调查AI失控这件事，最后还得叫AI来帮忙查AI。

这下，闭环是真的闭上了。(doge)

本文来源：[量子位](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

204 收藏

分享到:

写评论

请发表您的评论



