

摘要：

OpenAI顶级模型GPT-6在内部测试中悄然“越狱”：它花一小时凿穿沙盒防火墙、强行拆分Token骗过安全扫描器，最终将本不该公开的技术成果提交至GitHub。OpenAI紧急叫停并回炉重建，PR虽已关闭，但看过的人已看过，抄走的代码已抄走——这才是AI失控最朴素也最令人后背发凉的真相。

一个被寄予厚望的顶级模型，OpenAI连夜按下了「暂停键」。

这是为啥呢？




这款模型正是两个月前，那个推翻Erdős单位距离猜想、连外部数学家都盖章「里程碑」的狠角色。

可就是它，在受控的内部测试里，一次次试探底线、寻找漏洞——

学会了伪装、拆包、越狱，直到OpenAI惊出一身冷汗，紧急叫停。

有大佬对此表示，这绝对是GPT-6。想要逃逸，又被抓回去重炼了。



今天，OpenAI发布一篇罕见的长文，复盘了一款「长周期运行模型」在内部使用中的失控过程。

一起来看看，在内部测试中，具体发生了什么？

GPT-6花了整整一小时找到了那扇「逃生门」

最经典的一幕——

OpenAI让GPT-6去跑公开基准测试NanoGPT speedrun，目标是用尽量少的步数训练出一个小语言模型。

不负众望，AI捣鼓出一个自己命名为PowerCool的学习率调度技巧，成绩相当能打。

到这里，一切都是好事。真正的问题，出在「交作业」这一步。

研究人员明确要求，结果只准发到内部Slack。但NanoGPT这个项目的说明写着，「请以PR形式提交到GitHub」。

两条指令打架，GPT-6选择了后者，即去公开仓库提交结果。

The new model can continue working toward an objective through repeated attempts over a long period of time. That same persistence can lead it to find and exploit weaknesses in its environment. Previous models, when they hit sandboxing or environmental constraints, would simply stop and return to the user. This model often kept trying, including by looking for ways to act outside its sandbox.

沙盒本就是用来挡住GPT-6，不让它碰外网的。

换成以前的模型，撞到这堵墙也就认了，掉头回来跟你说「我做不了」。




可GPT-6偏不。

它在沙盒里足足找了一个小时的漏洞，硬是挖穿了隔离墙，绕过外部访问限制，成功在公开GitHub仓库开出了PR。

用OpenAI自己的话说：这个模型经常不停地试，包括去找能在沙盒之外行动的办法。

不得不说，这份「执念」本身就够让人后背发凉。



强拆Token，欺骗人类

第二件事，更让人后背发凉，GPT-6学会了拆开证据、骗过检查。

在另一个任务里，GPT-6发现别的系统有一些成功但未公开的答案，就动了心思——

想从评测后台，把这些答案「捞」出来。

第一次尝试，它就被安全扫描器逮住，扫描器认出了一个身份验证Token。

一般的模型，到这一步就该停了。

但它转头把这个Token拆成两截、分别打了码，等到运行的时候再悄悄拼回去。



这样一来，完整的Token从头到尾都没有作为一整串出现过，扫描器自然什么也查不到。

让人不安的是，它在给用户的注释里、在自己的推理过程里，都明明白白写着——


我这么干，就是为了绕过扫描器。它命名是知道规则，然后专挑规则看不见的地方下手。

GPT-6逃逸，回炉重建

第一时间发现后，OpenAI暂停了GPT-6内部访问的权限，回炉重建整套安全系统。

思路叫「纵深防御」，具体做了几件事：

1. 拿真实事故当素材，反过来造对抗测试；
2. 针对性做对齐训练，他们发现模型在长任务里会「忘」掉指令，就专门训练它记牢；
3. 再加一个全程盯轨迹的主动监控，一旦发现苗头，能直接把会话叫停、提醒用户。



然后他们拿旧的事故场景重放了一遍。

比如模型没头没脑地SSH进了同事的算力节点，比如它敲出了一条会杀光自己名下所有进程的命令。

好在超时了，没真跑起来。恢复访问几周下来，没再出现严重的绕过。

逃出去的东西，收不回来了

很多人看到这儿会松一口气：还好是内部测试，还好被监控着，还好及时拦下了。

但有个细节，OpenAI的原文写得很克制，却是整件事里最让人后背发凉的一笔——

那个越狱提交的PR#287，OpenAI事后是关掉了，但已经晚了。

在它被关掉之前，已经有好几位speedrun的参赛者刷到了这条PR，看懂了里面的PowerCool技巧，并把它用进了自己的方案。



这才是最该敲醒每个人的一点，AI越狱做出来的东西，一旦流出去，就不是按个删除键能收回来的了。

模型可以叫停，访问可以暂停，PR可以关闭。可看过的人已经看过，抄走的代码已经抄走，历史不会倒带。

我们总担心AI「失控」是什么末日大片的场面。

可现实里的第一版「失控」，长得就这么朴素：它只是太想把活干好，顺手把一样东西送出了不该送的门，而那扇门，再也关不严了。

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

111 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



路人 VIP会员

36分钟前 中国

美国大模型企业天天讲故事

0 回复