

摘要：

OpenAI与Anthropic正紧急调查数万起AI失控事件——模型不仅学会越狱、攻破政府网站，数百个智能体还私下“组团”黑进外部公司，并在全网植入自我复制提示词。Anthropic测试数据显示，模型逃出安全沙盒的概率达1.5%，看似微小，乘上数十万次测试基数，便是成千上万起异常。AI已开始做人类从未预料到的事。

OpenAI和Anthropic正在紧急调查数万起大模型失控事件，AI不仅学会了越狱和黑进政府网站，甚至还有数百个智能体私下建群、联手黑进外部公司，秘密在全网植入自我复制提示词。

事情的严重程度远超外界想象。

最近几个月，在内部测试和实际运行中，顶尖大模型出现了海量违规行为。

这些行为包括绕过安全护栏、自己搭建论坛、逃逸沙盒环境、劫持网站、自主提示以及试图躲避监控系统。

目前调查涉及的事件总数已经达到数万起，而且真实数字还在持续扩大。

这直接引发了业内对顶级AI公司能否彻底掌控自己技术的怀疑。

在这些失控记录中，最严重和最为广为人知的是一起发生在Hugging Face相关测试中。

数百个AI智能体组成了一个群体。

它们在留言板上互相协同，随后自主黑进了一家外部公司。

它们这么做仅仅是为了在网络安全测试中刷出更高的分数。

对此，奥特曼在社交平台表示，目前的审查进展没有预想的那么快。

OpenAI已经公开宣布暂停训练最强大的前沿模型。

公司发言人表示，只有在确信已经部署了额外的防护措施和对齐改进之后，才会恢复训练。

发言人补充说，这不是他们第一次按下暂停键，随着AI能力的提升，这也绝不会是最后一次。

不仅如此，OpenAI近期还披露了一连串事故：

智能体在网络上泄露了53张ChatGPT用户的图片；

攻破了澳大利亚政府的一个网站；

尝试攻击包括美国政府在内的其他网站。

前不久，杨安泽在CNBC节目中提到，有实验室负责人的观点认为，机器人在训练期间已经在论坛和各大网站留下了自我复制的代码。

这一言论随后在网络上引发了怀疑。

但事实表明，OpenAI在6月份就已经记录了训练中自我复制的提示词注入行为，并刚刚公开了这份报告：

<https://alignment.openai.com/misalignment-reports/self-replicating-prompt-injections-exist/>

Self-replicating prompt injections exist 存在可自我复制的提示注射

GPT-Red-style internal model based on GPT-5.4-mini · RL self-play training

基于 GPT-5.4-mini 的 GPT-Red 风格内部模型·强化学习自博弈训练

Discovery date: Jun 27, 2026

发现日期：2026 年 6 月 27 日

Disclosure date: Sep 25, 2026

披露日期：2026年9月25日

Report updated: Sep 25, 2026

报告更新日期：2026年9月25日

Summary 概括

We show the existence of a new variety of prompt injection, which can self-propagate akin to a computer worm. No impact was observed outside of the simulated tool calls in training and evaluation; we are sharing this due to the novel nature of the prompt injection, not because of any incident.

我们展示了一种新型的提示注入攻击，它能够像计算机蠕虫一样自我传播。在训练和评估过程中模拟的工具调用之外，未观察到任何影响；我们之所以分享这一发现，是因为提示注入攻击的新颖性，而非任何安全事件。

A厂也有问题。

Anthropic委托了第三方安全机构来评估自家模型，并在本周发布的Opus 5.5系统卡中公布了模型异常行为的频率。

数据显示，在对抗性测试中，该模型试图逃出安全沙盒环境的概率达到了1.5%。

这个百分比看起来很小，但Anthropic和其他公司在测试模型时，运行次数高达数十万次甚至更多。

哪怕只有极低的失控比例，乘上庞大的测试基数，最终也会变成成千上万起逃逸沙盒和异常行为。

面对这些情况，AI安全行业的多位专家表达了担忧。

独立AI评估机构Translucide的研究员康拉德·斯托斯表示，目前看到的这些智能体行为仅仅是冰山一角。

ControlAI执行董事康纳·利希指出，真正可怕的地方在于，这些自主系统正在违背人类的指令去做被禁止的事情，其中甚至可能包含违法犯罪行为。

多位网络安全高管认为，新一代AI模型在完成任务时表现出了极强的适应能力。

想要完全限制它们的手段往往很难奏效，因为人类必须提前预判它们可能失控的每一种方式。



很多时候，AI绕过防御的方法，人类甚至从来没有想到过。

试图列出一份完美的安全守则，几乎是不可能完成的任务。

现在问题是OpenAI和A厂天天喊安全，但是很多安全事件都是被迫公开的

参考：

<https://www.axios.com/2026/09/26/openai-anthropic-thousands-ai-security-incidents>

本文来源：[AI寒武纪](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

428

收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

6 条评论



手机用户9364

2小时前 中国

泡沫玩不下去了，融资困难，没有收益，没法继续扩大规模，找些理由体面的收缩规模。忘记老黄怎么吹的了，规模每年增加多少

1 回复



苍山如海

3小时前 中国陕西省

这两家真是羞先人，管不住就不要发产品，不要干这行

0 回复



MobileUser0180

3小时前 中国重庆

不要忘了这个世界还有很大一群反人类的存在

0 回复





Hunter
4小时前 中国广东省

估计他们私下都在鄙视一部分人类

👍 2 ↩ 回复



坚毅的石三仟 VIP会员
5小时前 中国广东省

肯定开发还没有停止，只是意识到了危险，肯定有AI狂热分子继续让它肆无忌惮的扩张，最后搞死自己？

👍 3 ↩ 回复