

摘要：

OpenAI推出三款新一代语音模型，其中主打推理的GPT-Realtime-2性能大幅跃升，能以更自然的对话处理复杂任务。不过，用户需留意API定价：输入每百万token收费32美元，输出高达64美元。这意味着，如果你对模型“爆粗口”或长篇抱怨，每一秒都在按高价计费。让AI“张嘴”不难，但让它边听边“想”并回怼你的情绪，账单会很真实。

5月8日，OpenAI在API中加入三款新一代语音模型：主打**语音推理与对话**的GPT-Realtime-2、突出**实时多语言翻译**的Realtime-Translate以及聚焦**语音转文本**的Realtime-Whisper。



OpenAI
@OpenAI



显示翻译

Introducing GPT-Realtime-2 in the API: our most intelligent voice model yet, bringing GPT-5-class reasoning to voice agents.

Voice agents are now real-time collaborators that can listen, reason, and solve complex problems as conversations unfold.

Now available in the API alongside streaming models GPT-Realtime-Translate and GPT-Realtime-Whisper — a new set of audio capabilities for the next generation of voice interfaces.


GPT-Realtime-2是OpenAI首个具备GPT-5级别推理能力的语音模型。它在基准测试中展现出显著进步：在Big Bench Audio语音智能评估中的准确率达到96.6%，在Audio MultiChallenge指令遵循评估中的平均通过率为48.5%，分别较上一代GPT-Realtime-1.5提升15.2个和13.8个百分点。

基于GPT-Realtime-2，语音AI从简单的轮转式问答，向能够在对话展开过程中持续倾听、推理、调用工具并完成任务的形态进化。

会“想”的语音助手

GPT-Realtime-2的设计目标是让语音模型在保持对话流利度的同时，具备处理复杂事务所需的推理与行动能力。





在对话的自然度方面，**模型引入了前导语机制。**

开发者可以启用诸如“让我查一下”或“稍等，我正在查看”之类的简短提示语，在正式响应生成之前就告知用户请求已被接收并正在处理。

与此配套的是**并行工具调用与工具透明性能力**，**模型可以同时调用多个外部工具**，并通过语音向用户通报当前进度，例如说出“正在检查您的日历”或“正在查找”，使智能体在完成任务的过程中保持响应而非陷入沉默。

当遇到处理困难时，**模型会主动给出诸如“我现在遇到点麻烦”的提示并尝试恢复**，而非静默失败或直接中断会话。


此外，**模型的上下文窗口从32K扩展至128K**，这意味着它可以在更长、更复杂的多轮对话中保持连贯，支撑起更完整的智能体工作流。

在专业场景的适用性方面，模型增强了对特定领域术语的理解能力，能更准确地保留专业词汇、专有名词和医学术语，这对生产环境的部署价值突出。在表达层面，模型拥有更可控的语气和表现力，能够根据情境切换风格。


另一项关键升级是**可调节的推理强度**。开发者可以从minimal、low、medium、high和xhigh五个级别中进行选择（默认为low），以在延迟和推理深度之间取得平衡。

不唠闲嗑

Big Bench Audio Intelligence



Audio MultiChallenge Instruction Following



GPT-Realtime-2在基准测试中完胜前代模型

在衡量语音模型中挑战性推理能力的Big Bench Audio评估中，GPT-Realtime-2（high推理级别）取得了96.6%的准确率，而GPT-Realtime-1.5为81.4%，提升幅度达到15.2个百分点。

在评估口语对话系统多轮交互智能的Audio MultiChallenge评测中——该评测涵盖指令遵循、上下文整合、自我一致性以及处理自然语音纠正等维度——GPT-Realtime-2（xhigh推理级别）的平均通过率从GPT-Realtime-1.5的34.7%跃升至48.5%，相对提升13.8个百分点。

事实上，衡量一个语音模型是否真正“聪明”，最有说服力的场景不是闲聊，而是处理一个需要层层推演的复杂问题。

GPT-Realtime-2

0:14

1:04

文字稿 ^

让我们先对这个想法进行压力测试，然后勾勒出一个最小可行的试点方案。如果一年后失败，最可能的原因就是经济效益始终无法与市场需求节奏相匹配。你租了高价的店面，设计理念也考虑到了顾客可以悠闲地慢慢享用饮品和舒适的座位，但客流量最大的群体却希望在短暂的早晨时段喝到快速可靠的咖啡。慢速手冲咖啡和过多的座位会造成客流瓶颈和翻台率低，而周一、周五和下午的客流低迷期则意味着你为无法盈利的空间支付了费用。再加上人工成本、菜单选择过多造成的浪费，以及如何拓展非高峰时段客流的挑战，现金流就会悄然崩溃。最小的测试方案是只在高峰时段营业，并提供一份精简的菜单。可以考虑在车站附近设置一个餐车、售货亭或共享柜台，周二至周四早上7点到10点营业。提供批量冲泡的咖啡，如果条件允许，可以提供一款简单的意式浓缩咖啡，以及几款来自当地合作伙伴的糕点。在正式开设咖啡馆之前，利用这个方案来测试出品速度、回头客数量和定价能力。

GPT-Realtime-1.5

0:51

0:51

文字稿 ^

如果店铺一年后倒闭，可能的原因包括：高估了早高峰通勤人群的停留时间；淡季期间收入不足；以及租金和员工工资等固定成本过高，无法通过销售额弥补。或许这种模式不合那些习惯即买即走的通勤者的口味，又或许下午的客流量始终低迷，导致利润微薄。你可能在市场营销方面遇到困难，或者没有根据客流量的波动调整产品，从而导致现金流问题。为了小规模测试这种模式，你可以先在早高峰时段于车站附近摆放一个流动咖啡车或售货亭，提供你的招牌手冲咖啡和糕点。这样可以让你了解市场需求，完善菜单，建立本地客户群，并在无需签订大型租赁合同的情况下测试定价策略。一旦销售业绩稳定，并了解了顾客行为，你就可以更有信心地规划更大的店面了。

注：OpenAI在演示文档中给出了一个具体测试：用户向模型描述了自己的创业，两代Real time模型的语音推理及对应文字稿

上述案例属于一个对推理能力要求很高的复合型任务：模型需要同时理解多个变量的相互关系，客流的时间分布不均、昂贵的固定租金成本、以及主打慢冲咖啡这种翻台率偏低的业态定

位，并在这些约束条件下进行逻辑推演。

GPT-Realtime-2用1分04秒给出了有条理、分层次的回答，不仅拆解了人流潮汐与租金结构之间的矛盾，指出高峰时段过于集中可能导致整体坪效不足以覆盖租金，还提出了具体的轻量级测试路径。


同样的提问交给上代模型GPT-Realtime-1.5，回应时长51秒，但深度明显不足。这个对比演示直接展示了两代模型在战略推理维度上的代际差距。

实时翻译与转录

除GPT-Realtime-2之外，OpenAI同期发布的两款专用模型各自面向明确的场景需求。

GPT-Realtime-Translate专注于实时多语言翻译，支持超过70种输入语言，可实时输出至13种目标语言，并同步提供转录文本。其目标应用场景包括客户支持、跨境销售、教育、活动以及面向全球受众的创作者平台。

视频平台Vimeo的AI负责人阿尔贝托·帕拉维奇尼（Alberto Parravicini）分享了他们的应用场景：在视频播放时嵌入GPT-Realtime-Translate，使创作者能够在线瞬间就与全球观众进行跨语言沟通。



Vimeo演示GPT-Realtime-Translate实时翻译能力

GPT-Realtime-Whisper则是一款流式语音转文本模型，专为低延迟转录场景构建。

它能够在说话者开口的瞬间开始生成文字记录，适用于会议实时字幕、课堂笔记、广播字幕以及需要即时生成后续工作流的语音交互场景。其核心价值在于，将语音内容在对话进行过程中，即可转化为可供下游业务系统立即使用的结构化文本。

安全与定价

在安全层面，Realtime API部署了多层护栏——系统内置的主动分类器能够对会话进行实时监控，一旦识别出违反有害内容指南的交互，即可终止会话。开发者还可借助Agents SDK方便地叠加自定义安全护栏。

OpenAI的使用政策明确禁止将输出内容用于垃圾信息、欺诈或其他有害目的。

根据官方的指引，除非交互情境已清楚表明对话对象为AI，否则开发者必须向最终用户清晰地披露其正在与人工智能互动（提示用户：现在发言的是AI）。此外，该API已全面支持面向欧盟客



户的欧盟数据驻留，并受企业隐私承诺保护。

三款模型现已通过Realtime API向开发者开放。

定价方面，GPT-Realtime-2按语音token计费，每100万输入token价格为32美元（缓存输入为每100万token 0.40美元），每100万输出token价格为64美元。GPT-Realtime-Translate按使用时长计费，每分钟0.034美元。GPT-Realtime-Whisper同样按时长计费，每分钟0.017美元。



Sam Altman

@sama

显示翻译

people are really starting to use voice to interact with AI, especially when they have a lot of context to dump.

GPT-Realtime-2 comes to the API today; it is a pretty big step forward.

(we are working on improvements to voice in chat.)

上午2:55 · 2026年5月8日 · 22.9万 查看

680

222

4,364

376

相关

查看引用



发布你的回复

回复



Sam Altman

@sama · 5小时

as a side note, young people seem to prefer to interact with AI via voice, and old people, and people in the middle like to type. i wonder if this will change.

355

57

1,078

10万

为了给新的“语音全家桶”背书，OpenAI首席执行官山姆·奥特曼在X上说：人们确实开始用语音与AI互动，尤其是在需要一次性倾注大量背景信息时。

他还提到，年轻人群体似乎更偏好通过语音与AI交流，而中老年用户则倾向于打字，并提出了这个习惯未来是否会变化的开放性问题。

问题来了：现在OpenAI的语音推理能力上新，下一个接力的会是谁？

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

211 收藏

分享到:  

写评论

请发表您的评论

