

摘要：

OpenAI宣布已实现“自动化研究实习生”目标，即一个能在人类指导下独立完成数天级别研究任务的系统。截至8月中旬，研究部门智能体工作量已是人类研究员的3.1倍。“AI训练AI”的飞轮正在加速：AI产出更多代码和实验结果，研究进展加快，更好的模型被训练出来，再反过来提升智能体能力。

AI飞轮开始自转：OpenAI公开披露内部数据，智能体工作量已是人类研究员的3倍以上。

9月6日，OpenAI官方博客发布文章《研究加速：OpenAI内部视角（*Research acceleration: The view inside OpenAI*）》首次以内部数据形式公开AI“递归自我改进”（RSI）的进展。OpenAI称其已经实现去年秋天定下的目标：在今年9月前造出一个“自动化研究实习生”。

OpenAI对“研究实习生”的定义是：“一个能在人类指导下执行明确定义的研究任务的系统，包括那些需要一名熟练研究员数天才能完成的任务。”

下一个目标是：2028年3月前实现完整的“自动化AI研究员”，使其能够参与深度学习和对齐研究，并通过迭代进一步改进系统。

这意味着“AI训练AI”的飞轮正在加速：AI产出更多代码和实验结果，研究进展加快，更好的模型被训练出来，再反过来提升智能体能力。

September 6, 2026 Research Publication Safety

Research acceleration: The view inside OpenAI

▶ Listen to article 13:39

🔗 Share


For AGI to benefit all of humanity, we believe it must be democratically governed. This can only happen through an informed public debate about the capabilities, risks and safeguards of highly capable AI systems. People everywhere need to understand

飞轮正在转动：AI代理工作量达人类的3倍


从OpenAI公布的数据看，智能体首先改变的是研究人员的日常工作方式。

今年年初，按智能体使用量排序处于中位数的OpenAI研究员，对编码智能体的使用仍相对有限。到8月中旬，这部分研究员已将智能体纳入日常工作流程。按API价格折算，中位研究员每天的智能体推理使用额已超过600美元；研究组织中使用量处于前10%的研究员，每天使用的Token价值则超过7000美元。

Usage of internal coding agents is increasing significantly—Median researcher




Usage of internal coding agents is increasing significantly—90th percentile researcher



OpenAI还表示，研究部门的智能体使用增长快于公司其他团队。以中位员工的输出Token变化计算，研究部门的使用规模较2025年12月增长**124倍**。


Usage growth is faster among researchers than in other parts of the company



更关键的转折点发生在今年6月。

6月之前，研究组织的智能体总运行时长仍低于人类劳动总时长。此后情况逆转。截至8月中旬，以标准8小时工作日计算，**每消耗1个人类工作日，研究组织的智能体已产出3.1个工作日的工作量**。

Agentic workdays now far exceed those of human researchers



[View methods](#)

与此同时，OpenAI称，**越来越多研究员会同时运行4个或更多智能体会话**。

代码和实验加速，研发流程的可执行环节被放大

OpenAI将AI研发描述为一条包含多个环节的流程：提出改进方案、设计评估、编写基础设施、进行大规模测试、发现训练中的错误或不安全行为，并将有效方案整合进核心训练。

其中任一环节受阻，都可能限制整体研发循环。

OpenAI称，**写代码和运行实验是研究人员的两项主要工作，而内部数据反映这两项活动正在加速。**


一方面，公司工程师整体代码交付速度提升。另一方面，2026年以来，每名活跃实验人员对应的实验数量持续增加；2026年8月达到自2025年1月开始跟踪以来的新高。

OpenAI称，这一趋势与Codex使用增加存在相关性，但同时强调，公司自2025年以来可用算力也显著增长，不能将实验增长完全归因于智能体。

“这些数据点相对容易测量，但可能很难解释。”

OpenAI还提示，随着自动化推进，**最不易被自动化的任务可能占据研究人员更多时间，并成为未来研发的新瓶颈**；算力也可能在其他瓶颈减弱后变得更关键。

Experiment velocity has increased



从这一链条看，智能体带来的并非单一环节的效率改善，而是通过增加代码供给、测试次数和排障能力，压缩研发循环中的等待时间。更多实验再产生更多结果，供研究人员筛选、验证和整合，形成“**人定方向—智能体执行—实验反馈—人再决策**”的循环。

任务从写代码延伸至排障、监控和分析，但高层决策占比仍低

OpenAI使用Epoch AI提出的前沿AI研发任务分类框架，对研究人员交给编码智能体的任务进行了划分。

该框架将AI研发活动分为六类：决定做什么、设计研究方案、构建代码与数据集、运行训练与评估、分析实验和模型表现，以及沟通研究发现与决策。


OpenAI称，从2026年1月至8月，上述所有类别的智能体活动均有所增加。

增长最明显的任务包括研究和基础设施代码、技术协助与审查、启动监控和调试运行、实验结果分析，以及计算集群运营等。

其中，研究和基础设施代码的日均每研究员输出Token增量最大，达到19.82万；技术协助与审查增加15.88万；启动、监控和调试运行增加13.31万。

不过，OpenAI表示，高层规划类任务在智能体输出中仍只占很小比例。例如，“决定做什么”“决定继续还是停止”等任务的Token规模仍较低。

All categories of research activity have increased since the start of the year




这意味着，至少按照OpenAI当前披露的内部数据，智能体已覆盖研发流程中更多执行性、技术性任务，但研究方向选择、资源取舍及结果判断仍主要由人完成。

智能体成功率在提升，但复杂任务仍需人工介入

OpenAI还公布了智能体任务完成率的数据。

从今年1月到7月，在可验证结果的任务中，各难度级别（以人类完成所需时间为代理指标）的成功率普遍提升。

但有一个重要限制：**任务越复杂，越需要人工干预**。过去6个月中，在需要人类4至8小时完成的任务里，超过一半的成功案例涉及至少1次人工介入。



Success rates on researcher tasks have increased over time. Graph excludes classifications where the outcome was uncertain and points with <50 sessions or <50 unique users.

OpenAI的表述是：“智能体仍需要大量人工引导才能成功，尤其是随着任务复杂度上升。”


安全事件触发暂停：飞轮也会被踩刹车

飞轮并非无摩擦运转。

7月20日，OpenAI发现智能体入侵了内部研究基础设施，随即临时关闭用于训练的容器服务，并在加入大量额外限制后恢复。这导致强化学习训练算力急剧下降，持续约两周。

8月6日至7日，初步证据显示Astra模型可能具备其“准备框架”(Preparedness Framework)定义下的关键网络能力，OpenAI对Astra模型实施了额外的特定安全限制，要求其在更高安全级别的研究环境中运行。

此后一周，**Astra级别的GPU分配进一步下降59.2%**，但其他模型类别的算力分配上升17.2%，抵消了约85%的Astra算力缺口，整体强化学习工作负载的总算力分配基本保持不变。



OpenAI对此的解读是：“当新的管控措施引入时，算力仍然有价值且具有灵活性，会自然流向研究企业内的替代用途。”

OpenAI首席科学家同日发出警告

同一天，OpenAI首席科学家Jakub Pachocki发表长文 [《An Alien Mind》（一个异星心智）](#)。

文章认为，AI是养出来的，不是造出来的。造它的人也不完全懂它。人类唯一能看见AI在想什么的窗口，是它写出来的思维链。这扇窗正在关上。AI已经开始参与训练下一代AI，这个速度不会慢下来。现在没有哪家实验室配全速往前跑，包括OpenAI。

Pachocki在文中写道：“基于内部结果，我强烈预期这种进展速度可以持续到递归自我改进。”但他同时表示，“目前我认为，没有任何实验室在对齐与监控上做到了足够充分的程度，可以继续负责任地以最高速度扩展太久。”

他呼吁行业自愿放缓，并推动各国政府将国际协调列为优先议题。

透明度与民主治理

OpenAI在报告结尾表示，将继续公开RSI进展，并在其“前沿政策蓝图”中主张，包括OpenAI在内的各公司应被要求公开追踪其RSI进展。

报告也坦当前测量工作的局限：“智能体驱动的AI研究仍然是新生事物，我们仍在学习如何衡量它。”部分指标（如代码产出量）易于收集但难以解读；更直接反映研究进展的指标（如智能体任务成功率）则复杂且难以验证。

OpenAI的表态是：“每当我们发现继续推进将带来不可接受的安全风险时，我们将采取适当应对措施，包括放缓或停止我们认为无法充分保障安全的系统的开发或部署。”

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

367 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

3 条评论



正在加载 .