

摘要：

OpenAI正终结应用边界，剑指“个人通用智能”(Personal AGI)。未来14倍极速推理或成行业标配，算力全面上云；同时，AI已悄然开启“递归自我改进”优化底层架构，推动运行成本暴降80%，编程将彻底沦为全员无感调用的基础能力。

OpenAI正在推动一场深层次的产品整合——不只是把两款应用合二为一，而是要让“ChatGPT”与“Codex”这两个概念本身彻底消失，最终收敛为一个长期理解用户、自主完成任务的个人通用智能（Personal AGI）。

OpenAI Codex负责人Tibo Sottiaux近日接受科技博主Matthew Berman专访时明确表示，Codex已深度并入ChatGPT产品体系，原本面向开发者的编程能力正逐步向全体用户开放。但他强调，这只是第一步。**Tibo 描绘的终局极为震撼：未来，所有复杂的底层架构都将被彻底隐藏。最终只剩下一个极其极简、深度理解你、并能瞬间调动海量云端算力的“个人通用智能”（Personal AGI）。**

访谈中，Tibo还披露了一系列具有市场参考价值的数据与判断：Codex用户量已达约2000万；OpenAI普通推理速度在过去三个月提升约60%；Ultra Fast极速模式目前最高可实现14倍生成加速，Tibo预测1至2年内这一速度将接近行业默认水准；此外，OpenAI已通过强大模型优化底层推理架构，令旗下Luna模型运行成本下降约80%，Tibo将这一过程明确性为递归自我改进（Recursive Self-Improvement）的早期形态。



以下为访谈核心观点：

Codex 已经并入 ChatGPT，但这只是第一步。 OpenAI 的终极目标，是让“ChatGPT”和“Codex”等产品边界继续淡化，最后演变为一个长期理解你的**个人通用智能（Personal AGI）**。

下一代模型将颠覆现有的智能体系统（Agent Harness）。 今天大家费时费力去手动维护技能（Skills）、记忆（Memory）、子智能体（Sub-agent），在 OpenAI 看来都还属于非常早期的笨拙形态。

笔记本电脑（Laptop）很快会成为 AI 能力的物理瓶颈。 未来模型可能同时并发处理 100 个应用，大量高负载任务必然全面转向**云端智能体（Cloud Agent）**。

Ultra Fast（极速模式）在 1~2 年后可能接近默认体验。 在不计算极速模式的前提下，OpenAI 的普通推理速度在过去三个月内也已经提升了约 60%。

模型已经开始反向优化自身的推理基础设施。 Tibo 明确表示，利用强大模型来重写底层系统和 CUDA 内核，已经是递归自我改进（Recursive Self-Improvement）的早期形态。

Codex 用户量已达 2000 万。 程序员只是第一批尝鲜者，未来“写代码”将成为所有知识工作者（产品、设计、销售）都能无感调用的底层能力。

边界消解，走向单一AI

Tibo在访谈中首先厘清了一个普遍的误解——Codex与ChatGPT的整合并非未来规划，而是已经发生的现实。

他将这一融合的必然性归结于模型能力本身的演进逻辑：**未来的模型天然具备编程、搜索、调研、工具调用、语音与视觉理解等能力，这些功能最终将构建在同一套智能体框架（Agent Harness）之上。**在此背景下，人为区分“程序员用Codex”与“普通用户用ChatGPT”将失去意义。

Tibo描述的终局是一个Personal AGI：**程序员、设计师、产品经理、销售人员乃至完全不懂编程的普通用户，调用的是同一套底层AI。**系统根据用户身份、所连接的工作工具及权限，自动呈现差异化的交互界面——程序员看到的是深度定制的开发环境，销售看到的是邮件与客户数据仪表盘，普通用户看到的依然是简洁的对话框。

他的表述清晰指向OpenAI的产品战略取向：不是构建多个垂直AI应用，而是打造一个AI，让它根据用户是谁自动适配。

Agent架构重构：复杂性下沉，界面趋简

Tibo对下一代智能体系统的判断是此次访谈中信息密度最高的部分之一。

他指出，当前许多高级Codex用户手动维护技能配置文件（Skills）、记忆上下文（Memory）与子智能体（Sub-agent）编排网络，在OpenAI看来仍属极早期的过渡形态。技能文件日积月累难以维护，记忆频繁丢失上下文，多个Sub-agent协同工作时的调度问题更容易打断用户体验。

Tibo的核心判断是：**模型能力越强，用户就越不应该直接介入管理Agent本身。理想的Agent应长期、深度理解用户——知晓其目标、日常工作流、个人习惯乃至团队进度，并自主决定调用何种技能、保留何种关键信息、是否在后台启动其他Agent。**

这一演进方向的本质是：底层架构可以极度复杂，但暴露给用户的界面必须持续趋简。

算力瓶颈：笔记本将让位于云端集群

Tibo提出了一个反直觉的判断：**未来制约Agent能力发挥的瓶颈，将是用户手边的个人电脑。**

他的论据是，现有PC的硬件设计完全以人类工作速度为基准——人一次只能操作有限数量的窗口与应用，处理速度存在明显的生理上限。但模型不受这些限制约束。他举例称，未来一个云端模型可能同时并发处理100个应用，在同一时间内探索多套解决方案、编写测试用例、编译代码、验证假设，并并行调度多个子Agent工作。

在这一并发量级下，即便是顶配MacBook也无法承载对应的工作负载。Tibo因此明确表示，**云端智能体（Cloud Agent）将成为主流范式：用户终端只是轻量交互入口，真正执行任务的是背**

后的云端计算集群。这意味着Agent的终局不是"本地更强的软件"，而是"云端随时待命的算力团队"。

速度跃迁：Ultra Fast或成两年内行业基准

在推理速度方面，Tibo给出了一个颇为激进的预测。

Ultra Fast模式目前最高可实现约14倍的生成速度提升。**Tibo预计，大约1至2年内，这一速度将逐渐接近行业默认体验。他同时补充了重要的适用边界：对于纯代码或文本生成任务，加速效果显著；若工作流程中包含大量外部工具调用（Tool calls）及网络I/O操作，受制于网络与架构延迟，实际感知加速比约为3至4倍。**

更值得关注的是速度提升背后的驱动因素。Tibo表示，OpenAI的提速并非单纯依赖堆叠GPU，模型本身的效率也在持续优化。Sol模型相比此前的Terra模型效率已大幅提升，下一代模型将在Token利用效率上进一步跃升。即便不开启Ultra Fast，OpenAI普通基准推理速度在过去约三个月内也已提升约60%。

工作范式变革：速度平权带来协作升级

Tibo指出，当AI响应速度趋近甚至超越人类思考与表达速度，人机关系将发生质变。

他观察到，当前许多重度Agent用户的工作模式是同时开启10至15个Agent窗口，将任务依次投入后轮流巡查进度，实际上成了疲于奔命的"AI项目经理"。这一模式的核心问题在于频繁的注意力切换。

Tibo表示，OpenAI目前高度重视对用户注意力的保护与管理。他描述了Ultra Fast与语音交互叠加后的理想场景：用户随口说出构思，AI瞬间生成原型；用户扫一眼后以语音指令调整，AI毫秒级完成修改；全程保持心流（In the flow）状态，无需任何上下文切换。一旦AI速度与人类思考速度对齐，人机协作将从单向的"派发任务"升级为真正的实时协同。

递归自我改进：已在底层代码中悄然发生

访谈中最具技术深度的讨论，指向了AI系统的自我优化能力。

Tibo透露，**OpenAI已在利用先进模型分析和优化现有模型的服务架构。他具体提到，Sol模型参与优化Luna模型的推理架构后，Luna的运行成本下降了约80%。模型正深度参与重写CUDA内核、优化推理栈、重新设计系统架构等底层基建工作。**

当主持人追问这是否构成"递归自我改进"（Recursive Self-Improvement）时，Tibo的回答是肯定的——"算，这就是早期形态"。

他同时校正了外界对这一概念的常见误判：公众惯常想象的递归自我改进是某一代模型自主写出下一代，但现实演进更为务实。模型变强后先协助工程师优化底层运行系统；系统因此提速降本；算力成本下降后模型能够承担更海量的工作，进而继续优化更复杂的架构。Tibo将其概括为"一个完整的闭环大系统"。

这意味着，外界长期等待的"AI开始自主迭代"时间节点，可能永远不会以戏剧化的方式出现——它已经在枯燥的底层架构优化中持续发生。

2000万用户背后：编程将成底层通用能力



Tibo在访谈中披露，Codex用户量已达约2000万，与ChatGPT的深度融合是近期增长提速的主要驱动力之一。

这一数据背后指向一个结构性趋势：**Codex的编程能力并入ChatGPT后，产品经理、设计师、财务与市场人员均可在无感知的状态下调用。以数据分析为例，用户请求ChatGPT处理5000条数据记录，系统在后台可能自动生成并运行Python脚本，最终将图表结果呈现给用户，全程无需用户具备任何编程知识。**

Tibo的判断是，代码在未来将成为AI操作数字世界的底层机器语言。所谓"Coding Agent"，最终服务的远不止编程场景本身。程序员只是这套底层能力革命最早的体验群体。

以下为访谈原文：

Tibo：

只要我想，只要我觉得时机合适，我随时都可以按下那个（额度重置）按钮。我其实不太去盯竞品在做什么，我更看重的是：我们能把什么做得独一无二？我们的价值观是什么？以及我们如何最大限度地全速朝那个方向推进？也许再过一两年，这种极速推理速度即便不能成为行业默认标准，也会非常接近默认状态。你看 Luna 模型的成本对吧？简直惊人地便宜。技术总有办法随着时间推移变得极其高效。我们非常专注于让尽可能多的人能够使用它，并直接优化用户从中获得的实际效用。

Matthew Berman：

我听说你们现在真的做出了一个实体的物理重置按钮？

Tibo：

是的，确实有。等会儿我拿给你看，真的非常酷。

Matthew Berman：Tibo，

非常感谢你能来做客。

Tibo：

不客气，很高兴来到这里。

Matthew Berman：

能和你交流我感到非常兴奋。我想先从你在 Google 的那段经历聊起。你之前在 DeepMind 团队，在 ChatGPT 问世之前，Google 内部其实做过一个叫“LM Chat”的东西。你曾发推特说，Google 当时因为太过顾虑而不敢发布它，DeepMind 也被限制发布可能颠覆 Google 现有业务的产品。我对这件事思考了很多。在那个远远早于 ChatGPT 改变世界的时期，你在研发这些产品时心里是怎么想的？

Tibo：

是的，那是一段非常令人兴奋的时光。DeepMind 是一个极富创造力的地方。我当时主要专注于加速前沿研究所需的基础设施与产品架构。那时团队内部显然有一个小组在攻坚大语言模型并探索模型规模的扩展。当他们取得了相当出色的成果后，大家很自然就会去想：“嘿，能不能把它



做成一个可以与之对话、并能用于各种任务的工具？”于是，类似“LM Chat”这样的想法便顺理成章地诞生了。它最初只是内部原型，但随后大家产生了将其打造成面向公众开放工具的雄心。

Matthew Berman：

那是哪一年？

Tibo：

大概是在 ChatGPT 发布的整整一年前左右。

Matthew Berman：

明白了。

Tibo：

不过当时我们还在做很多其他项目，这里就不展开说了。那里确实非常有创造力，但 DeepMind 本身的设计初衷并不是为了去发布消费级产品的。而从这个角度来说，OpenAI 是一个截然不同的地方。在 OpenAI，研究团队与产品团队的合作极其紧密。我们一起构思方案，协同设计许多东西。我们有着极强的“发布偏好”，而且非常渴望将产品推向公众使用，这一点我非常喜欢。这也是吸引我来到这里的原因——使命感、优秀的伙伴、极高的人才密度，OpenAI 真的有很多非常棒的特质。

Matthew Berman：

你在参与 LM Chat 项目时，就意识到它非常特别，或者将来会成为极其非凡的存在了吗？

Tibo：

确实感觉非常特别。因为那算是你第一次意识到大模型能够输出连贯、有逻辑且真正有用的文本。最开始它可能搞笑成分多于实用价值，但渐渐地，它变得越来越有用。

Matthew Berman：

你说你经常会反思那段经历，我很理解。我认为在很多层面上，Google 是自己绊倒了自己。你在那里学到了哪些经验教训，并带到了 OpenAI？

Tibo：

是的，正因如此我常思考这些。我会从团队文化以及 OpenAI 自身文化的角度去审视：哪些优秀的特质需要保留，哪些错误绝不能犯。OpenAI 拥有一种非常自下而上、充分赋权的文化。大家可以自由提出各种创意，聚在一起迅速把产品发布出去。在推动新产品想法时，几乎没有任何“阻碍能量”（官僚阻力），这种氛围既让人振奋又充满乐趣，一切的核心都是为了对世界产生积极影响。因此，保持这种文化对我来说至关重要。另一方面同样重要的是避免把产品搞得一团糟。你肯定不希望产品变成一个没有整体方向感和一致性的功能大杂烩。所以我们用追求极致的“极简”以及对产品品质的自豪感来与之平衡。我认为 ChatGPT 的 iOS 应用是市面上体验最好的 App 之一，我们希望保持这一点。我们在令人愉悦的体验、卓越性能、高效率 and 极简设计上投入了巨大精力。在坚守这些核心原则的同时，依然鼓励每个人勇于尝试新事物并迅速推向市场。

Matthew Berman：



如果要给初创企业创始人提建议，指导他们如何建立这种文化，OpenAI 内部有哪些具体、可落地的做法或机制可以供他们参考？

Tibo：

首先是要拥有坚定的信念；其次是想尽办法尽早获得真实用户，并根据用户反馈进行极其敏捷的迭代；最后则是必须具备“敢于自我颠覆”的意愿。这一点对早期初创公司可能感受不深，但对于像 OpenAI 这样规模的公司至关重要。我们不断涌现出新的研究成果和创意，能够准确判断何时是重金投入的最佳时机——哪怕这意味着必须从当前的核心主力业务中抽调资源——这虽然极其困难，但却至关重要。

Matthew Berman：

没错，这正是你刚才描述 Google 时提到的问题，他们当时就无法做到自我颠覆。

Tibo：

平心而论，Google 内部有他们自己的规划，一切都属于某个宏大战略的一部分。但对我个人而言，那并不是适合做这件事的地方。

Matthew Berman：

在 OpenAI 或任何一家逐渐走向成熟的公司，要维持这种快速发布产品和勇于自我颠覆的文化，是不是会变得越来越难？特别是当你手里已经有了一只疯狂盈利的“现金牛”业务，而旁边又出现了一个可能极具创新颠覆性的新事物时？

Tibo：

我们是一家极其前瞻性的公司。AI 的未来形态以及人类将如何从中受益，根本不会停下来等待你在接下来一个月或三个月内所守住的既得成果。所以必须全力以赴，保持清醒敏锐的眼光审视未来的技术走向，并找准自己的定位以精准顺应浪潮。即便是对 OpenAI 自身而言，也是在训练出模型后才逐步挖掘出其真正能力的——标准基准测试无法说明一切，我们必须亲自深度体验和测试模型，才会恍然大悟：“原来我们还可以通过这种独特的方式来发挥它的价值”，或者“哇，它居然能做到这个！”这时你对产品的理解就会发生质的飞跃。例如，我们刚刚推出的新版高级语音模式，与之对话体验极其愉悦、非常自然，而且它现在还具备了直接调用工具的能力。

Matthew Berman：

是的。

Tibo：

这彻底改变了使用方式。我现在花大量时间直接跟它说话。另一项我每天都在用的功能是语音听写，因为听写质量实在太高了，效率远超手动输入提示词。每天早上我坐在那里拿着手机直接口述：“噤里啪啦……给 ChatGPT 交代几件今天要处理的事情”，然后它直接调用我的各种工具去执行。

Matthew Berman：

确实。

Tibo：



在拥有高水平语音模型之前，这一切都是不可想象的。这会彻底颠覆你对产品形态的固有认知。

Matthew Berman：

我们继续聊聊新模型与新的运行框架（Harness）。几周前你在推特上发了一条非常轰动的推文：“Codex 在两到三个月内就会显得很原始，我们即将经历下一场重大演进，下一代模型需要的算力与环境远超你的笔记本电脑所能承载的极限。”我们先从 Harness 谈起，随着模型能力变强，运行框架还有哪些领域充满创新的空间？

Tibo：

实在太多了。除了刚才提到的语音交互，如果你是 Codex 或其他代码智能体的高级用户，你会发现自己其实已经对现阶段的一些笨拙之处习以为常了。比如，你必须手动维护技能规则文件来教导它，但很多人已经意识到这在长期维护中非常繁琐；记忆系统虽有雏形，但并不能完全记住上下文；如果你构建了子智能体协作网络，你还得去操心子智能体的调度，这在交互中常常会打破那种“流畅伙伴”的沉浸感。而用户真正想要的，是一个能够深刻理解你、理解你的目标与日常习惯、甚至了解你团队最新进展的伙伴；它不仅能被动响应，还能主动提出建议，在日常中辅助你，且永远不会破坏那种如同“完美专属搭档”般的沉浸感，这就是我们正在努力的方向。另外，当你拥有极其强大的模型时，你会发现笔记本电脑本身变成了一个物理瓶颈。笔记本电脑是专为人类设计的，它的设计初衷是为了适配人类的打字速度、思维节奏以及同时开启的应用窗口数量——这些都是人类生理能力的局限。但模型没有这些限制，未来模型完全可以游刃有余地并发处理上百个打开的应用程序。因此在资源调度方面，未来的模型必然需要获取远超笔记本电脑硬件能力的云端计算环境。

Matthew Berman：

我猜你指的是云端智能体。当我们拥有像“极速模式”这样将 Token 生成速率提升 10 到 14 倍的技术时，系统瓶颈就转移了——CPU、工具调用、网络输入输出等技术栈中的开销变成了新的制约瓶颈。

Tibo：

但你可以通过全并发执行多项任务来进行补偿。你可以让模型在探索解决方案的同时，并行编写测试用例、编译代码以及验证新假设，所有事情一并进行。这样你就转移了瓶颈，通过高度并发赋予系统更强的处理能力，而模型则可以在极短时间内高效完成深度推理。

Matthew Berman：

在以往的推理速度下，我常常不得不并行启动 10 到 15 个智能体，而不断切换上下文会带来巨大的认知负荷，因为发出指令后往往需要等上 30 到 45 分钟才能拿到结果。有了极速推理后，这种工作流发生了剧烈变化，我不再需要同时开 10 到 15 个，而是精简到 3 到 4 个。你如何看待独立开发者工作流的演进？

Tibo：

保护并友好地管理开发者的注意力，是我们非常重视的事。归根结底，我们的目标是为人赋能，这要求系统必须围绕人类的多任务处理习惯和注意力管理来构建——比如判断某件事是该立刻向你汇报，还是 30 分钟后提醒更合适。当极速生成与语音输入相结合时，AI 的响应速度甚至超过了你的思维节奏。你能够始终保持在专注心流中，实时构思方案、查看原型演练、生成即时报告，这种体验非常顺畅。你立刻就会意识到，过去那种在 10 个智能体之间来回切换的疲劳状态，你再也不想倒退回去了。

Matthew Berman：



是的。

Tibo：

我们致力于打造一种完全自然的体验，量身定做，让你无需去迁就技术，而是让技术主动适应你。

Matthew Berman：

过去几个月里讨论了很多关于智能体编程的技术，比如之前很火且依然常用的循环（Loops），以及现在大家常谈论的图结构（Graphs）。这些技术是否都是为了帮助独立开发者更好地管理注意力？我很喜欢这个概念。

Tibo：

我认为这里存在两类截然不同的问题形态：第一类是打造极致的“个人 AGI”或个人数字伙伴，它与你保持在同一心流中，主动提出见解，极其高效地执行你的具体意图。无论遇到技术难题、深度调研还是决策咨询，它都能胜任，且高度契合你作为独立个体的独特性。这是我们在全力攻坚的一大方向。另一类则是“端到端全自动化”，即构建能够自主接管超复杂业务流程的智能系统。例如自主分析生产环境日志并自动优化性能，或者捕捉系统回归问题并自动修复上线；在网络安全领域也是如此，漏洞扫描器一旦发现弱点，系统即可自主修复，将暴露漏洞的危险窗口期缩短至接近为零……

Matthew Berman：

……全程无需人类介入？

Tibo：

完全无需人类介入，或是仅在极高风险操作时需要人工做一次最小化的二次确认。它大部分时间是完全自动化的后台系统，你无需去实时掌控每一个执行细节。

Matthew Berman：

好的。

Matthew Berman：

我想换个话题。过去几个月 ChatGPT 和 Codex 一直处于合并融通的进程中。内部进展如何？感觉怎么样？客户的反馈如何？

Tibo：

这确实带来了巨大的收益。最初用户的反馈是：“为什么要合并它们？真的有必要这么做吗？”而我们的逻辑是：未来的下一代模型要求我们将两者合并。这是最纯粹、最正确的方向——我们要构建一个能力极其强大、全方位辅助你的个人智能体。它们的底层技术、运行 Harness 和设计哲学是完全相同的，具备高度多模态、语音优先和极高推理效率。无论你是在编写代码还是从事其他创作，这个智能体都能以最高效率完成。用户想要的交互界面应当自适应调整，而不是逼着用户提前选择“我是程序员，我要开发者界面”或是“我没有技术背景，给我一个极简界面”。人类发明的所谓“软件工程师”、“设计师”等职业标签，只是为了应对现实复杂性而归纳的抽象概念。但在现实中，每个个体都在技能光谱的某个特定位置上。我们要打造的理想界面，就是能够根据每个人的独特需求进行动态自适应。



Matthew Berman：

这是否意味着最终必然会演进为一个统一的单一界面，不再有切换产品的下拉菜单？想到我母亲会跟我使用完全相同的底层界面，这感觉太奇妙了——当然系统会根据我的需求进行深度定制，在处理复杂工作时呈现更多专业信息。你眼中的终局状态是怎样的？

Tibo：

完全正确，正是如此。你和你母亲使用的将是同一种底层个人 AGI。你们赋予它的任务和获得的效用截然不同，连接的生活/工作工具不同，输入的诉求也不一样，但它会自适应调整以最大化地契合并服务于每一个人。

Matthew Berman：

我想回到你刚才提到的“沉浸感 / 伙伴幻觉”。在这种终极形态下，普通用户眼中的完美交互体验是怎样的？几年后人机交互的真实日常会是什么样？

Tibo：

对我而言，它必须高度契合人类的本能表达习惯。大语言模型之所以能取得巨大成功，本质上是因为它使用了自然语言。自然语言是纯粹的人类概念，我们早已习惯以此交流。比如你明天给我写一封信，我不仅能读懂，而且因为我们彼此熟悉，我还能体会到文字背后的情绪波澜与细微语境。这一切都是深具人性化的。因此我们构建的技术深深植根于人类的沟通与协作方式之中，绝不应该出现“AI 无法理解你语气中的潜台词，或者误解了你文字本意”的情况。我们极力避免让用户去费力适应系统，而是让技术成为人类在现实世界中行动的自然延伸。

Matthew Berman：

人类交流中有大量非语言信息，比如手势和面部微表情。未来 AI 通过视觉感知来捕捉这些信息有多重要？因为你刚才主要描述的是文本与语言。对于在网络环境中成长起来的人，我们很习惯用文字及文字修饰来表达细微语气，但让 AI 看懂人类的面部表情和肢体语言在未来依旧重要吗？

Tibo：

我认为非常重要。未来的人机交互应当是无感的环境计算与极度自然的融合。比如我走进办公室在白板上随手画下一个构思，AI 应当能够实时感知并理解；我只需自然地问一句：“嘿，这个方案你看怎么样？”，我们就能直接通过语音展开讨论。自从我们上线了新版语音功能后，纯语音与 ChatGPT 交互的用户量正在爆发式增长。这印证了一个道理：只要你提供更加自然的交互方式，人类本能的总会选择阻力最小的路径。在输入框里打字也许对部分人很习惯，但绝非对所有入都是最轻松的。一旦有更轻松、更优秀的方式出现，人们自然会全面转向它。

Matthew Berman：

恭喜你们！我看到你今天早上发推公布 Codex 用户量突破了 2000 万大关。我看过增长曲线，在经历平稳增长后突然呈现出近乎垂直的爆发式拉升。我想聊聊与 Anthropic 的竞争，大众普遍将 OpenAI 与 Anthropic 视为当下的两大行业领头羊。曾有一段时间 Anthropic 几乎吸走了行业内所有的关注度，展现出极强的统治力，但随后局势突变。你如何看待当前的市场格局？

Tibo：

我们现在的核心是打造能力最强、效率极致的模型，并以打造惠及所有人的普惠产品为荣。我认为 OpenAI 做得极为出色的一点，就是关怀整个世界，并致力于将这一极其强大的技术交到尽可



能多的人手中。这也是我们合并 Codex 和 ChatGPT 的初衷——让这项技术变得更安全、更容易上手，使产品经理、设计师、销售、市场营销以及公关人员都能毫无门槛地使用它，并依托 ChatGPT 庞大的既有用户基础迅速分发普及。这正是推动用户指数级增长的核心动力。我并不太去盯竞品的一举一动，我关注的是我们自身独特的优势是什么，我们的使命是什么，以及我们如何以最大速度向目标全速迈进。

Matthew Berman：

我想再追问一点。虽然你不太关注 Anthropic，但很多用户在抉择：我更认可哪家产品？我该把每月 20 美元或 200 美元订阅费付给谁？从市场定位、品牌调性以及开发者/公众互动的角度来看，你认为 OpenAI 与 Anthropic 有何不同？

Tibo：

归根结底，我深深关切的是社区本身，为全球构建产品并携手所有人共同前进。你能从我们极度透明的做事风格中感受到这一点——我们从社区中汲取了大量灵感与建议。老实说，这个过程极其有趣，社区给予了我们巨大的能量。我们研发这项技术不是为了自娱自乐，不仅仅是为了加速 OpenAI 自身的发展，更是为了普惠全人类的使命。这种文化让我们非常接地气且充满活力，好的成果自然也会随之而来。

Matthew Berman：

说到这些好成果，我想聊聊“额度重置”。大家都在推特上紧盯你的动态。回顾 Codex 的增长曲线，这或许是个简单的问题：频繁给开发者重置额度，到底在多大程度上推动了市场营销与用户增长？还是说这纯粹是对开发者社区表达的一份善意？

Tibo：

这或许有些反直觉，但在 OpenAI，只要认准了就可以放手去做。最开始纯粹是因为我们在快速迭代过程中难免把服务搞崩，或者配置出错导致体验不佳，我们觉得必须给用户补偿：“嘿，感谢你们试用我们的产品，我们正全力以赴打造它，现在还是早期阶段。刚才服务中断了 30 分钟，我们深知这项工具对你们的工作至关重要，这是赠送的额外额度，感谢你们的陪伴与包容。”事情就是这样开始的，我至今依然秉持这个原则：只要我们搞砸了，或者系统体验未达预期且原因尚不明确，我们就会通过重置额度来补偿用户。后来这成了大家津津乐道的话题，甚至做出了一个实体按钮。但这背后完全没有复杂的官僚审查，不需要市场或财务部门层层审批。只要我认为合适，随时都可以按下按钮。我们的准则是：我们致力于打造惊艳的产品，一旦体验不尽如人意，我们就会尽全力弥补用户。

Matthew Berman：

我认为这种做法在社区中积累了巨大的好感度，对增长起到了不可忽视的作用。

Tibo：

真诚关怀用户能带来很大的力量。你可以口头上说在乎用户，也可以用实际行动证明——一旦出问题就坦诚致歉并给出切实补偿。

Matthew Berman：

这让我想起亚马逊的退货政策——只要有任何不满意，随时退货。你们在 OpenAI 塑造了同样的信任认知：“只要我们出差错，尽管重新使用这批 Token，再送你一批全新额度。”这非常令人欣赏。

Tibo：

此外在一些值得庆祝的里程碑时刻，没有什么比赠送算力额度更能表达心意了。每次发布新功能，我们都尽最大可能广泛推送，并对社区说：“去尽情体验新功能吧！如果还没试过 Ultra 极速模式，送你额外额度，赶紧去尝鲜！”

Matthew Berman：

我听说你们现在真的做了一个实体的重置按钮？

Tibo：

是的，确实有。

Matthew Berman：

好极了，采访完一定要带我开开眼界。

Tibo：

没问题，我一定拿给你看，超级酷。

Matthew Berman：

但要频繁进行额度重置，前提是必须具备强大的算力容量规划底气。我想借此聊聊“自我改进”。几周前你们发文称，Sol 模型优化了 Luna 模型的运行效率，使 Luna 的调用价格大幅降低了 80%，同时 Terra 模型也降价了。这种成本下降到底有多少归功于算法层面的效率提升，有多少是因为超前的算力容量布局让你们有利润空间主动降价让利？

Tibo：

我们在算力规划上做了极其超前的布局。回顾两年前，OpenAI 曾因为在算力上投入如此巨大的资金而饱受外界质疑。

Matthew Berman：

事后证明这是一次极其英明的神级押注。

Tibo：

没错。如今我们很庆幸拥有这些算力储备，其中很大一部分算力专门用于前沿研究，持续探索更强大的未来模型并优化现有模型的效率。更不可思议的是：当我们不断拓宽最强前沿模型的能力边界时，我们反过来可以用这些最强模型来迅速重新设计推理栈与底层系统架构，从而获得巨大的效率与性能跃升。我们不仅优化了成本效益，还大幅提升了推理速度——即便不开启 Ultra 极速模式，基准速度在过去 3 个月内也提升了约 60%。我们深入技术栈的每一个环节针对实际负载进行工程优化。依托最先进的模型，我们仅用一支精干的小型团队就达成了这一目标。每当取得重大的成本与性能突破时，我们的承诺是始终保持在性价比前沿，绝不把利润全吞进私囊，而是第一时间让利给用户与开发者——这就是我们在 Luna 上所做事情。

Matthew Berman：



在内部权衡将算力分配给新模型研发、现有模型效率优化还是线上推理服务时，内部讨论与博弈是怎样的？

Tibo：

我们始终基于第一性原理来做决策。算力有固定的研发配额与产品配额，产品内部会进行权衡取舍。但在 Luna 这次优化中甚至称不上是一次艰难的妥协，因为效率提升极为显著，在保持相同算力预算上限的前提下，我们支撑了吞吐量的巨幅增长。

Matthew Berman：

几个月前在降价公告之前，你们曾发文提到利用一个模型来训练或优化下一个模型，接着又看到利用 Sol 模型来优化 Luna 的底层运行效率。在我看来，这正是“递归式自我改进”的早期雏形。你怎么看？这是否正在发生？

Tibo：

是的，递归自我改进绝对是当前的核心课题。人们通常将其理解为纯算法研究层面上的“模型开发新模型”，但我们取得巨大突破的另一个维度，是利用这些前沿模型来构建和优化它们自身运行所依赖的关键基础设施——这同样是一种递归自我改进。整个系统是一个有机整体：包括推理技术栈、更底层的硬件优化以及我们所编写的 CUDA 内核，乃至开发出更高效的人机交互新产品。比如你刚才提到的云端智能体，一旦攻克它，人机协作的生产力将迎来质的飞跃。这让模型能够反哺并重塑自身赖以运转的基础设施。

Matthew Berman：

确实。

Tibo：

所以我们当然在全力推进这件事，如果手握这么强大的模型却不去用它优化基础设施，那才真是太愚蠢了。

Matthew Berman：

顺着自我改进的话题，Sam Altman 曾提到暂停了当下最前沿的强化学习训练。能聊聊背后的决策过程吗？内部讨论是怎样的？

Tibo：

这是研究团队内部的核心事务。OpenAI 始终能够将资源集中投向最关键的领域。随着模型能力大幅提升，对齐与安全显得前所未有地重要，加大在这方面的投入是必然的承诺。这次暂停是必要的，目的是让团队能够彻底理解并加固系统的各个组件，确保在拥有完全掌控力的前提下安全重启训练。在需要审慎对待的时刻，我们内部始终能够极其果断高效地做出这种决策。

Matthew Berman：

在解除暂停之前，内部是设定了明确必须达成的量化指标，还是属于“达标时我们自然能看出来”的探索状态？

Tibo：



这是由安全团队主导的。过程中伴随着深入的研讨与探索，但他们最终确立了一套非常清晰的原则规范，一旦达成这些安全准则，我们就会处于能够安全推进的最佳状态。

Matthew Berman：我想回到 Ultra Fast 极速模式，许多人尚未完全意识到这种生成速度所释放的巨大潜力。在拥有如此惊人的 Token 每秒生成速度之前，内部有哪些场景是根本无法实现的？

Tibo：

在面临高风险、高紧迫度的关键场景时，极速模式被大量使用。例如当出现线上故障时，应急指挥官和响应团队会立即获得 Ultra Fast 权限，因为此时分秒必争。此外，只要团队在攻坚极其关键的核心任务（或者他们自认为极度重要），他们都会申请使用极速模式。

Matthew Berman：

桌面宠物也算关键任务吗？

Tibo：

哈哈，Pets 虽然算不上生死攸关，但我很喜欢我的虚拟宠物，它一直挂在我的屏幕上。你在办公室走一圈，会看到大家屏幕上都挂着小宠物，视频会议连线时也能看到，非常解压且让人开心。不过严肃来说，比如有同事在攻关一个全新创意，觉得它极具潜力，而下周一就必须做出最终决定以确定是否能赶上 DevDay 开发者大会发布，这时当然会直接开启 Ultra Fast 全速冲刺。大家在工作习惯上各不相同，有人喜欢单线程聚焦，有人喜欢多任务并发。对于极度习惯多任务并发的人来说，Ultra Fast 的体感收益可能没那么强烈；但对于讨厌频繁切换上下文的人来说，它简直是神器。你在两者之间属于哪种类型？

Matthew Berman：

我有注意力缺陷多动障碍（ADHD），所以我经常疯狂切换上下文。

Matthew Berman：

很有意思的是，虽然我有 ADHD，但我其实很抗拒无休止的上下文切换，那会让我非常疲惫。我更希望能专注于两到三个任务，这也是为什么我对 Ultra Fast 如此兴奋的原因。

Tibo：

这很有趣，我们恰好相反。我很擅长在上下文切换中快速做各种小决策，但有时我确实也想专注在一件事情上，这时 Ultra Fast 能让你稳稳保持在心流中。Ultra Fast 在处理纯长文本/代码生成、少外部工具调用的任务时表现最为极致——比如构建网站或游戏的原型代码，它能带来整整 10 倍以上的速度爆发；但如果流程中涉及大量外部工具调用、网络延迟或复杂的智能体调度链路，那么整体感知加速比通常在 3 到 4 倍左右，而无法完全达到纯生成的 14 倍峰值。

Matthew Berman：

我知道 OpenAI 员工享有无限 Token 额度。如果是我，我肯定会毫不犹豫地吧参数拉满，时刻使用最新的顶尖模型并始终开启 Ultra Fast。内部员工都是这样拉满使用的吗？

Tibo：

我们并没有向所有内部员工无限制开放 Ultra Fast，绝大部分算力容量都优先保留给了外部用户和企业客户。如果彻底放开，内部员工完全有能力吃光所有线上 GPU 算力。所以我们做了一定



程度的合理限制，既确保员工能充分使用以深入理解产品、推动自我改进，又把绝大多数算力资源倾斜给真正的付费客户。

Matthew Berman：

明白。在 OpenAI 之外，这种极速低延迟还能解锁哪些令你最兴奋的新场景？

Tibo：

我个人最兴奋的是非纯文本交互。比如在一个共享画布上实时协同创作，生成不同的设计方案与图像让用户自由挑选分支；在短短一分钟内完成原型构建，并通过语音或文本进行毫秒级的实时微调。作为工程师，过去你可能需要坐在那里花几天反复权衡系统架构与需求，而现在你可以在一分钟内把原型跑起来查看实际效果，在心流中敏捷迭代，极速推理彻底释放了这种即时创造力。

Matthew Berman：

我想 Ultra Fast 的定价肯定会明显高于普通速度。你认为这种极速最终会变成行业默认标准，还是会一直维持溢价状态？

Tibo：

按照技术演进的历史规律，它必然会随时间推移变得越来越普及。智能体执行任务的速度每月都在跨越式提升，这不仅归功于纯推理速度，还得益于模型 Token 利用效率的提升（例如 Sol 的 Token 效率远高于 Terra，下一代模型又会比 Sol 更加高效）。加上推理硬件与底层架构的持续创新，我认为在一到两年内，现在的极速模式就会成为默认或接近默认的标准。当然届时依然存在更高阶的旗舰算力层级，供用户通过调用更多硬件来实现极致复杂的任务。

Matthew Berman：

访谈尾声我想探讨一个面向更广泛大众的话题。很多人对 AI 感到焦虑不安，无论是担心就业被自动化替代、环境影响，还是面对这一新生事物时的陌生与恐慌。你会对大众给予怎样的鼓励？

Tibo：

我们打造 ChatGPT 的初心是造福全世界。我们在模型效率上的巨额投入，直接服务于“普及普惠”和“赋能大众”的目标。推理服务成本越低，大众在日常生活中能用它做的事情就越多。如今模型已经极其高效，以 Luna 为例，它作为轻量级模型具备极高效率，但如果退回到六个月前，它的能力完全等同于当时的最强前沿模型。

Matthew Berman：

确实。

Tibo：

看看 Luna 的调用成本，便宜到了不可思议的地步，这是现象级的突破。

Matthew Berman：

就像你们最近与 Replit 合作的那样，现在直接免费开放给大众了。



Tibo：

是的，直接包含在免费模式中。顶尖智能的获取正在变得无处不在。唯有年复一年、月复一月地不断突破效率极限，这一切才成为可能。今天最前沿的算力与智能，在六个月后就会以极其廉价的方式普及。技术必然会随时间推移变得高效普惠，我们全力以赴的目标，就是让每个人都能直接享受智能带来的便利。

Matthew Berman：

对于那些甚至连第一次尝试 AI 都心存疑虑和顾忌的人，你会对他们说什么？你如何向他们描绘一幅 AI 真正造福世界的未来图景？

Tibo：

其实你完全不需要把目光放得太遥远。ChatGPT 正在以非常深刻且贴近个人的方式帮助大众：很多用户用它来辅助日常写作、寻求生活建议，甚至用于健康咨询。我们上线了健康与个人财务功能，我自己就经常使用。它给予了我很多原本极难获得的深度支持，例如让我在去看医生之前能够掌握更全面、更精准的信息。因此你不用想得太复杂，多去跟身边已经在使用 AI 的人聊聊，从他们如何利用 AI 获益的经历中汲取灵感，这正是你迈出第一步、探索它如何为自己所用的最好方式。

Matthew Berman：

好的，Tibo，非常感谢你的精彩分享。

Tibo：

谢谢你，非常感谢你的时间。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 364  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论



1 条评论



正在加载

