

摘要：

OpenAI产品负责人Tibo表示，对Astra的需求真的是史无前例的。优先事项始终是为现有用户保持优质服务，但如果这种情况持续下去，我们可能不得不暂时暂停新的Pro订阅。

GPT-6 Astra的发布正在引发一场算力与容量危机。OpenAI核心产品负责人Tibo公开示警：**Astra的用户需求已超出历史经验，公司可能不得不暂停新的Pro订阅。**

Tibo在X平台发文称，“Astra的需求真的是前所未有的。我们已经在拉动所有能拉的杠杆来维持服务，但直到现在，我从未见过任何类似的情况——而我们此前已经经历过非常陡峭的增长。”他表示，首要原则是确保现有用户的服务质量，但如果需求持续，“我们可能不得不暂时暂停新的Pro订阅”。这是OpenAI高管首次就单一模型需求公开发出供给预警。



Tibo

@thsottiaux



Demand for Astra is really unprecedented. We're pulling all the levers possible to sustain the demand, but I've not seen anything like it until now and we went through very steep growth before. Priority will always be to keep excellent service for existing users, but we might have to pause new Pro subscriptions for a bit if this continues.

1:34 PM · Sep 9, 2026 · 226.8K Views

市场影响不止于此。摩根士丹利在9月7日的报告中指出，**GPT-6 Astra的重要性在于它将AI的瓶颈叙事，从“已知需求需要多少基础设施”扭转为“随着模型智能提升，有多少新工作负载将变得经济上可行”——前者是需求侧质疑，后者是供给侧压力。这对算力、电力和半导体产业链的定价逻辑均构成直接影响。**

Tibo是谁：从“额度之神”到OpenAI核心产品掌舵人

Tibo全名Thibault Sottiaux，2024年从Google DeepMind加入OpenAI。在DeepMind的六年间，他参与搭建了支撑AlphaGo、AlphaStar等项目的基础设施，并在离职前短暂领导了Gemini的人类数据团队。

加入OpenAI后，他迅速从内部工具开发转向面向用户的产品。他率领一支最初仅30至40人的团队构建了Codex，并于2025年5月将其公开发布。Codex活跃用户随后以每天百万级的速度增长，至今年7月已达800万，远早于此前预测的9月里程碑。

2026年5月OpenAI内部大重组后，Tibo的职责进一步扩大——ChatGPT、Codex与开发者API三条产品线全部合并，统一由他负责执行，Greg Brockman负责整体产品战略。这意味着他掌管的是一个面向近10亿用户的超级应用入口。

Tibo在X平台上以频繁为用户重置Codex额度著称，被开发者社区戏称为“赛博义父”和“掌管Token水龙头的神”，甚至出现了专门追踪其重置动态的民间网站TiboGPT。这种高度透明的公开互动，已成为Codex产品体验的组成部分。

Astra的能力跃升：从Answer Engine到AI Agent



GPT-6 Astra的发布标志着一次实质性的能力边界扩张。OpenAI明确描述其能力为：操作计算机、浏览网页、使用软件、编写和运行代码、完成复杂工作流，并在科学、网络安全和专业领域执行长程任务。

在OSWorld 2.0测试中——该测试由CMU及斯坦福等团队提出，考察AI Agent在数字环境中完成复杂任务的能力并与人类专家基线对比——Astra得分72.6%，高于GPT-5.6 Sol的65.7%；完成任务的模拟时间从约75分钟压缩至约40分钟。

这一变化的核心意义在于：**AI正在从“回答得更好”，走向“成功把事情做完”**。AI的工作模式由此从“人→AI→答案”，演变为“人→AI Agent→任务→执行→结果”。Tibo本人在公开分享中透露，他每天向Codex分配超过100个复杂任务，包括整理资源、检查值班轮换、分析发布计划等，并使用Codex生成个性化的每日工作简报。

Token需求的乘数效应：工作能力提升与消耗成正比

Astra的能力跃升，将从根本上改变AI需求的测算逻辑。在Answer Engine时代，AI需求可以近似用“用户数×ARPU”衡量；但在AI Agent时代，这一公式已经失效。

Token总需求可以粗略表达为：Agent数量 × 每Agent任务数 × 每任务Token消耗。这三个变量在Astra发布后均面临同步扩张的压力。

首先是Agent数量的增加。一个人可能同时运行个人助理、编程、研究、财务等多个Agent，企业端则可能从数十个扩展至数千个。其次是单个Agent承接的任务复杂度上升——模型越能完成复杂任务，用户就越倾向于将更重、更长的工作交给Agent执行。第三是Agent从“偶尔调用”变为“持续运行”：任务越复杂，推理链越长，上下文越大，工具调用越多，Token消耗越大。

这意味着完全可能出现Agent数量增长20%、但Token总需求增长300%的情形。Tibo对Astra需求的预警，与这一逻辑高度吻合：能力提升直接驱动消耗放大，两者呈正相关。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

191 收藏

分享到:  

写评论

请发表您的评论



