

摘要：

它让音视频不再是“看完就过去”的东西，而是可以检索、复用、直接拿去干活的“数字资产”。

你一定有过这种经历：开完一场两小时的会议，录像文件安安静静躺在网盘里，但没人愿意回看——因为回看的成本几乎等于再开一次会。

一条爆款带货视频刷到了，你隐约觉得它的转化逻辑值得学，但既没时间逐帧拆解，拆了也不知道怎么变成自己的脚本。

还有英文播客、发布会直播、夹杂方言且需要复盘的客服录音——这些音视频内容每天都在大量产生，但对绝大多数人来说，它们被“看过”或“听过”之后，就再也没有然后了。

我们的日常中，大量非常非常有价值的音视频内容无法被拆开、被检索、更没法总结经验拿去复用。

而阿里千问刚刚发布的Qwen3.5-Omni，让我们觉得这个问题开始有解了。

它是千问最新一代全模态大模型，采用混合注意力MoE架构，在海量文本、视觉及超过1亿小时的音频数据上做了原生多模态预训练，在215项第三方性能测试中取得SOTA，多项核心指标超越Gemini-3.1 Pro。

		Qwen3.5-Omni-Plus	Qwen3.5-Omni-Flash	Qwen	Gemini
Audio Visual	DailyOmni	84.6	81.8	Qwen3-Omni-Flash-120I	Gemini-3.1-Pro
	WorldSense	62.8	57.9	69.3	81.4
	QualcommInteractive	68.5	66.3	53.9	65.5
	Omni Cloze	64.8	63.0	52.3	56.7
				55.5	57.2
Audio	Wenetspeech-net/meeting*	4.30/5.84	4.41/5.51	Qwen3-Omni-Flash-120I	Gemini-3.1-Pro
	Librispeech-other*	2.23	2.43	4.66/6.07	11.5/14.2
	Fleurs (60lang)*	6.55	10.8	2.62	4.41
	MIR-1K (vocal-only)*	4.56	4.94	-	7.32
	Fleurs S2IT (ZH, EN, SP,lang)	32.8	29.4	6.17	8.76
	VoiceBench	93.1	87.8	-	32.1
	URO-Bench-Pro (U/R/O)	66.3/86.3/99.8	64.1/83.8/98.7	87.1	88.9
	RUL-MuchoMusic	72.4	60.5	-	69.1/84.0/99.2
	MMAU-v0.5.15.25	82.2	80.4	51.5	59.6
Speech Generation (Main Tone)				78.8	81.1
	Seed-Test (zh/en/hand)*	1.07/1.36/6.25	1.09/1.64/6.41	Qwen3-TTS	Gemini-2.5-Pro-TTS
	Multi-Lingual (30lang)*	3.23	3.90	1.36/2.04/6.60	2.43/1.18/11.57
Vision				-	3.92
	RealWorldQA	84.1	77.5	Qwen3.5-397B-A17B-nothink	Gemini-3.0-Pro
	MVBench	79.0	70.8	79.1	83.3
	EmbSpatialBench	85.4	82.7	76.7	74.1
	OCRBench	91.3	89.1	83.4	61.2
Text				91.4	90.4
	IFEval	89.7	85.2	Qwen3-Omni-Flash-120I	Gemini-3.0-Pro
	MMLU-Redux	94.2	90.0	83.9	93.5
				87.4	95.9

* denotes that lower values mean better performance.

比跑分更值得说的，是我们在实测中实际体验到的东西——经过几轮极其刁钻的极限测试后，这个全模态模型彻底震撼到我了：

。我们让它拆解了一支《沙丘》预告片——它不仅按时间戳做了结构化分析，还推理出了角色间的隐含关系，生成了带节奏设计和调色建议的复刻分镜脚本；

- 我们给了它一条爆款TikTok带货视频——它拆出了完整的转化归因，输出了可以直接迁移到其他行业的5步脚本模板；
- 我们对着一张画得很丑的手绘草图口述需求——它直接生成了能跑的React页面，然后我们继续口述修改，它一轮轮迭代下去，上下文始终没丢。

这意味着，你可以把一场两小时的会议录像扔给它，拿回一份带时间戳的结构化纪要和待办清单；把一条竞品的爆款视频丢进去，直接拿到可迁移的脚本模板；用它给客服录音做质检，输出情绪轨迹和话术评分。

它的意义，绝不仅仅是多模态能力的又一次参数升级。它让我亲眼看到，原本只能“看一遍就过去”的音视频内容，是如何被生生拆解成可以直接拿去干活的“数据资产”的。

而如果你给你的龙虾接上Qwen3.5-Omni，给你的龙虾装上“眼睛”和“耳朵”，那么你就能获得一个真正能听懂语音指令、看懂视频内容、理解音频信息，还会操作电脑的数字员工。

这，或许才是那场我们期待已久的、属于全模态大模型的真正生产力革命。

接下来，我们先来看看实测细节，再聊聊这个模型正在改变什么，以及阿里拿它在下一盘什么棋。


拆电影、复盘带货、口述写代码：全模态能力全面进化

（1）沙丘：不止是“看懂故事”


我们选了没有字幕版的《沙丘》预告片作为第一个测试素材，来对Qwen3.5-Omni的多模态能力进行“极限测试”。

预告片天生就是视频理解领域最不友好的素材：密集的镜头切换、多线叙事、大量隐喻和视觉暗示，视听密度极高。

而对于Qwen3.5-Omni来说，第一轮的结构化信息提取几乎没有难度：剧情时间线、关键镜头、画面文字、说话人与台词、角色阵营关系、情绪变化曲线，全部按时间戳精准剥离。



第二轮，我们指定了第24秒出现的台词，要求它回答对应画面、说话者和情绪。它准确定位到“She would need to be strong, like her mother”，正确识别为保罗的画外旁白而非现场对话，对应画面为查妮沙漠逆光侧脸特写，情绪判断——温柔、敬重、期许——与画面完全吻合。




真正的考验，在于第三轮的“深层推理追问”——

我们要求它分析角色间的“隐含关系”并给出镜头和台词证据、识别预告片中的“伏笔”镜头及其对未来剧情的指向、生成一个45秒短视频复刻分镜脚本。

它准确识别出保罗与费德·罗萨之间的“镜像宿敌”关系、保罗与杰西卡之间的“断裂传承”张力、查妮作为“人性锚点”的角色定位，而且附带了视觉构图证据和台词对照。

它给出的复刻分镜脚本也不是模糊的叙事概括，而是带有“慢板抒情→快速剪辑→史诗爆发”的三段式节奏设计，甚至包含调色方向、音效提示和字幕处理建议。


说实话，到这一步，它已经不是在“看懂视频”，而是有点导演拆片的意思了。它把LLM的“视频理解”能力，从摘要层推到了镜头语言解读、关系推理层面。



(2) 带货：从一条爆款TikTok带货视频里，拆出转化的底层逻辑

对更多人来说，更现实的问题是：它在真实世界，在日常工作中是不是真的“有用”？

我们输入了一条义乌招商类TikTok爆款带货视频，要求Qwen3.5-Omni帮助我们拆解、复刻。



结果，模型不仅按Hook、卖点排序、画面证明点、字幕策略、情绪节奏、CTA时间点、目标人群七个维度完成了结构化拆解，它的归因分析也极具洞察力：三级物理证据链构建“所见即所得的信任”、“2万种SKU + 20美分均价”制造数字锚点、保姆式全案承诺实现风险逆转。

换句话说，它看出来了：这条视频卖的不是商品，而是确定性。



为了验证它是不是在生搬硬套营销学名词，我们告诉它，“我家工厂是卖T恤的，帮我按这个套路设计一个脚本”，要求它把这套逻辑迁移到“T恤定制工厂”场景。

结果，它不仅把刚刚分析出的5步转化模板成功迁移到T恤场景，还把Hook极其自然地改成了“拉扯T恤展示弹性”，把实力证明换成了“印花机喷墨特写+揉搓不掉色”，甚至附带了评论区运营引导私信的实操建议。

也就是说，大模型不再只是内容理解工具，它已经可以充当不知疲倦的电商分析师和社交媒体运营专家。



(3) 口述一个App：边看、边说、边改


第三个测试，堪称“Vibe Coding”的升级版——“音视频Vibe Coding”。

我们手绘了一张故意画得很粗糙的APP线框图，打开摄像头，手持草图对着镜头口述：“你看这个是我画的界面草图……请用React帮我生成完整代码，可以直接运行的。”

它识别了手绘布局并生成了React代码。接着我们继续口述修改——“导航栏改成侧边栏，主按钮放大一倍换圆角”，同时上传替换图片。之后又测了深色主题、进度条动画、按压反馈等迭代，它始终能延续上下文，不丢失之前的修改。

几轮修改后，网页成功上线。

整体体验上来说，它接住了人类最真实的交互方式：边看、边说、边改。不是以前那种“AI生成代码你自己去调”的体验，更像一个经验丰富的开发者坐在你的旁边。



(4) 连起来看

从《沙丘》的复杂叙事，到带货的商业分析，再到口述做App的随性交互，如果我们把上面的几个测试案例串起来看就会发现：

Qwen3.5-Omni成功证明了：它能把复杂的、混乱的、连续输入，变成可以直接拿去用的结果。

另外补充两个我们也测了但没展开写的用例：游戏视频生成解说：网页端出文案，API端出TTS语音；"24小时AI新闻编辑部"——50分钟国际新闻发布会音频走完信息提取、双语稿件生成和语音播报，效果都不错，感兴趣的朋友也可以试试。



底层改变：从"看懂内容"到"拆成资产"

前面三个场景能跑通，不仅因为"能力变强了"，而是底层产品设计发生了质变：它把连续、混杂、难以检索的音视频流，强制拆解为高度结构化的中间层。

(1) 拆得多细：不是摘要，是字段级的结构化资产

翻开官方API文档你会发现，Qwen3.5-Omni对音视频的推荐输出格式不是一句笼统的摘要，而是三层硬结构：

- Storyline（按时间戳融合音画细节的故事线）；



- Visible Text（带起止时间和外观特征的画面文字清单）；
- Speakers and Transcript（含说话人身份、口音、语气、情绪的逐字稿）。

换句话说，它拿到的不再是“一团视频”，而是一份可以被代码直接调用、检索和执行的结构化资产。这就是沙丘测试能做到精确回溯，TikTok测试能输出可迁移模板的底层原因。

支撑这种颗粒度的，是实打实的模型基础能力——混合注意力MoE架构，超过1亿小时音频数据的原生多模态预训练，模型智力与qwen3.5-plus同一水平，215项第三方测试取得SOTA。

（2）拆得多长：超大上下文窗口

256K上下文窗口，支持超过10小时音频、超过400秒720P视频。

长内容真正的难点从来不是“看完”，而是跨段关联和证据回溯——扔进10小时的会议录音，问“第5分钟提到的人在第30分钟说了什么”；输入带货直播录屏，让它揪出夸大宣传的时间点并附上画面和台词证据；用它给客服录音做质检，输出情绪轨迹和话术评分。

这些过去高度依赖人力、极易出错的信息整理工作，Qwen3.5-Omni正在试图接管。

（3）交互：是动态接口

实时交互这一面，它支持智能语义打断——不会因为你咳嗽一声或随口说个“嗯”就中断发言，过滤掉了无意义的背景音干扰。

它原生支持联网搜索的FunctionCall，能自主判断是否需要拉起搜索来回应实时问题，开发者还能在回执中看到精确的计量信息。这从工程层面缓解了企业用大模型时最头疼的“时效性与幻觉”问题。

语音表达层的能力提升同样很有价值，现在，它支持113种语种和方言的语音识别，三十六种语言和方言的语音合成，内置47个多语言说话人和8个方言说话人。

在我们的实测中，无论是自称“声音像温热奶茶”的客服角色Tina，还是四川话的“晴儿”，角色感和产品感都很强。

这不只是“听得懂更多”，而是为海外客服、审核质检、有声读物、播客配音这些高频场景备足了弹药。

一句话简单总结，Qwen3.5-Omni，让音视频变得“可拆”——不是“看懂了”，而是拆成可以检索、可以复用、可以直接拿去干活的现成素材。

阿里真正想卖的，也不只是一个模型

聊完产品和技术，值得把视线从模型本身移开，看看阿里最近在组织和产品上的一系列动作——一条清晰的商业暗线就会浮出来。

不久前，阿里成立了由CEO吴泳铭直管的 Alibaba Token Hub（ATH）事业群，明确提出以“创造Token、输送Token、应用Token”为核心。其中，首次亮相的“悟空事业部”定位极为明确：“B端AI原生工作平台，将模型能力深度融入企业工作流”。



而在钉钉最新发布的“悟空”产品中，核心逻辑已经从“沟通即生成”进化为了“沟通即执行”(CLI化，AI直接调底层接口)。AI 不再只是陪你聊天，而是被要求自己去网上看竞品视频、分析小红书爆款、跨系统拉取数据、甚至生成数据动画。

注意这里的关键词：看视频、听音频、跨平台执行。当AI Agent开始长出"手脚"，自主去处理大量音视频内容时，它对全模态理解能力的需求和Token的消耗量，都将远超纯文本对话时代。

在这个背景下回看Qwen3.5-Omni，它的极低定价（每百万Tokens输入不到0.8元，比Gemini-3.1 Pro的1/10还低）和强大的结构化音视频能力，更像是在为以悟空为代表的阿里B端企业级Agent大规模落地，储备高性价比、稳定的全模态基础设施。

要知道，把长达数小时的音视频拆解成精细的结构化数据，过去意味着企业需要拼装一整条链路——ASR转写、文本大模型、视觉理解模型、TTS合成——成本高、链路长、断点多。

而现在，一个端到端的全模态模型，把这件事的门槛彻底踏平了。

我觉得Qwen3.5-Omni真正值得被记住的，不是它今天能看懂一段多复杂的电影预告片而是从这一刻起，它开始能把音视频内容，变成企业 workflow 里可以切实处理、复用的“数字资产”——

全模态大模型驱动的生产力革命，正在来临。

本文来自[微信公众号“硬AI”](#)，关注更多AI前沿资讯请[移步这里](#)



风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 72 ★ 收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

