

摘要：

英伟达通过38项重大软件优化与25万次测试，仅用三个月便将GB200运行DeepSeek模型的能效提升4倍；GB300 NVL72则刷新训练纪录，性能半年增长1.5倍且扩展效率接近98.5%。在新架构Rubin加速落地的同时，英伟达持续深挖Blackwell平台潜能，展现出强大的软硬件协同优势。


英伟达正以持续的软件栈优化延长Blackwell平台的生命周期，同时为下一代Rubin架构的规模化落地蓄力。

在新一代Rubin平台加速部署的背景下，英伟达披露，**仅用三个月时间，便将GB200 NVL72在运行DeepSeek R1 0528模型时的每兆瓦算力吞吐量（TPS/MW）提升了4倍**。这一成果源自英伟达在四个月内完成的38项重大优化，背后支撑为逾25万次模拟配置测试及累计140万GPU小时的优化验证。

与此同时，GB300“Blackwell Ultra”平台在AI训练基准测试中持续刷新纪录。256卡规模下，GB300 NVL72在DeepSeek-V3 671B预训练任务中以每GPU 1648 TFLOPs的成绩创下历史最高纪录，较GB200的606 TFLOPs提升约3倍，且该指标在过去六个月内已累计提升1.5倍。

GB200能效大幅跃升，优化覆盖90%以上模型

英伟达表示，针对GB200 NVL72平台的系列优化，使其在运行DeepSeek R1 0528（1K输入/1K输出配置）时，每兆瓦算力吞吐量在三个月内实现4倍增长。




支撑这一提升的，是英伟达在四个月内完成的38项重大优化迭代。这些优化经由超过25万次模拟配置筛选，并累计消耗140万GPU小时进行实测验证。英伟达特别指出，其中逾90%的优化成果可跨模型复用，适用于其AI产品组合中的其他模型，而非专为单一任务量身定制。

这意味着，现有数据中心客户无需更换硬件，即可通过软件升级获得显著的能效收益——这对于算力成本高度敏感的超大规模云厂商和企业客户而言，具有直接的经济价值。


GB300刷新训练纪录，六个月性能提升1.5倍

在AI训练侧，GB300 NVL72同样展现出强劲的性能势头。在256卡规模下，基于Megatron Core框架对DeepSeek-V3 671B模型进行预训练，GB300 NVL72实现了每GPU 1648 TFLOPs的吞


吐量，较此前GB200的606 TFLOPs提升约3倍，并创下该任务的全球最高纪录。



值得关注的是，这一数字并非静止的硬件极限。GB300 NVL72在Megatron Core框架下的表现，已从2025年11月的1088 TFLOPs/GPU增长至2026年6月的1648 TFLOPs/GPU，六个月内累计提升约1.5倍。




在主流AI框架的协同优化方面，英伟达与PyTorch及JAX社区的深度合作同样带来显著增益。在TorchTitan（PyTorch原生训练栈）上，GB300 NVL72对DeepSeek-V3 671B的训练性能，相较未优化基线配置提升6倍，从199 TFLOPs/GPU跃升至1197 TFLOPs/GPU。JAX框架下的提升幅度更为突出，截至2026年7月，每GPU吞吐量达到4082 Tokens/s，对应1025 TFLOPs/GPU，较2026年1月的418 Tokens/s提升约10倍。



扩展效率接近理论上限，800 Gb/s网络是关键

大规模训练场景下的扩展效率，历来是衡量AI基础设施实用性的核心指标之一。英伟达披露，在256至1024卡的扩展区间内，GB300 NVL72在三大主流框架下均维持了接近理论上限的扩展效率：Megatron Core达到98.5%，TorchTitan与JAX均达到97%。

英伟达将这一扩展表现归因于NVL72机架内置的800 Gb/s Scale-Out网络芯片。高速互联直接决定了多机训练中的通信开销，进而影响整体扩展效率，该网络能力被视为支撑上述跨框架高效率表现的核心基础设施组件。



Rubin平台加速落地，Blackwell优化仍在持续

上述优化进展发布之际，英伟达下一代Vera Rubin平台已进入全球部署阶段。**据报道，Vera Rubin NVL72在Token吞吐量上相较Blackwell实现约10倍提升，GB200 NVL72约为80,000 Tokens/s，而Vera Rubin NVL72在同等150MW功耗下可达800,000 Tokens/s。**

然而，Blackwell平台已在全球无数数据中心完成部署，英伟达的策略与此前Hopper世代如出一辙——在新平台推进的同时，持续通过软件优化挖掘已部署硬件的潜力。这一做法不仅延长了现有客户的硬件投资回报周期，也强化了英伟达在AI基础设施生态中的平台黏性。对于市场而言，英伟达在Blackwell与Rubin双线并进的格局下，正逐步构筑起竞争对手难以在短期内逾越的软件护城河。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

11 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论