

摘要：

英伟达的产品迭代速度，正在撞上物理极限的墙。更大的芯片→更复杂的封装→更高的缺陷率→要么延迟、要么缩水。这是一条不能无限延伸的曲线。而与此同时，竞争对手们正在用另一种方式绕过这面墙：不做更大的芯片，做更专用的芯片。

两条看似无关的新闻，在6月最后一周先后落地。

6月25日，OpenAI发布首款自研AI推理芯片Jalapeño，与博通联手仅用9个月完成从设计到流片——这家全球最大的GPU买家，开始自己造芯片了。

6月30日，半导体研究机构SemiAnalysis在社交平台公开宣布：英伟达原版4芯片Rubin Ultra已在GTC 2026发布仅三个月后遭取消，新版性能缩水近半。“这一切发生的背景是，“该机构补充道，“英伟达的市场份额正在被侵蚀。”

而早在去年，媒体爆出Anthropic的年化营收已逼近70亿美元，旗下Claude Code在推出两个月内创造了5亿美元年化收入。而驱动这一切的算力底座，已经不再只有英伟达——谷歌TPU承担训练、亚马逊Trainium负责推理、英伟达GPU退居为“研究探索”的第三选项。

三条新闻，指向同一个问题：CUDA护城河——英伟达最坚固也最被神话的竞争壁垒——正在出现裂痕。

87%到75%，英伟达的“不可替代”正在瓦解

先看一组数字。

据Silicon Analysts基于英伟达/AMD财报及台积电产能分配数据的估算，英伟达在AI加速器市场（按收入计）的份额轨迹如下：

年份	英伟达数据中心收入	AI加速器总市场	英伟达份额	定制ASIC收入	AMD收入
2022	\$150亿	\$200亿	75%	\$20亿	<\$10亿
2023	\$475亿	\$550亿	86%	\$30亿	\$20亿
2024	\$1000亿+	\$1150亿	87% (顶峰)	\$80亿	\$50-60亿
2025E	\$1300亿+	\$1600亿	81%	\$150亿	\$100亿+
2026E	\$1500亿+	\$2000亿+	75%	\$250亿	\$150亿+

数据来源：NVIDIA/AMD季度财报，Silicon Analysts、TrendForce、Morgan Stanley估算

可以看到，英伟达的收入仍在增长——从150亿到1500亿，四年十倍。但份额从87%高峰滑向75%，意味着增量市场中有越来越大的一块被切走了。

切走这块蛋糕的，不是某一个对手，而是来自四面八方的竞争：谷歌TPU、亚马逊Trainium、微软Maia、Meta MTIA、博通定制的XPU——还有刚加入的OpenAI。

博通CEO陈福阳在2026财年一季报电话会上透露了一个此前未公开的数字：博通AI半导体收入已达到84亿年化运行率，同比增长10684亿年化运行率，同比增长106400-500亿的年度轨迹冲刺。这家公司已经签下了六个超大规模客户为其定制AI芯片，OpenAI是第六个。

换句话说，全球最大的几家云计算公司和AI公司，不约而同地选择了同一个方向：自己造芯片。

Anthropic的选择

如果说市场份额数据是冰冷的统计，那Anthropic的案例就是一个活生生的“去英伟达化”教科书。

Anthropic是目前全球增长最快的AI公司之一。 年化营收逼近70亿美元（2025年同期仅约10亿），服务超过30万家企业客户，大客户数量同比增长近7倍。Claude Code在推出两个月内创造了5亿美元年化收入，Anthropic称其为“史上增长最快的产品”。

而驱动这一切的算力底座，是一种被Anthropic CFO Krishna Rao称为“独特计算策略”的三平台架构：

芯片平台	用途	规模
谷歌TPU	Claude主力训练	百万级芯片，超1吉瓦算力
亚马逊Trainium	Claude推理（含Claude Code）	Project Rainier超算集群
英伟达GPU	前沿研究探索	三平台中最小份额

注意最后一列。英伟达GPU排第三，不是并列，不是“备选”，是三个选项里规模最小的那个。

这不是一个缺钱的小公司在用廉价替代品凑合。这是全球第二大AI公司，在生产环境中，用非英伟达芯片驱动其增长最快的产品。

SemiAnalysis在6月30日的帖子中特别点出了这一点：“Claude Code的推理工作有相当大一部分运行在Trainium上，Claude的训练在TPU上完成。就在一年前，TPU和Trainium能增长到这种规模，同时CUDA护城河被缓慢侵蚀，还是难以想象的事。”

Anthropic为什么要这样做？不是因为TPU和Trainium比H100更强——在绝对性能上它们可能仍有差距。而是因为特定场景下，专有芯片的性价比远超通用GPU。训练用TPU，因为谷歌给了几百亿美元的合同和百万颗芯片的供应承诺。推理用Trainium，因为AWS是其主要云服务商、已投资80亿美元，Project Rainier超算集群完全跑在Trainium 2上，没有GPU溢价。

亚马逊在Trainium上赌得很大。据其2026年一季报披露，Trainium产品线已获得超过2250亿美元的收入承诺，客户包括OpenAI和Anthropic。AWS的AI收入运行率已超过150亿美元，



Bedrock推理服务大部分跑在Trainium上。

这里的关键词不是"性能"，是"成本"。推理是每天都在烧钱的事。ChatGPT每次回答问题、API每次返回代码，背后都是GPU在跑电。Anthropic用Trainium替代GPU做推理，不是为了跑得更快，是为了每花一美元算更多次。

三道侵蚀切口：CUDA护城河从哪里裂开

CUDA之所以被视为英伟达最坚固的护城河，是因为它构建了一个"硬件-软件-开发者"的封闭生态：

- 20年积累，400万+开发者
- 所有主流ML框架优先为CUDA优化
- cuDNN、TensorRT、NCCL等优化库形成深度绑定
- 切换成本以年计，以亿美元衡量

但2026年的AI芯片竞争，不再是"做一个比H100快10%的GPU"——那是正面进攻，无人能赢。侵蚀来自三个侧面：

侵蚀路径一：自研ASIC——不打全战场，只切最肥的推理蛋糕

这是最致命的路径。它的逻辑不是"我能做得比英伟达好"，而是"我不需要GPU的所有功能，我只需要推理"。

一块英伟达H100要做的事：图形渲染、科学计算、AI训练、AI推理、视频编解码……一块Jalapeño只做一件事：运行OpenAI自己的模型进行推理。前者是瑞士军刀，后者是一把专砍一种木头的斧头——在特定任务上，斧头比军刀好用得多，也便宜得多。

OpenAI Jalapeño的定位极其精准：不和英伟达比全能，只在推理——这个每天消耗数十亿次API调用、每年燃烧数亿美元成本的场景——做到极致。OpenAI官方目标是降低30-50%的推理成本。在每天烧掉数百万美元推理费用的体量下，这意味着每年节省数亿美元的纯利润。

而且OpenAI不是第一家。微软Maia 200（2026年1月发布）、谷歌TPU Ironwood（第七代，首款专为推理设计）、亚马逊Trainium 3——四大云厂商全部亮出了自研推理芯片。再加上Meta MTIA和苹果的定制芯片，全球前七大科技公司中，只有一家还在"只买不造"——而它也在路上了。

侵蚀路径二：AMD——从"存在"到"可信替代"

AMD的AI GPU收入从2022年的不到10亿美元飙升至2026年预计的150亿美元以上，四年超过15倍增长。

这背后的关键转折点是MI400系列。基于CDNA5架构、432GB HBM4内存、19.6 TB/s带宽，预计2026年下半年量产。S&P Global预测MI400单系列将贡献72亿美元收入，占AMD数据中心业务的25%。

更重要的是客户端的信号。Meta已与AMD签署了高达6吉瓦的采购承诺——这不仅是AMD历史上最大的AI芯片订单，也是一个明确的信号：超大规模客户在做多供应商布局。



AMD的局限同样明显：台积电CoWoS产能分配仅约11%，而英伟达占据60%以上。产能天花板决定了AMD短期内无法对英伟达形成数量级冲击。但“可信的第二供应商”这个定位本身，就已经拆掉了“非英伟达不可”的叙事墙角。

侵蚀路径三：软件层解耦——Triton、JAX和“CUDA-Free”的未来

这是最容易被忽略、但长期最危险的一条路径。

CUDA的绑定依赖于一个简单事实：AI研究员写代码用PyTorch，PyTorch底层跑在CUDA上。但如果PyTorch底层不再依赖CUDA呢？

这正在发生。PyTorch团队已经验证了使用Triton编译器可以实现“CUDA-Free”推理——在H100和A100上运行Llama 3模型，Triton内核生成的token吞吐量可与CUDA媲美。2026年2月，Triton推出了新的多后端支持，允许同一套代码编译到不同硬件上——AMD GPU、英特尔GPU、甚至各种ASIC。

谷歌的JAX框架走得更远。它从一开始就设计为硬件无关——同样的代码可以在TPU、GPU甚至CPU上运行。Anthropic选择TPU进行训练，很大程度上就是因为JAX让它们可以在不重写模型代码的前提下迁移算力平台。

软件层的解耦意味着什么？意味着新一代AI研究员可能在从未写过一行CUDA代码的情况下，训练出最先进的模型。当开发者不再被锁定在CUDA生态中，“必须买英伟达”的硬逻辑就变成了“可以买英伟达”的软选择。

Rubin Ultra取消：物理极限的分水岭

回到开篇的新闻。英伟达4芯片Rubin Ultra在发布三个月后遭取消，被SemiAnalysis视为“制造执行层面的问题正在让更多市场份额流失”。

技术原因并不复杂。原版Rubin Ultra计划将4颗计算芯片+16个HBM4E内存模块集成在单一封装内，采用台积电CoWoS-L工艺。但据Global Semi Research，4芯片配置下出现了封装基板翘曲——基板向多个方向弯曲，导致计算芯片无法与基板完全接触。信号传输失效，芯片根本无法工作。

台积电的备选方案CoPoS（面板级封装）要到2028年底才能量产。英伟达等不起——所以新版Rubin Ultra回退到2芯片设计，性能缩水近半。

这件事的象征意义大于实际业务影响。

英伟达仍然会卖掉它能生产的每一块Rubin Ultra。但“从4芯片回退到2芯片”暴露了一个更深层的问题：**英伟达的产品迭代速度，正在撞上物理极限的墙。更大的芯片 → 更复杂的封装 → 更高的缺陷率 → 要么延迟、要么缩水。这是一条不能无限延伸的曲线。**

而与此同时，竞争对手们正在用另一种方式绕过这面墙：不做更大的芯片，做更专用的芯片。

定价权的裂缝

英伟达的护城河真正不可撼动的部分，不是CUDA软件生态，是制造端。台积电60%的CoWoS先进封装产能握在它手里。这是物理壁垒，不是软件壁垒。竞争对手可以写出更好的框架、设计出更高效的ASIC——但在出货量上追赶英伟达，首先要过台积电产能这一关。



但问题也就在这里：制造壁垒依赖的是一家第三方晶圆厂。它不是英伟达自己能控制的资产。

而英伟达88%的毛利率——H100成本3320美元、售价28000美元——建立在一个前提上：客户无法离开它。如果这个前提从"无法离开"变成"性价比最优的选择"，那定价权就不再是绝对的了。

Anthropic证明了另一条路：不追求最好的芯片，追求最适合的芯片。训练用TPU而不是GPU，不是因为TPU更快，而是因为谷歌给了足够多的芯片和足够好的价格。推理用Trainium而不是GPU，不是因为Trainium更强，而是因为AWS是战略股东，Project Rainier绕开了通用GPU的溢价。

当全球第二大AI公司把GPU降级为三大算力平台中最小的一块时，"必须买英伟达"这件事就不再是铁律了。

英伟达仍然是最好的。头部AI公司没有一个彻底离开了它——Anthropic保留了一部分GPU用于"前沿研究探索"，OpenAI的Jalapeño只做推理不做训练，Meta的MTIA只覆盖推荐系统和内容审核。

但从"只有英伟达"到"英伟达最贵，先用便宜的"，这中间的差距就是定价权的流失。

市场已经开始为这个可能性重新定价。今年以来，SemiAnalysis的每一次看空报告都引发相关板块剧烈震动：6月初SOCAMM削减消息导致美光单日跌13%，6月10日CPO延迟争议迫使英伟达高管出面辟谣，6月30日Rubin Ultra取消再度点燃讨论。

这些波动的背后，是市场在艰难回答一个以前不需要回答的问题：如果CUDA不是不可替代的，英伟达值多少钱。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

332 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

3 条评论





正在加载 ..