摘要：

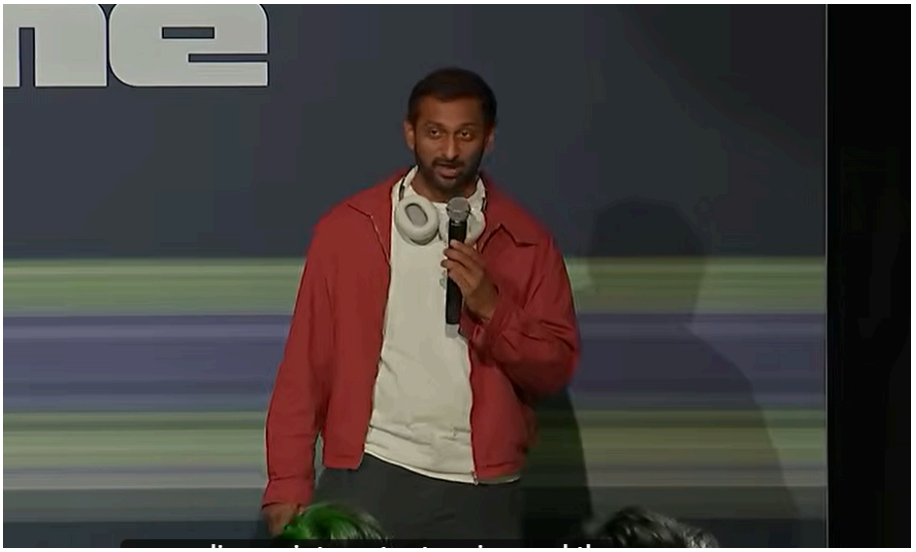
SemiAnalysis创始人Patel称，OpenAI和Anthropic预订了新增算力的25%到40%。“现在对很多人来说，已经不可能买到算力了。”此外，利率上行使Neocloud难借到钱，英伟达只给约6.5吉瓦托底，占比有限，算力的交付权仍向超大规模云厂商和两家实验室集中。

11月3日，半导体研究机构SemiAnalysis创始人兼CEO Dylan Patel在Runtime 2026上发表演讲，主题是算力、资本，以及谁能真正把算力交付出去。

他表示，OpenAI和Anthropic正在大量预订算力，以2027年为例，两家拿走的新增算力占比在25%到40%之间。在需求挤压下，英伟达H100数据中心芯片的一年期合约价，已从去年10月低点的每小时1.70美元涨到2.80美元左右。对其他公司来说，买得起算力，不等于拿得到算力。

资金端同样吃紧：近两个月美债收益率大幅上升，10年期收益率10月初已升至5%以上，靠借钱建机房的新兴云厂商越来越难融到资。

这场演讲发生在Anthropic公开递交S-1的一周后，市场刚刚看到一家头部实验室背后的算力账。Patel说，英伟达已经出面为约6.5吉瓦的算力托底，但在2030年前的新增算力里，这只占很小一部分、“杯水车薪”。



新增算力被两家实验室订走一大块

算力紧张的起点在买家太集中。全球算力总量已经涨得很快：2024年底约60吉瓦，今年底超过100吉瓦，两年接近翻倍。Patel说：

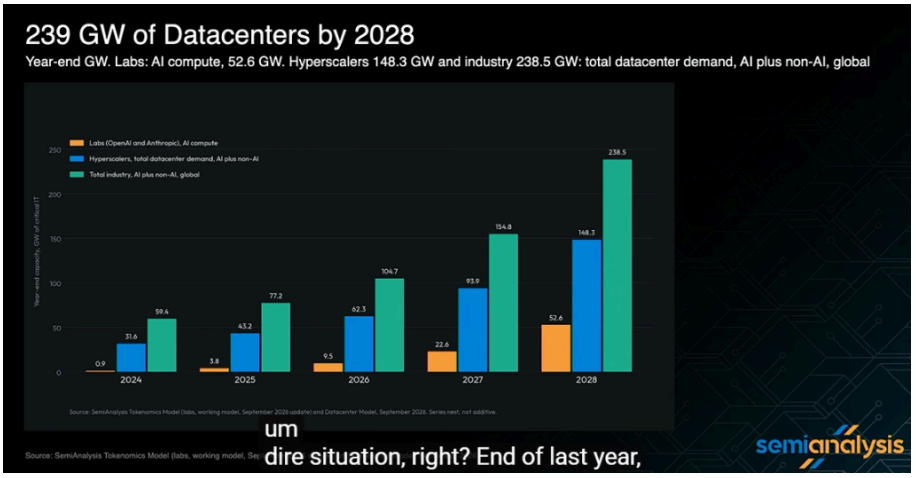
> **“2024年底全球有60吉瓦的算力，到今年年底已经超过100吉瓦，两年时间几乎翻了一番。”**

增量中最大的买家是OpenAI和Anthropic。两家手里的算力总量，去年底合计约4吉瓦，今年约10吉瓦，明年超过20吉瓦。**拆成增量看，2027年一年里两家合计新增约12吉瓦，而全球当年新增总量约40吉瓦，占比约三成。**到2028年，Patel称AI实验室一年就要新增约30吉瓦。

Patel估算：

> **“他们拿走的是新增算力里25%、30%、40%的那一部分。”**
>
> **“去年底，OpenAI和Anthropic的收入随着Claude Code开始飙升，于是他们疯狂买算力，Meta也开始疯狂买。”**
>
> **“现在对很多人来说，已经不可能买到算力了。”**

还有一个细节值得注意：这些算力主要用于训练，而不是用来服务用户（推理）。Patel说，Anthropic今天有4吉瓦，整个Claude Code只用其中约1吉瓦来服务，花在推理上的算力比训练“少得惊人”。这意味着，即便用户端的需求稳定下来，实验室训练新模型的预算仍会继续占用芯片。



卖开源模型推理太赚钱，租价被一路抬高

买家多了，价格会涨。Patel认为，推动租价的另一股力量是卖token（模型输出的计量单位）这门生意本身利润极高，使得愿意高价租GPU的人远不止两家实验室。

他给出的账是按每兆瓦算的。自建一个B300集群，把建设和五年运营摊下来，约合每年900万美元；向云厂商租，“能做到每年1400万美元就算你走运”。另一头，用这一兆瓦的算力去跑开源模型DeepSeek V4.1 Flash，在利用率60%的情况下，一年的收入约7000万美元。也就是说，哪怕租价高出自建成本五成，卖推理的收入仍是租金的五倍。（7000万美元是收入，未扣除人力和其他成本。）他说：

> **“即使你说利用率只有30%，你仍然会赚到离谱的钱。”**
>
> **“我认识的好几十个人，生意就是租一些GPU然后卖推理，赚了很多钱。”**

这个测算基于SemiAnalysis开源的InferenceX基准，用的是任何人都能下载的容器，只用了vLLM和SGLang两套开源推理软件，团队“只有四个工程师”，没有做投机解码等进一步优化。

价格数据与这套逻辑吻合。**Patel说，去年10月是低谷，H100约1.70美元，最低能找到1.45美元；现在成交价在2.40至3.20美元之间，中间值2.80美元：**

> **“两年前你要是签这个价，会被当成疯子，现在人们急着在这个区间签约。”**

SemiAnalysis自己的一年期合约指数，今年3月已经是2.35美元，10月Nebius等厂商的挂牌价也在继续上调。需要读者留意的是，Patel称SemiAnalysis自己也做算力撮合，所以掌握真实成交价，这同时也是一个利益相关的立场。

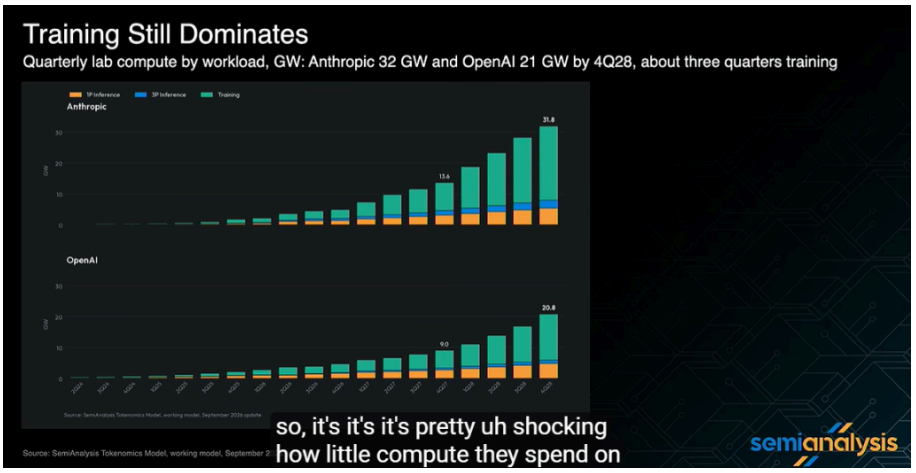
他对下一步的判断是：

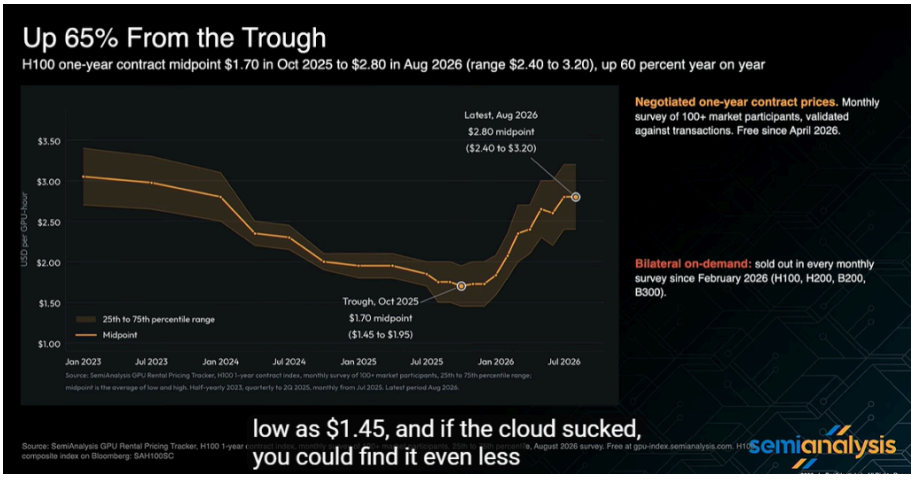
> “如果H100涨到3美元以上、B300涨到7美元以上，我不会感到意外。”

对买方，他的建议更直接：

> **“如果你能找到6美元一小时的B300，就应该签下来，然后去卖token。这个价格很离谱，但这是正确的决定。”**

障碍在于，云厂商都要求预付，创业公司更难：一年期的合约很难买到，而创业公司往往说不准自己一年后还在不在。至于闭源模型，他说Anthropic服务Fable和Opus 5.5的收入“超过1亿美元”，来自其IPO过程中披露给投资者的材料，实录没有说明单位，按上下文应是每兆瓦的年收入。





就算租得起，云厂商未必交付得了

租到算力只是第一步，集群好不好用才决定实际价值。SemiAnalysis做了一个叫ClusterMAX的评测，追踪了323家云供应商，评测了其中77家，给19家授予了奖牌（肯定）。

在Patel看来，最好的是CoreWeave和Nebius，但两家的可得性都很差：

> **“它们未来六个月不会再卖算力给你了，已经售罄。Nebius会让你预付整整一年，或者六个月，价格高得离谱，但这是从他们那里拿到算力的唯一办法。”**

Oracle和Google也被评为很好，其中Google从首轮的铜牌一路升级。下调的则更多：随着评测标准加严，Azure降为银牌，Together和AWS降为铜牌，Crusoe也被下调。AWS的问题偏体验：

> “要拿到一个集群，你得和大概十个人打交道，而且耗时极长，网络也有点难搞。”

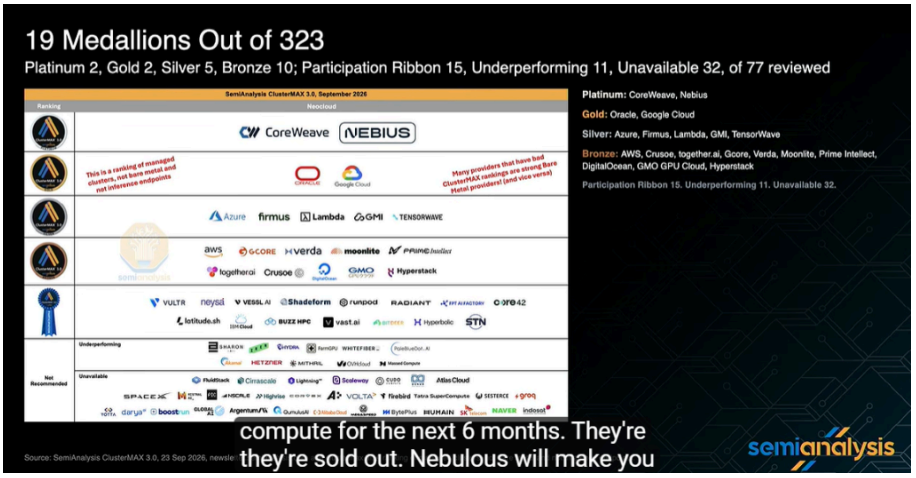
评测里最刺眼的是安全。SemiAnalysis让AI模型去攻击这些云：

> “有些漏洞是互联网上早已公开的，模型能直接找到并利用，然后访问其他客户的存储。”

其中一次，他们用一个“落后于OpenAI和Anthropic”的开源模型，拿到了整个集群的Slurm（常用的集群调度系统）权限，看到某国国防工业和国家安全情报机构的作业名称。他们随即停止测试，并发表了《大多数Neocloud在安全上很烂》。另一项测试是向GPU注入故障（他提到的Nvidia错误码XID 719），观察云厂商多久发现。结果是：

> “很多云要等到你提醒了才会发现，有些即便你提醒了，也要几天才响应。”

他把这称为最低限度的测试：GPU必然会出问题，云厂商应当靠自己的监控发现并修复。

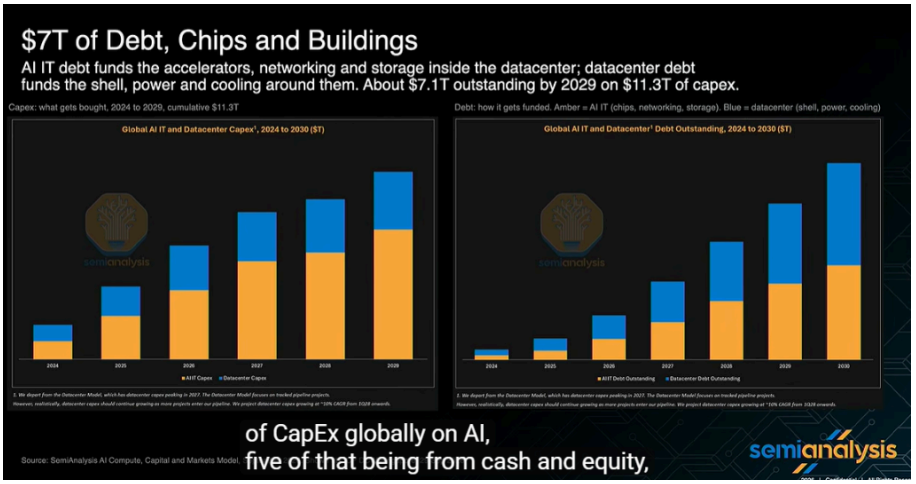


利率上行，新玩家借不到钱，英伟达托底也只是一小块

增加供给需要资本，而资本的价格正在上升。Patel重申，到2029年底全球AI资本开支约11万亿美元，其中约7万亿来自债务。大部分钱花在芯片上，其余是数据中心、能源，以及为了更快投产而在现场自建的电厂。

在这样的利率环境下，贷款流向呈现出明显的偏向。10年期美债收益率今年从3.96%升到10月初的5.31%，AI相关债务发行9月明显降温。Patel描述了一家有100兆瓦规模的Neocloud想扩到1吉瓦时的处境：

> “谁会借钱给他们？唯一的办法是把那一吉瓦卖给超大规模云厂商，再由超大规模云厂商去债市融资，你拿到了贷款，但这些算力没有一点能进入面向整个行业的市场。”



结果是，明年已签约的算力里，“大约65%到70%”流向超大规模云厂商和AI实验室。对创业公司来说，租集群要先付一半，三到九个月后才能交付：

> **“去找任何一家最近融到大钱的新实验室，对它们来说拿算力就是地狱。”**

英伟达的做法是给集群托底，Patel归纳为三类：

- **SoftBank Energy：** 只担保土地、电力和厂房。这是俄亥俄州一座9吉瓦的设施，约2030年投运，全部预留给OpenAI。

- **Firmus：** 英伟达承诺按某价格租下集群，使对方“不赚钱但也不亏钱”，但有了这份保证，别人就愿意放贷。超出该价格的每一美元每小时，英伟达拿走一半，Patel说“很聪明，我喜欢”。

- **残值担保：** 他只提到有这一类，没有展开。

规模上，英伟达已托底约6.5吉瓦，这部分会卖给开放市场而非只供实验室和超大规模云厂商。他给出的上限是45吉瓦，“即便如此也只占2030年前新增算力的很小一部分”。他由此认为，Fireworks、Modal等做推理的公司，以及不少新实验室，正转向自建集群，拿贷款、找英伟达背书。

演讲最后，他给出的判断是token的规模：几家提供商加起来每天处理超过100万亿token，各家年化收入都在攀升。他的结语是：

> **“希望他们能拿到算力，否则我们都是Anthropic和OpenAI的奴隶。”**



风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

145 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论