

摘要：

MoE架构将推理拆解为预填充、中间填充、解码注意力与解码专家四个阶段，各阶段硬件需求截然不同。SemiAnalysis认为内存带宽比内存容量更值钱，堆容量不如提速度。聚合式与分离式架构之争本质是“全能芯片”能否实现的赌注。调度层成为隐形价值洼地，KV缓存分级存储管理将催生新兴存储赛道机会。

当你向AI提问并收到回复，这个看似瞬间完成的交互背后，是一套横跨计算、存储、内存与网络调度的复杂工业体系。

9月22日，研究机构SemiAnalysis发布深度技术报告，系统拆解了大模型推理服务的底层架构。从用户发出请求到AI生成每一个token，每个环节如何运作、哪里是瓶颈、什么样的硬件在什么阶段真正创造价值。

报告指出，推理服务并非一个整体，而是由**预填充（Prefill）**、**中间填充（Midfill）**、**解码注意力（Decode Attention）**和**解码专家（Decode Experts）**四个工作阶段构成的“Token工厂”。

这一分析框架对于理解AI基础设施竞争的核心逻辑具有重要参考价值。每个阶段对算力、内存带宽和网络的需求截然不同，混同处理将损失混合专家（MoE）模型架构的结构性优势。

报告以英伟达Blackwell系列GPU为案例进行推演，其结论对硬件设计者、云服务商和模型部署方均具有直接指导意义。

"专家工厂"的诞生：MoE改变了什么

过去，我们讨论大模型，习惯用参数量说话——千亿、万亿，数字越大越震撼。但MoE的出现，让这种比较方式变得苍白。它真正改变的，不再是参数的总量，关键是哪些参数在哪个时刻被激活。

具体来说：每次处理一个词元Token（可以简单理解为一个词或一个字），MoE模型不会让全部参数都参与计算。它有一个“路由器”，会为每个Token精准定位出少数几个最合适的“专家模块”，让这些专家各司其职，处理完再把结果汇总。

这就好比一家超级医院，每个病人进门不是被所有科室的医生轮流问诊，而是智能分诊系统直接把他送到最对口的两三位专科医生面前。

这个机制带来了一系列连锁反应：

- 哪些数据必须“住”在离计算最近的地方，发生了根本变化；
- 内存、带宽、存储的价值权重，被彻底重新排列；
- 调度系统的复杂度，从线性增长变成了指数级跃迁。

换句话说，MoE让整个推理系统变成了一座需要精密协调的“智能工厂”。

推理服务是一座分工明确的流水线工厂


SemiAnalysis报告指出，AI推理服务是一个由多个专用工作节点池构成的循环系统，而非运行在单一服务器上的程序。

用户或其代理发出请求后，**调度层**（如英伟达Dynamo或Mooncake）将其放入队列，分配给输入**填充工作节点**处理。该节点负责将用户输入连同历史对话状态转化为新的上下文，再交由**解码工作节点**反复读取已积累的状态、逐步生成回答token。

在智能体（Agent）场景下，这一流程还会与工具调用、外部搜索等环节交织，形成每小时可达数千次的对话轮次。

Overview of a disaggregated inference service

Four resource pools joined by shared state; orchestration spans the whole factory




（推理服务中模型阶段的概述）

每一轮对话产生的“记忆”，在系统内部以一种叫做KV状态的形式存储。这些状态被设计成不可变的数据块（blob），像区块链账本上的记录一样，一旦生成便不再修改，只会不断追加。

Pre/Midfill and decode are separated at the KV-cache boundary

Decode contains two closely cooperating phases that repeat for every layer and generated token



（预填充和中间填充与 KV 缓存边界处紧密耦合的解码环路分离）

为什么要这样设计？因为AI对话天然是因果推进的——后一句话的理解，依赖于前面所有内容的积累。不可变结构，完美契合了这种单向流动的特性。


更炫技的是这套存储的层级设计：

- 最高频调用的实时数据（当前正在计算的上下文）住在GPU的HBM（高带宽内存）里，这里是寸土寸金的“黄金地段”；
- 次高频的中间态数据（刚完成的对话轮次）被迅速转移到CPU的DRAM，进行中转暂存；

- 低频沉淀的历史数据则被推入SSD或网络存储池，等待被召唤。

KV blobs moving through storage and worker memory

Immutable blobs move over the scale-out network; CPU DRAM is especially useful for outgoing staging



(KV 数据块在存储和工作内存中移动)

这套动态分级，让昂贵的HBM永远只服务于“正在赚钱的数据”，而不是白白浪费在存档上。

报告引用SemiAnalysis AgentX数据集的真实追踪数据显示，智能体对话过程中上下文的增长速度极快，但也会因压缩等模型行为产生大幅波动。边界模型供应商的领先AI公司被观察到正在反复压缩上下文以维持在百万Token限制之内。

在成本结构上，报告明确指出，HBM比DDR内存贵出数倍且供应受限，频繁复用的通用数据块（如系统提示）应保留在共享CPU内存或近端缓存设备中，而非占用昂贵的HBM资源。


四个工作阶段，对硬件的需求天差地别

SemiAnalysis报告最核心的贡献之一，是将推理过程细分为四个截然不同的计算区间，并指出将它们作为同一工作负载处理会造成严重的效率损失。

预填充（Prefill） 对应用户首次发起请求的场景，模型需要处理一整批新token。由于大量token共享权重加载，矩阵运算效率高，算术强度高，通常受计算能力约束，而非内存带宽。

Flow through an MoE pre/midfill layer

One layer: cached context plus a block of new tokens; K/V for the new block is appended during attention




(通过 MoE 预填充层的流程)

中间填充（Midfill） 在智能体工作流中日益重要。它在已有的长缓存前缀基础上追加少量新token——前缀可能已达数十万token，而新输入仅有数百至数千token。这一阶段兼具解码阶段

的大规模KV状态读取和预填充阶段的权重复用特性，算术强度可达单token解码的数百倍，但缓存状态的流量也远超同等规模的初始预填充。

Midfill combines a long cached prefix with a short new suffix

It has the context read of decode, but enough new tokens to batch expert work like prefill




(Midfill 将解码的缓存状态读取与足够的新标记相结合，以批量处理模型和专家工作)

解码注意力是生成回答token的核心环节，每次前向传播仅处理一个或少数几个token。随着上下文长度增长，注意力读取的数据量甚至可以超过模型权重本身的大小——在长上下文场景下，注意力是现代解码过程中最重的内存操作之一，尽管大多数模型参数实际上位于专家层。

Flow through one MoE decode layer

The activation advances to attention in the next layer; that next attention step appends its own K/V



(通过一个 MoE 解码层的流程)

解码专家 (Decode Experts) 是MoE架构特有的环节。路由器根据当前token的激活值，从庞大的专家库中选取少数几个专家执行计算。专家权重不携带任何查询历史，仅依赖当前激活，这使其可以在更广泛的GPU范围内分布部署。

这四道工序的神奇之处在于：它们对硬件的需求截然不同。

预填充是计算密集型的，中间填充是计算与内存的双重考验，而解码则几乎完全被内存带宽所主宰。把它们混为一谈，就像让短跑运动员和马拉松选手用同一套训练方案，必然是一场浪费。

内存带宽比内存容量更值钱


报告专门辟节讨论内存带宽与内存容量的经济权衡，得出一个对硬件设计和采购决策具有反直觉意义的结论：**在许多推理场景下，带宽比容量更能创造收益。**

数据在被处理时创造收益，在内存中闲置时只产生成本。一块内存吞吐极高的加速器，即便容量较小，其生成token的速率也可能超过低带宽高容量配置。

在达到“够用”的容量门槛之前，每增加一份内存都能显著提升收益；越过这个门槛后，曲线逐渐走平，继续堆容量的边际效益越来越低，最终可能变成一种浪费。

Revenue generated per machine versus local fast-memory capacity

Capacity matters until the working set fits safely; offload to LPDDR for better margins on the rest



18

（每台机器的收入与本地快速内存容量的关系）

报告给出了一个2027年的实用设计基准：以每token约70KB的KV状态、200万token的聚合活跃上下文计算，单个流水线阶段的KV状态需求约为140GB，加入双缓冲后接近280GB；再叠加模型权重、激活值、路由表和运行余量，单阶段约需400至500GB的本地快速内存。

这一基准同时说明，加速器HBM（高带宽内存）的最优用途是承载当前正在赚取收益的活跃批次数据。已完成处理的KV数据块应及时迁移至CPU DRAM，再转入更廉价的网络附加存储。将昂贵的HBM用于存储闲置上下文，是对稀缺资源的低效使用。

调度稳定性决定工厂级吞吐效率

即便硬件配置完善，推理服务的实际效率在很大程度上取决于调度层的设计质量。报告特别警告了一种在大规模推理集群中容易出现的系统性风险：**延迟反馈震荡（retirement-gated oscillation）**

首先要承认一个现实，预填充和中间填充是可预测的，只要知道输入长度和缓存大小，处理时间就能被精确估算。但解码是随机的，没有人知道模型什么时候会输出终止符号，一个回答可能3句话结束，也可能写出一篇论文。


这种不对称，给调度系统带来了巨大挑战。如果解码速度变慢（比如某个超长回答还没写完），后续的Prefill请求就会积压，整个流水线开始拥堵。

更糟糕的是，一旦出现延迟，系统可能过度补偿，突然放入大量新任务，导致新一轮拥堵。这是经典的延迟反馈震荡，就像交通信号灯控制失当时的道路潮汐现象。

工程师们的解法充满智慧：

- 。在各个阶段之间设置“就绪缓冲区”，让预填充完成的结果先在缓冲区等待，而不是直接堵在解码入口；

- 平滑化入场控制，不根据单次请求的完成情况来决定下一批任务的数量，而是观察整体积压趋势；
- 分层控制时间尺度：微秒级的硬件调度、毫秒级的Token流控制、秒级的缓冲管理、分钟级的工作节点重配置。绝对不能让慢变量去追快噪声。



(从延迟反馈震荡到稳定流动)

值得注意的是，高交互性和高利用率并不天然矛盾。只要调度系统足够聪明，完全可以在保持每个用户低延迟体验的同时，让机器整体保持高负荷运转。

关键在于，调度器要有足够的“视野”和足够快的“反应速度”。

聚合还是分离：一场没有标准答案的辩论

在推理系统的架构设计上，目前存在两种主流哲学的激烈交锋。

分离式（Disaggregated）架构主张让不同类型的工作节点各司其职：专门为Prefill优化的机器，专门为Decode优化的机器，各自配置最适合自己的工作模式的硬件。

Prefill机器可以更注重算力，Decode机器可以更注重内存带宽。任务来了，调度器决定送到哪台机器，完成后搬走KV缓存，交接给下一台。

聚合式（Aggregated）架构则主张一次对话的整个处理过程，尽量在同一台机器上完成。好处是显而易见的，不需要在不同机器之间搬运动辄几十GB的KV缓存，没有网络传输的延迟和开销，专家层可以天然共享，调度器的决策也简单得多。

聚合式的软肋同样明显，一台机器需要同时擅长高强度计算（服务Prefill）和高带宽内存访问（服务Decode），而这两种能力在硬件设计上往往存在取舍。

如果一台机器在其中某方面有短板，它就会在对应的工作模式下“跑不满”，白白浪费算力。


这场辩论的结论，取决于你能否造出那块“全能明星芯片”。如果未来某款加速器能同时拥有极高的计算密度和极高的内存带宽，聚合式架构将获得压倒性优势。否则，分离式架构仍然是在现有硬件条件下最务实的选择。

实例分析：预测 Kimi K3 在 Blackwell 系统上的性能

报告通过SemiAnalysis推理模拟器，对Kimi K3模型在B200、B300与GB200系统上采用16至64块GPU的不同配置进行了性能投影，覆盖交互延迟、吞吐量、能耗与内存占用四个维度。需要说明的是，这些均为工作负载与硬件的模拟预测，并非实测基准数据。




在解码阶段，GB200在延迟-吞吐权衡曲线的大部分区间表现领先，B200和B300亦提供具竞争力的配置点。最低延迟配置通常结合流水线与张量并行；而吞吐量导向的配置则倾向于每GPU单个注意力实例，不采用张量或流水线并行，同时保持尽可能宽的专家并行度。



（解码、中间填充和预填充的预计交互性和吞吐量边界。来源：SemiAnalysis 推理模拟器）

在中间填充阶段（127k缓存输入Token加1k新Token追加），GB200凭借NVL72架构将扩展带宽延伸至整个机架，在低首Token延迟区间领先；B300在吞吐量导向端追平差距。B200与B300通常采用PP=4配置，将专家全对全通信限制在节点内部的NVLink网络。


内存占用方面，投影结果显示大多数前沿配置的每GPU HBM峰值驻留量维持在80GB以下，支持了报告的核心论点：相较于最大化每块加速器的HBM容量，带宽管理与存储编排往往具有更高的经济价值。



（模拟边界上每个 GPU 的 HBM 峰值驻留时间预测。来源：SemiAnalysis 推理模拟器）

能耗分析方面，解码阶段因每个查询需约1000次模型前向传播而成为最大能耗来源；中间填充阶段因仅需对现有长上下文追加短序列，反而是能耗最低的模式。





（相同解码、中间填充和预填充边界下每次查询的预计能量。来源：SemiAnalysis 推理模拟器）

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

87 收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论

