

摘要：

Kimi K3的线性注意力虽引发对硬件需求的短期担忧，但SemiAnalysis指出，其超2.8万亿参数与大模型推理架构，反将加剧对高端GPU、HBM及高速互联的需求。专家并行设计推高芯片间通信压力，而线性注意力带来的成本下降，或借杰文斯悖论（效率提升刺激应用扩张）推动AI规模化落地，长期支撑基础设施持续增长。

月之暗面旗下大模型Kimi K3采用线性注意力机制，引发市场对英伟达、HBM以及网络设备需求可能受到削弱的担忧。

不过，半导体研究机构SemiAnalysis近日给出了截然不同的判断：**K3庞大的参数规模和推理架构需求，不仅不会削弱高端AI硬件需求，反而可能进一步强化对英伟达高端GPU、HBM以及高速互联设备的需求。**

SemiAnalysis指出，K3参数规模超过2.8万亿，模型权重容量超过1.5TB HBM。即便在相对有限的用户并发场景下，KV缓存仍需要大量卸载至CPU DDR5内存及NVMe存储，HBM空间并不会出现明显富余。

更重要的是，月之暗面此前透露，K3的高效推理部署需要至少64颗芯片组成的大规模扩展域架构。这一硬件需求与英伟达GB200/GB300 NVL72等机架级AI系统的设计方向高度匹配。

SemiAnalysis认为，市场此前将线性注意力理解为“削弱GPU需求”的逻辑存在偏差。真正的影响可能恰恰相反：**更高效的模型架构降低了AI推理成本，将推动更多应用落地，进而刺激GPU、HBM、DRAM以及网络基础设施的长期需求。**

with MXFP8 activations for broad hardware compatibility. To prevent expert imbalance from degrading throughput at large expert-parallel scales, we introduce a fully balanced expert-parallel training method with static shapes and no host synchronization on the critical path. Since inference efficiency likewise benefits from larger high-bandwidth communication domains, we recommend deploying Kimi K3 on supernode configurations with 64 or more accelerators. Finally, as KDA poses new challenges for conventional prefix caching, we have contributed a corresponding implementation to the vLLM community, to be released alongside the model. KDA with prefill cache allows us to serve Kimi K3 at a highly competitive token price despite its scale and long context.

无惧线性注意力迭代，英伟达芯片需求依旧坚挺

市场担忧主要来自Kimi K3采用的Kimi Delta Attention（KDA）机制。


相比传统Transformer注意力机制，KDA能够显著降低KV缓存的数据传输需求，最高可减少约10倍的网络带宽压力。这一变化令部分投资者联想到DeepSeek R1发布后市场对AI硬件需求的担忧，认为模型效率提升可能降低对高端算力硬件的依赖。

但SemiAnalysis认为，这一判断忽视了大模型推理中的另一项核心需求——参数规模带来的计算和互联压力。

K3拥有超过2.8万亿参数，其模型权重本身就需要依赖大规模分布式计算系统完成部署。与此同时，K3采用WideEP（Wide Expert Parallelism）优化策略，将896个专家模块分布到多颗GPU上，使单颗GPU仅需承载部分专家权重，从而提升计算利用率。

不过，WideEP也带来了新的挑战：专家之间频繁的数据交换需要更强大的网络互联能力。SemiAnalysis指出，GB200/GB300 NVL72采用的铜背板互联架构，提供的机架内带宽达到传统DGX B200系统的18倍，非常适合这类大规模专家并行推理任务。

换言之，KDA节省的KV缓存通信需求，可能被WideEP带来的权重交换需求部分抵消，整体AI基础设施压力并未明显下降。



64颗芯片扩展域并非英伟达独家受益

不过，市场对此也存在不同声音。知情人士GDP (@bookwormengr) 指出，月之暗面提到的“64颗芯片扩展域”并不一定意味着英伟达NVL72方案。华为昇腾950 SuperPod同样采用64颗芯片配置，并具备类似NVLink的统一总线（UB）内存扩展能力。

从架构能力看，昇腾950 SuperPod可支持跨16个机架扩展至1024颗NPU，在满足大规模模型推理需求方面同样具备竞争力。因此，K3带来的硬件需求增长，并不意味着英伟达将成为唯一受益者，但其对于高端AI互联系统的需求强化趋势仍然明确。



Moonshot 所指的 64 芯片扩展域未必是 NVL72，华为 Ascend 950 Superpod 机架正好是 64 个芯片（扩展域等效方案——可以使用类似 NVLink 的 UB 内存——可以扩展到 16 个机架，共 1024 个 NPU）。即使只有一个机架，使用 Ascend 950DT，总共也需要 9264 GB 的 HBRAM（每个 NPU 144 GB，共 64 个芯片），总内存带宽为 256 TB/s（64 个芯片，每个 NPU 4 TB/s），足以满足 K3 的需求。我坚信 Jevon 悖论，但如果不承认 KDA 在长时间上下文状态存储方面节省了大量空间（CSA、DeepSeek 的 HCA 也是如此），那就太虚伪了；因为即使模型很大，它也大多是 4 位的，而且非常稀疏。关键在于，那些运行着全球最多推理任务的公司，例如 OAI、Anthropic 和 GDM，是否拥有这类注意力架构。很难相信他们没有。但以防万一，如果他们没有，而他们采用了这类技术，这将显著减轻上下文记忆的压力。

上午 9:22 · 2026年7月18日 · 835 浏览量

杰文斯悖论：AI效率提升可能推动硬件需求增长

SemiAnalysis进一步援引杰文斯悖论（Jevons' Paradox）解释AI基础设施趋势。

该理论认为，当某项技术提升资源利用效率、降低单位成本后，需求往往不会下降，反而可能因应用范围扩大而增长。应用到AI领域，线性注意力机制降低推理成本后，可能推动更多企业部署AI应用，使全球AI推理规模进一步扩大，最终带动GPU、HBM、DRAM以及高速网络设备需求增长。

不过，GDP对此保持谨慎态度。他认可杰文斯悖论的长期逻辑，但指出，KDA对于长上下文任务中的状态存储优化具有现实意义。即使模型权重规模巨大，由于采用4bit量化以及高度稀疏化设计，实际内存压力可能低于市场直觉。

他认为，真正值得关注的变量在于全球推理需求最大的AI公司——OpenAI、Anthropic以及Google DeepMind——是否已经或未来会采用类似KDA、DeepSeek CSA/HCA等线性注意力方案。如果头部AI公司大规模采用此类架构，长上下文推理对内存和互联资源的需求可能出现明显下降，这将成为影响未来AI硬件需求结构的重要因素。

市场关注点转向：AI需求增长能否抵消架构效率提升

总体来看，Kimi K3的出现并未简单指向AI硬件需求下降。对于英伟达而言，真正的竞争焦点可能从“单卡性能”转向“系统级能力”——包括高速互联、机架级扩展以及大规模推理优化。

随着模型规模持续扩大，即使注意力机制不断优化，AI基础设施仍面临参数规模、专家并行、数据交换以及推理吞吐提升带来的压力。

未来市场需要关注的核心问题，不是线性注意力是否降低单项资源消耗，而是AI应用规模扩张带来的新增需求，能否持续超过架构效率提升带来的资源节省。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

374 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

7 条评论

路人 VIP会员
3分钟前 荷兰
K3太贵了，用不起
0 回复

MobileUser7493
1小时前 中国广东省
上次就是你唱空科技的
2 回复

hăppy eueyqăy
1小时前 中国广东省
我谢谢你，不然周一完蛋了
1 回复

momo 27分钟前 中国湖北省
回复 hăppy eueyqăy:
抖音上有人试用过Kimi，虽然好用，但是速度很慢
0 回复

路人 VIP会员 2分钟前 荷兰
回复 momo:
非常贵
0 回复

晴朗.
1小时前 中国辽宁省
搞笑，谁不知道现在去就是接盘
1 回复

gramme
1小时前 中国



现在又来说这话😏

👍 1 ↩ 回复

