摘要：

蚂蚁灵波开源触觉预训练基础模型LingBot-Touch，通过"统一坐标+分入口+共享主干+特征空间预测"架构，将磁触觉、视触觉、压阻式触觉三类传感器信号统一编码为触觉Token。实测显示，接入后机器人成功率平均提升20+百分点，且对从未出现在训练数据中的新传感器同样有效。代码与权重已全部开源。

太反差了。

明明给**机器人**装上了**触觉**，它咋就变得更笨了呢……



△图片由AI生成

事情是这样的。

最近有个团队做了个实验，他们在**Sharpa Wave灵巧手**的五个手指上都装上了触觉传感器，任务是**让它把一个袋子的拉链拉上**。

他们选用的动作模型是**π0.5**，在只靠摄像头的情况下，成功率来到了**39%**。

然后团队再把指尖传感器的读数原封不动地喂给它，按理来说，机器人多了一种感官，应当是拉拉链会更得心应手一些。

但您猜怎么着。

AUV（哎呦喂）……成功率直接**掉到了15%！**

而且这还不是个例。

同样是Sharpa Wave灵巧手和π0.5这个组合，接上原始触觉后去做**交接盒子**的任务，成功率从57%掉到48%。

即便是把灵巧手换成XHand，6项任务平均下来，成功率也从49.71%降到了48%。

那么机器人多了一种感官，反倒变得笨手笨脚的原因到底是什么？

答案是，问题出在了**读数**这件事儿上。

因为触觉数据和其它数据还不太一样，机器人的手指大部分时间是不接触物体的，所以读数差不多就是一大片“0”；即使开始接触物体，信号也是稀疏且带噪声的那种。

加之不同的传感器还各司其职，**视触觉**负责拍指尖软胶的形变，**磁触觉**负责测磁场，**压阻式触觉**负责记电阻……数据，不尽相同。



△三类触觉传感器怎么感知接触，各有什么取舍

例如对于**捏住一个瓶盖**这个任务来说，三种传感器能给出的是三种完全不一样的数字，动作模型**看不懂**不说，还得硬用……可以说在**帮倒忙**了。

那此局又该怎么破呢？

蚂蚁灵波给出了一种解法——在传感器和动作模型中间**加一个“翻译”**。

（注：上面的实验便是蚂蚁灵波做的。）

简单来说，就是先把各种传感器读到的数据，翻译成动作模型能看懂的那种，例如手指碰在哪儿、用了多大劲、力往哪边偏、有没有打滑，然后再交给它。

还是那个π0.5，还是那个拉拉链的任务，如此操作下来，成功率便直接飙升到了**59%**，甚至比完全不用触觉还高20个百分点；交接盒子这个任务的成功率，也从48%回到了63%。

而这个“翻译”，便是蚂蚁灵波今天**最新开源**的触觉预训练基础模型**LingBot-Touch**。

在它的加持之下，刚才我们提到的拧瓶盖的动作，就变得非常丝滑了：

要知道，拧瓶盖很容易翻车的地方，恰恰在指腹和瓶盖贴在一起的那一小块：捏得稍微松一点，指腹就会在盖面上打滑，手腕转了半圈，盖子却纹丝不动。而这一幕，正是摄像头看不清的。

那么，LingBot-Touch这个“翻译”，究竟是怎么做到的？

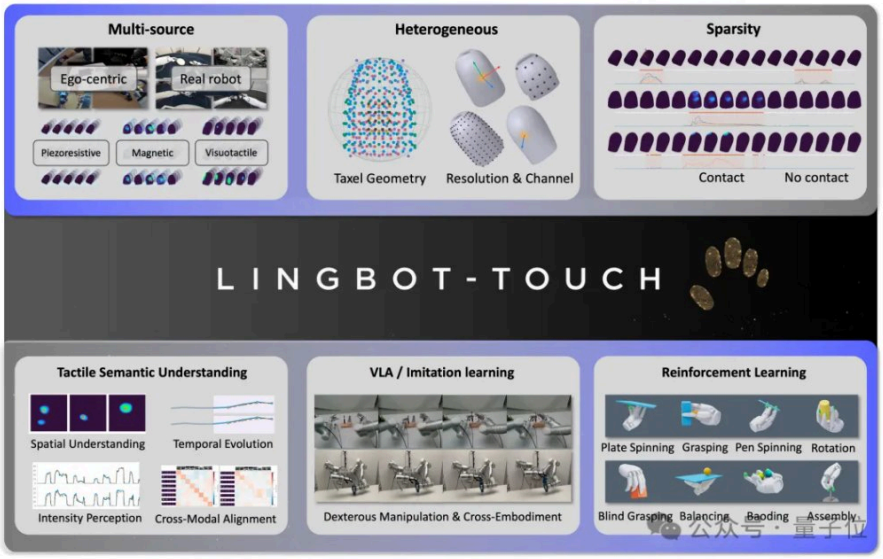
灵巧手需要一个翻译

我们先来把LingBot-Touch干的活儿给讲清楚。

简单来说，它负责接收磁触觉、视触觉、压阻式触觉这三类传感器的信号，再把它们**统一编码成一种触觉Token**，从中读出接触位置、受力大小，以及力的方向是怎么随时间变化的。

它的位置刚好卡在中间，往下能接上不同的传感器和灵巧手，往上则把这些Token交给不同的动作模型。

如此一来，不管各家传感器的信号如何五花八门，到了动作模型这里，都能被统一理解，可谓殊途同归。



△LingBot-Touch连接多种触觉传感器与真实灵巧操作

而且LingBot-Touch的轻量版**LingBot-Touch-Tiny**只有约**532万参数**，目前技术报告、代码和模型权重也都已经开源。

那么，LingBot-Touch又是怎么练成的呢？

整体来看，蚂蚁灵波团队主要分了三步走。

第一步是统一坐标。

团队遇到的第一个难题，是不同传感器的触点数量和排布差别实在太大。比如有的灵巧手光是拇指上就铺了116个触点，有的布料手套却只有一个3×3的小阵列。

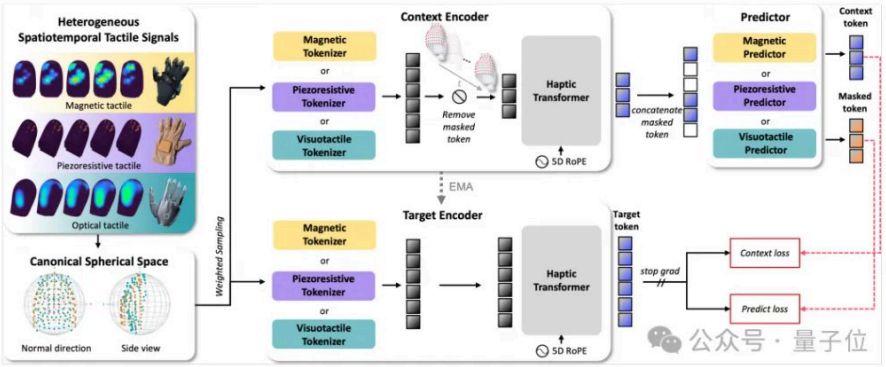
如果按编号硬对，那肯定是对不上的。

为此，团队先把所有传感器的触点都映射到同一个标准化的指尖空间里，再给每个Token发一个“地址”，这个地址由时间、手指和三维位置共同组成。

地址会通过旋转位置编码（RoPE）进入模型。这样一来，模型就不再要求固定的触点数量，即便换一种布局，也照样能读。

在此基础上，三类传感器各自有一个轻量的入口，负责把原始读数转成Token；入口后面，则共用同一个触觉Transformer主干。

也就是说，传感器之间的差异交给各自的入口去消化，接触本身的规律，则放到主干里一起学。



△LingBot-Touch整体架构，三类传感器分入口、共用一个主干

第二步是在特征空间里做预测。

坐标统一之后，团队又碰上了第二个坑，也就是开头我们提到的那一大片“0”。

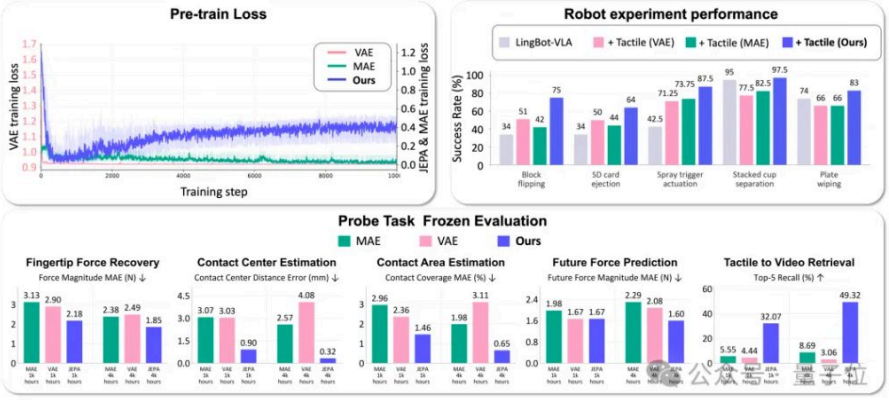
如果让模型去还原原始读数，它很快就会找到一条捷径，只要把“没碰到”的背景学好，损失就能降得很低。可这样一来，分数虽然好看，真正有用的接触信息却没学到多少。

所以LingBot-Touch选择了**JEPA路线**。

具体来说，训练时模型会随机遮住**90%**的触点，而且整段时间都遮着；然后，模型要根据剩下10%的变化，在特征空间里预测被遮住部分的表征，无需逐点还原读数。

如此操作之下，效果可谓是立竿见影，同样用1000小时数据训练，LingBot-Touch判断接触中心的误差是0.90毫米，而VAE和MAE都在3毫米以上。

再比如，用一段触觉去找对应的视频画面，LingBot-Touch的前5召回率是32.07%，另外两种方法则都不到6%。

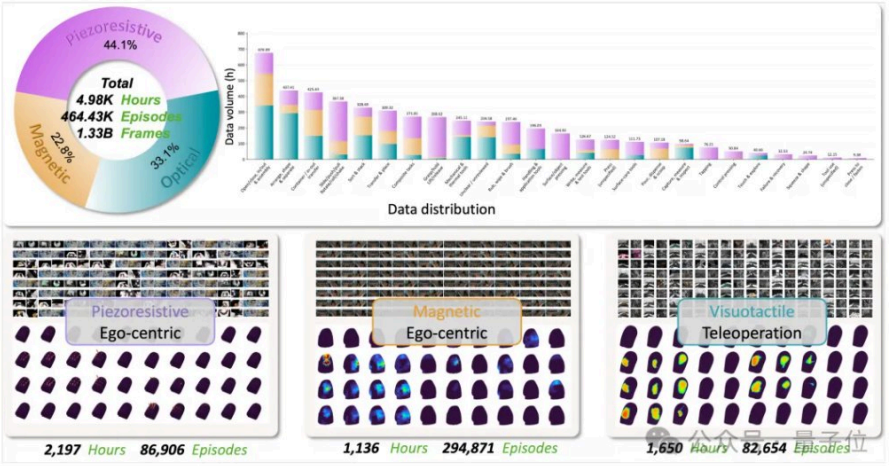


△同样的数据，特征空间预测与还原原始读数的效果对比

第三步是扩充数据，防止模型死记硬背。

LingBot-Touch的预训练数据一共有**4983小时**、约**13.3亿帧**。其中三分之二来自人戴着触觉手套干活，剩下三分之一来自遥操作Sharpa Wave双臂机器人。

之所以大量用手套，是因为它不需要机器人，一个人一天就能在普通环境里录上好几个小时。而且这些数据只标注了开、关、装配、倒水这类任务类别，没有一帧标过力的大小。



△预训练数据的构成，覆盖三类传感原理

不过，数据攒够了，团队还得防着模型“偷懒”。

因为预训练里只有三种传感器布局，模型很可能直接把这三套触点位置背下来，等碰到第四种布局就抓瞎了。

所以在训练时，团队会随机改变触点的采样密度，再把每个触点的位置小幅挪一挪，逼着模型去学接触本身的规律。

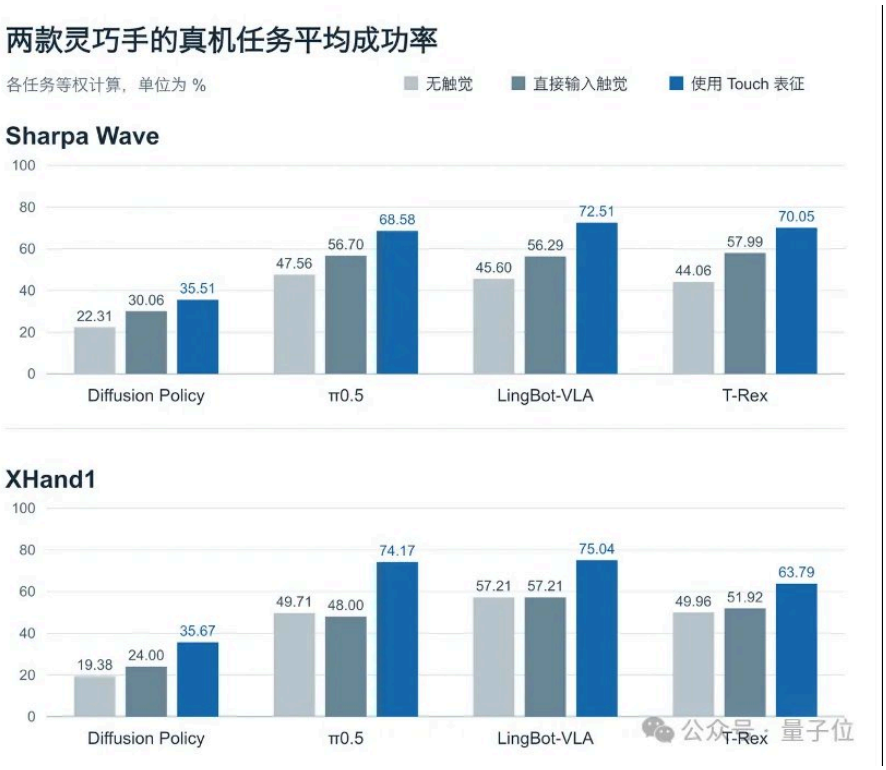
在这三步走完之后，就该上真机检验了。

测试覆盖了两款灵巧手，其中**高自由度**的Sharpa Wave做**20项**任务，**低自由度**的XHand做6项，一共**26项**。

参与测试的动作模型有四种，分别是Diffusion Policy、π0.5、LingBot-VLA和T-Rex。每种模型都要在不用触觉、直接喂原始信号、接入LingBot-Touch这三种设置下分别测试。

结果，在两款手上，四种模型都是接入LingBot-Touch的那一组平均成功率最高。

和不用触觉相比，T-Rex、π0.5、LingBot-VLA的成功率分别提升了23.18、21.81、24.81个百分点，而付出的代价，只是参数量多了0.13%到0.16%。



△两款灵巧手上，四种动作模型在三种设置下的平均成功率

就拿单手插吸管来说，这个任务的难点在于刺破封膜的那一下。吸管抵住透明封膜往下压，阻力越来越大，膜一破，手上会突然松掉。

摄像头很难分清膜是被压凹了还是已经被扎穿，但指尖可以。要是收力慢上一步，吸管就会直接冲到杯底。

当然，最能说明问题的，还得是XHand这组实验。

XHand用的磁触觉传感器，型号从来没出现在预训练数据里；而且预训练中的磁触觉数据，全部来自人戴的手套。接入XHand时，LingBot-Touch更是一个参数都没改。

即便如此，π0.5在6项任务上的平均成功率，还是从直接喂原始信号时的48.00%升到了74.17%。

其中分离叠杯这一项，成功率更是从32.5%翻了一倍多，达到了72.5%。

这个任务要求灵巧手只取走最上面的那一个杯子，它得用一只手扶住整摞杯子，另一只手捏着杯沿往外抽。如果阻力突然变小、指腹还稳稳贴着杯沿，说明杯子已经松脱，得马上收力；如果是指腹自己在杯沿上打滑，那就该重新抓。

这两种情况，手感截然不同。

换句话说，人手攒下的经验，帮机器人读懂了一只它从没摸过的手。

除此之外，团队还拿LingBot-Touch和此前的触觉基础模型FTP-1做了对比。

在Sharpa Wave上判断接触中心时，FTP-1的误差是2.19毫米，LingBot-Touch则是0.12毫米；在XHand上，误差也从5.89毫米降到了0.16毫米。

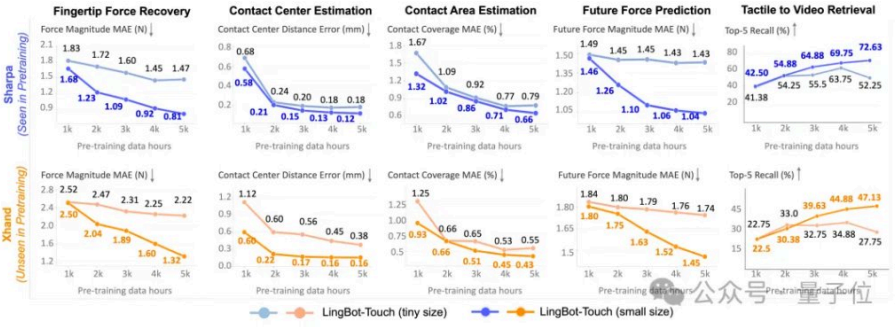
要知道，FTP-1在这两只手上还各自配了专门的适配器，而LingBot-Touch用的是同一个冻结的编码器。



△与FTP-1在两款灵巧手上的对比

另外，LingBot-Touch的**Scaling Law**也已经初步显现出来了。

Tiny版在4000小时左右开始饱和，换成容量更大的Small版，到5000小时效果还在往上涨；真机任务的成功率，同样随着预训练数据的增加而稳定提升。



△预训练数据量与模型规模对效果的影响

补齐了触觉的拼图

看完技术细节，我们再把LingBot-Touch放回蚂蚁灵波整条技术路线里，就能更清楚地看到它的位置。

在此之前，灵波的通用大脑已经铺开了三块能力，空间感知有LingBot-Vision和LingBot-Depth 2.0，环境交互有LingBot-Video和LingBot-World 2.0，灵巧操作则有LingBot-VLA 2.0和LingBot-VA 2.0。



可以看到，这几块能力大多在解决**碰到之前**的事，比如东西在哪、手该伸到哪、下一步该干什么。

不过一旦手指碰上物体，视觉能提供的信息就少了，比如指腹贴着瓶盖的地方会被手挡住，钥匙插进锁孔之后更是什么都看不见。

LingBot-Touch补上的，正是这一块。用一句话概括，就是**视觉管接触之前，触觉管接触之后。**

双手开锁就是一个典型的例子。

一只手握着挂锁，另一只手捏着钥匙对准锁孔，这一步主要靠眼睛；可钥匙往里一推，就有可能把锁顶歪，推到一半卡住了，还得退一点、换个角度再试。

等钥匙进了锁孔，摄像头基本就帮不上忙了，灵巧手只能靠钥匙传回指尖的阻力来判断。

看到这里，或许有小伙伴要问了，**灵波为什么要把触觉单独做成一个基础模型？**

原因在于，每只手的控制方式都不一样，但它们都得理解接触。

如果把“理解接触”这件事单独拎出来，做成可以复用的一层，那么一款硬件攒下的经验，就能成为下一款机器人的起点。

这个思路，其实和灵波之前做LingBot-VLA是一脉相承的。

VLA研究的是同一个大脑怎么驱动不同构型的机器人，也就是“一脑多机”；到了Touch这里，问题又往前推了一步，变成了不同的手、不同的传感器攒下的接触经验，能不能放在一起学，再用到新机器人身上。

而前面XHand那组结果，算是给出了一个初步的答案。

LingBot-Touch的几个设计选择，也正是从这个目标倒推出来的。用手套采数据，是因为手套不依赖机器人本体，数据规模才扩得上去；入口按传感原理设计、不按产品型号设计，是为了给以后的新传感器留出位置。

这也是灵波一直强调的**具身原生**，即从机器人在物理世界里怎么感知、怎么动手出发，来决定模型应该怎么设计、用什么数据训练。

目前，LingBot-Touch已经和LingBot-VLA、LingBot-Depth完成融合，用来提升通用大脑手眼协同、完成精细操作的能力。

在落地方面，灵波也正和乐聚、钛虎等本体伙伴，以及国大药房、隆盛等场景伙伴，在零售分拣、物流分拣和工业场景里开展商业化测试。

大模型越强，具身原生越不能缺席

聊完LingBot-Touch本身，我们再把视角拉远一点。

今年9月GPT-6 Astra发布之后，RoboDojo团队让它在零样本的条件下跑了42项仿真操作任务，结果它的综合得分在43个参评条目里排到了第一。

说实话，这件事让具身圈一度挺慌的。

但在同一份报告里，还有另一组数字。GPT-6 Astra在精度维度的成功率只有4%，而表现最好的公开策略是20.42%；插管、搭塔这类需要精确接触的任务，它几乎全军覆没，真机测试也因为安全问题被叫停。

报告把这个差距归结为缺少物理常识，也就是对接触、力和碰撞的理解。

而就在今天，Anthropic又发布了Claude Fable 5.2，大模型控制机器人的进度条又往前推了一步。

据Anthropic官方博客公布的内部测试结果，Fable 5.2在RoboDojo仿真测试中的平均成功率达到**64.9%**，是同一套测试框架下GPT-6 Astra（29.8%）的两倍还多，也超过了大多数专门为控制机器人打造的AI系统。

官方放出的演示里，由Fable 5.2控制的机器人还能解魔方、拧瓶盖、画画。不过，RoboDojo考的，是看着摄像头画面去控制一台仿真的双臂机器人。

从Fable 5.1到Fable 5.2，前后两个多月，同一套测试里的成功率就从27.6%涨到了64.9%。通用大模型理解任务、推理规划，乃至直接上手操作的本事，都在肉眼可见地变强。

但在我们看来，这并不意味着具身模型就该退到一边，只管“动手”。

仿真里的高分，和在真实世界里稳稳地把活干完，中间还隔着物理世界的泛化性。换一只手、换一种材质、换一个从没见过的场景，机器人还能不能干好？这个问题绕不过去，得由从物理世界里原生长出来的大脑自己去啃。

蚂蚁灵波CEO**朱兴**的判断也是如此。

他认为，GPT-6 Astra、Claude Fable 5.2这些数字世界大语言模型的进展，确实让机器人的复杂任务推理和物理操作能力更强，灵波也在积极吸收；但要真正跑通操作闭环，“物理操作泛化性这块硬骨头还是绕不开”，很大程度上仍要靠具身基础模型自身的突破。

在他看来，通用大模型和具身基础模型更接近**1+1>2**的关系，两者各自突破、相互促进，共同加速具身智能产业的成熟。

LingBot-Touch，就是灵波啃这块硬骨头的一次尝试。

触觉是一种物理世界原生的模态。互联网上有海量的文字、图片和视频，却几乎没有哪个网页记录过，拇指捏瓶盖时到底用了几牛的力。这类经验，只能在真实交互里一点点攒，而它恰恰是物理世界泛化性的根基之一。

例如灵巧手**摸麻将**，靠的就是这种经验。

二筒和三筒摸上去都是圆圈，想分清楚，得摸出一共有几个圆、各自排在哪儿，而这些线索全藏在指腹下浅浅的刻纹里。

过去，触觉一直是零零散散的，每家传感器一套数据、一套模型，换一只手就得从头再来。而LingBot-Touch证明了，触觉也可以有统一的表征。

如果再往前推一步，LingBot-Touch这套办法，即统一坐标、入口分开、主干共享、在特征空间里做预测，其实没有哪一环是只属于触觉的。

这套思路，也贯穿在蚂蚁灵波整条具身原生路线里。按照规划，灵波会持续探索物理操作泛化性的上限，打造跨构型的机器人行业通用大脑，推动视觉、深度、触觉乃至温度等更多物理模态在统一模型中对齐。至于机器人以后还会多出哪些感知方式，现在谁也说不准，但至少，已经有了一条可以参照的路。

这也正是蚂蚁灵波想做的事情，在硬件和场景之间做一层智能，把不同本体、不同传感器积累下来的物理经验，转化成可以共享的通用能力。

而且，蚂蚁灵波是以开源、可拆分的方式把这层能力给出去的，并且会在推进商业化的同时，持续向社区开源开放。

LingBot-Touch可以单独拿去用，接在π0.5、Diffusion Policy这些别家的动作模型上，一样有效；传感器厂商可以继续走自己的技术路线，整机厂也不用为了某个模型去换传感器。

奥迪今年初披露过一个数字，全行业线束生产与装配的自动化比例，还不到10%。这类边接触、边调整的活儿，正是灵巧手迟迟接不住的地方。

再看国内，中国的灵巧手和触觉传感器种类很多，过去这是数据互不相通的麻烦；可一旦经验能够共享，这份多样性反倒会变成数据上的优势。

总而言之，**机器人手上有了信号，也未必会用。**

正如朱兴所说，“模态输入的质量很大程度上决定了动作输出的质量”，没有好的输入，就没有好的输出。

通用大模型跑得越快，具身原生的大脑就越不能掉队。让机器人在物理世界里把活干稳、干好的那份能力，**终究要靠具身原生的大脑，在真实世界里一点一点练出来。**

项目主页：

https://technology.robbyant.com/lingbot-touch

技术报告：

https://github.com/Robbyant/lingbot-touch/tree/main/paper

GitHub：

https://github.com/Robbyant/lingbot-touch

Hugging Face：

https://huggingface.co/collections/robbyant/lingbot-touch

魔搭社区：

https://www.modelscope.cn/collections/Robbyant/LingBot-Touch

本文来源：量子位

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

62 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论