

摘要：

SemiAnalysis团队与超过50家企业深度交流后发现，Meta、Uber等公司“烧Token”事件被媒体严重夸大，根源是激励机制失当而非需求萎缩。同时，企业Token预算管控已成新常态，标准从每月250美元到数万美元不等。而编码场景贡献了OpenAI和Anthropic逾70%的ARR，企业AI的S曲线远未触顶。

企业AI消费的“无限畅饮”时代正在收尾，但账单管控并不等于踩刹车。

今年上半年，“Token最大化”(Tokenmaxxing)成为企业AI圈的流行词。Meta、Salesforce等公司主动鼓励员工尽可能多地消耗AI Token以提升生产力。Meta内部甚至出现了一个名为“克劳德经济学”(Claudeconomics)的排行榜，追踪公司前250名重度用户。数据显示，Meta员工在30天内消耗了超过**60万亿个Token**，单个最高消耗用户约达**2800亿个Token**。员工们为了角逐“Token传奇”“缓存巫师”等称号，让AI代理花数小时做无意义的研究来“烧Token”。

随后，Uber因在**四个月内烧光Claude Code和Codex全年预算**登上头条，随即对员工实施每月**1500美元**的使用上限，超出部分需逐案审批。


这些事件引发广泛关注。但SemiAnalysis团队在Databricks AI峰会上进行实地调研，并通过Slack、电话与超过50家企业客户深度交流后，得出了与媒体叙事截然不同的结论。

该机构认为，媒体的报道严重夸大了问题的普遍性。Meta和Uber的极端案例，根源是激励机制失当和内部管理松弛，而非企业AI投入整体失控。

头条故事被夸大，真实数据更温和

媒体报道可能夸大了企业AI预算危机。

关键数据支撑这一判断。SemiAnalysis援引Ramp的消费数据显示，前1%的头部客户每位员工年均AI支出约**9万美元**，前10%约为**7300美元**，而Ramp客户的中位数仅为**136美元**。Ramp客户整体技术应用水平已远高于普通企业，但《财富》500强媒体类客户的人均AI支出仍远低于**100美元**。



即便是“烧Token大户”Meta，按标价计算每年每位员工花费接近**5万美元**，据SemiAnalysis估算也仅占Anthropic客户收入的**3%至5%**。

Anthropic自身文档也印证了这一点：Claude Code开发者月均支出仅**150至250美元**，仅**10%**的用户日均花费超过30美元。

SemiAnalysis认为：“媒体的夸大报道并不属实——企业仍在持续投入，新的需求场景和垂直领域带来的Token消耗，正推动着AI列车以迅猛的速度继续前行。”

这意味着企业AI采用仍处在不均匀扩散阶段。不是所有员工都在高频调用大模型。很多公司只是少数团队、少数岗位先跑起来。

预算管控成新常态，但标准五花八门


超过50家受访企业中，大多数已对AI使用设置硬性上限。但各公司的标准差异极大，并无行业共识。

低端案例：

- 美国排名前三的**航空航天与国防制造商**：每人每月**250美元**上限，部分重度用户首月四天即耗尽额度
- **全球最大制药公司之一**：每人每月**500美元**，特殊情况可申请**1000美元**

高端案例：

- **Workday、Stripe**：员工月度预算约**2000美元**
- **上市网络安全公司**：初级员工每月**800美元**，高级员工**1600至4000美元**，数据科学家获最高额度
- **大型旅游科技公司**（1500名员工中800名工程师，年AI支出接近**1000万美元**）：默认每人每月**200美元**，根据职位可增至数万美元



预算设定逻辑也各有不同。一家**美国三大航空公司之一**的做法最为特殊：Token分配直接与具体项目及预期营收挂钩。例如，一个预期营收**1000万美元**的项目，财务团队批准**100万美元**总支出

预算，团队再自行决定其中多少比例用于Token——AI成本被纳入项目财务模型，而非单独的IT预算。

员工的“省Token”生存法则

预算压力倒逼出了一套实用的Token节约策略。

最典型的是“Copilot套利”：微软365企业版订阅用户可免费无限使用标准Copilot聊天机器人，且该使用量不计入月度AI预算。一家**大型荷兰消费品与健康科技公司**明确表示，员工会先用Copilot草拟和整合创意，再调用Claude或Codex处理最终任务，以此节约计量Token。

模型降级也是常见手段。那家全球旅游科技公司已将所有员工的Claude默认模型从**Opus切换为Sonnet**，Opus仍可使用但需主动选择。那家航空航天与国防制造商则直接“关闭”了**Opus 4.8和快速模式**。

对此，SemiAnalysis团队直接点评了管理层的逻辑：“管理层认为给员工更大的Token预算会促使他们自动化那些根本不该自动化的任务，比如撰写邮件。我们认为这种反自动化观点过于天真。”

便宜Token需求仍在增长，TaaS/API端点市场没有冷下来

预算管理不等于减少调用。企业更关心的是单位成本。

便宜Token的需求仍然强。前沿模型和开源模型的Token-as-a-Service/API端点市场都在增长。AWS Bedrock被纳入测算后，SemiAnalysis对AWS本季度整体增长率的估计高于市场预期。

TaaS供应商也在扩张。Together、Fireworks、Baseten等公司合计ARR已超过40亿美元。


这说明企业预算压力会改变采购结构。能用便宜模型解决的问题，就不会一直调用最贵模型。默认模型被降级，不代表AI使用减少，而是成本曲线被重新优化。

编码仍是最强需求，AI列车没有因为预算上限而减速

编码场景仍是当前AI收入最大的驱动力，OpenAI和Anthropic逾70%的ARR来自这一方向。Anthropic B2B占比超90%（OpenAI约60%），决定了其收入结构对企业端的依赖更深，也更稳定。

下一波增长被认为将来自网络安全和白领知识工作。随着Cowork、CoPilot、Codex及Computer类产品进一步渗透企业，编码市场拉动AI实验室ARR增长的路径，会在更广泛的场景中重演。

当前大多数财富500强企业的人均AI支出仍远低于2000美元/年，主要集中在工程和数据科学部门。这意味着AI在企业中的普及还处于早期阶段，增长空间并未消失，只是换了形态——从“随意烧钱”变成了“有预算地持续投入”。



AI真正的ROI：效率提升，但产出预期也在同步上升

在受访企业中，AI带来的效率提升案例真实存在，且效果显著。

- **亚马逊招聘部门**：从初步筛选到团队安置的流程，过去需要**6至9个月**，借助AI工具后缩短至**3至4个月**
- **一家为85%的《财富》500强提供数据分析服务的公司**：过去需要一周完成的工作，现在只需几小时

但效率提升的另一面是：产出预期同步上升。一位法律数据与风险解决方案公司的员工坦言，原本一周的工作量被压缩到几小时，"但公司却因此期待她完成更多工作，结果她比之前更忙碌了。"

SemiAnalysis指出，Uber、Meta等公司的Token超支事件，根本原因是**激励机制失当和监管松懈**，而非缺乏高ROI的应用场景。亚马逊尽管大规模裁员，但因AI工具带来的效率提升，正在以更快速度招聘新员工——这是AI作为"人力杠杆"最清晰的注脚。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 80 ⭐ 收藏

分享到:

写评论

请发表您的评论

