

摘要：

AI计费正告别单一的“Token时代”，搜索、缓存、运行时、会话时长乃至按结果付费等新单位涌现，账单从一维变为多维。企业预算口径被迫重构，从“谁的Token更便宜”转向“我的工作负载下谁的综合成本更低”。Token仍是底层计量颗粒，但已无法单独解释AI商业化。价值正从模型层向上转移，成本在下沉。

“Token经济”，正在成为AI行业近期最热的关键词之一。

当OpenClaw（俗称“龙虾”）成为全民关注点，引发了各大厂商加入“龙虾潮”，Token的消耗开始呈现出指数级的增长趋势。

有开发者社区和社交平台上开始频繁出现对比表，在不同模型上的Token消耗是多少、输出质量差异如何、折算下来“每千Token成本”谁最低。

但如果真的试图用Token去算一笔账，很快就会发现，事情已经没有那么简单了。

前几天，一个做财务的朋友问我：他们的agent每天几十万次调用，一个月到底要花多少钱？

这个问题听起来很基础，看似非常简单，可以通过“Token×单价×调用次数”来计算。

但是，当我翻开Anthropic的价格页打算粗算的时候，结果犯难了。

Claude Managed Agents的session runtime（会话运行时长）按\$0.08/session-hour（每会话·小时）独立计费，cache write（缓存写入）和cache hit（缓存命中）各有不同档位的乘数，跟Token根本不在一个维度上。

于是我把几家主流平台的价格页逐一翻了一遍，发现这件事远不是一道“干净的算术题”：

比如OpenAI的价格页更像一张资源总账。Token之外，web search（联网搜索）按千次调用收费，container按session（会话持续时间）时长收费，file search storage（文件检索存储）按GB/天收费，regional processing再叠一层10%。

Google Gemini收敛一些，但grounding（搜索增强）和context caching（上下文缓存）也各自被单列为独立计价项。

Anthropic三档缓存乘数叠一个session runtime（会话运行时长），又是另一套维度。三家已经没法用同一个公式算清楚。

再往上走一层，连商品边界本身都脱离了“模型”。Salesforce用Flex Credits把动作配额写进价格体系，Intercom干脆绕开Token，按outcome收费，每个 \$0.99，白纸黑字定义什么算一次“有效解决”。

一番搜索后能确定的只有一点：大家根本不是在卖同一种东西。

2026年一月，OpenAI CFO Sarah Friar在官网发表的《A business that scales with the value of intelligence》中，同时点出了其三条商业化路径：订阅、广告支撑的免费层、按用量计费的

API，还补了一句——未来将扩展到授权、IP 协议和按结果定价。连平台方自己都不再用单一的“按用量计费”来描述自己了。

在过去，对于各大模型的比拼，行业里经常提到“谁的Token更便宜”的讨论，默认了一个前提：行业已经存在一个被广泛接受的统一计量单位，大家比的只是价格。

但到了2026年4月，目前的现实是——Token早已不是AI账单里唯一的计费单位。AI商品正在从单一计量项走向多单位并存，企业的预算语言随之被改写。

因此，本文想讨论的不只是Token本身，而是梳理一条完整的变化路径：从收费方式的变化，到成本结构的分化，再到预算体系的调整，看Token经济如何被重新定义。

AI收费，告别“单一Token时代”

如果今天仍有人只讨论“哪个模型每百万Token更贵”，那看到的只是底层供给的一部分。

真实情况是，企业目前购买的是一段被组织过的智能劳动，裸模型只是其中的一小部分。

它可能同时包含模型推理、搜索、检索、缓存、上下文驻留、运行时、容器、团队席位、动作配额，乃至一个被明确定义的“完成件”。AI经济正在经历的，不是一场简单的价格战，而是计费对象的扩散。

这里最容易出现的误读，是把“计费单位变多”等同于“底层模型已经不重要”。

但事实恰恰相反：**模型仍是底层最核心的供给对象，只是它不再是企业成本解释框架里的唯一变量。**

一旦系统进入真实工作流，采购者与运营者就必须同时处理 grounding、batch（批量调用）、regional（区域路由）、runtime（运行时长）与席位切换，它们在同一张对账单上争夺预算。于是，账单不再是一列Token的累加，而是一组互相叠加的价格对象。

AI底层大概率会像电力一样，最终被压成公用事业：便宜、可计量、不可或缺，但也不再是价值最终停留的地方。

经济史上反复出现的模式是：电带来的生产率跃升，远比“有电就更快”复杂。让美国制造业真正起飞的，是工厂围绕电重写了生产组织，而不是电本身变得便宜。

AI成本，从统一定价走向按任务分化

过去我们习惯用“每百万Token多少钱”来理解AI成本，但今天这个锚点已经失效——账单的主角是谁，取决于你在跑什么样的任务。

先看一个轻量、高频、以检索为主的企业问答任务。

以Google Gemini 2.5 Flash-Lite标准档估算，5,000 input + 1,000 output Tokens，Token成本约 0.0009 美元；若同一次调用附带一次 grounded prompt，超出每日免费额度后，单次 grounding 价格为 0.035 美元，是Token成本的近四十倍。

在这类工作负载里，主导账单的是search / grounding这类外层能力，模型推理本身反而退居二线。



然而，如果换成更强的前沿模型，图景就完全不同。

以OpenAI GPT-5.4 标准档为例，5,000 input + 1,000 output Tokens约0.0275美元；一次web search的tool call fee为 0.01 美元（search content Tokens 另按模型费率计）；一次 1GB container session 为 0.03 美元。此时模型成本仍与工具调用处于同一数量级，在许多推理密集任务中甚至占大头。

再看Anthropic官方给出的 Claude Managed Agents worked example：一个一小时的Opus 4.6 coding session，50,000 input + 15,000 output的Token成本是0.625美元，session runtime仅0.08美元。runtime已经进入了商品列表，但远未“压倒”模型成本。

三个例子合起来指向同一件事：成本的大头在哪，取决于你让AI干什么样的活。

通俗的理解，你让AI查资料，钱主要花在搜索上；让它动脑子，钱主要花在模型上；让它一直在后台干活，“开机时长”本身就是一笔账，所以根本不存在一张能通用的“AI单位成本”表。所以AI经济的演变，不能被简化成“工具吃掉模型”或“模型吞噬一切”这种非黑即白的故事。

更准确的说法是：**买方必须开始按不同任务形态去理解total cost（总成本），不再假定存在一个统一的成本锚。**

这件事的后果，比“算术变复杂”要大得多。一旦计费单位裂变，原本用“每百万Token 多少钱”就能对账的人，现在必须同时理解search成本、cache命中率、runtime时长与 regional 溢价。

预算口径从一维变成多维，采购的比较轴也随之改写——从“谁的Token更便宜”，变成“在我的工作负载下，谁的综合成本更低”。计费单位的裂变，正在倒逼企业重写自己理解AI 支出的方式。

中国市场提供了一个“反向参照”。比如2024年国内大模型价格战打得异常惨烈，部分厂商降价超过97%，推理毛利一度跌至负数，但整场战争的叙事始终只围绕一件事：谁的百万 token 更便宜。

runtime、grounding、outcome这些在美国价格页上已经独立成行的维度，目前在中国仍处于早期。当所有玩家都挤在同一个计量单位上竞争，负毛利就不是意外，而是结构性的终点。

价格页先变，企业的预算体系也需跟上

计费单位的变化，最先出现在价格页上，最后才会反映到平台的营收盘子里。而夹在中间、最先被迫跟着调整的，是企业自己的预算表。

到目前为止，没有可靠的公开数据能证明OpenAI、Google或Anthropic的tool/storage/runtime营收已经超过model/Token营收。

所以，一家公司在价格页上加了多少新收费项，不代表他们的钱真的就是从那些新项目里挣回来的，这两件事不能画等号，还需要进一步等数据说话。

当前真正能确认的是：卖方的定价语言已经先变了，买方的预算口径没办法继续停在Token这一列上。

这其中的道理也不言而喻：当官方价格页已经把tool call（工具调用）、session runtime（会话运行时长）、outcome（结果）各自独立定价，企业的对账单就不可能再维持成一系列Token，否则卖方给的账单和买方的内部核算对不上。

Token不再是唯一的主角，它更像是底层的一种计量单位。真正影响账单的，是推理、搜索、缓存、运行时、席位、动作、结果这些叠在一起的成本。

文章开头Sarah Friar那句顺口提到的“未来还会扩展到授权、IP 协议、按结果定价”，其实就是这件事在OpenAI自己眼里的翻译——他们比任何人都更清楚，自己正在卖的不只是Token。

一旦买方的预算框架跟着调整，一些原本被忽视的东西会重新浮出水面。比如：

Model router不再只是“帮你挑哪个模型最合适”，而是在悄悄决定整张账单的结构——选错一层，预算的重心就会整体偏移；

Salesforce的Flex Credits卖的不是某一次具体调用，而是一份可以在不同动作、场景、团队之间自由调拨的“使用权”；

Outcome pricing的真正吸引力，在于它把预算直接绑在“完成件”上。企业第一次可以用结果，而不是过程，来和供应商对账。

新的计费单位或许还没改写卖方的收入结构，但它们已经在改写企业内部看待AI的方式。而一旦组织用新的语言理解自己的 AI 支出，预算最终流向哪一层、沉淀在哪一层，就不再是一张模型排行榜能决定的事了。

当计费单位裂变，价值开始分层

把视野再拉远一点，如果计费单位已经不只是token，那“钱到底会沉淀在哪一层”这件事，就得分层去看。

我自己的一个梳理方式去做理解，是把整个AI经济看成一套五层结算栈。当成一张正在成型的产业结构图来看，本系列接下来几篇会沿着这个框架逐层展开：



• 第一层·公用事业层：算力、Token、缓存、搜索、容器、文件检索，可计量、可路由的“认知吞吐量”

- 第二层 · 协议与能力层：MCP、A2A、Agent Skills 这类让模型、工具、数据源和agent 互操作的共同接口
- 第三层 · 知识封装层：Skill、Prompt、Eval、Policy、Memory，把行业know-how序列化下来
- 第四层 · 执行交付层：被托管、观测、监控的“数字劳动力”，marketplace正把agent 从“下载”变成“调用”
- 第五层 · 结果与责任层：Intercom的\$0.99 per outcome是最明确的公开信号之一，“被完成的工作”开始成为合同化的结算对象

如果把这五层放在一起看，会出现一个很清晰的分布规律：越靠下，越容易被单位化和路由化；越靠上，越深地嵌入上下文、验收和责任。

对应的商业模式也随之分化——底层依赖规模和效率，买方按成本比价；上层依赖不可替代性，买方按结果付费。这两种模式都可以成立，但它们的“价格锚”完全不同。前者锚定投入成本，后者锚定创造的价值。

Token经济，不再只关于Token

总之，今天再谈Token经济学，不再是简单的“Token 单价走势”，更值得研究的是：**Token作为底层计量颗粒，正在怎样与search、cache、runtime、seat、outcome这些更高层的单位一起**，重写企业对 AI 的预算语言。换句话说：Token还在，但它已经不能单独解释这门生意。

当然，这并不意味着Token不重要。

底层资源层依然可能是最大的利润池，甚至会出现高度集中的赢家。但到了2026年，如果想理解AI商业化的变化，只盯着Token，已经看不全了。问题从“Token多便宜”，变成了：整张账单是怎么被构成的。

那接下来应该看什么？比预测时间表更有意义的，是观察一些正在出现的信号：

第一，企业合同里，是否开始出现SLA、数据驻留、缓存策略、责任边界这些条款，而不再只谈Token单价。这意味着，买卖双方开始围绕“系统”和“责任”对齐，而不是单一资源。

第二，marketplace（Agent 商店/市场）上，是否开始出现带eval card的agent服务。也就是，“结果是否可被评估”，开始成为商品定义的一部分。

第三，是否出现第三方的审计、认证和争议处理服务。这是“按结果结算”走向合同化之前，必须补上的最后一块基础设施。

到2027年底，如果这三条里有两条以上落地，那么可以基本确认一件事：结算对象正在从Token向更高层上移。

Anthropic在4月7日以“invitation-only”的方式发布了Mythos（预览版），而与此同时，工作层模型的价格仍在持续下降。

一边是前沿能力不断集中，一边是工作层持续商品化。

成本在下沉，价值在上移。



这两条看似相反的变化，其实指向同一个方向：AI的价格正在走向分层，而价值也在随之重新分配。

当Token不再是唯一的计量单位，当账单被拆分成多种成本结构，企业最终为哪一层买单，就会决定价值沉淀在哪一层。

至于这种“成本下沉、价值上移”的结构，是如何在同一个体系中同时成立的，我们将在后续的解读中再逐一展开。

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

限免

259

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

3 条评论

- 慢就是快VS弱就是强

1小时前 中国陕西省

理解了，但真无奈，我不懂这方面的发展方向，无法下注。

0

回复
- 苍山如海

3小时前 中国陕西省

是个值得观察和思考的问题，决定未来那些方向更具备增长

0

回复
- MobileUser7489

3小时前 中国上海

写得好乱

0

回复